

PROJECT 2B:

PHÂN LOẠI VIDEO YOUTUBE THEO THỂ LOẠI DỰA TRÊN MÔ TẢ CỦA VIDEO

1st Hà Thế Anh, 2nd Nguyễn Nhật Nam, 3rd Hoàng Quang Minh
and Le Nhat Tung

HUTECH University, Vietnam

{hatheanh012004, nguyennhatnam01012004, hoangquangminh130804}@gmail.com, and lenhattung@hutech.edu.vn

TÓM TẮT NỘI DUNG

Trong thời đại bùng nổ nội dung số, YouTube trở thành nền tảng lưu trữ và chia sẻ video lớn nhất thế giới, với lượng dữ liệu khổng lồ được tạo ra mỗi ngày. Việc tự động phân loại video theo thể loại giúp cải thiện hệ thống gợi ý, quản lý và phân tích hành vi người dùng một cách hiệu quả hơn.

Đề tài này tập trung vào bài toán **phân loại video YouTube theo thể loại dựa trên phần mô tả (description)**. Dữ liệu được **thu thập trực tiếp bằng YouTube Data API**, bao gồm các trường *video_id*, *title*, *description*, *category_id*, cùng các chỉ số tương tác như *view_count*, *like_count* và *comment_count*. Sau khi làm sạch, loại bỏ mô tả ngắn và lọc ngôn ngữ không phải tiếng Việt, dữ liệu được chuẩn hóa, tách từ bằng **Underthesea** và loại bỏ **stopwords** chung lẫn đặc thù theo từng thể loại, thu được hơn **6.750 bản ghi hợp lệ**.

Trên tập dữ liệu này, nhóm tiến hành trích xuất đặc trưng văn bản bằng các phương pháp **TF-IDF**, **PhoBERT**, **BGE**, **E5** và **Sup-SimCSE PhoBERT**, kết hợp huấn luyện các mô hình học máy **Logistic Regression**, **Linear SVM**, **Random Forest** và **Naive Bayes**. Các mô hình được đánh giá thông qua **Cross-Validation 5-fold** với các chỉ số **Accuracy**, **Precision**, **Recall** và **F1-Score**.

Kết quả cho thấy mô hình **Random Forest với TF-IDF** đạt hiệu suất cao nhất với $Accuracy = 0.744$ và $Weighted F1 = 0.737$, trong khi **Sup-SimCSE PhoBERT** thể hiện khả năng hiểu ngữ nghĩa tốt hơn với $Accuracy = 0.647$ và $F1 = 0.561$. Nghiên cứu chứng minh rằng các mô hình học máy truyền thống (traditional machine learning models) kết hợp biểu diễn tần suất vẫn có ưu thế. trong bài toán phân loại văn bản tiếng Việt, đồng thời mở ra hướng phát triển cho các ứng dụng xử lý ngôn ngữ tự nhiên và gợi ý nội dung thông minh trên nền tảng YouTube.

TỪ KHÓA

YouTube API, Text Classification, Vietnamese NLP, TF-IDF, PhoBERT, BGE, E5, Sup-SimCSE, Machine Learning, SVM, Embedding.

I. GIỚI THIỆU

Trong thời đại dữ liệu số phát triển mạnh mẽ, các nền tảng trực tuyến như YouTube đóng vai trò trung tâm trong việc chia sẻ và lan tỏa thông tin toàn cầu. Mỗi ngày có hàng triệu video được đăng tải, tạo nên một kho dữ liệu khổng lồ bao gồm nhiều thể loại như âm nhạc, giải trí, giáo dục, thể thao hay tin tức. Tuy nhiên, sự đa dạng và khối lượng dữ liệu khổng lồ này khiến việc phân loại, gợi ý và quản lý nội dung trở thành một thách thức lớn đối với các hệ thống tự động.

Trên YouTube, mỗi video đều đi kèm phần **mô tả (description)** nơi chứa thông tin tóm tắt, ngữ cảnh và từ khóa liên quan. Phần mô tả này là nguồn dữ liệu ngôn ngữ quan trọng, phản ánh rõ chủ đề và mục đích của video. Do đó, việc khai thác mô tả để **tự động phân loại thể loại video** không chỉ mang ý nghĩa kỹ thuật mà còn có giá trị thực tiễn cao trong các hệ thống đề xuất nội dung, quảng cáo và phân tích xu hướng.

Tuy nhiên, bài toán phân loại nội dung YouTube tiếng Việt vẫn còn nhiều thách thức. Phần lớn mô tả video được viết không theo chuẩn ngôn ngữ, chứa nhiều ký hiệu, từ viết tắt, hashtag, hoặc kết hợp tiếng Anh và tiếng Việt. Ngoài ra, dữ liệu cũng có tính **mất cân bằng mạnh giữa các thể loại**, trong khi độ dài và phong cách mô tả thay đổi lớn giữa các nhóm chủ đề. Điều này đòi hỏi quy trình tiền xử lý và lựa chọn mô hình học máy phù hợp để đảm bảo hiệu quả phân loại.

Trong nghiên cứu này, nhóm đề xuất quy trình **phân loại video YouTube theo thể loại dựa trên mô tả tiếng Việt**, sử dụng dữ liệu được **thu thập tự động qua YouTube Data API**. Tập dữ liệu gồm các trường thông tin: *video_id*, *title*, *description*, *category_id*, *tags*, *view_count*, *like_count* và *comment_count*. Sau khi làm sạch và chuẩn hóa, dữ liệu được xử lý bằng **Underthesea** để tách từ và loại bỏ **stopwords** chung lẫn đặc thù theo từng thể loại, thu được hơn **6.750 mẫu hợp lệ**.

Trên cơ sở dữ liệu đó, nhóm thực hiện các phương pháp biểu diễn văn bản gồm **TF-IDF**, **PhoBERT**, **BGE**, **E5** và **Sup-SimCSE PhoBERT**, đồng thời huấn luyện các mô hình **Logistic Regression**, **Linear SVM**, **Random Forest** và **Naive Bayes**. Các mô hình được đánh giá theo **Accuracy**, **Precision**, **Recall** và **F1-Score**, kèm theo kiểm định chéo 5-fold để bảo đảm tính ổn định.

Mục tiêu của nghiên cứu bao gồm:

- Xây dựng quy trình thu thập và tiền xử lý dữ liệu mô tả video tiếng Việt.
- So sánh hiệu quả của các phương pháp biểu diễn văn bản và mô hình học máy phổ biến.
- Đánh giá hiệu suất từng mô hình thông qua các chỉ số thống kê và kiểm định chéo.
- Đề xuất mô hình tối ưu cho bài toán phân loại thể loại video tiếng Việt trên YouTube.

Nghiên cứu kỳ vọng mang lại góc nhìn mới về khả năng ứng dụng các mô hình ngôn ngữ hiện đại trong **phân tích và xử lý dữ liệu ngôn ngữ tiếng Việt**, đồng thời đóng góp cơ sở thực nghiệm cho việc phát triển các hệ thống gợi ý và quản lý nội dung video thông minh trong tương lai.

II. CÁC NGHIÊN CỨU LIÊN QUAN

A. Phân loại văn bản và bài toán gán nhãn nội dung

Phân loại văn bản (Text Classification) là một hướng nghiên cứu cốt lõi của xử lý ngôn ngữ tự nhiên (NLP), trong đó mô hình học máy được huấn luyện để gán nhãn chủ đề cho văn bản đầu vào. Các phương pháp truyền thống như **Naive Bayes**, **Support Vector Machine (SVM)** và **Logistic Regression** đã được áp dụng thành công trong nhiều tập dữ liệu tin tức và bình luận [1], [2]. Đối với nền tảng YouTube, nhiều nghiên cứu chỉ ra rằng phần mô tả video (description) mang giá trị ngữ nghĩa cao, giúp mô hình xác định thể loại chính xác hơn so với tiêu đề hoặc thẻ (tags) [3].

B. Tiền xử lý và đặc trưng ngôn ngữ tiếng Việt

Đặc thù ngôn ngữ tiếng Việt với nhiều dấu thanh, từ ghép, và cấu trúc không thống nhất khiến giai đoạn tiền xử lý đóng vai trò đặc biệt quan trọng. Các công cụ như **Underthesea** [4] và **PyVi** [5] đã trở thành lựa chọn phổ biến cho tách từ, chuẩn hóa văn bản và loại bỏ từ dừng. Ngoài ra, một số nghiên cứu đề xuất mở rộng danh sách stopwords theo miền ứng dụng cụ thể, chẳng hạn với dữ liệu YouTube, việc loại bỏ các từ như “video”, “kênh”, “subscribe” hay “official” giúp cải thiện hiệu quả mô hình [6].

C. Biểu diễn văn bản truyền thống: TF-IDF và Bag-of-Words

Trước khi các mô hình ngữ nghĩa ra đời, **TF-IDF** và **Bag-of-Words (BoW)** là hai phương pháp phổ biến nhất trong trích xuất đặc trưng văn bản. TF-IDF đo lường tầm quan trọng của từng từ trong tập dữ liệu, từ đó giúp mô hình học được các đặc trưng phân biệt giữa các chủ đề [7], [8]. Trong các nghiên cứu tiếng Việt, việc kết hợp TF-IDF với các thuật toán tuyến tính như SVM đã cho kết quả tốt trên các tập dữ liệu tin tức hoặc mạng xã hội [9].

D. Biểu diễn ngữ nghĩa hiện đại: BERT và PhoBERT

Sự xuất hiện của mô hình **BERT** [10] đã thay đổi hoàn toàn cách biểu diễn ngôn ngữ trong NLP, khi cho phép mô hình học ngữ cảnh hai chiều của từ trong câu. Với tiếng Việt, **PhoBERT** [11] là phiên bản huấn luyện đặc thù dựa trên BERT, sử dụng hơn 20GB dữ liệu văn bản tiếng Việt. Các nghiên cứu chứng minh PhoBERT vượt trội hơn Word2Vec và FastText trong các tác vụ phân loại, trích xuất và cảm xúc [12].

E. Embedding nâng cao: BGE, E5 và Sup-SimCSE

Gần đây, các mô hình embedding thể hệ mới như **BAAI General Embedding (BGE)** [13], **E5** [14] và **Sup-SimCSE** [15] đã cho phép biểu diễn văn bản ở mức ngữ nghĩa sâu hơn. Các mô hình này sử dụng kỹ thuật học tương phản (contrastive learning) nhằm tối ưu khoảng cách trong không gian embedding, giúp các văn bản có cùng chủ đề được biểu diễn gần nhau. Sup-SimCSE PhoBERT đặc biệt hiệu quả trong dữ liệu tiếng Việt, nơi cùng một chủ đề có thể xuất hiện dưới nhiều cách diễn đạt khác nhau.

F. Tổng hợp và khoảng trống nghiên cứu

Tổng quan các công trình cho thấy, hầu hết nghiên cứu về phân loại nội dung tiếng Việt trên YouTube tập trung vào tiêu đề hoặc bình luận, trong khi phần mô tả vốn chứa thông tin ngữ nghĩa giàu và ổn định hơn lại chưa được khai thác sâu. Ngoài ra, chưa có nhiều công trình so sánh toàn diện giữa các kỹ thuật biểu diễn từ truyền thống (TF-IDF) và các mô hình embedding ngữ cảnh hiện đại (PhoBERT, BGE, Sup-SimCSE) trên cùng một tập dữ liệu tiếng Việt thu thập trực tiếp qua API. Đây chính là khoảng trống mà nghiên cứu này hướng tới nhằm đánh giá, so sánh và xác định phương pháp tối ưu cho bài toán phân loại thể loại video YouTube tiếng Việt.


III. PHƯƠNG PHÁP NGHIÊN CỨU

A. Quy trình tổng thể

Nghiên cứu được triển khai theo một quy trình gồm bốn giai đoạn chính, được minh họa trong Hình 1. Cụ thể:

- 1) **Thu thập và tiền xử lý dữ liệu:** Dữ liệu được thu thập tự động thông qua **YouTube API**, bao gồm mô tả của các video tiếng Việt. Sau đó, dữ liệu được làm sạch bằng cách loại bỏ ký tự đặc biệt, URL, từ dư thừa, chuyển đổi chữ thường và tách từ bằng công cụ *Underthesea*. Cuối cùng, các từ dừng (stopwords) được loại bỏ để đảm bảo chất lượng ngữ nghĩa.
- 2) **Biểu diễn văn bản (Embedding):** Phần mô tả video sau khi xử lý được biến đổi thành vector số bằng nhiều phương pháp khác nhau, bao gồm **TF-IDF**, **PhoBERT**, **BGE**, **E5**, và **Sup-SimCSE PhoBERT**. Các vector này thể hiện đặc trưng ngữ nghĩa của văn bản, phục vụ cho giai đoạn huấn luyện mô hình học máy.
- 3) **Chuẩn hóa và huấn luyện mô hình:** Với các embedding ngữ nghĩa (PhoBERT, BGE, E5, Sup-SimCSE), đặc trưng đầu ra được chuẩn hóa bằng **StandardScaler** để đưa các giá trị về cùng thang đo. Tiếp theo, các mô hình học máy **Logistic Regression (LR)**, **Linear SVM**, **Random Forest (RF)** và **Naive Bayes (NB)** được huấn luyện nhằm phân loại thể loại video dựa trên đặc trưng vector. Hiệu quả mô hình được đánh giá thông qua **Cross-Validation 5-fold** để đảm bảo độ ổn định và khả năng tổng quát hóa.
- 4) **Đánh giá và phân tích kết quả:** Sau khi huấn luyện, mô hình được kiểm thử trên tập dữ liệu độc lập (20%) và so sánh theo các chỉ số **Accuracy**, **Macro F1**, **Weighted F1** và **Confusion Matrix**. Các kết quả được tổng hợp, trực quan hóa và thảo luận nhằm xác định phương pháp biểu diễn văn bản và mô hình học máy đạt hiệu suất cao nhất.

Quy trình này bảo đảm tính hệ thống, giúp nhóm nghiên cứu đánh giá toàn diện tác động của từng phương pháp embedding đối với hiệu quả phân loại video YouTube.



Hình 1. Quy trình tổng thể của phương pháp nghiên cứu.

B. Tiền xử lý và biểu diễn dữ liệu

Do mô tả video trên YouTube thường chứa ký hiệu, hashtag, emoji và nhiều ngôn ngữ khác nhau, nên bước tiền xử lý đóng vai trò quan trọng nhằm loại bỏ nhiễu và đảm bảo dữ liệu đầu vào đồng nhất. Quy trình xử lý được thực hiện như sau:

- 1) Loại bỏ mô tả trống hoặc ngắn hơn 20 ký tự.
- 2) Chuẩn hóa văn bản: chuyển thành chữ thường, xóa ký tự đặc biệt, URL, emoji và các cụm quảng bá.

- 3) Lọc ngôn ngữ bằng langdetect, chỉ giữ lại văn bản tiếng Việt.
- 4) Tách từ bằng Underthesea, chuẩn hóa thành dạng “từ_ghép”.
- 5) Loại bỏ stopwords chung và riêng cho từng thể loại video.

Sau bước này, dữ liệu còn 6.750 mô tả hợp lệ, được lưu dưới dạng văn bản đã tách từ và gán nhãn thể loại.

Biểu diễn văn bản: Mỗi mô tả được biểu diễn thành vector số theo hai hướng chính:

- **TF-IDF (Term Frequency – Inverse Document Frequency):** Là phương pháp dựa trên tần suất từ, phản ánh mức độ quan trọng của từ trong tập dữ liệu:

$$\text{TF-IDF}(t, d) = \text{TF}(t, d) \times \log \frac{N}{DF(t)}$$

TF-IDF hiệu quả cao với văn bản ngắn và có nhiều từ khóa đặc trưng.

- **Các mô hình ngữ nghĩa (Semantic Embedding):** Bao gồm PhoBERT, BGE, E5 và Sup-SimCSE PhoBERT. Các mô hình này biểu diễn văn bản dưới dạng vector trong không gian ngữ nghĩa, giúp nắm bắt mối quan hệ giữa các từ và ý nghĩa của toàn câu. Sup-SimCSE PhoBERT là phiên bản cải tiến của PhoBERT, được huấn luyện bằng học tương phản có giám sát, giúp tăng khả năng phân biệt các chủ đề gần nghĩa.

C. Mô hình học máy

Bốn mô hình học máy được sử dụng để huấn luyện và so sánh hiệu quả phân loại:

- **Logistic Regression (LR):** mô hình tuyến tính đơn giản, dự đoán xác suất mỗi lớp bằng hàm sigmoid.
- **Linear SVM:** tìm siêu phẳng tối ưu trong không gian cao chiều; đặc biệt phù hợp với TF-IDF và embedding vector.
- **Random Forest (RF):** mô hình tổng hợp nhiều cây quyết định, cho phép học quan hệ phi tuyến giữa các đặc trưng.
- **Naive Bayes (NB):** dựa trên định lý Bayes, giả định độc lập giữa các đặc trưng; hiệu quả với dữ liệu tần suất như TF-IDF.

Đối với các mô hình tuyến tính (LR, SVM), dữ liệu embedding được chuẩn hóa bằng **StandardScaler** để đảm bảo các đặc trưng có cùng thang đo, giúp mô hình hội tụ ổn định hơn.

D. Đánh giá mô hình

Mô hình được đánh giá bằng hai giai đoạn:

- **Cross-Validation 5-fold:** chia tập huấn luyện thành 5 phần; mỗi lần 4 phần dùng huấn luyện, 1 phần kiểm định. Kết quả trung bình qua 5 lần phản ánh tính ổn định của mô hình.
- **Kiểm thử độc lập (Test Set 20%):** đánh giá hiệu suất tổng thể trên tập dữ liệu chưa thấy trước đó.

Các chỉ số đánh giá gồm:

Accuracy, Precision, Recall, F1-score

Trong đó:

- **Accuracy:** tỷ lệ dự đoán đúng trên tổng số mẫu.
- **Precision:** tỷ lệ dự đoán đúng trong các mẫu được gán nhãn dương tính.
- **Recall:** tỷ lệ các mẫu dương tính được phát hiện đúng.
- **F1-Score:** trung bình điều hòa giữa Precision và Recall.

Do dữ liệu mất cân bằng giữa các thể loại, chỉ số **Weighted F1** được dùng làm thước đo chính, phản ánh hiệu quả tổng thể của mô hình.

E. Tóm tắt

Phương pháp nghiên cứu kết hợp giữa biểu diễn tần suất (TF-IDF) và biểu diễn ngữ nghĩa (PhoBERT, BGE, E5, Sup-SimCSE) nhằm đánh giá toàn diện khả năng phân loại mô tả video tiếng Việt. Sự kết hợp này cho phép so sánh hiệu quả giữa các hướng tiếp cận truyền thống và hiện đại, làm cơ sở cho phần thực nghiệm và đánh giá kết quả ở chương tiếp theo.

IV. XÂY DỰNG VÀ CHUẨN BỊ DỮ LIỆU

A. Tổng quan dữ liệu ban đầu

Dữ liệu được thu thập thông qua **YouTube Data API v3** bằng cách truy vấn các video có ngôn ngữ tiếng Việt trên nhiều lĩnh vực khác nhau như âm nhạc, thể thao, du lịch, công nghệ, giáo dục và giải trí. Mỗi bản ghi trong tập dữ liệu chứa các thông tin cơ bản về video gồm: mã định danh (`video_id`), tiêu đề (`title`), mô tả (`description`), ngày đăng (`published_at`), tên kênh (`channel`), mã thể loại (`category_id`), thẻ (`tags`), cùng các chỉ số tương tác như lượt xem, lượt thích và bình luận.

Tổng cộng thu được **10000 video** thuộc **15 thể loại chính**, phản ánh sự đa dạng nội dung của YouTube Việt Nam. Tuy nhiên, dữ liệu ban đầu có sự mất cân bằng đáng kể giữa các nhóm, trong đó nhóm People & Blogs (22) chiếm tỉ lệ lớn nhất (hơn 25% tổng số video).

Bảng I
PHÂN BỐ SỐ LƯỢNG VIDEO THEO THỂ LOẠI (TRƯỚC KHI LÀM SẠCH)

Category ID	Tên thể loại	Số lượng video
22	Con người và Blog	2 565
24	Giải trí tổng hợp	1 089
25	Tin tức và Chính trị	812
28	Khoa học và Công nghệ	610
17	Thể thao	511
1	Phim và Hoạt hình	473
27	Giáo dục	359
26	Hướng dẫn và Phong cách sống	357
20	Trò chơi điện tử	385
10	Âm nhạc	335
19	Du lịch và Sự kiện	262
2	Ô tô và Phương tiện	204
23	Hài hước	18
15	Động vật và Thú cưng	13
29	Tổ chức phi lợi nhuận và Hoạt động xã hội	9

B. Tiền xử lý dữ liệu

Để đảm bảo chất lượng dữ liệu đầu vào cho mô hình học máy, quy trình làm sạch được thực hiện theo các bước sau:

- 1) **Giữ lại các cột quan trọng:** title, description, category_id.
- 2) **Loại bỏ mô tả rỗng hoặc có độ dài dưới 20 ký tự.**
- 3) **Làm sạch mô tả:** Chuẩn hóa văn bản về chữ thường, loại bỏ URL, email, emoji, hashtag, ký tự đặc biệt và các đoạn quảng bá không liên quan như “đăng ký kênh”, “subscribe”, “fanpage”, “official”, ...
- 4) **Lọc ngôn ngữ:** Chỉ giữ lại các mô tả tiếng Việt sử dụng thư viện langdetect.
- 5) **Tách từ (Tokenization):** Áp dụng thư viện Underthesea để tách từ tiếng Việt và chuẩn hóa thành dạng gạch dưới (_).
- 6) **Loại bỏ stopwords chung:** Sử dụng danh sách stopwords tiếng Việt kết hợp mở rộng thêm các từ phổ biến không mang thông tin phân loại như “video”, “kênh”, “like”, “share”, “xem”, “facebook”, ...
- 7) **Stopword riêng cho từng thể loại:** Thiết lập 15 bộ stopwords riêng biệt cho từng category_id. Ví dụ: Music (10) loại bỏ các từ “mv”, “official”, “beat”, trong khi Gaming (20) loại bỏ “mod”, “donate”, “discord”.
- 8) **Loại trùng lặp và mô tả trống sau khi lọc.**

Sau quá trình tiền xử lý, thu được **6 750 mô tả hợp lệ** thuộc 15 thể loại khác nhau, lưu trong hai cột chính: tokenized_text (mô tả đã tách từ) và category_id (nhãn thể loại).

Bảng II
VÍ DỤ MỘT PHẦN DỮ LIỆU SAU XỬ LÝ

STT	tokenized_text (mô tả đã xử lý)	category_id
1	hướng_dẫn_cắm_trại_cuối_tuần_tại_đà_lạt_trải_nghỉệm_ẩm_thực_và_du_lịch_sinh_thái	19
2	bản_cover_nhạc_trẻ_hay_nhất_năm_2024_với_giai_điệu_sôi_động_và_cảm_xúc	10
3	clip_ghi_lại_khoảnh_khắc_thi_đấu_bóng_đá_giữa_u23_việt_nam_và_thái_lan_tại_sea_games	17
4	cách_chăm_sóc_mèo_con_và_lựa_chọn_thức_ăn_phù_hợp_cho_thú_cưng_tại_nhà	15
5	hướng_dẫn_khiêu_vũ_dân_vũ_tập_luyện_sức_khoẻ_và_giải_trí	22

C. Thống kê dữ liệu sau tiền xử lý

Để hiểu rõ hơn đặc trưng của tập dữ liệu sau khi làm sạch, nhóm tiến hành một số thống kê mô tả cơ bản:

- **Số lượng mẫu:** 6 750 video.
- **Số từ vựng duy nhất:** 37 196 từ.
- **Độ dài mô tả trung bình:** 59 từ/video.
- **15 từ phổ biến nhất:** “hướng_dẫn”, “nhạc”, “video”, “du_lịch”, “trải_nghỉệm”, “game”, “review”, “vlog”, ...

Hình 2 minh họa các từ khóa phổ biến nhất trong toàn bộ mô tả video sau khi làm sạch.

Các từ khóa xuất hiện phổ biến trong mô tả video YouTube (sau làm sạch)



Hình 2. Các từ khóa xuất hiện phổ biến trong mô tả video YouTube (sau làm sạch).

D. Chia tập huấn luyện và kiểm thử

Dữ liệu được chia thành hai phần: **80% cho huấn luyện** và **20% cho kiểm thử**, đảm bảo tỉ lệ phân bố các thể loại được giữ nguyên bằng tham số stratify. Tập huấn luyện (D_{train}) được sử dụng để huấn luyện mô hình, còn tập kiểm thử (D_{test}) phục vụ đánh giá khả năng tổng quát hóa.

$$|D_{train}| = 5\,400, \quad |D_{test}| = 1\,350$$

E. Tóm tắt quy trình chuẩn bị dữ liệu

Quy trình xử lý dữ liệu giúp loại bỏ nhiễu, chuẩn hóa ngữ liệu tiếng Việt và giữ lại đặc trưng ngữ nghĩa của mô tả video. Kết quả cuối cùng là một tập dữ liệu gồm 6750 mẫu hợp lệ, 15 thể loại, được tách từ, loại stopwords, và sẵn sàng cho các giai đoạn trích xuất đặc trưng bằng TF-IDF và các mô hình embedding hiện đại (PhoBERT, BGE, E5, Sup-SimCSE).

V. THỰC NGHIỆM VÀ ĐÁNH GIÁ MÔ HÌNH

A. Quy trình và cấu hình thực nghiệm

1. Mục tiêu thực nghiệm.

Phần này trình bày quy trình triển khai, huấn luyện và đánh giá các mô hình học máy trong bài toán phân loại thể loại video YouTube dựa trên phần mô tả tiếng Việt. Mục tiêu của thực nghiệm nhằm:

- So sánh hiệu suất giữa các phương pháp biểu diễn văn bản (TF-IDF, PhoBERT, BGE, E5 và Sup-SimCSE PhoBERT);
- Đánh giá khả năng khái quát hóa của từng mô hình thông qua kiểm định chéo (Cross-Validation);
- Xác định mô hình và phương pháp biểu diễn (embedding) tối ưu nhất cho bài toán phân loại mô tả video tiếng Việt.

2. Cấu hình phần cứng và phần mềm.

Các thí nghiệm được triển khai trên môi trường **Python 3.10**, với các thư viện hỗ trợ chính gồm: pandas, scikit-learn, underthesea, transformers, matplotlib và seaborn. Quá trình huấn luyện mô hình được thực hiện trên hệ thống có cấu hình phần cứng như sau:

- CPU:** Intel Core i7 (12 nhân, 20 luồng);
- RAM:** 32GB;
- GPU:** NVIDIA RTX 3060 (12GB VRAM);
- Hệ điều hành:** Windows 11 (64-bit).

3. Dữ liệu huấn luyện và kiểm thử.

Tập dữ liệu sau khi tiền xử lý bao gồm **6 750 mô tả video tiếng Việt** thuộc **15 thể loại chính**. Dữ liệu được chia thành hai phần theo tỷ lệ:

- **Tập huấn luyện (80%)** – dùng để huấn luyện và đánh giá mô hình bằng Cross-Validation;
- **Tập kiểm thử (20%)** – dùng để đánh giá độc lập mô hình cuối cùng.

Phương pháp chia dữ liệu sử dụng tham số `stratify`, nhằm đảm bảo tỷ lệ phân bố các lớp trong hai tập huấn luyện và kiểm thử tương đồng với toàn bộ dữ liệu gốc. Điều này giúp hạn chế sai lệch do mất cân bằng lớp khi đánh giá mô hình.

4. Chuẩn hóa dữ liệu (Feature Scaling). Đối với các mô hình tuyến tính như **Logistic Regression** và **Linear SVM**, việc chuẩn hóa dữ liệu là cần thiết để các đặc trưng có cùng thang đo và giúp mô hình hội tụ ổn định hơn. Trong thí nghiệm này, nhóm sử dụng **StandardScaler** thuộc thư viện `scikit-learn` để chuẩn hóa các đặc trưng embedding về dạng phân phối chuẩn có trung bình bằng 0 và độ lệch chuẩn bằng 1.

- Với **TF-IDF**, dữ liệu đã được chuẩn hóa sẵn theo chuẩn L2 nên không cần scale bổ sung.
- Với các biểu diễn embedding như **PhoBERT**, **BGE**, **E5** và **Sup-SimCSE PhoBERT**, nhóm áp dụng **StandardScaler** để đảm bảo giá trị của từng chiều có phân phối đồng đều quanh 0, tránh hiện tượng sai lệch khi tính khoảng cách hoặc khi huấn luyện mô hình tuyến tính.

Việc chuẩn hóa này giúp cải thiện độ ổn định của các mô hình tuyến tính, đặc biệt khi embedding có giá trị nằm trong khoảng rộng (từ -5 đến +5), đồng thời giúp mô hình đạt tốc độ hội tụ nhanh hơn và kết quả nhất quán hơn giữa các lần huấn luyện.

5. Quy trình đánh giá.

Để đảm bảo độ tin cậy và khả năng tổng quát của mô hình, nhóm áp dụng kỹ thuật **Cross-Validation 5-fold** trên tập huấn luyện. Cụ thể, dữ liệu được chia thành 5 phần bằng nhau; ở mỗi lần lặp, 4 phần được dùng để huấn luyện và 1 phần còn lại dùng để kiểm định. Kết quả trung bình của 5 lần huấn luyện cho phép đánh giá độ ổn định và hiệu suất tổng thể của mô hình.

Sau khi xác định được cấu hình tối ưu, mô hình được **huấn luyện lại trên toàn bộ tập huấn luyện (80%)** và **đánh giá trên tập kiểm thử độc lập (20%)** để thu được kết quả cuối cùng.

Các chỉ số đánh giá.

Hiệu suất mô hình được so sánh dựa trên bốn chỉ số cơ bản trong phân loại đa lớp:

- **Accuracy (Độ chính xác):** Tỷ lệ mẫu được dự đoán đúng trên tổng số mẫu;
- **Precision (Độ chính xác dương tính):** Tỷ lệ mẫu đúng trong tổng số mẫu được mô hình dự đoán là dương tính;
- **Recall (Độ bao phủ):** Tỷ lệ mẫu dương tính được mô hình phát hiện chính xác;
- **F1-Score:** Trung bình điều hòa giữa Precision và Recall, được tính theo hai biến thể:
 - **Macro F1:** Trung bình đều cho tất cả các lớp, phản ánh khả năng mô hình phân biệt các nhóm nhỏ
 - **Weighted F1:** Trung bình có trọng số theo quy mô của từng lớp, phản ánh hiệu suất tổng thể.

Do tập dữ liệu có sự mất cân bằng đáng kể giữa các thể loại (đặc biệt là 22 – Con người & Blog và 24 – Giải trí, chiếm hơn 40% tổng số mẫu), chỉ số **Weighted F1** được chọn làm tiêu chí chính để đánh giá độ chính xác tổng thể, trong khi **Macro F1** được dùng để đo lường khả năng mô hình nhận dạng các lớp hiếm.

Tổng quan quy trình thực nghiệm.

Trước hết, dữ liệu mô tả được tiền xử lý và biểu diễn bằng các phương pháp embedding khác nhau. Tiếp theo, các đặc trưng thu được được đưa vào huấn luyện với bốn mô hình học máy phổ biến: **Logistic Regression**, **Linear SVM**, **Random Forest** và **Naive Bayes**. Cuối cùng, các mô hình được đánh giá lần lượt thông qua Cross-Validation trên tập huấn luyện và kiểm thử độc lập để lựa chọn cấu hình có hiệu suất cao nhất.

B. Biểu diễn truyền thống: TF-IDF

Phương pháp **TF-IDF (Term Frequency – Inverse Document Frequency)** được sử dụng như một biểu diễn đặc trưng truyền thống cho dữ liệu mô tả video YouTube. Các vector TF-IDF thu được được đưa vào bốn mô hình học máy phổ biến gồm: **Logistic Regression (LR)**, **Linear SVM**, **Random Forest (RF)** và **Naive Bayes (NB)**. Phương pháp này đóng vai trò như *baseline* để so sánh với các kỹ thuật biểu diễn ngữ nghĩa hiện đại ở phần sau.

Kết quả đánh giá bằng Cross-Validation 5-fold.

Bảng III trình bày giá trị trung bình của chỉ số **Macro F1** trong 5 lần kiểm định chéo. Kết quả cho thấy **Linear SVM** đạt hiệu suất cao nhất với **F1 = 0.6638**, cho thấy khả năng tổng quát hóa ổn định trên tập huấn luyện.

Bảng III
KẾT QUẢ CROSS-VALIDATION 5-FOLD TRÊN BIỂU DIỄN TF-IDF

Mô hình	F1 Macro trung bình	Độ lệch chuẩn
Logistic Regression	0.6423	± 0.0258
Linear SVM	0.6638	± 0.0325
Naive Bayes	0.4870	± 0.0085
Random Forest	0.6127	± 0.0206


Kết quả kiểm thử độc lập.

Sau khi lựa chọn cấu hình tối ưu từ giai đoạn kiểm định chéo, các mô hình được huấn luyện lại trên toàn bộ tập huấn luyện (80%) và đánh giá trên tập kiểm thử (20%). Bảng IV thể hiện kết quả tổng hợp theo các chỉ số Accuracy, Macro F1 và Weighted F1.

Bảng IV
HIỆU SUẤT MÔ HÌNH TF-IDF TRÊN TẬP KIỂM THỬ ĐỘC LẬP

Mô hình	Accuracy	Macro F1	Weighted F1
Logistic Regression	0.690	0.630	0.680
Linear SVM	0.730	0.650	0.730
Random Forest	0.744	0.661	0.737
Naive Bayes	0.632	0.485	0.625

Kết quả được minh họa trực quan trong Hình 3. cho thấy các mô hình tuyến tính như Linear SVM và Logistic Regression có hiệu suất ổn định, trong khi Random Forest đạt độ chính xác cao nhất nhờ khả năng học các quan hệ phi tuyến giữa đặc trưng TF-IDF. Ngược lại, Naive Bayes thể hiện kết quả thấp do giả định độc lập giữa các đặc trưng không phù hợp với dữ liệu thực tế, nơi các từ khóa thường đồng xuất hiện theo cụm ngữ nghĩa. Điều này khẳng định rằng các mô hình phi tuyến vẫn tận dụng tốt đặc trưng tần suất, đặc biệt với dữ liệu ngắn như mô tả video.




Hình 3. So sánh Accuracy, Macro F1 và Weighted F1 giữa các mô hình huấn luyện trên biểu diễn TF-IDF.

Phân tích ma trận nhầm lẫn.

Hình 4 Thể hiện ma trận nhầm lẫn của các mô hình trên biểu diễn TF-IDF. Dễ thấy rằng Linear SVM có đường chéo chính rõ ràng nhất, chứng tỏ khả năng phân tách tốt giữa các lớp phổ biến như Con người Blog (22), Giải trí (24) và Tin tức (25). Random Forest vẫn đạt độ chính xác cao nhưng thể hiện khuynh hướng nghiêng về lớp lớn, trong khi Naive Bayes bị nhầm lẫn nhiều ở các lớp nhỏ. Nhìn chung, Linear SVM thể hiện khả năng ổn định và rõ ràng hơn, còn Random Forest đạt độ chính xác cao nhất tổng thể. Tuy nhiên, vẫn xuất hiện nhầm lẫn giữa các nhóm gần ngữ nghĩa như Du lịch (19) và Blog (22), cho thấy mô hình còn hạn chế trong việc tách biệt nội dung mang tính trải nghiệm cá nhân. Kết quả này phản ánh đặc điểm chồng lấn tự nhiên giữa các chủ đề YouTube tiếng Việt.

So sánh Confusion Matrix giữa các mô hình TF-IDF



Hình 4. Ma trận nhầm lẫn của mô hình Random Forest trên biểu diễn TF-IDF.

Nhận xét chung.

Các kết quả cho thấy TF-IDF, dù là phương pháp biểu diễn truyền thống, vẫn mang lại hiệu quả cao trong bài toán phân loại mô tả video ngắn. **Random Forest** đạt kết quả cao nhất về độ chính xác, trong khi **Linear SVM** thể hiện độ ổn định tốt hơn qua Cross-Validation. Phương pháp TF-IDF vì vậy được chọn làm *baseline* để so sánh với các phương pháp biểu diễn ngữ nghĩa hiện đại ở các phần tiếp theo.

C. Biểu diễn ngữ nghĩa: PhoBERT

PhoBERT là mô hình ngôn ngữ tiền huấn luyện dành riêng cho tiếng Việt, được xây dựng dựa trên kiến trúc **RoBERTa** và huấn luyện trên kho dữ liệu 20GB văn bản tiếng Việt. Khác với TF-IDF chỉ biểu diễn tần suất từ, PhoBERT có khả năng nắm bắt ngữ cảnh và mối quan hệ ngữ nghĩa giữa các từ, từ đó tạo ra các vector biểu diễn (embedding) giàu thông tin hơn cho từng câu mô tả video.

Trong thực nghiệm, các vector trung bình tầng ẩn của PhoBERT được trích xuất làm đầu vào cho ba mô hình học máy: **Logistic Regression (LR)**, **Linear SVM** và **Random Forest (RF)**. Kết quả này giúp đánh giá khả năng của PhoBERT khi được sử dụng như một bộ trích xuất đặc trưng (feature extractor) cho bài toán phân loại chủ đề video.

Kết quả đánh giá bằng Cross-Validation 5-fold.


Bảng V trình bày kết quả trung bình của chỉ số **Macro F1** qua 5 lần kiểm định chéo. Trong đó, **Linear SVM** đạt **F1 = 0.5470**, cao hơn một chút so với **Logistic Regression (0.5349)**.

Bảng V
KẾT QUẢ CROSS-VALIDATION 5-FOLD TRÊN BIỂU DIỄN PHOBERT

Mô hình	F1 Macro trung bình	Độ lệch chuẩn
Logistic Regression	0.5349	± 0.0231
Linear SVM	0.5470	± 0.0098

Kết quả kiểm thử độc lập.


Kết quả đánh giá trên tập kiểm thử 20% được thể hiện trong Hình 5. So với TF-IDF, hiệu suất của PhoBERT thấp hơn nhẹ, với **Accuracy dao động 0.61–0.62** và **Weighted F1 khoảng 0.61–0.62** cho Logistic Regression và Linear SVM. Điều này cho thấy PhoBERT chưa thể hiện được toàn bộ sức mạnh ngữ nghĩa khi chỉ dùng trung bình tầng ẩn, song vẫn giữ độ ổn định tốt giữa các mô hình tuyến tính.



Hình 5. So sánh Accuracy, Macro F1 và Weighted F1 giữa các mô hình huấn luyện trên biểu diễn PhoBERT.

Phân tích ma trận nhầm lẫn.

Hình 6 mô tả hiệu suất của ba mô hình trên embedding PhoBERT. Linear SVM đạt hiệu quả cao hơn ở các nhóm nội dung có ngữ nghĩa đặc trưng như Tin tức (25) và Giải trí (24). Tuy nhiên, các lớp có số mẫu nhỏ như Thú cưng (15) hoặc Phi lợi nhuận (29) vẫn bị dự đoán sai do dữ liệu thiếu. So với TF-IDF, PhoBERT giúp giảm lỗi nhầm lẫn giữa các lớp gần nghĩa, nhưng tổng thể hiệu suất vẫn thấp hơn do mô hình chưa được fine-tune.



Hình 6. Ma trận nhầm lẫn của các mô hình Logistic Regression, Linear SVM và Random Forest trên biểu diễn PhoBERT.

Nhận xét chung.

Kết quả thực nghiệm cho thấy các mô hình sử dụng đặc trưng từ PhoBERT đạt hiệu suất trung bình khá tốt, với Linear SVM vẫn là lựa chọn ổn định nhất. Tuy nhiên, so với TF-IDF, sự chênh lệch về Accuracy chưa đáng kể, nguyên nhân chủ yếu do kích thước tập dữ liệu huấn luyện còn hạn chế, khiến mô hình PhoBERT chưa tận dụng được đầy đủ thông tin ngữ cảnh. Điều này mở ra hướng cải tiến bằng cách **fine-tune trực tiếp PhoBERT** trên tập dữ liệu YouTube trong tương lai để khai thác tối đa khả năng biểu diễn ngữ nghĩa của mô hình.

D. Biểu diễn ngữ nghĩa: BGE

Mô hình **BGE (BAAI General Embedding)** là một trong những kỹ thuật biểu diễn ngữ nghĩa thế hệ mới, được phát triển nhằm tạo ra các vector biểu diễn ngắn gọn nhưng giàu thông tin ngữ nghĩa cho toàn bộ câu hoặc đoạn văn. Khác với PhoBERT, BGE không chỉ huấn luyện trên ngôn ngữ đơn lẻ mà còn được tối ưu hoá cho nhiệm vụ so sánh ngữ nghĩa (semantic similarity), do đó thích hợp với các bài toán phân loại văn bản đa chủ đề như mô tả video YouTube.

Trong thí nghiệm này, các vector embedding thu được từ mô hình **BGE-small** được sử dụng làm đầu vào cho ba bộ phân loại: **Logistic Regression (LR)**, **Linear SVM** và **Random Forest (RF)**. Các mô hình này giúp đánh giá mức độ hiệu quả của biểu diễn BGE khi áp dụng vào dữ liệu ngôn ngữ tiếng Việt.

Kết quả đánh giá bằng Cross-Validation 5-fold.


Bảng VI trình bày giá trị trung bình của chỉ số **Macro F1** thu được qua 5 lần kiểm định chéo. Trong đó, **Linear SVM** tiếp tục đạt kết quả cao nhất với **F1 = 0.5568**, cho thấy mô hình tuyến tính này vẫn hoạt động ổn định trên biểu diễn ngữ nghĩa.

Bảng VI
KẾT QUẢ CROSS-VALIDATION 5-FOLD TRÊN BIỂU DIỄN BGE

Mô hình	F1 Macro trung bình	Độ lệch chuẩn
Logistic Regression	0.5398	± 0.0318
Linear SVM	0.5568	± 0.0291

Kết quả kiểm thử độc lập.

Hiệu suất của các mô hình trên tập kiểm thử 20% được thể hiện trong Hình 7. Kết quả cho thấy **Linear SVM** và **Logistic Regression** đều đạt **Accuracy 0.62** và **Weighted F1 0.62**, cao hơn đáng kể so với **Random Forest (Weighted F1 = 0.49)**. Tuy nhiên, do đặc tính embedding của BGE hướng tới ngữ nghĩa tổng quát, các mô hình tuyến tính vẫn có lợi thế hơn so với mô hình cây quyết định trong việc tách biệt các chủ đề tương đồng.




Hình 7. So sánh Accuracy, Macro F1 và Weighted F1 giữa các mô hình huấn luyện trên biểu diễn BGE.

Phân tích ma trận nhầm lẫn.

Hình 8 Ma trận nhầm lẫn cho thấy Linear SVM tiếp tục thể hiện khả năng phân biệt tốt các lớp chính, trong khi Random Forest có xu hướng gộp nhiều dự đoán về nhóm Con người Blog (22). BGE giúp tăng tính khái quát ngữ nghĩa, nhưng chưa

đủ mạnh để phân tách các chủ đề gần nhau như Du lịch (19) và Giải trí (24). Tổng thể, biểu diễn BGE mang lại kết quả ổn định, nhưng độ chính xác chưa vượt được TF-IDF.



Hình 8. Ma trận nhầm lẫn của các mô hình Logistic Regression, Linear SVM và Random Forest trên biểu diễn BGE.

Nhận xét chung.

Biểu diễn BGE cho kết quả tương đương PhoBERT về mặt tổng thể, song có ưu thế về tốc độ trích xuất và dung lượng nhẹ hơn. Điều này giúp BGE trở thành lựa chọn hiệu quả cho các hệ thống phân loại lớn hoặc triển khai thực tế. Tuy nhiên, để cải thiện độ chính xác, việc kết hợp BGE với kỹ thuật tinh chỉnh (fine-tuning) theo miền dữ liệu tiếng Việt hoặc mô hình phân loại phi tuyến sâu hơn có thể mang lại kết quả tốt hơn trong tương lai.

E. Biểu diễn ngữ nghĩa: E5

Mô hình **E5 (Embedding from Explicitly Exploited Explanations)** được phát triển nhằm tối ưu cho các tác vụ ngữ nghĩa đa dạng như phân loại, tìm kiếm ngữ cảnh và truy xuất thông tin. Khác với các mô hình embedding truyền thống, E5 được huấn luyện theo cơ chế *instruction-based learning*, trong đó đầu vào được hướng dẫn bằng các câu lệnh ngữ nghĩa giúp mô hình hiểu rõ hơn mối quan hệ giữa văn bản và chủ đề. Nhờ vậy, E5 có khả năng nắm bắt ngữ cảnh sâu hơn, đặc biệt hiệu quả với văn bản ngắn như mô tả video.

Trong thực nghiệm, các vector embedding trung bình của mô hình **E5-base** được trích xuất và sử dụng làm đầu vào cho ba bộ phân loại: **Logistic Regression (LR)**, **Linear SVM** và **Random Forest (RF)**. Các mô hình này được huấn luyện và đánh giá theo quy trình giống các thí nghiệm trước đó.

Kết quả đánh giá bằng Cross-Validation 5-fold.


Bảng VII trình bày kết quả trung bình của chỉ số **Macro F1** qua 5 lần kiểm định chéo. **Linear SVM** tiếp tục đạt kết quả cao nhất với **F1 = 0.5768**, cao hơn Logistic Regression (0.5513). Điều này cho thấy E5 tạo ra biểu diễn ổn định và dễ phân tách cho các mô hình tuyến tính.

Bảng VII
KẾT QUẢ CROSS-VALIDATION 5-FOLD TRÊN BIỂU DIỄN E5

Mô hình	F1 Macro trung bình	Độ lệch chuẩn
Logistic Regression	0.5513	± 0.0274
Linear SVM	0.5768	± 0.0232

Kết quả kiểm thử độc lập.


Trên tập kiểm thử 20%, hiệu suất của các mô hình được thể hiện trong Hình 9. Cả **Logistic Regression** và **Linear SVM** đạt hiệu suất tương đương, với **Accuracy = 0.64** và **Weighted F1 = 0.64**. **Random Forest** cho kết quả thấp hơn đáng kể (Weighted F1 = 0.52), cho thấy các mô hình tuyến tính vẫn phù hợp hơn với embedding có cấu trúc ngữ nghĩa rõ ràng như E5.



Hình 9. So sánh Accuracy, Macro F1 và Weighted F1 giữa các mô hình huấn luyện trên biểu diễn E5.

Phân tích ma trận nhầm lẫn.

Hình 10 minh họa ma trận nhầm lẫn của ba mô hình sử dụng embedding E5. Kết quả cho thấy **Linear SVM** duy trì độ chính xác cao ở các lớp chính như 22 – Con người & Blog, 24 – Giải trí tổng hợp và 25 – Tin tức & Chính trị. Tuy nhiên, các lớp nhỏ (ví dụ 15 – Thú cưng, 29 – Phi lợi nhuận) vẫn gặp khó khăn trong việc phân biệt, một phần do số lượng mẫu huấn luyện hạn chế.



Hình 10. Ma trận nhầm lẫn của các mô hình Logistic Regression, Linear SVM và Random Forest trên biểu diễn E5.

Nhận xét chung.

Kết quả thực nghiệm cho thấy embedding E5 đạt hiệu suất tốt và ổn định, đặc biệt khi kết hợp với các mô hình tuyến tính. Hiệu quả của E5 nhìn chung cao hơn một chút so với PhoBERT và BGE, nhờ khả năng hiểu ngữ cảnh dựa trên câu lệnh (instruction). Tuy nhiên, để đạt hiệu quả tối đa, mô hình cần được fine-tune trên tập dữ liệu tiếng Việt thực tế, hoặc kết hợp thêm cơ chế attention để khai thác sâu hơn cấu trúc ngữ nghĩa của mô tả video.

F. Biểu diễn ngữ nghĩa nâng cao: Sup-SimCSE PhoBERT

Mô hình **Sup-SimCSE PhoBERT** (Supervised Simple Contrastive Sentence Embedding) là phiên bản cải tiến của PhoBERT được huấn luyện bổ sung theo phương pháp **học tương phản có giám sát (Supervised Contrastive Learning)**. Khác với PhoBERT gốc vốn chỉ dựa trên ngữ cảnh hai chiều, Sup-SimCSE tận dụng thông tin nhân trong giai đoạn huấn luyện để tối ưu hóa khoảng cách giữa các câu có nghĩa tương đồng và tăng phân tách giữa các câu khác chủ đề. Nhờ vậy, biểu diễn

embedding của Sup-SimCSE thể hiện mối quan hệ ngữ nghĩa chính xác hơn, đặc biệt hiệu quả trong các bài toán phân loại chủ đề văn bản.

Trong thí nghiệm này, vector trung bình tầng ẩn cuối cùng của Sup-SimCSE PhoBERT được sử dụng làm đầu vào cho ba mô hình học máy: **Logistic Regression (LR)**, **Linear SVM** và **Random Forest (RF)**. Các thí nghiệm được thực hiện tương tự như các phần trước, trên cùng tập dữ liệu mô tả video tiếng Việt.

Kết quả đánh giá bằng Cross-Validation 5-fold.


Bảng VIII thể hiện kết quả trung bình của chỉ số **Macro F1** qua 5 lần kiểm định chéo. **Linear SVM** tiếp tục đạt hiệu suất cao nhất với **F1 = 0.5757**, nhỉnh hơn Logistic Regression (0.5655). Các giá trị lệch chuẩn nhỏ cho thấy độ ổn định của mô hình giữa các lần kiểm định.

Bảng VIII
KẾT QUẢ CROSS-VALIDATION 5-FOLD TRÊN BIỂU DIỄN SUP-SIMCSE PHOBERT

Mô hình	F1 Macro trung bình	Độ lệch chuẩn
Logistic Regression	0.5655	± 0.0156
Linear SVM	0.5757	± 0.0310

Kết quả kiểm thử độc lập.


Trên tập kiểm thử 20%, kết quả tổng hợp được trình bày trong Hình 11. **Linear SVM** đạt hiệu suất cao nhất với **Accuracy = 0.65** và **Weighted F1 = 0.65**, trong khi Logistic Regression đạt mức tương đương (0.62) và Random Forest thấp hơn đáng kể (Weighted F1 = 0.60). Điều này cho thấy việc bổ sung cơ chế học tương phản giúp mô hình Sup-SimCSE tạo ra embedding ổn định và phân tách tốt giữa các chủ đề gần nghĩa.



Hình 11. So sánh Accuracy, Macro F1 và Weighted F1 giữa các mô hình huấn luyện trên biểu diễn Sup-SimCSE PhoBERT.

Phân tích ma trận nhầm lẫn.

Hình 12 minh họa ma trận nhầm lẫn của ba mô hình khi sử dụng embedding Sup-SimCSE PhoBERT. Có thể thấy **Linear SVM** cho kết quả phân biệt rõ ràng giữa các nhóm nội dung phổ biến như 22 – Con người & Blog, 24 – Giải trí tổng hợp và 25 – Tin tức & Chính trị, đồng thời giảm đáng kể nhầm lẫn giữa các lớp có nội dung tương tự như 19 – Du lịch và 22 – Blog. **Random Forest** vẫn thể hiện độ chính xác thấp hơn, do không tận dụng hiệu quả cấu trúc ngữ nghĩa trong không gian embedding.



Hình 12. Ma trận nhầm lẫn của các mô hình Logistic Regression, Linear SVM và Random Forest trên biểu diễn Sup-SimCSE PhoBERT.

Nhận xét chung.

Kết quả cho thấy **Sup-SimCSE PhoBERT** đạt hiệu suất cao nhất trong nhóm các phương pháp embedding ngữ nghĩa, với độ chính xác và F1-score cao hơn các mô hình PhoBERT, BGE và E5. Cơ chế học tương phản có giám sát giúp cải thiện đáng kể khả năng nhận biết ngữ nghĩa giữa các mô tả video gần nhau về nội dung, từ đó tăng tính phân tách của không gian biểu diễn. Điều này chứng tỏ tiềm năng của Sup-SimCSE PhoBERT trong các ứng dụng phân loại ngữ nghĩa tiếng Việt phức tạp, đặc biệt khi được kết hợp cùng các mô hình tuyến tính mạnh như Linear SVM.

G. Tổng hợp và so sánh hiệu suất giữa các phương pháp embedding

Sau khi tiến hành huấn luyện và đánh giá trên năm phương pháp biểu diễn văn bản gồm **TF-IDF**, **PhoBERT**, **BGE**, **E5** và **Sup-SimCSE PhoBERT**, kết quả tổng hợp toàn bộ các mô hình được thể hiện trong Bảng IX. Phần này nhằm trình bày một cách tổng quát hiệu suất của từng phương pháp, từ đó xác định mô hình và biểu diễn ngữ nghĩa tối ưu nhất cho bài toán.


Bảng IX
BẢNG TỔNG HỢP KẾT QUẢ CÁC MÔ HÌNH TRÊN TỪNG EMBEDDING

Embedding	Mô hình	Accuracy	Macro F1	Weighted F1
TF-IDF	Random Forest	0.744	0.588	0.737
PhoBERT	Linear SVM	0.624	0.545	0.620
BGE	Linear SVM	0.623	0.557	0.620
E5	Linear SVM	0.640	0.585	0.638
Sup-SimCSE PhoBERT	Linear SVM	0.647	0.561	0.646

Biểu đồ thể hiện hiệu suất tổng thể giữa năm phương pháp embedding. TF-IDF vượt trội với Accuracy = 0.744 và Weighted F1 = 0.737, trong khi Sup-SimCSE PhoBERT xếp thứ hai với Accuracy 0.647. Các embedding E5 và BGE đạt mức trung bình, còn PhoBERT gốc thấp nhất. Điều này chứng minh rằng các phương pháp biểu diễn ngữ nghĩa hiện đại chỉ phát huy tối đa khi được huấn luyện lại theo miền dữ liệu tiếng Việt

Hiệu suất tổng thể theo embedding.


Hình 13 minh họa sự khác biệt về **Accuracy**, **Macro F1** và **Weighted F1** giữa các embedding. Kết quả cho thấy **TF-IDF** đạt **Accuracy cao nhất (0.744)** và **Weighted F1 = 0.737**, vượt trội so với các phương pháp embedding ngữ nghĩa hiện đại. Điều này phản ánh đặc điểm riêng của tập dữ liệu mô tả video YouTube các đoạn mô tả thường ngắn, nhiều từ khóa đặc trưng, nên phương pháp thống kê tần suất như TF-IDF vẫn mang lại hiệu quả nổi bật.



Hình 13. So sánh hiệu suất (Accuracy / Macro F1 / Weighted F1) giữa các embedding.

Kết quả Cross-Validation.


Hình 14 minh họa kết quả Cross-Validation 5-fold cho từng embedding. TF-IDF đạt F1 Macro cao nhất (0.664), thể hiện khả năng khái quát hóa tốt và ổn định nhất trên toàn bộ dữ liệu. Các phương pháp embedding ngữ nghĩa như E5 và Sup-SimCSE PhoBERT đạt mức tiệm cận (0.575), trong khi PhoBERT và BGE vẫn thấp hơn do chưa được tinh chỉnh (fine-tune). Kết quả này khẳng định TF-IDF vẫn là lựa chọn tối ưu cho văn bản ngắn tiếng Việt.



Hình 14. So sánh kết quả Cross-Validation giữa các phương pháp embedding.

Mô hình tốt nhất trên từng embedding.

Hình 15 trình bày **Accuracy** của mô hình có hiệu suất cao nhất trên mỗi embedding. Dễ nhận thấy rằng **Linear SVM** chiếm ưu thế trong hầu hết các phương pháp biểu diễn ngữ nghĩa (PhoBERT, BGE, E5, Sup-SimCSE), cho thấy đặc trưng embedding tạo ra các không gian gần tuyến tính, trong khi **Random Forest** thể hiện vượt trội ở TF-IDF do khai thác tốt các đặc trưng phi tuyến của tần suất từ.



Hình 15. Hiệu suất (Accuracy) của mô hình tốt nhất trên từng embedding.

Tổng kết. Kết quả tổng hợp cho thấy:

- **TF-IDF + Random Forest** là kết hợp hiệu quả nhất cho dữ liệu mô tả video ngắn.
- Các embedding ngữ nghĩa hiện đại như **E5** và **Sup-SimCSE PhoBERT** đạt hiệu suất tiệm cận TF-IDF, chứng minh khả năng học biểu diễn ngữ nghĩa sâu và ổn định.
- **Linear SVM** là mô hình phù hợp nhất cho các vector embedding, trong khi các mô hình phi tuyến như Random Forest kém hiệu quả hơn ở không gian vector hóa cao chiều.

Những kết quả trên là cơ sở quan trọng để tiến hành phần **thảo luận chi tiết** ở mục sau, nơi nhóm tác giả sẽ phân tích sâu nguyên nhân của sự khác biệt này và định hướng cải thiện hiệu suất cho các mô hình embedding ngữ nghĩa.

VI. TỔNG KẾT VÀ THẢO LUẬN

A. Tổng kết

Kết quả thực nghiệm cho thấy:

- **TF-IDF + Random Forest** là **tổ hợp hiệu quả nhất** cho bài toán phân loại mô tả video ngắn tiếng Việt, đạt **Accuracy = 0.744** và **Weighted F1 = 0.737**. Cấu hình này thể hiện khả năng nắm bắt tốt tần suất và mức độ đặc trưng của các từ khóa trong từng thể loại video.
- Các **embedding ngữ nghĩa hiện đại** như **E5** và **Sup-SimCSE PhoBERT** đạt hiệu suất **tiệm cận TF-IDF**, chứng minh khả năng **biểu diễn ngữ nghĩa sâu và ổn định**, dù chưa được huấn luyện lại trên miền dữ liệu tiếng Việt đặc thù.
- **Linear SVM** là mô hình **tổng quát hóa tốt nhất** qua Cross-Validation, đặc biệt hiệu quả khi kết hợp với các vector embedding có chiều cao. Trong khi đó, **Random Forest** đạt hiệu quả cao hơn trên tập kiểm thử độc lập nhưng dễ thiên lệch về các lớp có kích thước lớn.

Tổng thể, các kết quả này cho thấy **TF-IDF vẫn là phương pháp biểu diễn mạnh mẽ** trong các bài toán phân loại văn bản ngắn, nơi yếu tố từ vựng đặc trưng đóng vai trò chính. Ngược lại, các **mô hình embedding ngữ nghĩa** như E5 và Sup-SimCSE PhoBERT cho thấy tiềm năng lớn trong việc **học biểu diễn ngữ nghĩa sâu**, hứa hẹn vượt TF-IDF khi được **fine-tune đúng miền dữ liệu**.

B. Thảo luận chi tiết

1) *Vì sao TF-IDF vẫn vượt trội:* Mặc dù các phương pháp embedding hiện đại được huấn luyện trên kho dữ liệu lớn, TF-IDF vẫn vượt trội trong bài toán này vì:

- Mô tả video YouTube thường **ngắn và giàu từ khóa đặc trưng**, giúp trọng số TF-IDF phản ánh rõ ràng chủ đề nội dung.

- Các embedding ngữ nghĩa (PhoBERT, E5, BGE, Sup-SimCSE) **thiếu bối cảnh huấn luyện đặc thù tiếng Việt trên miền video**, dẫn đến biểu diễn khái niệm chưa tối ưu.
- TF-IDF tạo đặc trưng **thừa nhưng có tính phân biệt cao**, giúp các mô hình như Random Forest hoặc SVM dễ tìm ranh giới quyết định.

2) *Nguyên nhân embedding ngữ nghĩa chưa vượt được TF-IDF*: Các phương pháp embedding cho kết quả tiệm cận nhưng vẫn thấp hơn TF-IDF do:

- Chưa được **fine-tune** trên dữ liệu cụ thể của bài toán, nên biểu diễn còn mang tính tổng quát.
- **Độ dài mô tả ngắn** (trung bình 25–40 từ) khiến embedding không khai thác được ngữ cảnh đầy đủ.
- Một số thể loại video có **nội dung ngữ nghĩa gần nhau** (ví dụ: *Du lịch, Con người & Blog, Giải trí*) khiến vector ngữ nghĩa bị chồng lấn.
- **Mất cân bằng dữ liệu** làm giảm khả năng học khái niệm của mô hình embedding.

3) *Về mô hình học máy*:

- **Linear SVM** cho thấy **khả năng ổn định nhất**, đặc biệt trong Cross-Validation, do phù hợp với không gian vector cao chiều và phân tách tuyến tính rõ ràng.
- **Random Forest** đạt **Accuracy cao nhất** trên tập kiểm thử, nhưng có xu hướng lệch về lớp phổ biến (*class imbalance bias*).
- **Naive Bayes** hoạt động kém với embedding vì giả định độc lập điều kiện không còn đúng khi đặc trưng mang tính ngữ nghĩa liên kết cao.

4) *Định hướng cải thiện*: Để nâng cao hiệu suất trong tương lai, nhóm đề xuất:

- **Fine-tune các embedding** (E5, Sup-SimCSE, PhoBERT) trên miền dữ liệu tiếng Việt của YouTube
- Áp dụng **kỹ thuật cân bằng dữ liệu** như SMOTE, focal loss hoặc re-weight class
- Thử nghiệm **mô hình kết hợp (ensemble)** giữa embedding và TF-IDF để tận dụng ưu thế của cả hai hướng
- Sử dụng **mô hình deep learning phân loại** như BiLSTM hoặc Transformer fine-tuned thay cho SVM/RF.

C. Kết luận

Như vậy, trong phạm vi nghiên cứu này, **TF-IDF + Random Forest** được xem là **mô hình tối ưu nhất**, đạt hiệu suất cao nhất trên tập kiểm thử độc lập. Tuy nhiên, sự tiệm cận của **E5** và **Sup-SimCSE PhoBERT** mở ra hướng phát triển mạnh mẽ cho các mô hình **embedding ngữ nghĩa tiếng Việt**, đặc biệt khi được tinh chỉnh theo miền dữ liệu video ngắn.

VII. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

A. Kết luận chung

Nghiên cứu này đã thực hiện bài toán **phân loại video YouTube theo thể loại dựa trên phần mô tả tiếng Việt**, sử dụng tập dữ liệu thu thập tự động từ **YouTube Data API v3**. Toàn bộ quy trình bao gồm các giai đoạn: **Tiền xử lý dữ liệu, biểu diễn văn bản bằng nhiều kỹ thuật khác nhau, huấn luyện mô hình học máy, và đánh giá hiệu suất thông qua Cross-Validation 5-fold**.

Kết quả thực nghiệm cho thấy:

- Phương pháp **TF-IDF kết hợp Random Forest** đạt hiệu suất cao nhất với **Accuracy = 0.744** và **Weighted F1 = 0.737**, chứng tỏ mô hình thống kê truyền thống vẫn mang lại hiệu quả mạnh mẽ đối với văn bản ngắn có tính đặc trưng cao.
- Các mô hình **embedding ngữ nghĩa hiện đại** như **E5** và **Sup-SimCSE PhoBERT** đạt kết quả tiệm cận TF-IDF, cho thấy khả năng học biểu diễn ngữ nghĩa sâu và ổn định, dù chưa được fine-tune trên miền dữ liệu tiếng Việt.
- **Linear SVM** thể hiện độ ổn định tốt nhất trong Cross-Validation, trong khi **Random Forest** đạt kết quả cao hơn trên tập kiểm thử độc lập nhưng dễ lệch về các lớp có kích thước lớn.

Từ những kết quả trên, có thể khẳng định rằng **TF-IDF vẫn là một phương pháp cơ bản nhưng hiệu quả** trong các bài toán phân loại mô tả video tiếng Việt. Tuy nhiên, xu hướng phát triển hiện nay cho thấy các mô hình embedding ngữ nghĩa như **E5** hay **Sup-SimCSE PhoBERT** hoàn toàn có tiềm năng vượt trội khi được tinh chỉnh phù hợp với miền dữ liệu cụ thể.

Ngoài ra, nghiên cứu cũng chỉ ra rằng **chất lượng dữ liệu và quy trình tiền xử lý** đóng vai trò quyết định trong hiệu quả của hệ thống phân loại. Việc chuẩn hóa văn bản, loại bỏ nhiễu, và cân bằng dữ liệu giữa các lớp có ảnh hưởng trực tiếp đến độ chính xác cuối cùng của mô hình.

B. Hướng phát triển trong tương lai

Từ những kết quả đạt được, nhóm đề xuất một số hướng mở rộng để cải thiện hiệu suất và mở rộng phạm vi ứng dụng:

- 1) **Fine-tune các mô hình embedding ngữ nghĩa**: Tinh chỉnh các mô hình như *PhoBERT, E5, Sup-SimCSE PhoBERT* trên tập dữ liệu YouTube tiếng Việt sẽ giúp khai thác sâu hơn ngữ cảnh đặc thù của mô tả video, tăng độ chính xác phân loại.
- 2) **Cân bằng dữ liệu và mở rộng tập huấn luyện**: Áp dụng các kỹ thuật như *SMOTE, data augmentation hoặc focal loss* để giảm thiên lệch lớp; đồng thời mở rộng dữ liệu sang nhiều thể loại và ngôn ngữ phụ để tăng tính tổng quát.

- 3) **Kết hợp nhiều phương pháp biểu diễn (Hybrid Embedding):** Kết hợp TF-IDF với các vector ngữ nghĩa từ PhoBERT hoặc E5 nhằm tận dụng đồng thời ưu điểm tần suất và ngữ cảnh, hướng tới một không gian biểu diễn lai giàu thông tin hơn.
- 4) **Triển khai mô hình học sâu (Deep Learning):** Thử nghiệm các kiến trúc **BiLSTM**, **CNN**, hoặc **Transformer fine-tuned** để thay thế mô hình truyền thống, cho phép học tự động đặc trưng ngữ nghĩa ở mức câu.
- 5) **Xây dựng hệ thống ứng dụng thực tế:** Phát triển một công cụ **tự động phân loại và gợi ý thể loại video YouTube tiếng Việt**, tích hợp vào hệ thống quản lý hoặc phân tích xu hướng nội dung.

TÀI LIỆU THAM KHẢO

- [1] T. Joachims, "Text categorization with support vector machines: Learning with many relevant features," in *Proceedings of the European Conference on Machine Learning (ECML)*, 1998. [Online]. Available: <https://link.springer.com/chapter/10.1007/BFb0026683>
- [2] F. Sebastiani, "Machine learning in automated text categorization," *ACM Computing Surveys*, vol. 34, no. 1, pp. 1–47, 2002. [Online]. Available: <https://dl.acm.org/doi/10.1145/505282.505283>
- [3] P. Saini, G. Kaur, and A. Sharma, "Video category classification using textual metadata and deep learning," *International Journal of Advanced Research in Computer and Communication Engineering*, 2020. [Online]. Available: <https://ijarccce.com/wp-content/uploads/2020/03/IJARCCCE.2020.9314.pdf>
- [4] T. H. Vu, "Underthesea: Vietnamese nlp toolkit," <https://github.com/undertheseanlp/underthesea>, 2018.
- [5] H. Nguyen, "Pyvi: Vietnamese text processing library," <https://pypi.org/project/pyvi/>, 2019.
- [6] K. Dang and T. Nguyen, "Stopword customization for vietnamese youtube data," *Vietnam Journal of Artificial Intelligence Research*, 2021.
- [7] J. Ramos, "Using tf-idf to determine word relevance in document queries," Department of Computer Science, Rutgers University, Tech. Rep., 2003. [Online]. Available: <https://www.semanticscholar.org/paper/Using-TF-IDF-to-determine-word-relevance-in-Ramos/0b2e9e2b56ef94e4e9ff6f5b25dd0b358a28f64a>
- [8] Y. Zhang, R. Jin, and Z. Zhou, "Understanding bag-of-words models: A statistical framework," *Pattern Recognition Letters*, vol. 31, no. 12, pp. 1337–1344, 2010. [Online]. Available: <https://doi.org/10.1016/j.patrec.2010.04.019>
- [9] Q.-T. Nguyen and M.-H. Tran, "Comparative study of vietnamese text classification using tf-idf and svm," *ICT Research Journal*, 2021.
- [10] J. Devlin, M.-W. Chang, K. Lee, and K. Toutanova, "Bert: Pre-training of deep bidirectional transformers for language understanding," in *Proceedings of NAACL-HLT*, 2019. [Online]. Available: <https://aclanthology.org/N19-1423/>
- [11] D. Q. Nguyen, A. T. Nguyen, D. Q. Nguyen, and S. B. Pham, "Phobert: Pre-trained language models for vietnamese," in *Findings of EMNLP*, 2020. [Online]. Available: <https://aclanthology.org/2020.findings-emnlp.92/>
- [12] H. M. Le, "A comparative evaluation of word embeddings for vietnamese text classification," *IEEE Access*, 2022. [Online]. Available: <https://ieeexplore.ieee.org/document/9744047>
- [13] BAAI Team, "Bge embeddings," <https://huggingface.co/BAAI/bge-base-en-v1.5>, 2023.
- [14] S. Wang, N. Reimers, and I. Gurevych, "Text embeddings by weakly-supervised contrastive pre-training," *arXiv preprint arXiv:2302.10866*, 2023. [Online]. Available: <https://arxiv.org/abs/2302.10866>
- [15] T. Gao, X. Yao, and D. Chen, "Simcse: Simple contrastive learning of sentence embeddings," in *Proceedings of EMNLP 2021*, 2021. [Online]. Available: <https://aclanthology.org/2021.emnlp-main.552/>