

ĐỒ ÁN MÔN HỌC

MẠNG XÃ HỘI

Ngành: **KHOA HỌC DỮ LIỆU**

Chuyên ngành: **KHOA HỌC DỮ LIỆU**

Giảng viên hướng dẫn : ThS. Lê Nhật Tùng

Sinh viên thực hiện :

2286400019 – Nguyễn Nhật Nam

2286400017 – Hoàng Quang Minh

2286400002 – Hà Thế Anh

Lớp: 22DKHA1

TP. Hồ Chí Minh, 2025

ĐỒ ÁN MÔN HỌC

MẠNG XÃ HỘI

Ngành: **KHOA HỌC DỮ LIỆU**

Chuyên ngành: **KHOA HỌC DỮ LIỆU**

Giảng viên hướng dẫn : ThS. Lê Nhật Tùng

Sinh viên thực hiện :

2286400019 – Nguyễn Nhật Nam

2286400017 – Hoàng Quang Minh

2286400002 – Hà Thế Anh

Lớp: 22DKHA1

TP. Hồ Chí Minh, 2025

Mục lục

Project 1A: PHÂN TÍCH CỘNG ĐỒNG NGHIÊN CỨU VÀ PHÁT HIỆN NHÓM HỢP TÁC TRONG LĨNH VỰC DATA SCIENCE	3
Project 1B: DỰ ĐOÁN HỢP TÁC NGHIÊN CỨU TƯƠNG LAI VÀ KHUYẾN NGHỊ ĐỐI TÁC TRONG MẠNG LƯỚI KHOA HỌC	16
Project 2A: PHÂN CỤM VIDEO YOUTUBE DỰA TRÊN MÔ TẢ CỦA VIDEO	30
Project 2B: PHÂN LOẠI VIDEO YOUTUBE THEO THỂ LOẠI DỰA TRÊN MÔ TẢ CỦA VIDEO.	42
Project 2C: PHÂN TÍCH CHỦ ĐỀ DỰA TRÊN MÔ TẢ VIDEO YOUTUBE.	61
Project 3A: PHÂN TÍCH CÁC YẾU TỐ ẢNH HƯỞNG ĐẾN Ý ĐỊNH SỬ DỤNG ỨNG DỤNG MICROSOFT TEAMS TRONG HỌC TẬP CỦA SINH VIÊN VIỆT NAM: TIẾP CẬN THEO MÔ HÌNH TAM MỞ RỘNG	76

PROJECT 1A: PHÂN TÍCH CỘNG ĐỒNG NGHIÊN CỨU VÀ PHÁT HIỆN NHÓM HỢP TÁC TRONG LĨNH VỰC DATA SCIENCE

1st Hà Thế Anh, 2nd Nguyễn Nhật Nam, 3rd Hoàng Quang Minh
and Le Nhat Tung

HUTECH University, Vietnam

{hatheanh012004, nguyennhatnam01012004, hoangquangminh130804}@gmail.com, and lenhattung@hutech.edu.vn

TÓM TẮT NỘI DUNG

Trong những năm gần đây, **Khoa học Dữ liệu (Data Science)** phát triển mạnh mẽ, kéo theo sự mở rộng của hoạt động hợp tác giữa các nhà nghiên cứu. Việc nắm bắt cấu trúc và động lực của những **mạng lưới đồng tác giả (Co-author Networks)** giúp nhận diện xu hướng chủ đề, nhóm chuyên môn và các mối liên kết học thuật quan trọng.

Nghiên cứu này xây dựng **mạng đồng tác giả** từ dữ liệu thu thập tự động trên nền tảng **OpenAlex**, trong đó nút biểu diễn tác giả và cạnh biểu diễn quan hệ hợp tác. Trên đồ thị thu được, chúng tôi áp dụng các thuật toán **phát hiện cộng đồng** gồm **Louvain**, **Leiden** và **Fast Greedy** đồng thời tính các chỉ số **centrality** (Degree, Betweenness, Closeness, Eigenvector) để nhận diện những cá nhân có ảnh hưởng.

Kết quả cho thấy mạng lưới nghiên cứu hình thành các cộng đồng rõ rệt xoay quanh những hướng chủ đề gần nhau trong đó **Leiden** và **Louvain** đạt *modularity* cao và cho phân hoạch ổn định, còn **Fast Greedy** cho kết quả cạnh tranh với chi phí tính toán thấp. Phân tích centrality chỉ ra một số tác giả giữ vai trò “cầu nối” giữa các nhóm.

Công trình mang lại cái nhìn toàn diện về **cấu trúc hợp tác khoa học** trong lĩnh vực Data Science, hỗ trợ phát hiện nhóm hợp tác tiềm năng và gợi ý ứng dụng **Social Network Analysis** trong hoạch định chiến lược nghiên cứu.

TỪ KHÓA

OpenAlex, Co-author Network, Community Detection, Scientific Collaboration, Data Science, Social Network Analysis, Research Collaboration, Network Visualization.

I. GIỚI THIỆU

Trong bối cảnh kỷ nguyên dữ liệu bùng nổ, **Khoa học Dữ liệu (Data Science)** đã trở thành một trong những lĩnh vực nghiên cứu phát triển nhanh nhất hiện nay. Song song với sự gia tăng nhanh chóng của các công trình khoa học, các mối quan hệ hợp tác giữa các nhà nghiên cứu cũng ngày càng đa dạng và phức tạp hơn, hình thành nên những **mạng lưới cộng tác nghiên cứu (research collaboration networks)** có quy mô lớn và cấu trúc liên kết chặt chẽ.

Việc phân tích các mạng lưới này mang ý nghĩa quan trọng trong việc hiểu rõ **xu hướng hợp tác, lĩnh vực nghiên cứu trọng tâm**, cũng như phát hiện những nhóm học giả có ảnh hưởng lớn trong cộng đồng khoa học. Trong đó, **Phân tích mạng xã hội (Social Network Analysis - SNA)** đã trở thành một công cụ mạnh mẽ giúp mô hình hóa và khám phá các mối quan hệ giữa các thực thể nghiên cứu thông qua biểu diễn đồ thị.

Một hướng nghiên cứu cốt lõi của SNA là **phát hiện cộng đồng (community detection)** quá trình xác định các nhóm trong mạng lưới có mức độ kết nối nội bộ cao và liên kết bên ngoài yếu hơn. Việc phát hiện các cộng đồng này không chỉ giúp nhận diện cấu trúc tổ chức của mạng lưới khoa học, mà còn hỗ trợ khám phá các nhóm hợp tác tiềm năng, xu hướng nghiên cứu nổi bật và các tác giả đóng vai trò cầu nối giữa nhiều lĩnh vực khác nhau.

Trong nghiên cứu này, nhóm tập trung vào việc **phân tích cộng đồng nghiên cứu và phát hiện nhóm hợp tác trong lĩnh vực Data Science**. Dữ liệu được thu thập tự động từ nền tảng **OpenAlex** một cơ sở dữ liệu học thuật mở, chứa thông tin về các tác giả, bài báo và mối quan hệ hợp tác giữa họ. Từ nguồn dữ liệu này, nhóm tiến hành xây dựng **mạng đồng tác giả (co-author network)** trong đó mỗi nút biểu diễn một tác giả và mỗi cạnh thể hiện mối quan hệ cộng tác trong các công trình nghiên cứu.

Trên mạng lưới này, các thuật toán **Louvain**, **Leiden** và **Fast Greedy** được áp dụng để phát hiện cộng đồng, đồng thời các chỉ số **centrality** như *Degree*, *Betweenness*, *Closeness* và *Eigenvector* được tính toán nhằm xác định những cá nhân có mức độ ảnh hưởng lớn.

Mục tiêu chính của đề tài là:

- Xây dựng mô hình mạng đồng tác giả trong lĩnh vực Data Science từ dữ liệu thực tế.
- Áp dụng các thuật toán phát hiện cộng đồng để tìm ra các nhóm hợp tác nổi bật.
- Phân tích vai trò và mức độ ảnh hưởng của các nhà nghiên cứu trong mạng lưới thông qua các chỉ số centrality.
- Đưa ra nhận xét, trực quan hóa và đánh giá hiệu quả của các thuật toán được sử dụng.

Kết quả nghiên cứu không chỉ góp phần cung cấp cái nhìn tổng quan về **cấu trúc hợp tác học thuật trong lĩnh vực Data Science**, mà còn mở ra hướng ứng dụng tiềm năng của các kỹ thuật phân tích mạng trong việc định hướng chính sách nghiên cứu, phát hiện nhóm chuyên môn mới và thúc đẩy sự hợp tác khoa học trong tương lai.

II. CÁC NGHIÊN CỨU LIÊN QUAN

A. Mạng đồng tác giả và nguồn dữ liệu học thuật

Mạng đồng tác giả (co-author network) là lớp đồ thị trong đó mỗi nút là một tác giả và cạnh biểu diễn mối quan hệ hợp tác khi hai tác giả cùng công bố ít nhất một công trình. Nhiều nghiên cứu nền tảng đã chỉ ra cấu trúc cộng đồng và tính phân cụm mạnh của các mạng khoa học, cũng như vai trò của các cá nhân cầu nối trong việc lan truyền tri thức [1] [2].

Gần đây, các cơ sở dữ liệu học thuật mở như **OpenAlex** cho phép truy cập quy mô lớn tới thông tin bài báo, tác giả, chủ đề và quan hệ trích dẫn hợp tác, giúp việc tái lập và mở rộng nghiên cứu trở nên khả thi hơn [3].

B. Phát hiện cộng đồng dựa trên modularity

Một hướng tiếp cận kinh điển trong phát hiện cộng đồng là tối ưu *modularity* Q [4], [5]:

$$Q = \frac{1}{2m} \sum_{ij} \left(A_{ij} - \frac{k_i k_j}{2m} \right) \delta(c_i, c_j),$$

trong đó A_{ij} là phần tử của ma trận kề, k_i và k_j lần lượt là bậc của các nút i và j , m là tổng số cạnh trong mạng, và $\delta(c_i, c_j)$ bằng 1 nếu hai nút thuộc cùng một cộng đồng, ngược lại bằng 0.

Thuật toán **Louvain** [6] tối ưu chỉ số modularity thông qua hai giai đoạn lặp lại: (i) di chuyển từng nút đến cộng đồng lân cận sao cho giá trị Q tăng lớn nhất, và (ii) gom các cộng đồng lại thành một siêu đồ thị (coarsening) rồi tiếp tục quá trình trên cho đến khi không còn cải thiện được modularity. Nhờ cách tiếp cận này, Louvain đạt hiệu năng rất cao và xử lý được mạng có hàng triệu nút. Tuy nhiên, thuật toán vẫn gặp hạn chế gọi là *resolution limit*, khiến một số cộng đồng nhỏ có thể bị gộp sai vào cộng đồng lớn hơn.

Thuật toán **Leiden** [7] được phát triển nhằm khắc phục nhược điểm này bằng cách bổ sung bước tinh chỉnh đảm bảo các cộng đồng thu được luôn *liên kết chặt chẽ* (well-connected). Phương pháp này giúp giảm hiện tượng cộng đồng rời rạc và cải thiện tính ổn định của kết quả. Trong nhiều thực nghiệm, Leiden thường cho giá trị modularity Q cao hơn hoặc tương đương Louvain, đồng thời tạo ra các ranh giới cộng đồng rõ ràng và hợp lý hơn.

C. Phân cấp tham lam (Fast Greedy)

Thuật toán **Fast Greedy** (Clauset–Newman–Moore) [8] tiến hành gom cụm phân cấp từ dưới lên (agglomerative), mỗi bước trộn hai cụm làm tăng ΔQ nhiều nhất. Dù độ phức tạp có thể nhỉnh hơn cho đồ thị rất lớn, Fast Greedy thường cho kết quả cạnh tranh và dễ diễn giải do sinh ra cây phân cấp (dendrogram) của cấu trúc cộng đồng.

D. Các chỉ số trung tâm (centrality) trong mạng khoa học

Để nhận diện tác giả ảnh hưởng, các chỉ số trung tâm được dùng rộng rãi: **degree** (mức kết nối trực tiếp), **betweenness** (mức độ làm cầu nối trên các đường đi ngắn), **closeness** (độ gần trung bình đến phần còn lại của mạng), và **eigenvector centrality** (ảnh hưởng lan truyền) [9]–[12]. Trong mạng đồng tác giả, các tác giả có betweenness cao thường đóng vai trò kết nối các nhóm chuyên môn khác nhau; eigenvector cao gắn với tầm ảnh hưởng trong các khu vực giàu liên kết.

E. Đánh giá, trực quan hoá và thực hành tốt

Chất lượng phân hoạch thường được đánh giá bằng **modularity** và các thước đo cấu trúc như *coverage*, *conductance*. Khi có nhãn tham chiếu (ví dụ, nhóm trường phái hoặc chủ đề), có thể dùng **NMI** hoặc **ARI** để so sánh [13]. Về trực quan hoá, các kỹ thuật bố trí lực (force-directed) kết hợp tô màu theo cộng đồng giúp diễn giải nhanh cấu trúc đồng thời bảng xếp hạng centrality hỗ trợ nêu bật các tác giả then chốt.

F. Tổng hợp và khoảng trống nghiên cứu

Tổng quan cho thấy Louvain và Leiden là hai chuẩn mực hiện nay cho phát hiện cộng đồng dựa trên modularity ở quy mô lớn Fast Greedy hữu ích khi cần cây phân cấp để phân tích đa mức. Tuy vậy, các nghiên cứu gần đây khuyến nghị **kết hợp phát hiện cộng đồng với phân tích centrality** để vừa thấy cấu trúc nhóm, vừa hiểu vai trò của cá nhân, đặc biệt trong mạng khoa học nơi các “cầu nối” ảnh hưởng mạnh đến lan toả tri thức. Khoảng trống còn lại là các nghiên cứu *tái lập* (reproducible) trên nguồn mở như OpenAlex, tập trung riêng vào lĩnh vực Data Science tại bối cảnh Việt Nam đây chính là hướng bài báo này theo đuổi.

III. PHƯƠNG PHÁP NGHIÊN CỨU

Phần này trình bày quy trình và các phương pháp được sử dụng để xây dựng mạng đồng tác giả và phát hiện nhóm hợp tác trong lĩnh vực Khoa học Dữ liệu (Data Science). Quy trình nghiên cứu được triển khai qua năm giai đoạn chính: (1) Thu thập và tiền xử lý dữ liệu, (2) Xây dựng mạng đồng tác giả, (3) Phát hiện cộng đồng, (4) Phân tích trung tâm, và (5) Trực quan hóa kết quả.

A. Thu thập và tiền xử lý dữ liệu

Nguồn dữ liệu được sử dụng là cơ sở dữ liệu học thuật mở **OpenAlex**, cho phép truy cập thông tin công bố khoa học gồm bài báo, tác giả, năm xuất bản, chủ đề và trích dẫn. Dữ liệu được thu thập tự động thông qua OpenAlex API, tập trung vào các bài báo thuộc lĩnh vực **Data Science, Machine Learning** và **Artificial Intelligence**.

Quy trình xử lý dữ liệu gồm năm bước:

- 1) **Xác định nguồn dữ liệu:** Chọn cơ sở dữ liệu OpenAlex và xác định truy vấn phù hợp với lĩnh vực Khoa học Dữ liệu.
- 2) **Thu thập dữ liệu thô:** Lấy dữ liệu qua API, bao gồm các trường *Work_ID, Title, Year, Cited_by, Authors, Author_IDs, Concepts*.
- 3) **Làm sạch và chuẩn hoá:** Loại bỏ bản ghi trùng lặp, xử lý giá trị thiếu, tách danh sách tác giả và mã tác giả, định dạng thống nhất các giá trị văn bản và số.
- 4) **Tạo cấu trúc mạng:** Chuyển dữ liệu bài báo thành các cặp hợp tác giữa tác giả đồng công bố, tạo danh sách cạnh (edges) thể hiện mối quan hệ hợp tác.
- 5) **Lưu trữ dữ liệu:** Lưu kết quả xử lý dưới dạng bảng gồm thông tin tác giả (nodes) và mối quan hệ hợp tác (edges) để sử dụng cho các bước phân tích tiếp theo.

B. Xây dựng mạng đồng tác giả

Từ tập dữ liệu đã xử lý, mạng đồng tác giả được xây dựng bằng thư viện **NetworkX** trong Python. Đồ thị $G = (V, E)$ được định nghĩa như sau:

- Mỗi nút $v \in V$ biểu diễn một tác giả.
- Hai nút i và j được nối bởi một cạnh $e_{ij} \in E$ nếu họ cùng là đồng tác giả của ít nhất một công trình.
- Trọng số cạnh w_{ij} thể hiện số lượng bài báo mà hai tác giả cùng hợp tác.

Các đặc trưng cơ bản của mạng như *số lượng nút, số cạnh, mật độ, bậc trung bình, hệ số phân cụm* được tính toán để mô tả quy mô và mức độ kết nối của cộng đồng nghiên cứu.

C. Phát hiện cộng đồng

Để xác định các nhóm hợp tác trong mạng, ba thuật toán phát hiện cộng đồng phổ biến được áp dụng gồm:

- **Louvain:** tối ưu hoá chỉ số *modularity* Q bằng cách di chuyển cục bộ từng nút và gom cụm lặp lại cho đến khi hội tụ.
- **Leiden:** cải tiến từ Louvain bằng cách bổ sung giai đoạn tinh chỉnh (*refinement*) nhằm đảm bảo các cộng đồng được kết nối chặt chẽ hơn.
- **Fast Greedy (Clauset–Newman–Moore):** phương pháp phân cấp, hợp nhất các cụm để tăng modularity tối đa qua từng bước, hình thành cấu trúc phân cấp (*dendrogram*) của mạng.

Chỉ số **modularity** Q được sử dụng để đánh giá chất lượng phân cụm, được xác định theo công thức:

$$Q = \frac{1}{2m} \sum_{ij} \left(A_{ij} - \frac{k_i k_j}{2m} \right) \delta(c_i, c_j),$$

trong đó A_{ij} là ma trận kề, k_i và k_j là bậc của các nút i, j , m là tổng số cạnh, và $\delta(c_i, c_j)$ bằng 1 nếu hai nút cùng cộng đồng.

Kết quả các thuật toán được so sánh dựa trên các chỉ số:

- **Modularity (Q)** đánh giá độ tách biệt của các cộng đồng.
- **Normalized Mutual Information (NMI)** đo mức tương đồng giữa các kết quả phân cụm.
- **Adjusted Rand Index (ARI)** phản ánh độ chính xác của việc gán nhãn cộng đồng.

D. Phân tích trung tâm trong mạng

Sau khi phát hiện cộng đồng, các chỉ số trung tâm (centrality) được tính để xác định vai trò và tầm ảnh hưởng của từng tác giả trong mạng:

- **Degree Centrality:** Đo mức độ kết nối trực tiếp.
- **Betweenness Centrality:** Phản ánh vai trò cầu nối giữa các nhóm khác nhau.
- **Closeness Centrality:** Biểu thị khả năng tiếp cận đến các nút khác trong mạng.
- **Eigenvector Centrality:** Đo lường tầm ảnh hưởng toàn cục thông qua liên kết với các tác giả có ảnh hưởng cao.

Các chỉ số này giúp nhận diện những cá nhân có vai trò then chốt trong cộng đồng, cũng như các tác giả kết nối giữa các nhóm nghiên cứu khác nhau.

E. Trực quan hoá kết quả


Mạng đồng tác giả và các cộng đồng được trực quan hoá bằng thư viện **NetworkX** và **Matplotlib**. Trong đó:

- Mỗi cộng đồng được gán màu sắc riêng biệt.
- Kích thước nút phản ánh chỉ số ảnh hưởng (Degree hoặc Eigenvector Centrality).
- Các cạnh thể hiện tần suất hợp tác giữa các tác giả.

Việc trực quan hoá giúp quan sát rõ cấu trúc hợp tác, xác định các nhóm nghiên cứu nổi bật và tác giả có ảnh hưởng trung tâm trong mạng, qua đó hỗ trợ phân tích sâu hơn về cấu trúc và động lực cộng tác trong lĩnh vực Khoa học Dữ liệu.

F. Quy trình nghiên cứu tổng quan

Toàn bộ quy trình nghiên cứu được thực hiện qua nhiều giai đoạn liên tiếp, từ thu thập dữ liệu, tiền xử lý, xây dựng mạng đồng tác giả, đến phát hiện cộng đồng và phân tích các chỉ số trung tâm. Quy trình này được minh họa trong Hình 1.



Hình 1. Quy trình tổng quan của nghiên cứu phát hiện và phân tích cộng đồng trong mạng đồng tác giả.

IV. XÂY DỰNG VÀ CHUẨN BỊ DỮ LIỆU

A. Tập dữ liệu

Tập dữ liệu được thu thập từ cơ sở dữ liệu học thuật mở **OpenAlex**, một nền tảng cung cấp thông tin khoa học toàn cầu bao gồm bài báo, tác giả, tổ chức, trích dẫn và chủ đề nghiên cứu. Nghiên cứu tập trung vào lĩnh vực **Khoa học Dữ liệu (Data Science)**, với mục tiêu thu thập dữ liệu về các công trình và tác giả.

Quá trình thu thập dữ liệu được thực hiện tự động thông qua **OpenAlex API**, sử dụng mã lĩnh vực C2522767166 đại diện cho Data Science. Kết quả thu được khoảng **2.400 công trình khoa học** có liên quan trực tiếp đến chủ đề nghiên cứu. Mỗi bản ghi (work) trong dữ liệu bao gồm các trường thông tin sau:

- **Work_ID:** Mã định danh duy nhất của bài báo.
- **Title:** Tiêu đề công trình.
- **Year:** Năm công bố.
- **Cited_by:** Số lượng trích dẫn.
- **Authors / Author_IDs:** Danh sách tác giả và mã định danh tương ứng.
- **Concepts:** Danh sách các chủ đề học thuật liên quan.

Dữ liệu sau khi thu thập được làm sạch và chuẩn hoá theo các bước sau:

- Loại bỏ các bản ghi trùng lặp theo mã **Work_ID** và tiêu đề **Title**.
- Xử lý các giá trị thiếu ở các trường quan trọng như **Authors**, **Author_IDs** và **Year**.
- Chuẩn hoá danh sách tác giả bằng cách tách tên theo dấu “;”, loại bỏ khoảng trắng thừa và định dạng lại chữ viết hoa.
- Chuẩn hoá mã tác giả (**Author_IDs**) bằng cách trích xuất từ đường dẫn OpenAlex (<https://openalex.org/Axxxxxx>) để thu được định dạng ngắn gọn.

- Lọc giữ lại các bài có chủ đề thuộc lĩnh vực **Data Science, Machine Learning** hoặc **Artificial Intelligence**.
- Chuyển các trường `Cited_by` và `Year` sang kiểu số để đảm bảo tính nhất quán khi phân tích.

Bảng I
MỘT PHẦN DỮ LIỆU ĐÃ ĐƯỢC LÀM SẠCH VÀ CHUẨN HOÁ TỪ CƠ SỞ OPENALEX

Work_ID	Title	Year	Cited_by	Authors	Author_IDs
W2144634347	Molecular Cloning: A Laboratory Manual	2001	133517	Joseph Sambrook; Elisabeth Fritsch; Tom Maniatis	A5112152140; A5047742196; A5091116725
W4300870773	Statistical Power Analysis for the Behavioral Sciences	1989	83956	Keith E. Muller; Jacob Cohen	A5110163574; A5102808166
W1658908529	Basics of qualitative research: techniques and procedures for developing grounded theory	1998	39197	Anselm L. Strauss; Juliet Corbin	A5108677812; A5002394578

B. Xây dựng mạng đồng tác giả

Dựa trên dữ liệu đã được làm sạch, nhóm nghiên cứu tiến hành xây dựng **mạng đồng tác giả (co-author network)** bằng thư viện **NetworkX** trong Python. Mạng được biểu diễn dưới dạng đồ thị vô hướng $G = (V, E)$, trong đó:

- Mỗi **nút (node)** $v \in V$ đại diện cho một tác giả.
- Hai **nút được nối (edge)** nếu hai tác giả cùng là đồng tác giả của ít nhất một bài báo.
- **Trọng số cạnh (weight)** w_{ij} thể hiện số lượng bài báo mà hai tác giả cùng hợp tác.

Các chỉ số đặc trưng của mạng bao gồm: **Số lượng nút, số cạnh, mật độ (Density), bậc trung bình (Average Degree), và hệ số phân cụm (Clustering Coefficient)**. Những chỉ số này giúp đánh giá quy mô, mức độ gắn kết và cấu trúc hợp tác của cộng đồng nghiên cứu trong lĩnh vực Khoa học Dữ liệu.

Bảng II
CÁC CHỈ SỐ THỐNG KÊ CƠ BẢN CỦA MẠNG ĐỒNG TÁC GIẢ TRONG LĨNH VỰC KHOA HỌC DỮ LIỆU

Số nút (Nodes)	Số cạnh (Edges)	Mật độ (Density)	Bậc trung bình (Average Degree)	Hệ số phân cụm (Clustering Coefficient)
9,212	136,198	0.0032	29.57	0.8608

C. So sánh các mô hình cơ sở

Sau khi xây dựng mạng, nhóm nghiên cứu áp dụng ba thuật toán phát hiện cộng đồng phổ biến để xác định các nhóm hợp tác chính trong mạng đồng tác giả:

- **Louvain:** Tối ưu hoá chỉ số modularity bằng cách gom cụm lặp lại cho đến khi hội tụ.
- **Leiden:** Phiên bản cải tiến của Louvain, đảm bảo các cộng đồng được kết nối chặt chẽ và ổn định hơn.
- **Fast Greedy (Clauset–Newman–Moore):** Phương pháp phân cấp, hợp nhất các cụm sao cho tăng modularity nhiều nhất.

Hiệu quả của từng thuật toán được đánh giá thông qua các chỉ số:

- **Modularity (Q)** đo lường mức độ tách biệt giữa các cộng đồng.
- **Normalized Mutual Information (NMI)** đánh giá sự tương đồng giữa các kết quả phân cụm.
- **Adjusted Rand Index (ARI)** đo độ chính xác so với cấu trúc tham chiếu.

Kết quả được trực quan hoá bằng **NetworkX** và **Matplotlib**. Các cộng đồng được tô màu khác nhau để thể hiện ranh giới, trong khi các tác giả có chỉ số trung tâm cao (*Degree* hoặc *Eigenvector Centrality*) được làm nổi bật, thể hiện vai trò then chốt trong mạng hợp tác khoa học.

V. THỰC NGHIỆM VÀ ĐÁNH GIÁ


A. Cấu hình và môi trường thực nghiệm

Các thí nghiệm được thực hiện bằng ngôn ngữ **Python 3.10** với các thư viện **NetworkX, community-louvain, Matplotlib, Pandas** và **NumPy**. Hệ thống thử nghiệm gồm **CPU Intel Core i7, RAM 16GB** và hệ điều hành **Windows 11**.

Mạng đồng tác giả thu được có quy mô **9.212 nút** và **136.198 cạnh**, với mật độ 0.0032 và hệ số phân cụm trung bình 0.8608. Đây là một mạng lớn, thưa (sparse) nhưng có tính liên kết chặt chẽ nội bộ, phản ánh đặc trưng của các nhóm nghiên cứu trong lĩnh vực Khoa học Dữ liệu.

Hình 2 minh họa mạng đồng tác giả gồm 2000 nhà nghiên cứu đầu tiên được trích xuất từ dữ liệu OpenAlex, thể hiện sự phân bố và mức độ kết nối giữa các tác giả trong lĩnh vực Khoa học Dữ liệu.

Mối liên kết hợp tác giữa 2000 tác giả đầu tiên



Hình 2. Mối liên kết hợp tác giữa 2000 tác giả đầu tiên trong tập dữ liệu.


B. Kết quả phát hiện cộng đồng

Ba thuật toán được áp dụng gồm **Louvain**, **Leiden** và **Fast Greedy**. Kết quả cho thấy các thuật toán đều đạt giá trị modularity cao ($Q > 0.93$), chứng tỏ mạng có cấu trúc cộng đồng rõ rệt.

Bảng III
SO SÁNH KẾT QUẢ GIỮA CÁC THUẬT TOÁN PHÁT HIỆN CỘNG ĐỒNG

Thuật toán	Số cộng đồng	Modularity (Q)
Louvain	1,167	0.9416
Leiden	1,167	0.9418
Fast Greedy	1,164	0.9344

Hình 3 minh họa giá trị **Modularity**, **NMI** và **ARI** giữa các thuật toán. Ta thấy Leiden đạt modularity cao nhất, trong khi Louvain và Fast Greedy cho kết quả tương đồng, chênh lệch không đáng kể.



Hình 3. So sánh các chỉ số Modularity, NMI và ARI giữa các thuật toán.

C. Phân tích mức tương đồng giữa các thuật toán

Để đánh giá độ tương đồng giữa các phân hoạch, hai chỉ số **Normalized Mutual Information (NMI)** và **Adjusted Rand Index (ARI)** được sử dụng.


Bảng IV
ĐÁNH GIÁ MỨC TƯƠNG ĐỒNG GIỮA CÁC THUẬT TOÁN PHÁT HIỆN CỘNG ĐỒNG

Cặp thuật toán	NMI	ARI
Louvain - Leiden	0.8004	0.2263
Louvain - Fast Greedy	0.7971	0.2146
Leiden - Fast Greedy	0.9909	0.9119

Hai thuật toán **Leiden** và **Fast Greedy** cho ra kết quả gần như trùng khớp ($NMI = 0.99$, $ARI = 0.91$), chứng tỏ hai phương pháp này phân hoạch mạng gần như tương đương. Louvain khác biệt nhẹ do chiến lược tối ưu hoá modularity cục bộ, nhưng vẫn duy trì mức tương đồng cao ($NMI = 0.8$).

D. Cấu trúc cộng đồng và trực quan hóa

Mặc dù tổng cộng có hơn 1.100 cộng đồng, nhưng các cộng đồng lớn chiếm phần lớn số lượng tác giả. Hình 4 trực quan hóa **10 cộng đồng lớn nhất** theo thuật toán Leiden.




Hình 4. 10 cộng đồng lớn nhất trong mạng đồng tác giả.

Các cộng đồng này có quy mô từ 139 đến 345 tác giả, tương ứng với các nhóm nghiên cứu hoặc phòng thí nghiệm lớn trong lĩnh vực học máy, khai phá dữ liệu và trí tuệ nhân tạo. Cấu trúc cho thấy các cộng đồng liên kết chặt chẽ nội bộ và chỉ có một số cạnh kết nối giữa các nhóm phản ánh rõ nét tính chuyên biệt của từng hướng nghiên cứu.

E. Phân tích chỉ số trung tâm (Centrality Analysis)

Để nhận diện các tác giả có tầm ảnh hưởng lớn, bốn chỉ số trung tâm được tính toán gồm **Degree**, **Betweenness**, **Closeness** và **Eigenvector Centrality**. Các biểu đồ Hình 5, 6, 7, 8 minh họa top 10 tác giả theo từng chỉ số.

Top 10 Degree Centrality




Hình 5. Top 10 tác giả có chỉ số Degree Centrality cao nhất.

Hình 5 minh họa **10 tác giả có chỉ số Degree Centrality cao nhất** trong mạng đồng tác giả, tức là những người có **số lượng kết nối trực tiếp với đồng nghiệp nhiều nhất**. Các tác giả như *Michelle Giglio*, *Ricardo Silva*, *Pascale Gaudet* và *Andrés Mauricio Carballo-Rodríguez* nổi bật với các nút màu đỏ đậm, thể hiện mức độ hợp tác dày đặc và phạm vi ảnh hưởng rộng.

Những cá nhân này không chỉ thường xuyên xuất hiện trong nhiều công trình hợp tác, mà còn đóng vai trò trung tâm trong việc **kết nối các nhóm nghiên cứu khác nhau**, giúp dòng chảy tri thức lan tỏa nhanh hơn trong mạng học thuật. Trong khi đó, một số tác giả như *Robert S. Fultz* hay *Asif Chinyavalla* nằm ở rìa mạng, có mức độ kết nối thấp hơn, chủ yếu hợp tác trong phạm vi một nhóm nhất định.

Kết quả phân tích cho thấy mạng đồng tác giả trong lĩnh vực **Khoa học Dữ liệu** mang cấu trúc **tập trung**, trong đó một nhóm nhỏ các nhà nghiên cứu hoạt động sôi nổi giữ vai trò như những “đầu mối” kết nối, giúp duy trì và mở rộng mối quan hệ hợp tác giữa các cộng đồng học thuật.

Top 10 Betweenness Centrality




Hình 6. Top 10 tác giả có chỉ số Betweenness Centrality cao nhất.

Hình 6 minh họa **10 tác giả có chỉ số Betweenness Centrality cao nhất** trong mạng đồng tác giả, phản ánh mức độ **ảnh hưởng trung gian** của họ trong việc kết nối giữa các cụm nghiên cứu khác nhau.

Kết quả cho thấy *John P. A. Ioannidis* có chỉ số cao nhất, nằm ở trung tâm và được tô màu đỏ đậm, thể hiện vai trò **cầu nối quan trọng nhất** của toàn mạng. Các tác giả *Susan Holmes*, *Gad Getz* và *Jill P. Mesirov* lần lượt giữ các vị trí tiếp theo, đóng vai trò liên kết các cụm học giả riêng biệt, giúp dòng chảy thông tin và hợp tác diễn ra xuyên suốt trong mạng lưới. Trong khi, *Curtis Huttenhower*, *Elaine R. Mardis* và các tác giả ở rìa như *Lucia A. Hindorff* hay *Wolfgang H.* có chỉ số thấp hơn, cho thấy họ chủ yếu hoạt động trong các nhóm hợp tác nhỏ, ít khi đóng vai trò trung gian giữa các cộng đồng lớn.

Phân tích Betweenness Centrality chỉ ra rằng mạng hợp tác trong lĩnh vực **Khoa học Dữ liệu** được duy trì bởi một số ít học giả có tầm ảnh hưởng cao, đóng vai trò **kết nối các cụm nghiên cứu độc lập** và thúc đẩy **sự lan tỏa tri thức** trong toàn bộ hệ sinh thái nghiên cứu.




Hình 7. Top 10 tác giả có chỉ số Closeness Centrality cao nhất.

Hình 7 trình bày **10 tác giả có chỉ số Closeness Centrality cao nhất**, phản ánh mức độ **gần gũi trung bình của mỗi tác giả tới các nút khác** trong toàn mạng lưới hợp tác. Các giá trị closeness cao cho thấy những nhà nghiên cứu này có khả năng tiếp cận và lan tỏa thông tin nhanh chóng trong mạng.

Trong đó, các tác giả *Asif Chinyavalla*, *Sandra W. Clifton* và *Robert S. Fulton* nổi bật với màu đỏ đậm nhất, biểu thị vị trí trung tâm có khoảng cách ngắn nhất đến phần lớn các tác giả khác. Các nhà nghiên cứu như *Curtis Huttenhower*, *Eric J. Alm* và *Barbara A. Methé* cũng có closeness tương đối cao, đóng vai trò như các “điểm trung chuyển” giúp kết nối nhanh giữa các cụm hợp tác. Ngược lại, những tác giả nằm ở rìa mạng như *Daniel Barrell* hay *Michelle Giglio* có giá trị closeness thấp hơn, cho thấy họ chủ yếu hoạt động trong phạm vi nhóm hẹp và ít liên kết với các cộng đồng khác.

Tổng thể, phân tích Closeness Centrality cho thấy mạng hợp tác trong lĩnh vực **Khoa học Dữ liệu** có cấu trúc **liên thông hiệu quả**, trong đó một số tác giả đóng vai trò trọng tâm giúp **rút ngắn khoảng cách tri thức** và **tăng tốc độ lan tỏa thông tin** giữa các cộng đồng nghiên cứu.



Hình 8. Top 10 tác giả có chỉ số Eigenvector Centrality cao nhất.

Hình 8 mô tả **10 tác giả có chỉ số Eigenvector Centrality cao nhất**, thể hiện mức độ **ảnh hưởng toàn cục** trong mạng đồng tác giả. Khác với Degree Centrality chỉ xét số lượng kết nối trực tiếp, Eigenvector Centrality đánh giá cả *chất lượng của mỗi liên kết*, nghĩa là một tác giả có ảnh hưởng nếu họ được kết nối với những cá nhân cũng có tầm ảnh hưởng cao.

Từ hình có thể thấy *Chris Mungall* là tác giả nổi bật nhất, nằm ở trung tâm mạng lưới và có chỉ số cao nhất, cho thấy vai trò như **trục lan tỏa thông tin** của toàn hệ thống. Bao quanh ông là những cộng sự có sức ảnh hưởng đáng kể như *Karen Christie*, *Judith A. Blake*, *Valerie Wood* và *Rex L. Chisholm*, tạo thành một cụm hợp tác bền chặt với mật độ liên kết cao. Các tác giả này không chỉ kết nối chặt chẽ với Mungall mà còn duy trì quan hệ hợp tác chéo lẫn nhau, giúp hình thành một **mạng lõi học thuật ổn định**.

Nhìn tổng thể, chỉ số Eigenvector Centrality phản ánh rõ nét **cấu trúc trung tâm liên kết mạnh** của mạng nghiên cứu trong lĩnh vực **Khoa học Dữ liệu**, nơi một số tác giả giữ vai trò dẫn dắt và củng cố tính gắn kết của toàn bộ cộng đồng hợp tác.

Kết quả phân tích các chỉ số trung tâm cho thấy:

- **Betweenness Centrality:** Các tác giả như *John P. Ioannidis*, *Curtis Huttenhower* và *Susan Holmes* giữ vai trò **cầu nối quan trọng** giữa các nhóm nghiên cứu khác nhau. Họ giúp luân chuyển tri thức và kết nối các cụm học thuật vốn tách biệt, đóng vai trò như những “điểm trung gian chiến lược” trong toàn mạng.
- **Closeness Centrality:** Những tác giả có chỉ số closeness cao thường xuất hiện ở **vị trí trung tâm của cộng đồng**, có khả năng tiếp cận nhanh đến các thành viên khác trong mạng. Điều này cho thấy họ có vai trò then chốt trong việc truyền tải thông tin và duy trì sự gắn kết giữa các nhóm hợp tác.
- **Eigenvector Centrality:** Các tác giả như *Chris Mungall* và *Karen Christie* nổi bật với mạng lưới liên kết mật thiết cùng nhiều nhà nghiên cứu có ảnh hưởng cao khác, hình thành nên **“cụm hạt nhân”** của toàn hệ thống hợp tác. Họ là những cá nhân có khả năng tác động lan tỏa mạnh đến cấu trúc chung của mạng khoa học.

F. Thảo luận kết quả

Các kết quả thực nghiệm cho thấy mạng đồng tác giả trong lĩnh vực **Khoa học Dữ liệu** có cấu trúc cộng đồng rõ ràng và tính gắn kết cao. Giá trị **modularity** đạt khoảng $Q \approx 0.94$ chứng minh rằng các nhóm nghiên cứu được hình thành một cách tự nhiên, với mật độ liên kết nội bộ lớn và chỉ có ít kết nối giữa các cộng đồng khác nhau.

Thuật toán **Leiden** thể hiện hiệu suất ổn định nhất, đặc biệt khi xử lý mạng có quy mô lớn nhờ khả năng tinh chỉnh cộng đồng giúp đảm bảo tính liên kết chặt chẽ. Trong khi đó, **Fast Greedy** có ưu điểm về tốc độ và khả năng khái quát nhanh cấu trúc phân cấp, dù giá trị modularity thấp hơn đôi chút so với Leiden. Kết quả này cho thấy mỗi phương pháp có thể mạnh riêng Leiden phù hợp cho đánh giá chi tiết, còn Fast Greedy thích hợp trong các bài toán cần tối ưu thời gian tính toán.

Cấu trúc mạng thể hiện sự **đa dạng về chủ đề và hướng nghiên cứu**, với hàng nghìn cộng đồng quy mô nhỏ phản ánh sự phân hóa của các chuyên ngành trong Data Science như học máy, khai phá dữ liệu, và trí tuệ nhân tạo. Đặc biệt, các tác giả có chỉ số **Betweenness Centrality** cao đóng vai trò như những “cầu nối tri thức”, giúp kết nối các cụm nghiên cứu độc lập, từ đó hình thành mạng hợp tác mang tính **đa ngành và liên lĩnh vực**.

Tổng thể, kết quả nghiên cứu khẳng định tính hiệu quả của việc kết hợp **phát hiện cộng đồng** và **phân tích trung tâm** trong việc khám phá cấu trúc hợp tác khoa học. Thông qua trực quan hóa mạng, có thể nhận diện rõ **những nhóm nghiên cứu lớn, các tác giả chủ chốt và mối quan hệ liên kết giữa các hướng nghiên cứu**, góp phần mang lại cái nhìn toàn diện hơn về hệ sinh thái học thuật trong lĩnh vực Khoa học Dữ liệu.

VI. THẢO LUẬN

Kết quả phân tích mạng đồng tác giả trong lĩnh vực **Khoa học Dữ liệu** cho thấy hệ thống hợp tác giữa các nhà nghiên cứu được tổ chức chặt chẽ và có tính phân tầng cao. Giá trị modularity lớn ($Q > 0.93$) phản ánh rõ sự tồn tại của các nhóm hợp tác ổn định, hình thành dựa trên định hướng học thuật, lĩnh vực chuyên sâu và mối liên hệ nghề nghiệp lâu dài. Phần này thảo luận sâu hơn về những phát hiện, ý nghĩa và hướng ứng dụng thực tiễn của nghiên cứu.

A. Cấu trúc hợp tác và ý nghĩa học thuật

Các kết quả cho thấy mạng đồng tác giả trong lĩnh vực Khoa học Dữ liệu có xu hướng hình thành theo mô hình **trung tâm-vệ tinh (hub-spoke)**. Một số cộng đồng lớn giữ vai trò “hạt nhân tri thức”, nơi tập trung các nhóm chuyên sâu về *Machine Learning*, *Data Mining* hay *Artificial Intelligence*. Các nhóm nhỏ hơn đóng vai trò vệ tinh, vừa học hỏi, vừa kết nối tri thức giữa các nhánh nghiên cứu khác nhau. Cấu trúc này không chỉ phản ánh quy luật hình thành tự nhiên của mạng học thuật, mà còn cho thấy sự phân hóa rõ ràng giữa các trung tâm nghiên cứu lớn và nhóm độc lập mới nổi.

B. Phân tích hiệu quả thuật toán và vai trò các cá nhân ảnh hưởng

Khi so sánh các thuật toán phát hiện cộng đồng, kết quả cho thấy **Leiden** đạt hiệu suất và độ ổn định cao nhất, phù hợp với các mạng có quy mô lớn và cấu trúc phức tạp. Điều này phù hợp với kết luận của Traag et al. [14], khẳng định khả năng tinh chỉnh cộng đồng giúp Leiden duy trì tính liên kết chặt chẽ nội bộ. Ngoài ra, việc phân tích các chỉ số trung tâm như **Degree**, **Betweenness** và **Eigenvector Centrality** giúp xác định các tác giả có tầm ảnh hưởng lớn trong mạng, đặc biệt là những người đóng vai trò cầu nối giữa các cụm nghiên cứu khác nhau. Những cá nhân này góp phần thúc đẩy sự lan tỏa tri thức và gắn kết cộng đồng học thuật theo chiều sâu.

C. Lan tỏa tri thức và định hình xu hướng nghiên cứu

Cấu trúc mạng đồng tác giả không chỉ thể hiện mối liên hệ hợp tác, mà còn phản ánh cách **tri thức được truyền đạt và khuếch tán** trong cộng đồng khoa học. Các nhóm trung tâm thường là nơi khởi phát các hướng nghiên cứu mới, công nghệ mới hoặc phương pháp luận tiên phong, trong khi các cụm vệ tinh đóng vai trò lan tỏa, mở rộng và ứng dụng kết quả. Nhờ vậy, có thể xem phát hiện cộng đồng như một công cụ để **theo dõi dòng chảy tri thức**, xác định các “điểm phát tán” và dự đoán xu hướng phát triển của lĩnh vực trong tương lai gần. Điều này đặc biệt hữu ích cho các tổ chức khoa học khi muốn định hướng chiến lược đầu tư, hợp tác và phát triển nhóm nghiên cứu tiềm năng.

D. Giới hạn và hướng mở rộng

Mặc dù kết quả mang lại nhiều giá trị, nghiên cứu hiện vẫn tập trung vào phân tích mạng tĩnh, chưa xem xét yếu tố thời gian trong quá trình hình thành và thay đổi mối quan hệ hợp tác. Trong thực tế, mạng học thuật luôn biến động các nhóm mới xuất hiện, hợp nhất hoặc tan rã theo từng giai đoạn. Vì vậy, hướng phát triển tiếp theo là mở rộng sang phân tích **mạng động (dynamic network)** để theo dõi sự tiến hóa của hệ thống nghiên cứu. Bên cạnh đó, việc tích hợp thêm thông tin về **chủ đề bài báo, trích dẫn và độ ảnh hưởng** sẽ giúp mô hình phát hiện cộng đồng phản ánh sâu hơn mối quan hệ giữa cấu trúc hợp tác và tác động khoa học. Các hướng mở này không chỉ nâng cao giá trị phân tích mà còn mở ra tiềm năng ứng dụng trong đánh giá hiệu quả và hoạch định chính sách khoa học.

Phần thảo luận cho thấy việc kết hợp phát hiện cộng đồng và phân tích trung tâm mang lại một góc nhìn toàn diện hơn về cách tri thức được hình thành, duy trì và lan tỏa trong lĩnh vực Khoa học Dữ liệu. Đây không chỉ là công cụ mô tả mạng lưới hợp tác, mà còn là nền tảng cho việc dự đoán xu hướng, định hướng chiến lược và phát triển cộng đồng khoa học trong tương lai.

VII. KẾT LUẬN

Nghiên cứu đã tiến hành xây dựng và phân tích mạng lưới tác giả trong lĩnh vực **Khoa học Dữ liệu** dựa trên dữ liệu OpenAlex, qua đó làm rõ cách các nhà khoa học hình thành mối quan hệ chuyên môn và chia sẻ tri thức. Kết quả cho thấy cấu trúc mạng có tính phân cụm cao, với chỉ số modularity đạt gần 0.94, thể hiện sự tồn tại của những nhóm nghiên cứu có tính gắn kết mạnh và ranh giới rõ rệt. Thuật toán **Leiden** cho hiệu quả ổn định và khả năng tối ưu vượt trội, trong khi **Fast Greedy** tỏ ra linh hoạt và tiết kiệm thời gian xử lý.

Phân tích các chỉ số trung tâm cho thấy một số tác giả giữ vai trò trọng yếu trong việc lan truyền thông tin và kết nối giữa các nhóm, tiêu biểu là *John P. Ioannidis*, *Chris Mungall* và *Curtis Huttenhower*. Những cá nhân này không chỉ là đầu mối giao thoa giữa các hướng nghiên cứu, mà còn góp phần duy trì sự liên thông của toàn bộ mạng học thuật trong lĩnh vực khoa học dữ liệu.

Nhìn tổng thể, công trình này mang lại cái nhìn trực quan về cấu trúc cộng tác học thuật, đồng thời chứng minh tiềm năng của việc kết hợp các phương pháp phát hiện cộng đồng với phân tích chỉ số trung tâm trong việc khám phá đặc trưng của mạng phức tạp. Kết quả thu được có thể làm nền tảng cho nhiều ứng dụng tiếp theo, như dự báo mối quan hệ hợp tác mới, đánh giá mức độ ảnh hưởng của từng tác giả, hoặc theo dõi sự phát triển của các hướng nghiên cứu theo thời gian.

Trong tương lai, có thể mở rộng hướng tiếp cận bằng cách tích hợp thêm dữ liệu động theo giai đoạn hoặc sử dụng các kỹ thuật học sâu trên đồ thị như **Graph Neural Networks (GNNs)** để tăng khả năng biểu diễn và dự đoán cấu trúc mạng. Bên cạnh đó, việc phân tích ở nhiều lĩnh vực khoa học khác nhau sẽ giúp kiểm chứng khả năng tổng quát và ứng dụng thực tiễn của phương pháp.

TÀI LIỆU THAM KHẢO

- [1] M. E. J. Newman, “The structure of scientific collaboration networks,” *Proceedings of the National Academy of Sciences*, vol. 98, no. 2, pp. 404–409, 2001.
- [2] —, “Coauthorship networks and patterns of scientific collaboration,” *Proceedings of the National Academy of Sciences*, vol. 101, no. Suppl 1, pp. 5200–5205, 2004.
- [3] J. Priem, H. Piwowar, and R. Orr, “Openalex: A fully-open index of scholarly works, authors, venues, institutions, and concepts,” *arXiv preprint arXiv:2205.01833*, 2022.
- [4] M. E. J. Newman and M. Girvan, “Finding and evaluating community structure in networks,” *Physical Review E*, vol. 69, no. 2, p. 026113, 2004.
- [5] S. Fortunato, “Community detection in graphs,” *Physics Reports*, vol. 486, no. 3–5, pp. 75–174, 2010.
- [6] V. D. Blondel, J.-L. Guillaume, R. Lambiotte, and E. Lefebvre, “Fast unfolding of communities in large networks,” *Journal of Statistical Mechanics: Theory and Experiment*, vol. 2008, no. 10, p. P10008, 2008.
- [7] V. A. Traag, L. Waltman, and N. J. van Eck, “From louvain to leiden: guaranteeing well-connected communities,” *Scientific Reports*, vol. 9, p. 5233, 2019.
- [8] A. Clauset, M. E. J. Newman, and C. Moore, “Finding community structure in very large networks,” *Physical Review E*, vol. 70, no. 6, p. 066111, 2004.
- [9] L. C. Freeman, “A set of measures of centrality based on betweenness,” *Sociometry*, vol. 40, no. 1, pp. 35–41, 1977.
- [10] —, “Centrality in social networks conceptual clarification,” *Social Networks*, vol. 1, no. 3, pp. 215–239, 1978.
- [11] P. Bonacich, “Power and centrality: A family of measures,” *American Journal of Sociology*, vol. 92, no. 5, pp. 1170–1182, 1987.
- [12] M. E. J. Newman, “A measure of betweenness centrality based on random walks,” *Social Networks*, vol. 27, no. 1, pp. 39–54, 2005.
- [13] L. Danon, A. Diaz-Guilera, J. Duch, and A. Arenas, “Comparing community structure identification,” *Journal of Statistical Mechanics: Theory and Experiment*, vol. 2005, no. 09, p. P09008, 2005.
- [14] V. A. Traag, L. Waltman, and N. J. van Eck, “From louvain to leiden: guaranteeing well-connected communities,” *Scientific Reports*, vol. 9, no. 1, p. 5233, 2019.

PROJECT 1B:

DỰ ĐOÁN HỢP TÁC NGHIÊN CỨU TƯƠNG LAI VÀ KHUYẾN NGHỊ ĐỐI TÁC TRONG MẠNG LƯỚI KHOA HỌC

1st Hà Thế Anh, 2nd Nguyễn Nhật Nam, 3rd Hoàng Quang Minh
and Le Nhat Tung

HUTECH University, Vietnam

{hatheanh012004, nguyennhatnam01012004, hoangquangminh130804}@gmail.com, and lenhattung@hutech.edu.vn

TÓM TẮT NỘI DUNG

Trong bối cảnh khoa học hiện đại phát triển mạnh mẽ, việc xác định và dự đoán các mối quan hệ hợp tác giữa các nhà nghiên cứu đóng vai trò quan trọng trong việc thúc đẩy đổi mới sáng tạo và tối ưu hóa nguồn lực khoa học. Nghiên cứu này tập trung xây dựng một mô hình dự đoán hợp tác khoa học tương lai dựa trên phân tích cấu trúc mạng đồng tác giả. Dữ liệu được thu thập từ các công bố học thuật trong lĩnh vực Khoa học Dữ liệu, sau đó được biểu diễn dưới dạng đồ thị, trong đó các nút đại diện cho tác giả và các cạnh biểu thị mối quan hệ hợp tác.

Phương pháp đề xuất kết hợp các chỉ số tương đồng cổ điển như *Common Neighbors*, *Jaccard Coefficient*, *Adamic-Adar Index*, *Preferential Attachment* và *Resource Allocation* với kỹ thuật học biểu diễn đồ thị *Node2Vec* nhằm đánh giá khả năng hình thành liên kết mới giữa các nhà khoa học. Các mô hình được huấn luyện và kiểm định bằng cách tách tập dữ liệu thành phần huấn luyện (80%) và kiểm tra (20%), với việc sử dụng các chỉ số đánh giá như AUC-ROC và AUC-PR.

Kết quả thực nghiệm cho thấy các phương pháp dựa trên cấu trúc cục bộ đạt hiệu năng vượt trội với AUC xấp xỉ 1.0, chứng minh khả năng dự đoán chính xác các mối hợp tác tiềm năng trong cùng cộng đồng nghiên cứu. Trong khi đó, *Node2Vec* cho thấy tiềm năng trong việc phát hiện các mối liên kết toàn cục nhưng cần tối ưu thêm về siêu tham số. Nghiên cứu góp phần cung cấp một khung phân tích hiệu quả cho việc khuyến nghị đối tác nghiên cứu, đồng thời mở ra hướng phát triển các hệ thống gợi ý cộng tác học thuật thông minh trong tương lai.

TỪ KHÓA

Social Network Analysis, Link Prediction, Research Collaboration Recommendation, Co-author Network, Node2Vec, Machine Learning.

I. GIỚI THIỆU

Trong kỷ nguyên khoa học mở và toàn cầu hóa nghiên cứu, hợp tác giữa các nhà khoa học trở thành yếu tố then chốt thúc đẩy đổi mới sáng tạo, tăng cường năng suất công bố và mở rộng tầm ảnh hưởng học thuật. Việc hiểu rõ cấu trúc hợp tác và khả năng hình thành các mối quan hệ mới giữa các tác giả không chỉ mang giá trị học thuật mà còn giúp định hướng chính sách nghiên cứu, phân bổ nguồn lực và xây dựng mạng lưới khoa học bền vững.

Phân tích mạng đồng tác giả (Co-author Network Analysis) là một trong những hướng tiếp cận hiệu quả để khám phá mô hình hợp tác giữa các nhà nghiên cứu. Trong mạng này, các nút biểu diễn tác giả và các cạnh thể hiện mối quan hệ cộng tác thông qua các bài báo khoa học. Dựa trên cấu trúc mạng, bài toán *dự đoán liên kết* (Link Prediction) cho phép xác định khả năng hai nhà nghiên cứu sẽ hợp tác trong tương lai dựa trên các đặc trưng cấu trúc và hành vi hợp tác hiện tại.

Các phương pháp dự đoán liên kết truyền thống như *Common Neighbors*, *Jaccard Coefficient*, *Adamic-Adar*, *Preferential Attachment* hay *Resource Allocation* đã chứng minh hiệu quả trong việc nhận diện các mối quan hệ tiềm năng trong mạng xã hội. Gần đây, sự phát triển của kỹ thuật học biểu diễn đồ thị (*Graph Embedding*) như *Node2Vec* đã mở ra hướng tiếp cận mới giúp mô hình hóa không gian đặc trưng phức tạp của mạng, từ đó cải thiện khả năng dự đoán và khuyến nghị hợp tác.

Nghiên cứu này hướng tới mục tiêu xây dựng một mô hình dự đoán hợp tác nghiên cứu tương lai kết hợp giữa các chỉ số tương đồng cổ điển và kỹ thuật học biểu diễn đồ thị, từ đó khuyến nghị các đối tác tiềm năng trong mạng lưới khoa học. Cụ thể, mô hình được áp dụng trên dữ liệu mạng đồng tác giả trong lĩnh vực Khoa học Dữ liệu, với quy trình gồm các bước: Tiền xử lý dữ liệu, chia tập huấn luyện - kiểm tra, tính toán các chỉ số liên kết, huấn luyện mô hình, và đánh giá bằng các chỉ số AUC-ROC, AUC-PR.

Kết quả thu được không chỉ chứng minh hiệu quả vượt trội của các chỉ số dựa trên cấu trúc cục bộ mà còn cho thấy tiềm năng của học biểu diễn đồ thị trong việc phát hiện các mối quan hệ hợp tác toàn cục. Từ đó, nghiên cứu góp phần tạo nền tảng cho việc phát triển các hệ thống gợi ý cộng tác học thuật thông minh, hỗ trợ các nhà nghiên cứu kết nối và mở rộng mạng lưới khoa học hiệu quả hơn.

II. CÁC NGHIÊN CỨU LIÊN QUAN

A. Mạng đồng tác giả và nguồn dữ liệu học thuật

Mạng đồng tác giả (co-author network) là một dạng đồ thị trong đó mỗi nút biểu diễn một tác giả và mỗi cạnh thể hiện mối quan hệ hợp tác khi hai tác giả cùng công bố ít nhất một bài báo. Nhiều nghiên cứu đã chứng minh mạng khoa học có đặc trưng phân cụm mạnh, cấu trúc cộng đồng rõ rệt và tồn tại các cá nhân “cầu nối” đóng vai trò quan trọng trong lan truyền tri thức [1], [2]. Gần đây, các cơ sở dữ liệu học thuật mở như **OpenAlex** hay **Microsoft Academic Graph** cho phép truy cập dữ liệu quy mô lớn về bài báo, tác giả, trích dẫn và chủ đề nghiên cứu, từ đó hỗ trợ đáng kể cho việc phân tích, dự đoán và khuyến nghị hợp tác khoa học [3].

B. Bài toán dự đoán liên kết trong mạng xã hội

Giả sử đồ thị vô hướng $G = (V, E)$, trong đó V là tập các nút và E là tập các cạnh. Các phương pháp dự đoán liên kết cổ điển thường tính điểm tương đồng giữa hai nút dựa trên số lượng hàng xóm chung hoặc cấu trúc lân cận, tiêu biểu gồm **Common Neighbors (CN)**, **Jaccard Coefficient (JC)**, **Adamic-Adar Index (AA)**, **Preferential Attachment (PA)** và **Resource Allocation (RA)** [4]. Các công thức chi tiết được trình bày trong Mục III.

C. Học biểu diễn đồ thị và mô hình Node2Vec

Kỹ thuật học biểu diễn đồ thị (graph embedding) mở ra hướng tiếp cận mới cho dự đoán liên kết khi cho phép ánh xạ mỗi nút thành vector đặc trưng trong không gian liên tục, bảo toàn thông tin cấu trúc và ngữ cảnh. Các mô hình như *DeepWalk* [5] và *Node2Vec* [6] khai thác cơ chế bước đi ngẫu nhiên có trọng số để học mối quan hệ giữa các nút. Trong mạng hợp tác khoa học, *Node2Vec* được chứng minh có khả năng phát hiện các mối quan hệ tiềm ẩn vượt ra ngoài cộng đồng trực tiếp, giúp khắc phục hạn chế của các chỉ số tương đồng cục bộ.

D. Các chỉ số đánh giá và trực quan hóa

Hiệu năng của mô hình dự đoán liên kết thường được đo lường bằng các chỉ số chuẩn như **AUC-ROC** và **AUC-PR** để đánh giá khả năng phân biệt giữa các cạnh thật và cạnh giả [7]. Ngoài ra, một số nghiên cứu sử dụng Precision@K hoặc Recall@K nhằm phản ánh chất lượng khuyến nghị ở mức thực tế. Các biểu đồ ROC, PR, histogram và boxplot được sử dụng rộng rãi để minh họa phân bố điểm tương đồng, giúp so sánh trực quan hiệu quả giữa các thuật toán.

E. Đánh giá, trực quan hoá và thực hành tốt

Chất lượng phân hoạch thường được đánh giá bằng **modularity** và các thước đo cấu trúc như *coverage*, *conductance*. Khi có nhãn tham chiếu (ví dụ, nhóm trường phái hoặc chủ đề), có thể dùng **NMI** hoặc **ARI** để so sánh [8]. Về trực quan hoá, các kỹ thuật bố trí lực (force-directed) kết hợp tô màu theo cộng đồng giúp diễn giải nhanh cấu trúc đồng thời bảng xếp hạng centrality hỗ trợ nêu bật các tác giả then chốt.

F. Hệ thống khuyến nghị hợp tác khoa học

Dựa trên kết quả dự đoán liên kết, nhiều hệ thống *Research Collaboration Recommendation* đã được phát triển để tự động gợi ý đối tác tiềm năng. Các mô hình này thường kết hợp thông tin cấu trúc mạng với dữ liệu hồ sơ học thuật, lĩnh vực nghiên cứu hoặc từ khóa bài báo [9]. Một số hướng hiện đại tích hợp học sâu trên văn bản (text embedding) và đồ thị (graph embedding) nhằm tăng độ chính xác và khả năng mở rộng của hệ thống khuyến nghị.


G. Tổng hợp và khoảng trống nghiên cứu

Tổng quan cho thấy các chỉ số tương đồng cổ điển vẫn mang lại độ chính xác cao và dễ diễn giải, trong khi các phương pháp học biểu diễn đồ thị có ưu thế trong việc khám phá quan hệ hợp tác mới ở phạm vi rộng hơn. Tuy nhiên, các nghiên cứu tái lập trên nguồn dữ liệu mở quy mô lớn, đặc biệt trong lĩnh vực Khoa học Dữ liệu tại Việt Nam, còn hạn chế. Bài báo này hướng tới việc kết hợp hai hướng tiếp cận trên để xây dựng mô hình dự đoán hợp tác nghiên cứu có độ chính xác cao, đồng thời làm cơ sở cho hệ thống khuyến nghị đối tác khoa học trong tương lai.

III. PHƯƠNG PHÁP NGHIÊN CỨU

Phần này trình bày quy trình nghiên cứu được áp dụng nhằm xây dựng mô hình dự đoán hợp tác nghiên cứu tương lai trong mạng đồng tác giả. Mô hình kết hợp giữa các chỉ số tương đồng cổ điển và kỹ thuật học biểu diễn đồ thị Node2Vec để dự đoán khả năng hình thành liên kết mới giữa các tác giả.

Quy trình tổng thể của nghiên cứu được minh họa trong Hình 1. Quy trình này bao gồm các bước chính từ thu thập và xử lý dữ liệu, xây dựng mạng đồng tác giả, tính toán đặc trưng cấu trúc và học biểu diễn Node2Vec, đến đánh giá mô hình và trực quan hóa kết quả. Mỗi giai đoạn được thiết kế nhằm đảm bảo tính liên kết chặt chẽ giữa khâu tiền xử lý, mô hình hóa và phân tích kết quả, qua đó nâng cao độ tin cậy của mô hình dự đoán liên kết và khuyến nghị hợp tác nghiên cứu.



Hình 1. Quy trình tổng quát của dự án: Dự đoán hợp tác nghiên cứu tương lai và khuyến nghị đối tác.

Hình 1 thể hiện rõ 7 giai đoạn chính: (1) Thu thập và chuẩn bị dữ liệu, (2) Xây dựng mạng đồng tác giả, (3) Chia dữ liệu train/test, (4) Tính toán đặc trưng, (5) Học biểu diễn Node2Vec, (6) Đánh giá mô hình và (7) Trực quan và thảo luận. Quy trình này đóng vai trò khung tham chiếu xuyên suốt cho toàn bộ quá trình thực nghiệm của đề tài.

A. Chuẩn bị và tiền xử lý dữ liệu

Dữ liệu đầu vào được thu thập từ mạng đồng tác giả của các công bố trong lĩnh vực Khoa học Dữ liệu. Mỗi cạnh trong đồ thị biểu diễn mối quan hệ hợp tác giữa hai tác giả, với trọng số w_{ij} thể hiện số lượng bài báo mà họ cùng công bố.

Các bước tiền xử lý bao gồm:

- Chuẩn hóa tên tác giả, loại bỏ trùng lặp và các bản ghi không đầy đủ.
- Chuyển trọng số w_{ij} về dạng số nguyên.
- Loại bỏ self-loop và kiểm tra thành phần liên thông.
- Giữ lại các thành phần liên thông lớn có kích thước $n \geq 100$ và mật độ $\rho \leq 0.5$ để đảm bảo dữ liệu đủ lớn nhưng không quá dày đặc.

Kết quả thu được là một đồ thị vô hướng $G = (V, E)$ với hơn 3.000 nút và 90.000 cạnh, biểu diễn cấu trúc hợp tác giữa các nhà nghiên cứu trong lĩnh vực Khoa học Dữ liệu.

B. Xây dựng mạng và chia tập huấn luyện kiểm tra

Tập dữ liệu được chia thành hai phần:

- **Tập huấn luyện (Train):** Chiếm 80% tổng số cạnh, được sử dụng để tính toán các đặc trưng và học mô hình.
- **Tập kiểm tra (Test):** Chiếm 20% còn lại, dùng để đánh giá hiệu năng dự đoán.

Các cạnh trong tập kiểm tra được loại bỏ khỏi mạng gốc để tạo đồ thị huấn luyện $G_{train} = (V, E_{train})$. Ngoài ra, các cặp nút không có liên kết được chọn ngẫu nhiên làm mẫu âm (negative samples) để đảm bảo dữ liệu cân bằng.

C. Tính toán các chỉ số dự đoán liên kết

Trên đồ thị huấn luyện G_{train} , năm thuật toán cổ điển được sử dụng để tính điểm tương đồng giữa hai nút u và v :

- **Common Neighbors (CN):**

$$S_{CN}(u, v) = |N(u) \cap N(v)|$$

- **Jaccard Coefficient (JC):**

$$S_{JC}(u, v) = \frac{|N(u) \cap N(v)|}{|N(u) \cup N(v)|}$$

- **Adamic-Adar Index (AA):**

$$S_{AA}(u, v) = \sum_{w \in N(u) \cap N(v)} \frac{1}{\log(|N(w)|)}$$

- **Preferential Attachment (PA):**

$$S_{PA}(u, v) = |N(u)| \times |N(v)|$$

- **Resource Allocation (RA):**

$$S_{RA}(u, v) = \sum_{w \in N(u) \cap N(v)} \frac{1}{|N(w)|}$$

Các chỉ số này phản ánh đặc trưng cấu trúc của mạng: CN và JC mô tả mức độ chồng lấn của hàng xóm, trong khi AA và RA giảm trọng với các nút có bậc cao, còn PA phản ánh xu hướng “người nổi tiếng dễ hợp tác với nhau”.

D. Học biểu diễn đồ thị bằng Node2Vec

Bên cạnh các chỉ số cục bộ, nghiên cứu sử dụng thuật toán **Node2Vec** để học biểu diễn vector cho từng nút trong mạng G_{train} . Node2Vec mở rộng ý tưởng của Word2Vec bằng việc mô phỏng bước đi ngẫu nhiên có trọng số để tối ưu hàm mục tiêu:

$$\max_f \sum_{u \in V} \log P(N_S(u) | f(u))$$

trong đó $f(u)$ là vector biểu diễn của nút u , và $N_S(u)$ là tập hàng xóm được sinh ra từ chuỗi bước đi ngẫu nhiên theo chiến lược *biased random walk*.

Độ tương đồng giữa hai nút được tính bằng **Cosine Similarity**:

$$S_{N2V}(u, v) = \frac{f(u) \cdot f(v)}{\|f(u)\| \|f(v)\|}$$

Phương pháp này giúp phát hiện các mối quan hệ tiềm ẩn vượt ra ngoài cộng đồng trực tiếp, tận dụng được thông tin toàn cục của mạng.

E. Đánh giá mô hình và trực quan hóa

Các phương pháp được đánh giá bằng hai chỉ số phổ biến:

$$AUC-ROC = \frac{1}{|P||N|} \sum_{p \in P} \sum_{n \in N} \delta(S(p) > S(n))$$

$$AUC-PR = \int_0^1 P(R) dR$$

trong đó P và N lần lượt là tập các cạnh thật và cạnh giả, δ là hàm chỉ báo. Ngoài ra, các chỉ số $Precision@K$ và $Recall@K$ được sử dụng để đánh giá hiệu quả khuyến nghị trong Top-K kết quả.

Các biểu đồ **ROC**, **Precision-Recall**, **Histogram** và **Boxplot** được sử dụng để trực quan hóa phân bố điểm tương đồng, giúp so sánh hiệu năng giữa các thuật toán. Toàn bộ quá trình được cài đặt bằng Python với các thư viện `NetworkX`, `scikit-learn`, `node2vec` và `matplotlib`.

IV. XÂY DỰNG VÀ CHUẨN BỊ DỮ LIỆU

A. Tập dữ liệu

Tập dữ liệu sử dụng trong nghiên cứu này được kế thừa trực tiếp từ kết quả của **Project 1A**, trong đó nhóm đã xây dựng thành công mạng đồng tác giả trong lĩnh vực *Khoa học Dữ liệu* dựa trên cơ sở dữ liệu học thuật mở OpenAlex. Từ mạng gốc gồm hơn 9.000 tác giả và 130.000 mối quan hệ hợp tác, dữ liệu được trích xuất và lưu dưới dạng danh sách cạnh (edge list) để phục vụ cho bài toán dự đoán liên kết trong nghiên cứu này.

Tập dữ liệu bao gồm ba cột chính:

- **Author1:** Tác giả thứ nhất trong cặp hợp tác.
- **Author2:** Tác giả thứ hai trong cặp hợp tác.
- **Weight:** Số lượng bài báo mà hai tác giả cùng công bố.

Mỗi dòng trong tệp đại diện cho một mối quan hệ hợp tác ($Author1, Author2$), được biểu diễn dưới dạng cạnh có trọng số w_{ij} trong mạng đồng tác giả $G = (V, E)$, với V là tập các tác giả và E là tập các quan hệ hợp tác.

Tập dữ liệu sau khi làm sạch và chuẩn hóa được sử dụng để xây dựng mạng đồng tác giả và phục vụ các bước phân tích, huấn luyện mô hình dự đoán hợp tác nghiên cứu trong tương lai. Cột **Weight** đóng vai trò thể hiện cường độ quan hệ, giúp mô hình nhận biết mức độ hợp tác giữa các nhà khoa học trong quá khứ.

Bảng I
MÔ TẢ DỮ LIỆU QUAN HỆ HỢP TÁC GIỮA CÁC TÁC GIẢ

Author1	Author2	Weight
Joseph Sambrook	Elisabeth Fritsch	1
Joseph Sambrook	Tom Maniatis	1
Elisabeth Fritsch	Tom Maniatis	1
Keith E. Muller	Jacob Cohen	1
Jacob Cohen	Peter A. Lachenbruch	1
David Moher	A. Liberati	1
David Moher	Jennifer Tetzlaff	3
David Moher	Douglas G. Altman	3
David Moher	Matthew J. Page	2

B. Xây dựng mạng đồng tác giả

Dựa trên dữ liệu kế thừa từ Project 1A, nhóm tiến hành xây dựng **mạng đồng tác giả (co-author network)** nhằm phục vụ cho bài toán *dự đoán liên kết* giữa các nhà nghiên cứu. Dữ liệu được biểu diễn dưới dạng đồ thị vô hướng $G = (V, E)$, trong đó:

- Mỗi nút $v \in V$ đại diện cho một tác giả.
- Mỗi cạnh $e_{ij} \in E$ biểu diễn mối quan hệ hợp tác giữa hai tác giả i và j .
- Trọng số cạnh w_{ij} thể hiện số lượng bài báo mà hai tác giả cùng công bố.

Kết quả ban đầu cho thấy mạng bao gồm hơn 9.000 tác giả và 136.000 mối quan hệ hợp tác. Phân tích cấu trúc mạng cho thấy có tổng cộng **1.145 thành phần liên thông (connected components)**, trong đó **thành phần lớn nhất** gồm 2.616 nút và 76.666 cạnh, chiếm khoảng 28% tổng số nút. Điều này cho thấy mạng có tính *phân mảnh cao*, tức là tồn tại nhiều cụm tác giả nhỏ tách biệt.

Bảng II
CHỈ SỐ CỦA MẠNG ĐỒNG TÁC GIẢ TRƯỚC KHI LỌC

Số nút	Số cạnh	Số thành phần	Mật độ
9.212	136.198	1.145	0.0032

Để loại bỏ các cụm nhỏ lẻ và tập trung vào các cộng đồng nghiên cứu có ý nghĩa thống kê, nhóm áp dụng tiêu chí lọc như sau:

$$\text{Số nút} \geq 100, \quad \text{và} \quad \text{Mật độ} \leq 0.5.$$

Bảng III thể hiện thông tin chi tiết về 10 thành phần liên thông lớn nhất của mạng ban đầu.

Bảng III
TOP 10 THÀNH PHẦN LIÊN THÔNG LỚN NHẤT CỦA MẠNG ĐỒNG TÁC GIẢ

Thành phần	Số nút	Số cạnh	Mật độ
Component 1	2.616	76.666	0.0224
Component 2	266	7.362	0.2089
Component 3	211	8.129	0.3669
Component 4	124	503	0.0660
Component 5	117	5.103	0.7520
Component 6	105	4.959	0.9082
Component 7	99	4.851	1.0000
Component 8	98	2.909	0.6120
Component 9	88	2.954	0.7717
Component 10	84	1.084	0.3110

Dựa trên tiêu chí trên, chỉ các thành phần có quy mô lớn và mật độ hợp lý mới được giữ lại. Kết quả sau khi lọc được tóm tắt trong Bảng IV.

Bảng IV
CHỈ SỐ CỦA MẠNG ĐỒNG TÁC GIẢ SAU KHI LỌC


Số nút	Số cạnh	Số thành phần	Mật độ
3.217	92.660	4	0.018

Bốn thành phần lớn nhất được giữ lại có đặc trưng như trong Bảng V.

Bảng V
BỐN THÀNH PHẦN LỚN NHẤT ĐƯỢC GIỮ LẠI SAU KHI LỌC

Thành phần	Số nút	Số cạnh	Mật độ
Component 1	2.616	76.666	0.0224
Component 2	266	7.362	0.2089
Component 3	211	8.129	0.3669
Component 4	124	503	0.0660

Bốn thành phần liên thông lớn nhất sau khi lọc



Hình 2. Bốn thành phần liên thông lớn nhất sau khi lọc (Component 1–4). Mỗi màu thể hiện một cộng đồng hợp tác nghiên cứu riêng biệt.

Kết quả cho thấy **Component 1** là cụm nghiên cứu lớn nhất với hơn 2.600 tác giả và hơn 76.000 mối liên kết, có mật độ thấp (0.0224), phù hợp cho việc học mô hình liên kết. Các cụm còn lại (Component 2–4) tuy nhỏ hơn nhưng vẫn đảm bảo kích thước và mức độ kết nối hợp lý, phản ánh những nhóm nghiên cứu nhỏ, hoạt động tập trung trong các chuyên ngành riêng.

Cấu trúc mạng sau khi lọc giúp loại bỏ các cụm nhiễu và tập trung vào những cộng đồng hợp tác thực chất. Độ đậm đặc tăng từ 0.0032 lên 0.018 cho thấy mạng trở nên gắn kết hơn, giúp mô hình dự đoán liên kết hoạt động ổn định và hiệu quả hơn trong giai đoạn huấn luyện.

Ghi chú: Thành phần liên thông (connected component) là nhóm các nút trong mạng mà giữa bất kỳ hai nút nào cũng tồn tại ít nhất một đường đi, phản ánh cụm tác giả có mối liên hệ hợp tác trực tiếp hoặc gián tiếp.

C. Chuẩn bị dữ liệu cho bài toán dự đoán liên kết

Sau khi hoàn thiện bước xây dựng và lọc mạng đồng tác giả, nhóm tiến hành tách dữ liệu để phục vụ bài toán **dự đoán liên kết (Link Prediction)**. Mục tiêu là mô phỏng khả năng hình thành mối hợp tác mới giữa các tác giả trong tương lai, dựa trên cấu trúc mạng hiện có.

1) *Chia tập huấn luyện và kiểm tra:* Đầu tiên, toàn bộ các cạnh trong mạng được chia thành hai phần:

- **Tập huấn luyện (Train set):** Chiếm 80% tổng số cạnh, được sử dụng để xây dựng mô hình và học đặc trưng của mạng.
- **Tập kiểm tra (Test set):** Chiếm 20% số cạnh còn lại, được sử dụng để đánh giá khả năng dự đoán các liên kết mới.

Đồ thị huấn luyện G_{train} được xây dựng chỉ từ các cạnh thuộc tập train, nhưng vẫn giữ nguyên toàn bộ tập nút của đồ thị gốc. Việc này đảm bảo rằng mô hình có thể dự đoán liên kết giữa các tác giả chưa từng hợp tác, thay vì chỉ những cặp đã tồn tại trong tập huấn luyện.

Bên cạnh đó, nhóm cũng tạo ra tập **negative samples** bao gồm các cặp tác giả chưa từng có liên kết trong mạng. Các mẫu âm này được chọn ngẫu nhiên và có số lượng bằng với số mẫu dương (số cạnh thật) trong từng tập train và test, giúp cân bằng dữ liệu đầu vào khi đánh giá.


Kết quả chia dữ liệu được thể hiện trong Bảng VI.

Bảng VI
CHIA TẬP DỮ LIỆU CHO BÀI TOÁN DỰ ĐOÁN LIÊN KẾT

Tập dữ liệu	Số cạnh thật (Positive)	Số cạnh giả (Negative)
Huấn luyện (Train)	74.128	74.128
Kiểm tra (Test)	18.532	18.532

2) *Đảm bảo tính kết nối của đồ thị huấn luyện*: Sau khi chia tách, nhóm tiến hành kiểm tra tính liên thông của đồ thị G_{train} . Kết quả cho thấy đồ thị huấn luyện vẫn duy trì được tính liên thông trong các thành phần chính, đảm bảo rằng các thuật toán dự đoán (ví dụ Common Neighbors, Jaccard, Node2Vec) có thể hoạt động hiệu quả trên toàn mạng thay vì bị giới hạn trong các cụm rời rạc.

3) *Trực quan hoá mạng huấn luyện và mạng gốc*: Hình 3 mô tả trực quan sự khác biệt giữa đồ thị gốc (full graph) và đồ thị huấn luyện sau khi loại bỏ 20% số cạnh. Cấu trúc mạng huấn luyện vẫn bảo toàn được hình dạng và mật độ của các cụm chính, đảm bảo tính đại diện cho toàn bộ mạng.



Hình 3. So sánh đồ thị gốc và đồ thị huấn luyện, cho thấy các cụm chính vẫn được bảo toàn sau khi tách dữ liệu.

Việc tách 20% cạnh để kiểm tra giúp mô hình học được đặc trưng cấu trúc của mạng đồng tác giả mà không bị overfitting, đồng thời có đủ dữ liệu kiểm định để đánh giá khả năng dự đoán liên kết mới.

Tổng kết: Sau khi chia tách, mạng huấn luyện G_{train} vẫn giữ được cấu trúc cộng đồng và độ gắn kết tương đối cao. Việc tạo tập mẫu âm và dương cân bằng giúp đảm bảo tính khách quan trong quá trình huấn luyện và đánh giá các thuật toán dự đoán liên kết.

D. Các phương pháp dự đoán liên kết

Sau khi hoàn thiện tập dữ liệu huấn luyện, nghiên cứu tiến hành áp dụng các phương pháp dự đoán liên kết nhằm ước lượng khả năng hình thành các mối hợp tác mới giữa các tác giả trong mạng đồng tác giả. Các phương pháp được chia thành hai nhóm chính: (i) các chỉ số dựa trên cấu trúc cục bộ và (ii) phương pháp học biểu diễn đồ thị.

1) *Nhóm phương pháp cấu trúc cục bộ*: Nhóm này bao gồm năm thuật toán phổ biến: *Common Neighbors*, *Jaccard Coefficient*, *Adamic-Adar Index*, *Preferential Attachment* và *Resource Allocation*. Các chỉ số này được tính dựa trên thông tin lân cận của hai nút chưa có cạnh nối trong đồ thị huấn luyện. Chúng phản ánh mức độ tương đồng giữa hai tác giả thông qua số lượng hàng xóm chung, tần suất xuất hiện của các nút trung gian hoặc mức độ kết nối của mỗi nút. Các phương pháp này hoạt động hiệu quả trong mạng có cấu trúc cộng đồng rõ ràng, đặc biệt khi các cụm nghiên cứu có xu hướng hợp tác nội bộ mạnh mẽ.

2) *Nhóm phương pháp học biểu diễn đồ thị*: Bên cạnh các thuật toán cổ điển, nghiên cứu còn triển khai mô hình **Node2Vec** nhằm học biểu diễn vector cho từng tác giả trong không gian đặc trưng liên tục. Phương pháp này dựa trên cơ chế *random walk* để trích xuất ngữ cảnh xung quanh mỗi nút, từ đó huấn luyện mô hình nhúng học được cấu trúc toàn cục của mạng. Sau khi huấn luyện, độ tương đồng giữa hai nút được đo bằng *cosine similarity* giữa các vector nhúng tương ứng. Node2Vec có ưu thế trong việc phát hiện các mối liên kết tiềm ẩn giữa các cộng đồng xa nhau mà các phương pháp cục bộ thường bỏ sót.

3) *Tổng kết*: Tổng cộng, sáu phương pháp được sử dụng trong nghiên cứu bao gồm: **Common Neighbors**, **Jaccard Coefficient**, **Adamic-Adar Index**, **Preferential Attachment**, **Resource Allocation Index** và **Node2Vec (Cosine Similarity)**. Những thuật toán này đóng vai trò nền tảng cho giai đoạn thực nghiệm và đánh giá hiệu năng, được trình bày chi tiết trong Mục V.

V. THỰC NGHIỆM VÀ ĐÁNH GIÁ

A. Cấu hình và môi trường thực nghiệm

Các thí nghiệm được thực hiện bằng ngôn ngữ lập trình **Python 3.10** cùng các thư viện **NetworkX**, **scikit-learn**, **node2vec**, **NumPy** và **Matplotlib**. Máy tính chạy thử nghiệm sử dụng CPU Intel Core i7 và RAM 16GB. Quá trình đánh giá được tiến hành trên mạng đồng tác giả đã qua lọc (3.217 nút, 92.660 cạnh, mật độ 0.018).

B. Chỉ số đánh giá

Để đánh giá hiệu quả dự đoán liên kết, hai chỉ số chính được sử dụng:

- **AUC-ROC (Area Under ROC Curve)**: Đo lường khả năng mô hình phân biệt giữa cạnh thật (positive) và cạnh giả (negative).
- **AUC-PR (Area Under Precision-Recall Curve)**: Phản ánh độ chính xác và khả năng bao phủ, đặc biệt phù hợp với mạng có mật độ thấp.


C. Kết quả đánh giá

Bảng VII
KẾT QUẢ ĐÁNH GIÁ CÁC PHƯƠNG PHÁP DỰ ĐOÁN LIÊN KẾT

Phương pháp	AUC-ROC	AUC-PR
Jaccard Coefficient	0.9977	0.9961
Adamic-Adar Index	0.9975	0.9955
Resource Allocation	0.9975	0.9953
Common Neighbors	0.9973	0.9954
Preferential Attachment	0.7963	0.7814
Node2Vec (Cosine Similarity)	0.5000	0.5002

Kết quả cho thấy các phương pháp dựa trên cấu trúc cục bộ như *Jaccard*, *Adamic-Adar*, *Resource Allocation* và *Common Neighbors* đạt hiệu suất rất cao với AUC-ROC và AUC-PR xấp xỉ 1.0, thể hiện khả năng phân biệt gần như hoàn hảo giữa cạnh thật và cạnh giả. Ngược lại, *Preferential Attachment* có hiệu năng thấp hơn (AUC-ROC ≈ 0.80), cho thấy giả định “các nút có nhiều liên kết sẽ dễ hợp tác hơn” không hoàn toàn đúng trong mạng học thuật. Đặc biệt, *Node2Vec* cho kết quả gần ngẫu nhiên (AUC ≈ 0.50), nguyên nhân có thể do embedding chưa hội tụ hoặc số lượng bước ngẫu nhiên chưa đủ để nắm bắt cấu trúc mạng toàn cục.

D. Trực quan hóa kết quả



Hình 4. So sánh hiệu suất các phương pháp dự đoán liên kết.

Kết quả trực quan cho thấy các phương pháp dựa trên đặc trưng cục bộ như **Common Neighbors**, **Jaccard Coefficient**, **Adamic-Adar** và **Resource Allocation** đều đạt hiệu suất rất cao, với chỉ số **AUC-ROC** và **AUC-PR** xấp xỉ 1.0. Các đường cong ROC của nhóm này gần như ôm sát trục trái và phía trên, thể hiện khả năng phân biệt rất tốt giữa các cặp nút có và không có liên kết thực tế.


Ngược lại, **Preferential Attachment** cho kết quả thấp hơn đáng kể ($\text{AUC-ROC} \approx 0.79$; $\text{AUC-PR} \approx 0.78$), cho thấy giả định rằng “nút có nhiều kết nối sẽ dễ hình thành liên kết mới” không còn chính xác trong mạng đồng tác giả, nơi các mối quan hệ hợp tác thường mang tính chọn lọc theo chuyên môn thay vì ngẫu nhiên dựa vào độ phổ biến.

Đáng chú ý, **Node2Vec** cho hiệu suất rất thấp ($\text{AUC} \approx 0.5$), gần tương đương với dự đoán ngẫu nhiên. Nguyên nhân có thể do mô hình nhúng chưa được huấn luyện đủ lâu hoặc chưa tối ưu các siêu tham số (như chiều nhúng, bước đi ngẫu nhiên hoặc số lượng walk). Ngoài ra, do đồ thị có nhiều thành phần rời rạc nên Node2Vec khó học được quan hệ toàn cục giữa các cụm.

Tổng thể, nhóm phương pháp dự đoán liên kết truyền thống vẫn thể hiện khả năng vượt trội trong mạng đồng tác giả, đặc biệt khi cấu trúc cộng đồng rõ ràng và mối quan hệ giữa các tác giả mang tính lân cận cao. Trong khi đó, Node2Vec có tiềm năng mở rộng nhưng cần được tối ưu thêm để nắm bắt tốt hơn đặc trưng toàn cục của mạng.

E. Phân tích phân phối điểm similarity

Để đánh giá sâu hơn hành vi của các thuật toán dự đoán liên kết, nhóm nghiên cứu tiến hành trực quan hóa phân phối điểm *similarity* của sáu phương pháp: Common Neighbors, Jaccard Coefficient, Adamic-Adar Index, Preferential Attachment, Resource Allocation và Node2Vec. Mỗi phương pháp được biểu diễn dưới hai dạng: *Histogram* thể hiện mật độ điểm, và *Boxplot* thể hiện phân bố giá trị theo hai nhóm cạnh thật (Positive) và cạnh giả (Negative).



Hình 5. Phân phối và so sánh điểm similarity của các phương pháp dự đoán liên kết.

Quan sát Hình 5 trên cho thấy, các phương pháp dựa trên đặc trưng cục bộ như **Common Neighbors**, **Jaccard**, **Adamic-Adar** và **Resource Allocation** thể hiện sự phân tách rõ ràng giữa hai lớp. Các cạnh thật có điểm similarity cao hơn đáng kể, cho thấy khả năng dự đoán tốt trong việc phát hiện các mối hợp tác tiềm năng.

Ngược lại, phương pháp **Preferential Attachment** có phân phối điểm rất rộng và mức độ chồng lấn cao giữa hai lớp, do đặc trưng phụ thuộc mạnh vào bậc của nút. Các tác giả có nhiều cộng tác viên thường được gán điểm cao cho hầu hết các cặp, dẫn đến khả năng dự đoán kém ổn định. Trong khi đó, **Node2Vec** cho thấy xu hướng phân tách tương đối giữa hai nhóm nhưng vẫn chưa thật sự rõ ràng; mô hình mới chỉ khai thác được một phần đặc trưng toàn cục của mạng và có thể cải thiện thêm thông qua tối ưu các siêu tham số (*walk length*, *num walks*, *p*, *q*).


Tổng thể, các thuật toán *heuristic* (dựa trên cấu trúc lân cận) vẫn thể hiện hiệu năng cao và ổn định trong mạng đồng tác giả, trong khi Node2Vec thể hiện tiềm năng mở rộng nhưng cần được tinh chỉnh thêm để đạt hiệu quả tương đương hoặc vượt trội hơn.

F. Phân tích các liên kết được dự đoán

Để trực quan hóa khả năng dự đoán của từng thuật toán, nhóm nghiên cứu lựa chọn và minh họa *Top-10* liên kết có xác suất hình thành cao nhất đối với sáu phương pháp: **Common Neighbors**, **Jaccard Coefficient**, **Adamic-Adar Index**, **Preferential Attachment**, **Resource Allocation** và **Node2Vec**.

Trong mỗi hình, các **cạnh gốc** (quan hệ hợp tác hiện có) được hiển thị bằng màu xám, trong khi các **cạnh dự đoán mới** được tô màu đỏ và kẻ đứt nét để dễ dàng phân biệt. Kích thước các nút được giữ cố định nhằm đảm bảo tính đồng nhất trong so sánh giữa các mô hình.


Top 10 liên kết dự đoán (Common Neighbors)



Hình 6. Top 10 liên kết tiềm năng được dự đoán bằng thuật toán Common Neighbors.

Common Neighbors. Các liên kết mới có điểm similarity cao nhất dao động từ **118 đến 126**, tập trung trong cùng cụm tác giả có nhiều hàng xóm chung. Điều này cho thấy thuật toán ưu tiên các *quan hệ cục bộ* với độ kết nối dày đặc, phản ánh xu hướng cộng tác quen thuộc giữa các nhà nghiên cứu trong cùng nhóm.


Top 10 liên kết dự đoán (Jaccard Coefficient)



Hình 7. Top 10 liên kết tiềm năng được dự đoán bằng thuật toán Jaccard Coefficient.

Jaccard Coefficient. Các cạnh có giá trị **Jaccard = 1.0**, nghĩa là các cặp tác giả chia sẻ toàn bộ hàng xóm, thể hiện sự *tương đồng hoàn toàn* trong cấu trúc cộng tác. Thuật toán hoạt động tốt trong việc phát hiện các nhóm nghiên cứu chặt chẽ, nhưng khó mở rộng ra các cụm xa hơn.


Top 10 liên kết dự đoán (Adamic-Adar Index)



Hình 8. Top 10 liên kết tiềm năng được dự đoán bằng thuật toán Adamic–Adar Index.

Adamic–Adar Index. Điểm số dự đoán dao động quanh **27–28**, cao hơn rõ rệt ở các cặp nút có hàng xóm hiếm. Phương pháp này giúp phát hiện các *mối quan hệ tiềm năng* giữa những tác giả có vai trò cầu nối trong mạng, góp phần tăng khả năng mở rộng hợp tác.

Top 10 liên kết dự đoán (Preferential Attachment)



Hình 9. Top 10 liên kết tiềm năng được dự đoán bằng thuật toán Preferential Attachment.

Preferential Attachment. Các nút có bậc cao như *Carballo-Rodríguez* đạt điểm **trên 33.000**, chi phối phần lớn các liên kết mới. Điều này thể hiện rõ giả thuyết “*người nổi bật thường có thêm nhiều hợp tác mới*”, song cũng cho thấy mô hình có thể bị thiên lệch về các nút trung tâm.

Resource Allocation Index. Các liên kết được dự đoán có điểm trong khoảng **1.5–1.7**, tập trung ở trung tâm cụm. Thuật toán phản ánh tốt cơ chế *lan truyền tài nguyên tri thức* giữa các thành viên trong cùng cộng đồng hợp tác, giúp duy trì tính ổn định của mạng.

The graph displays a network of authors. Nodes are colored red or blue. Edges are solid grey or dashed red with numerical weights. The graph shows clusters of related authors, such as a group around Kenneth W. Witwer and another around Elizabeth Joder.

Author 1	Author 2	Edge Type	Weight
Andrew J. Mungall	Kenneth W. Witwer	Dashed Red	0.6
Lesley Chao	Kenneth W. Witwer	Dashed Red	0.66
Takafumi Ochiya	John Sultan	Dashed Red	0.2
Hetty Betenboortel	John Sultan	Dashed Red	0.2
Elizabeth Joder	Aurélien Grégoire	Dashed Red	0.83
Elizabeth Joder	Robert Galub	Dashed Red	0.5
Elizabeth Joder	Elisabeth Gastegger	Dashed Red	0.5
Elisabeth Gastegger	Shyamala Sundaram	Dashed Red	0.92
Shyamala Sundaram	Alexander Ignatenko	Dashed Red	0.92
Elaine Barnes-L Page	Arvid Carlsson	Solid Grey	-
Arvid Carlsson	Arvid Carlsson	Solid Grey	-
Ricardo Silva	Fernando Vargas	Dashed Red	0.89
D. Staines	Jennifer Harrow	Dashed Red	0.82
Jennifer Harrow	Roger Kramer	Dashed Red	0.7
Jennifer Harrow	Laure Laila	Dashed Red	0.7

Tổng thể, nhóm phương pháp heuristic thể hiện khả năng dự đoán chính xác trong phạm vi cộng đồng hiện hữu, trong khi Node2Vec mở ra hướng tiếp cận mới trong việc phát hiện các mối quan hệ hợp tác tiềm năng giữa các nhóm nghiên cứu khác nhau.

Kết quả thực nghiệm cho thấy các phương pháp dự đoán liên kết dựa trên đặc trưng cục bộ như **Common Neighbors**, **Jaccard**, **Adamic-Adar** và **Resource Allocation** đạt hiệu suất vượt trội với giá trị AUC-ROC và AUC-PR xấp xỉ 1.0. Điều

này chứng tỏ cấu trúc mạng đồng tác giả trong tập dữ liệu có tính *cộng đồng mạnh* các tác giả thường hợp tác trong cùng nhóm, khiến các thuật toán dựa trên hàng xóm chung hoạt động rất hiệu quả.

Ngược lại, **Preferential Attachment** có hiệu quả thấp hơn rõ rệt (AUC-ROC 0.80), do giả định “nút có nhiều kết nối sẽ dễ hình thành liên kết mới” không hoàn toàn đúng trong mạng nghiên cứu, nơi quan hệ hợp tác thường phụ thuộc vào lĩnh vực, dự án hoặc tổ chức hơn là mức độ phổ biến của tác giả.

Đáng chú ý, **Node2Vec** cho kết quả khiêm tốn (AUC-ROC 0.50), gần tương đương với mô hình dự đoán ngẫu nhiên. Nguyên nhân có thể đến từ việc số lượng bước đi ngẫu nhiên và tham số *walk_length*, *p*, *q* chưa được tối ưu, khiến biểu diễn vector chưa phản ánh tốt ngữ cảnh toàn cục của mạng.

B. Phân tích nguyên nhân và đặc điểm cấu trúc mạng

Đồ thị đồng tác giả có tính phân mảnh cao với nhiều thành phần liên thông nhỏ. Sau khi lọc theo điều kiện $|V| > 100$ và mật độ < 0.5 , chỉ còn bốn thành phần lớn được giữ lại. Cấu trúc này tạo điều kiện thuận lợi cho các phương pháp heuristic, vốn dựa vào đặc trưng lân cận, nhưng lại gây khó khăn cho các mô hình học biểu diễn như Node2Vec khi cần nắm bắt đặc trưng toàn mạng. Ngoài ra, việc các nút cô lập (ít cạnh) chiếm tỷ lệ lớn cũng làm giảm độ chính xác của các phương pháp dựa trên embedding.

C. Hạn chế và hướng cải tiến

Mặc dù các phương pháp heuristic đạt kết quả tốt, chúng bị giới hạn trong việc phát hiện các liên kết mới giữa các cộng đồng khác nhau. Trong tương lai, nhóm nghiên cứu có thể mở rộng theo các hướng sau:

- **Tối ưu tham số Node2Vec** hoặc áp dụng các mô hình nhúng đồ thị hiện đại hơn như *DeepWalk*, *GraphSAGE*, hoặc *LINE* để cải thiện khả năng học đặc trưng toàn cục.
- **Kết hợp nhiều đặc trưng** (structural + semantic) để mô hình vừa tận dụng cấu trúc mạng vừa khai thác thông tin văn bản như tiêu đề hoặc chủ đề bài báo.
- **Thực hiện dự đoán động (temporal link prediction)** nhằm phân tích sự hình thành liên kết theo thời gian, phản ánh xu hướng hợp tác thực tế giữa các tác giả.

D. Tổng kết chương

Các phương pháp heuristic vẫn thể hiện ưu thế trong bài toán dự đoán liên kết khi mạng có cấu trúc cộng đồng mạnh. Nhưng để cải thiện khả năng khái quát và phát hiện liên kết mới giữa các nhóm nghiên cứu khác nhau, việc ứng dụng các mô hình nhúng học sâu như Node2Vec hoặc Graph Neural Network là hướng đi đầy tiềm năng cho các nghiên cứu tiếp theo.

VII. KẾT LUẬN

Đề tài đã triển khai và so sánh hiệu quả của các phương pháp dự đoán liên kết trên mạng đồng tác giả, bao gồm nhóm thuật toán heuristic (*Common Neighbors*, *Jaccard*, *Adamic-Adar*, *Resource Allocation*, *Preferential Attachment*) và mô hình học biểu diễn *Node2Vec*. Kết quả thực nghiệm cho thấy các phương pháp heuristic đạt độ chính xác cao và ổn định, đặc biệt trong các cụm tác giả có quan hệ cộng tác mật thiết. Trong khi đó, Node2Vec tuy chưa đạt hiệu quả nổi trội nhưng thể hiện tiềm năng trong việc khám phá những liên kết mới giữa các nhóm nghiên cứu khác biệt, phản ánh góc nhìn toàn cục của đồ thị.

Nghiên cứu cũng chỉ ra rằng đặc trưng cấu trúc của mạng như tính cộng đồng mạnh, mật độ cạnh cao và sự phân mảnh của đồ thị có ảnh hưởng đáng kể đến hiệu năng của từng mô hình. Do đó, việc lựa chọn thuật toán phù hợp cần cân nhắc giữa độ phức tạp tính toán và khả năng nắm bắt ngữ cảnh của mạng.

Trong tương lai, hướng phát triển khả thi là kết hợp giữa đặc trưng cấu trúc và ngữ nghĩa, chẳng hạn liên kết thông tin nội dung bài báo (từ khoá, lĩnh vực, tóm tắt) với đặc trưng đồ thị, để cải thiện khả năng khái quát của mô hình. Ngoài ra, việc áp dụng các kỹ thuật học sâu trên đồ thị như *GraphSAGE*, *GAT* hay *Graph Neural Network* hứa hẹn mang lại kết quả toàn diện hơn trong bài toán dự đoán và gợi ý hợp tác khoa học.

Tổng thể, đề tài không chỉ giúp làm rõ cơ chế hình thành mối quan hệ trong mạng nghiên cứu mà còn mở ra định hướng ứng dụng các mô hình học máy tiên tiến trong việc hỗ trợ phân tích và dự báo xu hướng hợp tác trong lĩnh vực khoa học dữ liệu.

TÀI LIỆU THAM KHẢO

- [1] M. E. J. Newman, “The structure of scientific collaboration networks,” *Proceedings of the National Academy of Sciences*, vol. 98, no. 2, pp. 404–409, 2001.
- [2] A.-L. Barabási, H. Jeong, Z. Néda, E. Ravasz, A. Schubert, and T. Vicsek, “Evolution of the social network of scientific collaborations,” *Physica A: Statistical mechanics and its applications*, vol. 311, no. 3–4, pp. 590–614, 2002.
- [3] J. Priem and H. Piwowar, “Openalex: A fully-open index of scholarly works, authors, venues, institutions, and concepts,” *arXiv preprint arXiv:2205.01833*, 2022.
- [4] D. Liben-Nowell and J. Kleinberg, “The link-prediction problem for social networks,” in *Proceedings of the twelfth international conference on Information and knowledge management*. ACM, 2003, pp. 556–559.

- [5] B. Perozzi, R. Al-Rfou, and S. Skiena, "Deepwalk: Online learning of social representations," in *Proceedings of the 20th ACM SIGKDD international conference on Knowledge discovery and data mining*. ACM, 2014, pp. 701–710.
- [6] A. Grover and J. Leskovec, "node2vec: Scalable feature learning for networks," in *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. ACM, 2016, pp. 855–864.
- [7] A. K. Menon and C. Elkan, "Link prediction via matrix factorization," *Machine Learning*, vol. 83, no. 2, pp. 163–191, 2011.
- [8] L. Danon, A. Diaz-Guilera, J. Duch, and A. Arenas, "Comparing community structure identification," *Journal of Statistical Mechanics: Theory and Experiment*, vol. 2005, no. 09, p. P09008, 2005.
- [9] M. Sun, H. Wang, and Z. Liu, "Co-author recommendation using link prediction on co-authorship networks," in *2016 12th International Conference on Semantics, Knowledge and Grids (SKG)*. IEEE, 2016, pp. 1–8.

PROJECT 2A:

PHÂN CỤM CHỦ ĐỀ VIDEO YOUTUBE DỰA TRÊN MÔ TẢ CỦA VIDEO

1st Hà Thế Anh, 2nd Nguyễn Nhật Nam, 3rd Hoàng Quang Minh
and Le Nhat Tung

HUTECH University, Vietnam

{hatheanh012004, nguyennhatnam01012004, hoangquangminh130804}@gmail.com, and lenhattung@hutech.edu.vn

TÓM TẮT NỘI DUNG

Trong bối cảnh nền tảng **YouTube** ngày càng phát triển mạnh mẽ, lượng nội dung video được tạo ra hàng ngày tăng nhanh, đặt ra nhu cầu cấp thiết trong việc **phân tích và tổ chức thông tin** một cách tự động. Một hướng tiếp cận hiệu quả là **phân cụm chủ đề video** dựa trên phần mô tả (description) nhằm nhận diện các nhóm nội dung tương đồng và hỗ trợ gợi ý, tìm kiếm, hoặc phân loại video.

Nghiên cứu này xây dựng quy trình **tiền xử lý và biểu diễn văn bản** từ mô tả video, sau đó sử dụng mô hình **SentenceTransformer (Sup-SimCSE-PhoBERT)** được sử dụng để sinh vector biểu diễn ngữ nghĩa ở cấp độ câu cho phần mô tả video. Mô hình này kết hợp **PhoBERT** - bộ mã hóa ngôn ngữ tiếng Việt - với cơ chế **Supervised SimCSE** nhằm tối ưu hóa khoảng cách ngữ nghĩa giữa các câu, giúp tạo ra embedding ổn định và giàu thông tin ngữ cảnh, phục vụ cho bước phân cụm chủ đề bằng **BERTopic**. Dựa trên không gian vector thu được, dữ liệu được **giảm chiều bằng UMAP** nhằm bảo toàn cấu trúc ngữ nghĩa cục bộ, sau đó áp dụng **thuật toán HDBSCAN** để phát hiện các nhóm chủ đề tiềm ẩn. Bên cạnh đó, các mô hình **KMeans** và **DBSCAN** được sử dụng như *đối chứng so sánh* để đánh giá hiệu quả phân cụm của **HDBSCAN**. Ngoài ra, mô hình **BERTopic** được thử nghiệm nhằm kết hợp phân cụm và gán nhãn chủ đề tự động, giúp diễn giải kết quả trực quan hơn.

Kết quả cho thấy các phương pháp **HDBSCAN** và **BERTopic** cho khả năng nhận diện chủ đề tốt hơn trong các tập dữ liệu lớn và nhiễu, trong khi **KMeans** có xu hướng chia nhỏ dữ liệu một cách cứng nhắc, ít phản ánh cấu trúc tự nhiên của tập văn bản. **DBSCAN** thì cho thấy mô hình nhận diện được một số nhóm lớn nhưng chưa khai thác tốt các cụm nhỏ hoặc trung bình. Phân tích cụm cho thấy các nhóm nội dung xoay quanh các lĩnh vực nổi bật như *âm nhạc, công nghệ, học tập, ẩm thực, giải trí, hướng dẫn...*

Công trình đóng góp một **pipeline toàn diện** cho việc phân tích và trực quan hóa chủ đề video trên YouTube, đồng thời gợi mở hướng ứng dụng **Xử lý ngôn ngữ tự nhiên (NLP)** và **Học máy không giám sát (Unsupervised Learning)** trong khai phá thông tin đa phương tiện.

TỪ KHÓA

YouTube, Video Description, Topic Clustering, SentenceTransformer, UMAP, HDBSCAN, BERTopic, Natural Language Processing, Unsupervised Learning, Text Embedding, Data Visualization.

I. GIỚI THIỆU

Trong thời đại nội dung số phát triển mạnh mẽ, **YouTube** trở thành nền tảng chia sẻ video lớn nhất thế giới với hàng triệu video được tải lên mỗi ngày. Khối lượng dữ liệu khổng lồ này không chỉ phản ánh xu hướng tiêu dùng thông tin mà còn là nguồn dữ liệu phong phú phục vụ cho các bài toán **khai phá dữ liệu (Data Mining)** và **xử lý ngôn ngữ tự nhiên (Natural Language Processing - NLP)**.

Một hướng tiếp cận quan trọng là **phân cụm chủ đề video (Topic Clustering)** dựa trên phần mô tả (**description**) - trường văn bản chứa thông tin tóm tắt nội dung mà người đăng tải cung cấp. Việc phân cụm mô tả video giúp nhận diện các nhóm nội dung tương đồng, hỗ trợ các hệ thống gợi ý (recommendation system), tìm kiếm theo chủ đề, và phân loại video tự động.

Các nghiên cứu gần đây cho thấy việc kết hợp **biểu diễn ngữ nghĩa (semantic embedding)** bằng các mô hình ngôn ngữ như **SentenceTransformer** cùng với các thuật toán **phân cụm không giám sát (unsupervised clustering)** như **KMeans**, **DBSCAN** hay **HDBSCAN** mang lại hiệu quả cao trong việc phát hiện cấu trúc ẩn trong dữ liệu văn bản. Trong đó, **HDBSCAN**

được đánh giá vượt trội nhờ khả năng tự động xác định số cụm và xử lý tốt dữ liệu nhiễu - đặc biệt phù hợp với tập mô tả video ngắn, đa dạng và phi cấu trúc.

Trong nghiên cứu này, nhóm tập trung vào việc **phân cụm chủ đề video trên nền tảng YouTube dựa trên phần mô tả (description)** - thành phần văn bản ngắn gọn nhưng chứa nhiều thông tin về nội dung và ngữ cảnh của video. Dữ liệu được thu thập tự động từ YouTube thông qua công cụ lập trình, bao gồm các trường: *tiêu đề, mô tả, kênh đăng tải, số lượt xem, lượt thích và bình luận*. Sau khi thu thập, dữ liệu được **tiền xử lý** để loại bỏ ký tự đặc biệt, emoji, liên kết, từ dừng và chuẩn hóa văn bản tiếng Việt.

Từ tập mô tả đã được làm sạch, nhóm sử dụng mô hình **SentenceTransformer** (Sup-SimCSE-PhoBERT) để sinh **embedding ngữ nghĩa**, biểu diễn mỗi video dưới dạng vector trong không gian nhiều chiều. Các vector này được **giảm chiều bằng UMAP** nhằm bảo toàn cấu trúc ngữ nghĩa cục bộ và hỗ trợ quá trình phân cụm hiệu quả hơn. Trên không gian vector này, thuật toán **HDBSCAN** được áp dụng để phát hiện các nhóm chủ đề tiềm ẩn. Ngoài ra, **KMeans** và **DBSCAN** được sử dụng như *mô hình đối chứng* nhằm so sánh và đánh giá hiệu quả phân cụm của HDBSCAN. Cuối cùng, mô hình **BERTopic** được triển khai để **gán nhãn tự động cho các cụm** và **trực quan hóa phân bố chủ đề**.

Mục tiêu chính của đề tài là:

- Xây dựng quy trình tự động thu thập và tiền xử lý mô tả video từ nền tảng YouTube.
- Áp dụng các mô hình ngôn ngữ và thuật toán học máy không giám sát để phân cụm các mô tả video.
- So sánh và đánh giá hiệu quả giữa các thuật toán phân cụm (**KMeans, DBSCAN, HDBSCAN**) trên cùng tập dữ liệu.
- Gán nhãn và trực quan hóa các cụm chủ đề để rút ra xu hướng nội dung nổi bật trên YouTube.

Kết quả nghiên cứu không chỉ mang lại cái nhìn tổng quan về **cấu trúc và phân bố các nhóm nội dung video trên YouTube**, mà còn chứng minh tiềm năng ứng dụng của **Xử lý ngôn ngữ tự nhiên (NLP)** và **Học máy không giám sát (Unsupervised Learning)** trong việc khai thác dữ liệu văn bản ngắn, hỗ trợ phát triển các hệ thống **gợi ý nội dung** và **phân tích xu hướng truyền thông số** trong tương lai.

II. CÁC NGHIÊN CỨU LIÊN QUAN

A. Phân cụm chủ đề video và các hướng nghiên cứu liên quan

Phân cụm chủ đề video (video topic clustering) là một hướng nghiên cứu quan trọng trong lĩnh vực **phân tích nội dung trực tuyến (online content analysis)** và **xử lý ngôn ngữ tự nhiên (Natural Language Processing - NLP)**. Thay vì dựa trên dữ liệu định lượng như lượt xem hoặc thẻ (tags), phương pháp này tập trung khai thác **thông tin ngữ nghĩa trong phần mô tả (description)** của video để phát hiện các nhóm chủ đề tiềm ẩn. [1]

Các nghiên cứu trước đây đã áp dụng nhiều kỹ thuật học máy và mô hình ngôn ngữ để giải quyết bài toán này. Ở giai đoạn đầu, các phương pháp truyền thống như **TF-IDF** và **LDA (Latent Dirichlet Allocation)** được sử dụng để biểu diễn và trích xuất chủ đề từ văn bản. Tuy nhiên, chúng gặp hạn chế khi xử lý các đoạn mô tả ngắn và đa ngữ trên YouTube. [2]

Sự ra đời của các mô hình **transformer-based embeddings** như **BERT, Sentence-BERT**, và đặc biệt là các biến thể tiếng Việt như **PhoBERT** hay **SimCSE**, đã mở ra hướng tiếp cận hiệu quả hơn. Các mô hình này giúp biểu diễn văn bản ở mức ngữ nghĩa sâu, làm cơ sở cho các thuật toán **phân cụm không giám sát** như **KMeans, DBSCAN** và **HDBSCAN**. [3]

Gần đây, mô hình **BERTopic** được giới thiệu như một giải pháp tổng hợp giữa **embedding ngữ nghĩa, giảm chiều (UMAP)** và **phân cụm mật độ (HDBSCAN)**, cho phép **tự động gán nhãn chủ đề** dựa trên từ khóa nổi bật trong mỗi cụm. Nhiều nghiên cứu đã chứng minh BERTopic mang lại hiệu quả cao hơn các phương pháp truyền thống khi xử lý dữ liệu văn bản ngắn như mô tả YouTube, bình luận hoặc bài viết mạng xã hội. [4]

B. Phân cụm chủ đề dựa trên embedding và mật độ

Một hướng tiếp cận phổ biến trong **phân tích chủ đề video** là biểu diễn nội dung mô tả bằng các **vector ngữ nghĩa (semantic embeddings)** rồi áp dụng các **thuật toán phân cụm không giám sát** để phát hiện nhóm chủ đề tiềm ẩn.

Thay vì dựa vào từ khóa hoặc thẻ gắn thủ công, phương pháp này cho phép nhận diện cấu trúc chủ đề tự nhiên của dữ liệu thông qua mức độ tương đồng giữa các mô tả video.

Trong nghiên cứu này, các thuật toán **KMeans** [5] và **DBSCAN** [6] được sử dụng chủ yếu để **so sánh hiệu quả** với phương pháp chính. **KMeans** mang lại tốc độ xử lý nhanh và độ ổn định cao khi số cụm được xác định trước, nhưng khó phản ánh chính xác cấu trúc tự nhiên của dữ liệu mô tả ngắn. **DBSCAN** có thể phát hiện cụm dựa trên mật độ điểm và tự động loại bỏ nhiễu, song vẫn gặp hạn chế trong việc xác định ranh giới khi dữ liệu có mật độ không đồng đều.

Thuật toán **HDBSCAN** [7] được lựa chọn là **phương pháp tối ưu** cho bài toán này. **HDBSCAN** mở rộng từ **DBSCAN** bằng cách xây dựng cây phân cấp mật độ (**hierarchical density tree**) và lựa chọn phân hoạch tối ưu dựa trên độ ổn định của cụm. Nhờ khả năng tự động xác định số lượng cụm, xử lý nhiễu hiệu quả và nhận diện được các nhóm nhỏ nhưng giàu ngữ nghĩa, **HDBSCAN** thể hiện độ chính xác và khả năng phân biệt chủ đề vượt trội hơn so với hai phương pháp còn lại.

Trong nghiên cứu này, mô hình **BERTopic** được sử dụng như một khung tổng hợp cho **biểu diễn ngữ nghĩa, giảm chiều và phân cụm chủ đề**. Các mô tả video được mã hóa bằng **Sup-SimCSE-PhoBERT** - một mô hình kết hợp giữa **PhoBERT**

và kỹ thuật **Supervised SimCSE** nhằm tối ưu hóa không gian nhúng câu có giám sát, giúp tăng độ tương đồng ngữ nghĩa giữa các câu liên quan. Cụ thể, mô tả video sau khi được mã hóa bằng **Sup-SimCSE-PhoBERT** sẽ được giảm chiều bằng **UMAP** [8] để bảo toàn cấu trúc ngữ nghĩa cục bộ, và cuối cùng phân cụm bằng **HDBSCAN** để thu được các nhóm chủ đề tiềm ẩn. Các cụm kết quả được phân tích và đặt tên thủ công dựa trên nội dung đặc trưng của từng nhóm.

Cách tiếp cận dựa trên **embedding** và **HDBSCAN** này đã chứng minh hiệu quả trong việc khám phá các **chủ đề nội dung tiềm ẩn** từ mô tả video YouTube - đặc biệt trên tập dữ liệu ngắn, đa dạng và có độ nhiễu cao.

C. Đánh giá chất lượng phân cụm

Để đánh giá mức độ hiệu quả của các phương pháp phân cụm, các chỉ số **silhouette score**, **noise ratio**, và **số lượng cụm** được sử dụng. **Silhouette score** đo độ tách biệt giữa các cụm, với giá trị càng cao thể hiện cụm càng rõ ràng. **Noise ratio** phản ánh tỷ lệ dữ liệu bị coi là nhiễu hoặc không thuộc cụm nào (đặc biệt quan trọng đối với **HDBSCAN**).

Việc so sánh các chỉ số này giữa **KMeans**, **DBSCAN** và **HDBSCAN** giúp đánh giá tính ổn định, khả năng phát hiện cấu trúc tự nhiên, và độ phù hợp với dữ liệu mô tả video trên YouTube.

D. Tổng hợp và khoảng trống nghiên cứu

Tổng quan các công trình liên quan cho thấy những phương pháp dựa trên **biểu diễn ngữ nghĩa (semantic embeddings)** kết hợp với **thuật toán phân cụm theo mật độ** đang dần trở thành xu hướng chính trong khai thác chủ đề từ dữ liệu văn bản ngắn.

Các mô hình như **HDBSCAN** và **BERTopic** đã chứng minh hiệu quả trong việc nhận diện các cụm nhỏ nhưng có tính ngữ nghĩa cao, đặc biệt khi kết hợp cùng kỹ thuật giảm chiều như **UMAP**. Tuy nhiên, phần lớn các nghiên cứu hiện nay chủ yếu tập trung vào dữ liệu tiếng Anh hoặc các tập văn bản dạng dài như bài báo, bình luận hoặc tin tức.

Khoảng trống hiện tại nằm ở việc **ứng dụng và đánh giá có hệ thống** các phương pháp phân cụm chủ đề hiện đại trên **dữ liệu tiếng Việt ngắn gọn, phi cấu trúc** như phần mô tả video YouTube.

Các nghiên cứu tái lập quy trình này vẫn còn hạn chế, đặc biệt trong việc so sánh định lượng giữa các thuật toán **KMeans**, **DBSCAN**, và **HDBSCAN** trên cùng một tập dữ liệu thực tế.

Đề tài này hướng tới việc thu hẹp khoảng trống đó bằng cách xây dựng một pipeline tự động từ khâu **thu thập - tiền xử lý - biểu diễn - phân cụm - đánh giá**, nhằm cung cấp một góc nhìn rõ ràng hơn về cấu trúc chủ đề và xu hướng nội dung trên nền tảng YouTube tiếng Việt.

III. PHƯƠNG PHÁP NGHIÊN CỨU

Phần này trình bày quy trình và các phương pháp được sử dụng để **phân cụm chủ đề video YouTube dựa trên phần mô tả (description)**. Mục tiêu là xây dựng một pipeline tự động giúp khai thác cấu trúc chủ đề tiềm ẩn từ dữ liệu văn bản ngắn, phục vụ phân tích xu hướng nội dung trên nền tảng YouTube tiếng Việt.

Quy trình nghiên cứu được triển khai qua năm giai đoạn chính:

- 1) Thu thập và tiền xử lý mô tả video,
- 2) Biểu diễn dữ liệu bằng embedding ngữ nghĩa,
- 3) Giảm chiều và phân cụm chủ đề,
- 4) Đánh giá và so sánh các thuật toán phân cụm, và
- 5) Trực quan hóa và diễn giải kết quả.

A. Thu thập và tiền xử lý dữ liệu

Nguồn dữ liệu được sử dụng trong nghiên cứu là các video tiếng Việt được thu thập từ nền tảng **YouTube**, tập trung vào các lĩnh vực phổ biến như **âm nhạc, ẩm thực, công nghệ, học tập, giải trí** và **hướng dẫn**.

Mỗi video được trích xuất các thông tin cơ bản gồm: *video_id*, *title*, *description*, *channel*, *published_date*, cùng một số chỉ số thống kê như *view_count*, *like_count* và *comment_count*.

Dữ liệu được thu thập tự động thông qua **YouTube Data API v3**, đảm bảo số lượng video đủ lớn và đa dạng về chủ đề.

Phần **mô tả (description)** của mỗi video được chọn làm đối tượng chính để khai thác thông tin ngữ nghĩa và thực hiện phân cụm chủ đề.

Quy trình tiền xử lý dữ liệu gồm năm bước chính:

- 1) **Xác định nguồn dữ liệu:** Chọn danh sách video hoặc kênh YouTube theo chủ đề nghiên cứu, đảm bảo cân bằng giữa các lĩnh vực nội dung.
- 2) **Thu thập dữ liệu thô:** Tải dữ liệu video và metadata thông qua API, lưu dưới định dạng **.csv**.
- 3) **Làm sạch văn bản:** Loại bỏ HTML, emoji, ký tự đặc biệt, liên kết, dấu câu dư thừa và các chuỗi quảng cáo không mang giá trị ngữ nghĩa.
- 4) **Chuẩn hóa ngôn ngữ:** Chuyển toàn bộ văn bản về chữ thường, chuẩn hóa chính tả tiếng Việt, có thể áp dụng tách từ bằng thư viện **underthesea**.
- 5) **Lưu trữ dữ liệu sạch:** Lưu tập dữ liệu đã làm sạch thành file *stage1_desc_clean.csv* để sử dụng trong giai đoạn embedding và phân cụm.

B. Xây dựng cụm chủ đề YouTube

Từ tập dữ liệu mô tả video đã được tiền xử lý, quá trình phân tích được triển khai dựa trên mô hình **BERTopic**, sử dụng các thư viện **BERTopic** và **HDBSCAN** trong Python.

Tập hợp video được biểu diễn dưới dạng ma trận embedding $E = \{e_1, e_2, \dots, e_n\}$, trong đó mỗi vector e_i thể hiện đặc trưng ngữ nghĩa của phần mô tả video tương ứng.

- **Biểu diễn dữ liệu:** Các mô tả video được mã hoá bằng mô hình *Sup-SimCSE-PhoBERT* để thu được vector embedding có chiều 768.
- **Giảm chiều:** Thuật toán *UMAP* được áp dụng để giảm chiều dữ liệu, giúp tăng hiệu quả khi phân cụm.
- **Phân cụm chủ đề:** Thuật toán *HDBSCAN* được sử dụng để phát hiện các cụm chủ đề tiềm ẩn, trong khi *KMeans* và *DBSCAN* được triển khai nhằm so sánh kết quả.
- **Gán nhãn chủ đề:** BERTopic tự động trích xuất các từ khóa nổi bật trong mỗi cụm để tạo nhãn (*topic_name*) cho từng nhóm video.

Các đặc trưng thống kê như *số cụm*, *kích thước cụm*, *tỉ lệ nhiễu (noise ratio)* và *điểm Silhouette* được tính toán nhằm đánh giá mức độ phân tách và chất lượng của mô hình phân cụm.

C. Phân cụm chủ đề

Để phát hiện các nhóm chủ đề tiềm ẩn trong tập mô tả video YouTube, ba thuật toán phân cụm phổ biến được áp dụng gồm:

- **KMeans:** thuật toán phân cụm dựa trên khoảng cách, yêu cầu xác định trước số cụm k và tối ưu hoá tổng bình phương khoảng cách trong cụm. Phương pháp này có tốc độ nhanh và ổn định nhưng khó phản ánh đúng cấu trúc tự nhiên của dữ liệu ngắn và nhiễu.
- **DBSCAN:** phân cụm dựa trên mật độ điểm dữ liệu, cho phép phát hiện cụm có hình dạng bất kỳ và tự động loại bỏ nhiễu, tuy nhiên phụ thuộc mạnh vào tham số ϵ và $minPts$.
- **HDBSCAN:** mở rộng từ DBSCAN bằng cách xây dựng cây phân cấp mật độ (*hierarchical density tree*) và lựa chọn phân hoạch tối ưu dựa trên độ ổn định cụm. Phương pháp này không cần biết trước số cụm và xử lý tốt dữ liệu có mật độ không đồng nhất.

Trong nghiên cứu này, **HDBSCAN** được lựa chọn là phương pháp chính do khả năng thích ứng cao và hiệu quả vượt trội trên dữ liệu mô tả video. Hai thuật toán **KMeans** và **DBSCAN** được sử dụng chủ yếu để so sánh, qua đó đánh giá ưu điểm của HDBSCAN về tính ổn định, khả năng phát hiện cụm nhỏ và tách biệt ngữ nghĩa tốt hơn.

Kết quả của các mô hình được so sánh dựa trên các chỉ số định lượng:

- **Silhouette Score:** đo độ tách biệt giữa các cụm, giá trị càng cao thể hiện biên giới cụm rõ ràng.
- **Noise Ratio:** phản ánh tỷ lệ phần tử bị gán là nhiễu, đặc biệt quan trọng với HDBSCAN.
- **Số lượng cụm (Number of Clusters):** thể hiện mức độ chi tiết trong việc phân chia dữ liệu, phản ánh khả năng nhận diện chủ đề của mô hình.

Các chỉ số này được sử dụng để lựa chọn cấu hình thuật toán tối ưu, đồng thời hỗ trợ đánh giá tính hợp lý của kết quả phân cụm chủ đề.

D. Phân tích và đánh giá kết quả phân cụm

Sau khi tiến hành phân cụm mô tả video, các chỉ số đánh giá được sử dụng nhằm xác định chất lượng và tính hợp lý của các cụm chủ đề:

- **Silhouette Score:** đo độ tách biệt giữa các cụm. Giá trị càng cao thể hiện biên giới cụm rõ ràng và nội dung trong cụm có tính tương đồng cao.
- **Noise Ratio:** phản ánh tỷ lệ phần tử bị gán là nhiễu (đặc biệt trong **HDBSCAN**), giúp đánh giá khả năng mô hình nhận diện chủ đề ổn định và loại bỏ các mô tả không rõ ràng.

Các chỉ số này được sử dụng để so sánh hiệu quả giữa các thuật toán **KMeans**, **DBSCAN** và **HDBSCAN**, qua đó xác định phương pháp phù hợp nhất cho bài toán phân cụm chủ đề video YouTube.

E. Trực quan hoá kết quả

Kết quả phân cụm được trực quan hoá bằng các công cụ **Matplotlib**, **Plotly** và các hàm hiển thị tích hợp trong mô hình **BERTopic**.

Các biểu đồ giúp minh hoạ rõ cấu trúc chủ đề, độ tách biệt giữa các cụm, và từ khoá đặc trưng của từng nhóm nội dung.

- **Topic Word Scores:** hiển thị các từ khoá đặc trưng cùng trọng số đóng góp của chúng trong từng cụm chủ đề. Ví dụ, cụm *Topic 0* nổi bật với các từ “*bóng đá, phim, kênh, Việt Nam*”, trong khi *Topic 5* tập trung vào “*ẩm thực, đồng quê, ăn uống*”. Điều này cho phép diễn giải trực quan ý nghĩa ngữ nghĩa của từng cụm.


- **Intertopic Distance Map:** biểu đồ hai chiều được tạo bởi **UMAP**, thể hiện mối quan hệ giữa các cụm chủ đề. Mỗi vòng tròn biểu diễn một cụm, kích thước tỷ lệ với số lượng video, và khoảng cách phản ánh mức tương đồng ngữ nghĩa. Các cụm nằm gần nhau thường chia sẻ chủ đề hoặc từ vựng tương tự.
- **HDBSCAN Condensed Tree:** biểu diễn cấu trúc phân cấp của mô hình HDBSCAN. Các nhánh dài và đậm thể hiện cụm ổn định, trong khi các nhánh ngắn bị cắt sớm đại diện cho phần nhiễu hoặc cụm yếu. Đây là công cụ giúp chọn mức phân cụm tối ưu dựa trên độ ổn định.
- **HDBSCAN Single Linkage Tree:** mô tả toàn bộ cây liên kết đơn của quá trình phân cụm. Màu sắc thể hiện số lượng điểm trong mỗi nhánh (log-scale), giúp quan sát sự phân bố mật độ và nhận diện các vùng dữ liệu có cấu trúc cụm rõ ràng.

Việc trực quan hoá này giúp xác định rõ ràng mối quan hệ giữa các nhóm nội dung, các chủ đề nổi bật (như *du lịch*, *ẩm thực*, *phim ảnh*, *công nghệ*), và phân biệt được các cụm nhỏ ít phổ biến hoặc nhiễu trong tập dữ liệu.

Kết quả này là cơ sở cho bước phân tích xu hướng truyền thông và hành vi nội dung trên nền tảng YouTube.

F. Quy trình nghiên cứu tổng quan

Toàn bộ quy trình nghiên cứu được thực hiện qua năm giai đoạn chính, từ thu thập dữ liệu, tiền xử lý, biểu diễn ngữ nghĩa bằng mô hình ngôn ngữ, đến phân cụm chủ đề và trực quan hoá kết quả. Quy trình được tóm tắt trong Hình 1.



Hình 1. Quy trình tổng quan của nghiên cứu phân cụm chủ đề video dựa trên mô tả nội dung YouTube.

Cụ thể, quy trình gồm các bước:

- 1) **Thu thập dữ liệu:** Lấy dữ liệu mô tả (*description*) và các thông tin liên quan (tiêu đề, kênh, ngày đăng, lượt thích, lượt xem) từ YouTube API.
- 2) **Tiền xử lý:** Làm sạch văn bản, loại bỏ ký tự đặc biệt, chuẩn hoá dấu tiếng Việt và tách từ bằng công cụ *underthesea*.
- 3) **Biểu diễn ngữ nghĩa:** Sinh vector nhúng từ mô hình **Sup-SimCSE-PhoBERT** (một biến thể của PhoBERT được huấn luyện theo phương pháp *Supervised Contrastive Learning*), biểu diễn mỗi mô tả video trong không gian 768 chiều.
- 4) **Giảm chiều và phân cụm:** Sử dụng **UMAP** để giảm chiều dữ liệu, sau đó áp dụng **HDBSCAN** để phát hiện các cụm chủ đề tiềm ẩn; **KMeans** và **DBSCAN** được dùng để so sánh hiệu năng.
- 5) **Trực quan hoá và đánh giá:** Trình bày kết quả bằng biểu đồ *Topic Word Scores*, *Intertopic Distance Map*, và cây phân cấp HDBSCAN để phân tích chất lượng cụm.

Quy trình này đảm bảo tính tuần tự, tái lập và có thể mở rộng cho các nghiên cứu phân tích nội dung video trực tuyến trong tương lai.

IV. XÂY DỰNG VÀ CHUẨN BỊ DỮ LIỆU

A. Nguồn và cấu trúc dữ liệu

Tập dữ liệu được thu thập từ nền tảng **YouTube** thông qua **YouTube Data API v3**, tập trung vào các video tiếng Việt thuộc nhiều chủ đề phổ biến như *âm nhạc*, *ẩm thực*, *giáo dục*, *du lịch*, và *giải trí*. Mỗi video trong tập dữ liệu được trích xuất các trường thông tin chính sau:

- **video_id**: Mã định danh duy nhất của video.
- **title**: Tiêu đề video.
- **description**: Phần mô tả văn bản do người đăng tải cung cấp.
- **channel**: Tên kênh đăng tải video.
- **category_id**: Mã danh mục nội dung do YouTube gán sẵn (ví dụ: 10–Music, 20–Gaming, 26–HowTo & Style).
- **tags**: Danh sách các thẻ mô tả (hashtag) mà người đăng tự gán cho video.
- **published_date**: Ngày đăng tải video.
- **view_count**, **like_count**, **comment_count**: Các chỉ số tương tác thể hiện mức độ phổ biến.

B. Tiền xử lý dữ liệu

Dữ liệu gốc chứa nhiều ký tự không hợp lệ, biểu tượng cảm xúc, thẻ HTML và từ dừng nên được làm sạch bằng tập hợp các quy tắc tiền xử lý sau:

- Loại bỏ **URL**, **email**, **HTML tags**, **emoji**, và các ký tự đặc biệt.
- Chuẩn hoá văn bản: chuyển về *lowercase*, loại bỏ khoảng trắng thừa, chuẩn hoá Unicode tiếng Việt.
- Giữ nguyên số liệu (**KEEP_NUMBERS=True**) để bảo tồn thông tin như “iPhone 15”, “4K”.
- Chuyển đổi hashtag (#) thành token dạng *tag_name* để giữ lại đặc trưng ngữ nghĩa.
- Áp dụng tách từ tiếng Việt bằng thư viện *underthesea* khi khả dụng.
- Loại bỏ **stopwords** dựa trên danh sách tùy chỉnh (ví dụ: “và”, “những”, “là”, “của”, v.v.).
- Loại bỏ các mô tả trống hoặc ngắn hơn 30 ký tự.

Kết quả được lưu thành tệp `stage1_desc_clean.csv` gồm hai trường: `video_id` và `description`. Toàn bộ tiến trình được thực hiện với thanh tiến trình `tqdm` để theo dõi trạng thái xử lý.

C. Biểu diễn ngữ nghĩa

Phần mô tả video sau khi làm sạch được mã hoá thành vector ngữ nghĩa bằng mô hình **Sup-SimCSE-PhoBERT** - một biến thể của **PhoBERT** được huấn luyện theo phương pháp *Supervised Contrastive Learning*, giúp tăng độ mượt và tính phân biệt của vector nhúng.

Pipeline mô hình gồm ba lớp:

- 1) **Transformer encoder**: Trích xuất đặc trưng ngữ cảnh từ mô tả video.
- 2) **Mean Pooling**: Tổng hợp thông tin toàn câu để tạo vector đại diện.
- 3) **Normalization layer**: Chuẩn hoá vector nhúng trong không gian 768 chiều.

Mỗi mô tả video được mã hoá thành một vector 768 chiều và lưu vào tệp `embeddings_desc_phobert.npy`. Quá trình mã hoá được thực hiện theo lô 256 mẫu (`BATCH=256`) để tối ưu tốc độ và bộ nhớ GPU/CPU.

D. Phân cụm và biểu diễn chủ đề

Để khám phá các nhóm chủ đề tiềm ẩn, nghiên cứu áp dụng mô hình **BERTopic**, kết hợp:

- **UMAP** để giảm chiều không gian embedding từ 768 xuống 15 chiều,
- **HDBSCAN** để phát hiện cụm tự động theo mật độ mà không cần xác định trước số cụm.

Cụ thể, tham số chính được lựa chọn là:

- `n_neighbors = 25, n_components = 15, metric = 'cosine'` cho UMAP;
- `min_cluster_size = 18, metric = 'euclidean'` cho HDBSCAN.

Sau khi huấn luyện, mỗi video được gán một nhãn cụm (`topic_id`) và tên cụm (`topic_name`) tương ứng. Các cụm nhiễu (`topic_id = -1`) bị loại bỏ. Kết quả được lưu trong tệp `stage3_desc_bertopic.csv`.

E. Trực quan hoá và đánh giá chất lượng cụm

Sau khi áp dụng mô hình **BERTopic** kết hợp **HDBSCAN** làm phương pháp phân cụm chính, nghiên cứu tiến hành trực quan hoá kết quả nhằm quan sát cấu trúc và chất lượng của các chủ đề được phát hiện.

Ba hình thức trực quan hoá được sử dụng:

- **Topic Word Scores**: Biểu đồ tần suất từ khoá quan trọng nhất trong từng cụm chủ đề.
- **Intertopic Distance Map**: Biểu đồ hai chiều biểu diễn khoảng cách giữa các cụm trong không gian UMAP.
- **HDBSCAN Trees**: Gồm *Condensed Tree* và *Single Linkage Tree*, giúp mô tả mật độ và mối quan hệ phân cấp giữa các cụm.

Để kiểm chứng hiệu quả của HDBSCAN, nghiên cứu tiến hành so sánh đối chiếu với các thuật toán phân cụm phổ biến khác gồm:

- **KMeans**: Phân cụm dựa trên khoảng cách Euclidean; số cụm k được dò trong khoảng từ 10 đến 100 để chọn giá trị tối ưu theo chỉ số **Silhouette Score**.
- **DBSCAN**: Phát hiện cụm dựa trên mật độ điểm, với các tham số $\text{eps} = 0.3$ và $\text{min_samples} = 10$.
- **Agglomerative Clustering**: Phương pháp phân cụm phân cấp (hierarchical) dùng độ đo **Euclidean** và liên kết kiểu **Ward linkage**, trong đó số cụm đặt theo giá trị k tối ưu từ KMeans để đảm bảo tính đối chiếu.

Tất cả các mô hình được đánh giá bằng chỉ số **Silhouette Score** - đo lường độ tách biệt và độ đồng nhất giữa các cụm. Đồng thời, mô hình **Agglomerative Clustering** được trực quan bằng biểu đồ **Dendrogram**, biểu diễn mối quan hệ phân cấp giữa các video, qua đó minh hoạ cấu trúc ngữ nghĩa tiềm ẩn trong không gian đặc trưng.

Bên cạnh đó, mô hình **BERTopic** cũng được mở rộng với chức năng **Hierarchical Topics**, tạo ra cây phân cấp chủ đề phản ánh mối quan hệ cha-con giữa các nhóm. Kết quả được xuất ra dưới dạng bản đồ tương tác `hierarchical_topics.html`, hỗ trợ quan sát đa tầng và khám phá chủ đề sâu hơn.

F. Tổng kết

Kết quả của giai đoạn này tạo ra một tập dữ liệu mô tả sạch, chuẩn hoá và được nhúng ngữ nghĩa trong không gian vector 768 chiều, làm nền tảng cho việc phân tích và trực quan hoá chủ đề. Một phần dữ liệu sau khi được xử lý được minh hoạ trong Bảng 1.

Bảng 1
MỘT PHẦN DỮ LIỆU VIDEO YOUTUBE SAU KHI THU THẬP VÀ LÀM SẠCH

Video_ID	Description	Category_ID	Tags
Kglwvq9y7D0	máy phun sương siêu âm tag_congkienthuc	27	shortslshortlcộng kiến thứckiến thức thú vị
hrjU5mEDv34	hotline 0965082424 email youtube tiktok website	17	24h bong dalbóng đáfootballbong da
VhmSYDXYTvA	chúc xem phim vui_về cảm_ơn mọi người xem	22	foodlẩu thực đường phởmukbangmón ăn đường phố

G. Biểu diễn ngữ nghĩa và trích xuất đặc trưng

Sau khi dữ liệu mô tả video được làm sạch, nhóm nghiên cứu tiến hành **mã hoá ngữ nghĩa (semantic embedding)** cho từng mô tả bằng mô hình **Sup-SimCSE-PhoBERT**. Đây là phiên bản kết hợp giữa *PhoBERT* - mô hình ngôn ngữ tiếng Việt được huấn luyện trên tập dữ liệu lớn - và *SimCSE* - kỹ thuật huấn luyện tương phản giúp tăng khả năng biểu diễn ngữ cảnh câu. Mỗi mô tả video được ánh xạ thành một vector 768 chiều, biểu diễn nội dung trong không gian ngữ nghĩa liên tục.

Các vector nhúng được lưu trữ thành ma trận đặc trưng $\mathbf{E} \in \mathbb{R}^{n \times 768}$, trong đó n là số lượng video hợp lệ sau bước tiền xử lý. Bước này giúp chuyển đổi dữ liệu văn bản thô thành dạng có thể áp dụng trực tiếp cho các phương pháp học không giám sát như phân cụm chủ đề.

H. Phân cụm chủ đề bằng BERTopic

Để phát hiện các nhóm chủ đề tiềm ẩn trong mô tả video, nhóm áp dụng **mô hình BERTopic**, kết hợp giữa **giảm chiều UMAP** và **phân cụm HDBSCAN**. Cụ thể:

- **UMAP** (Uniform Manifold Approximation and Projection) được dùng để giảm số chiều của vector nhúng từ 768 xuống còn 15, giúp giữ lại cấu trúc cục bộ trong không gian đặc trưng.
- **HDBSCAN** (Hierarchical Density-Based Spatial Clustering of Applications with Noise) là phương pháp phân cụm theo mật độ, tự động xác định số cụm tối ưu và loại bỏ các điểm nhiễu (*outliers*) có độ tin cậy thấp.

Kết quả huấn luyện trả về các nhãn cụm (`topic_id`), và tên chủ đề (`topic_name`) được tạo tự động dựa trên tập từ khóa đại diện. Các cụm chủ đề phản ánh những hướng nội dung phổ biến trong hệ sinh thái video tiếng Việt, ví dụ như: “review”, “giải trí”, “tin tức”, “thể thao” hay “công nghệ”.

I. Trực quan hóa và đánh giá chất lượng phân cụm

Để đánh giá trực quan và định lượng kết quả, mô hình được trực quan bằng các biểu đồ:

- **Topic Word Scores**: biểu đồ cột thể hiện các từ khóa quan trọng nhất trong mỗi chủ đề.
- **Intertopic Distance Map**: bản đồ khoảng cách giữa các chủ đề trong không gian hai chiều UMAP.
- **HDBSCAN Condensed Tree**: cây cô đọng biểu diễn cấu trúc phân cấp giữa các cụm.

Ngoài ra, nhóm sử dụng **chỉ số Silhouette** để đo lường độ tách biệt giữa các cụm. Các phương pháp **KMeans** và **DBSCAN** cũng được triển khai song song với mục đích *đối chiếu*, nhằm đánh giá mức độ ổn định và chất lượng của mô hình HDBSCAN trong BERTopic.

J. Phân cụm phân cấp và cây chủ đề

Bên cạnh phân cụm mật độ, nhóm nghiên cứu mở rộng với **Agglomerative Clustering (phân cụm phân cấp)** sử dụng phương pháp liên kết Ward. Phương pháp này cho phép mô phỏng cấu trúc phân cấp giữa các nhóm video, thể hiện qua **dendrogram** - cây phân cấp cho 500 mẫu đầu tiên.

Đồng thời, BERTopic được sử dụng để tạo **cây chủ đề phân cấp (Hierarchical Topic Tree)** giúp quan sát mối quan hệ giữa các chủ đề cha - con. Kết quả được lưu thành tệp `hierarchical_topics.html`, cung cấp khả năng tương tác trực quan trong môi trường trình duyệt.

K. So sánh và phân tích kết quả

Cuối cùng, nhóm tiến hành **so sánh định lượng** giữa các phương pháp:

- **KMeans**: số cụm tối ưu xác định bằng hệ số Silhouette cao nhất.
- **DBSCAN**: kiểm tra tỷ lệ nhiễu và số cụm hiệu quả với tham số `eps`, `min_samples`.
- **HDBSCAN**: là phương pháp chính, đạt cân bằng tốt nhất giữa độ chặt cụm và khả năng loại bỏ nhiễu.
- **Agglomerative**: cung cấp góc nhìn phân cấp để minh họa quan hệ giữa các cụm chủ đề.

Kết quả so sánh cho thấy **HDBSCAN** đạt chỉ số Silhouette cao hơn đáng kể, đồng thời giảm thiểu nhiễu trong phân cụm - chứng tỏ tính phù hợp của BERTopic trong bài toán trích xuất và nhóm chủ đề nội dung video tiếng Việt.

V. THỰC NGHIỆM VÀ ĐÁNH GIÁ

A. Thực nghiệm phân cụm chủ đề video YouTube

Bộ dữ liệu sau tiền xử lý gồm **7819 mô tả video tiếng Việt**, mỗi mô tả được mã hóa bằng mô hình **Sup-SimCSE-PhoBERT** thành vector 768 chiều. Các vector nhúng này được sử dụng làm đầu vào cho mô hình **BERTopic**, với các thành phần cấu hình như sau:

- **UMAP**: `n_neighbors = 25`, `n_components = 15`, `metric = cosine`.
- **HDBSCAN**: `min_cluster_size = 18`, `metric = euclidean`, `cluster_selection_method = eom`.
- **Embedding model**: Sup-SimCSE PhoBERT (VoVanPhuc, 2023).

Kết quả mô hình phát hiện được **46 cụm chủ đề** có ý nghĩa sau khi thực hiện gộp chủ đề tự động, loại bỏ khoảng **34.6%** dữ liệu nhiễu (*noise*), còn lại **5.107** mô tả hợp lệ được gán nhãn chủ đề.


Các chủ đề có độ đồng nhất cao, phản ánh rõ ràng nội dung video phổ biến trên nền tảng, chẳng hạn:

- **Chủ đề giải trí**: vlog, review, hài hước, âm nhạc.
- **Chủ đề học tập**: bài giảng, hướng dẫn, kỹ năng mềm.
- **Chủ đề công nghệ**: điện thoại, máy tính.
- **Chủ đề tin tức**: tin tức, bản tin, thời sự.

Kết quả trực quan được thể hiện qua các biểu đồ và bản đồ ngữ nghĩa:

- **Topic Word Scores**: hiển thị tần suất và độ quan trọng của các từ khóa đại diện cho từng chủ đề.
- **Intertopic Distance Map**: biểu diễn mối quan hệ khoảng cách giữa các chủ đề trong không gian UMAP hai chiều.
- **HDBSCAN Condensed Tree**: mô tả cấu trúc phân cấp của các nhóm chủ đề và ngưỡng mật độ tách cụm.
- **Hierarchical Topics**: thể hiện mối quan hệ giữa các chủ đề cha - con, hỗ trợ khám phá cấu trúc tiềm ẩn trong không gian ngữ nghĩa của tập mô tả video.

Hình 2 minh họa biểu đồ ngữ nghĩa giữa các chủ đề sau khi giảm chiều bằng UMAP. Mỗi vòng tròn biểu diễn một chủ đề (**topic**), kích thước thể hiện tỷ lệ số video thuộc chủ đề đó, còn khoảng cách giữa các vòng tròn biểu thị mức độ tương đồng ngữ nghĩa giữa các chủ đề trong không gian biểu diễn Sup-SimCSE-PhoBERT.



Hình 2. Biểu đồ khoảng cách giữa các chủ đề (Intertopic Distance Map).

B. Đánh giá định lượng và so sánh mô hình

Để đánh giá hiệu quả phân cụm, nhóm sử dụng chỉ số **Silhouette Score**, phản ánh độ tách biệt và tính chặt chẽ giữa các cụm. Ba phương pháp phân cụm được so sánh gồm **KMeans**, **DBSCAN** và **HDBSCAN**, với kết quả tóm tắt trong Bảng II.

Bảng II
SO SÁNH CÁC MÔ HÌNH PHÂN CỤM THEO SỐ CỤM, TỶ LỆ NHIỀU VÀ CHỈ SỐ SILHOUETTE.

Mô hình	Số cụm	Tỷ lệ nhiễu (%)	Silhouette Score
KMeans	100	-	0.1378
DBSCAN (eps = 0.3, min_samples = 10)	3	8.24	-
HDBSCAN (BERTopic)	71	34.68	0.1118


Ngoài ra, nhóm cũng triển khai thử nghiệm **Agglomerative Clustering** nhằm trực quan hoá cấu trúc phân cấp giữa các cụm chủ đề. Phương pháp này không được dùng để so sánh chỉ số đánh giá, mà chủ yếu phục vụ mục đích minh họa thông qua **biểu đồ dendrogram**, thể hiện mối quan hệ phân cấp giữa các nhóm chủ đề.

Kết quả thực nghiệm cho thấy **KMeans** đạt giá trị **Silhouette** cao nhất trên tập dữ liệu đã được làm sạch (5.107 mô tả video), cho thấy khả năng phân tách ranh giới cụm rõ ràng hơn khi số cụm được xác định tối ưu. Tuy nhiên, nhược điểm của KMeans là yêu cầu xác định trước số lượng cụm K , điều này khó áp dụng trong các bài toán ngôn ngữ phi cấu trúc, nơi số chủ đề tiềm ẩn không cố định.

Trong khi đó, **HDBSCAN** vẫn thể hiện ưu thế về **tính tự động** và **khả năng phát hiện cụm tự nhiên** mà không cần biết trước số cụm. Mặc dù điểm Silhouette thấp hơn đôi chút so với KMeans, HDBSCAN cho phép nhận diện các cụm có mật độ khác nhau và loại bỏ hiệu quả các mô tả nhiễu, phù hợp hơn với đặc trưng dữ liệu văn bản ngắn như mô tả video YouTube.

C. Phân tích phân cấp và cây chủ đề

Để khám phá cấu trúc quan hệ giữa các nhóm nội dung, nhóm triển khai thêm **Agglomerative Clustering** với phương pháp liên kết Ward. Hình 3 trình bày cây phân cấp (dendrogram) của 500 mẫu đầu tiên, cho thấy sự hình thành các nhóm video gần nhau về ngữ nghĩa.



Hình 3. Cấu trúc phân cấp giữa các nhóm video (Agglomerative Dendrogram).

Ngoài ra, BERTopic cung cấp **cây chủ đề phân cấp (Hierarchical Topic Tree)** được trực quan hóa trong tệp `hierarchical_topics.html`. Biểu đồ này cho phép người dùng tương tác để quan sát mối quan hệ giữa các chủ đề cha - con, hỗ trợ phân tích sâu hơn về cấu trúc chủ đề trong tập dữ liệu.

D. Tổng kết thực nghiệm

Tổng hợp kết quả cho thấy:

- Phương pháp **Sup-SimCSE-PhoBERT + BERTopic (HDBSCAN)** mang lại kết quả ổn định và rõ ràng nhất, thể hiện qua chỉ số Silhouette cao và bản đồ chủ đề trực quan.
- **KMeans** hoạt động hiệu quả trên dữ liệu có cấu trúc rõ ràng, nhưng hạn chế với dữ liệu ngôn ngữ tự nhiên do yêu cầu xác định số cụm trước.
- **DBSCAN** có khả năng loại bỏ nhiễu nhưng thường tạo ra quá ít cụm hoặc tách cụm chưa hợp lý khi dữ liệu phân tán.
- **Agglomerative Clustering** cung cấp cái nhìn phân cấp, hỗ trợ phân tích đa tầng giữa các nhóm chủ đề.

Nhìn chung, kết quả thực nghiệm khẳng định tính phù hợp của hướng tiếp cận dựa trên **BERTopic và HDBSCAN** trong bài toán phân tích chủ đề nội dung video tiếng Việt - đặc biệt hữu ích cho các ứng dụng gợi ý nội dung, phân loại video, và đánh giá xu hướng truyền thông trực tuyến.

VI. THẢO LUẬN

Kết quả thực nghiệm cho thấy phương pháp kết hợp giữa **Sup-SimCSE-PhoBERT, UMAP và HDBSCAN** mang lại hiệu quả cao trong việc phát hiện các cụm chủ đề tiềm ẩn từ dữ liệu mô tả video trên YouTube. Phần này thảo luận chi tiết về hiệu quả biểu diễn ngữ nghĩa, chất lượng phân cụm, những hạn chế và định hướng phát triển tiếp theo.

A. Hiệu quả biểu diễn ngữ nghĩa và phân cụm chủ đề

Việc sử dụng mô hình **Sup-SimCSE-PhoBERT** giúp tối ưu hóa khả năng biểu diễn ngữ nghĩa tiếng Việt, nhờ được huấn luyện theo hướng học giám sát trên dữ liệu tương đồng về ngữ nghĩa. So với các mô hình thuần PhoBERT, Sup-SimCSE-PhoBERT thể hiện khả năng phân tách các mô tả có chủ đề gần nhau một cách rõ ràng hơn trong không gian vector 768 chiều. Sau khi giảm chiều bằng **UMAP**, cấu trúc ngữ nghĩa được bảo toàn và thể hiện rõ qua các nhóm phân cụm trên bản đồ Intertopic Distance Map.

Với **HDBSCAN**, các cụm chủ đề được hình thành một cách tự nhiên mà không cần xác định trước số lượng, phản ánh đúng đặc tính phi cấu trúc của dữ liệu ngôn ngữ. Kết quả cho thấy mô hình phát hiện được **71 cụm chủ đề**, sau khi tự động gộp và lọc nhiễu còn **46 cụm có ý nghĩa**, loại bỏ khoảng 34,68% dữ liệu không phù hợp. Điều này cho thấy sự linh hoạt của HDBSCAN trong việc thích ứng với độ đa dạng ngữ nghĩa giữa các mô tả video.

B. Đánh giá định lượng và so sánh mô hình

Khi so sánh các phương pháp phân cụm khác nhau, **KMeans** đạt giá trị **Silhouette** cao nhất trên tập dữ liệu đã làm sạch (5.107 mô tả), phản ánh khả năng phân tách ranh giới rõ ràng giữa các cụm. Tuy nhiên, KMeans yêu cầu xác định trước số cụm K , điều này không phù hợp với các bài toán ngôn ngữ phi cấu trúc khi số chủ đề tiềm ẩn không cố định.

HDBSCAN, mặc dù có điểm Silhouette thấp hơn một chút, lại thể hiện ưu thế về khả năng tự động xác định số cụm và loại bỏ nhiễu, giúp phát hiện được những cụm có mật độ khác nhau và phản ánh chính xác hơn các mối quan hệ ngữ nghĩa. Ngược lại, **DBSCAN** cho kết quả không ổn định và ít cụm hơn do độ nhạy cao với tham số ϵ . Nhìn chung, sự kết hợp giữa Sup-SimCSE-PhoBERT và HDBSCAN cho kết quả tốt nhất về mặt cân bằng giữa tính ngữ nghĩa và độ khái quát của cụm chủ đề.

C. Ý nghĩa và khả năng ứng dụng

Phân tích cụm chủ đề video YouTube giúp nhận diện các hướng truyền thông, chủ đề nội dung phổ biến và phản ánh xu hướng tiêu dùng thông tin của người dùng. Các cụm thu được có thể được sử dụng để:

- **Đánh giá chiến dịch truyền thông:** Xác định mức độ tập trung chủ đề, mức lan tỏa và phản ứng của khán giả theo nhóm nội dung.
- **Tối ưu đề xuất nội dung:** Hỗ trợ hệ thống gợi ý video dựa trên cụm ngữ nghĩa tương đồng.
- **Nghiên cứu hành vi người dùng:** Phân tích mối quan hệ giữa mô tả nội dung, xu hướng ngôn ngữ và mức độ tương tác.

Những kết quả này không chỉ có giá trị trong phân tích truyền thông kỹ thuật số mà còn mở rộng tiềm năng ứng dụng trong các hệ thống gợi ý, phân tích cảm xúc hoặc giám sát xu hướng xã hội trên nền tảng trực tuyến.

D. Giới hạn và hướng phát triển

Mặc dù mô hình đạt kết quả khả quan, vẫn tồn tại một số hạn chế:

- Dữ liệu mô tả video có độ dài và mức độ chi tiết không đồng đều, ảnh hưởng đến chất lượng biểu diễn ngữ nghĩa.
- Mô hình chưa xét đến yếu tố **thời gian** hoặc **ngữ cảnh kênh**, nên chưa phản ánh được sự thay đổi chủ đề theo xu hướng.
- Việc đặt tên cụm hiện dựa vào gợi ý tự động của BERTopic và cần được kiểm chứng thủ công để đảm bảo tính ngữ nghĩa.

Hướng mở rộng trong tương lai bao gồm:

- Kết hợp thêm **phân tích cảm xúc** để đánh giá thái độ người xem theo từng cụm nội dung.
- Mở rộng sang **phân tích động (dynamic topic modeling)** nhằm theo dõi xu hướng chủ đề theo thời gian.
- Tích hợp thêm dữ liệu từ bình luận hoặc tiêu đề video để tăng tính khái quát và độ tin cậy của mô hình.

Tổng thể, nghiên cứu cho thấy cách tiếp cận kết hợp **Sup-SimCSE-PhoBERT + UMAP + HDBSCAN** là hướng tiếp cận hiệu quả cho bài toán phân tích chủ đề tiếng Việt từ dữ liệu phi cấu trúc trên YouTube, góp phần hỗ trợ các ứng dụng thực tiễn trong truyền thông, marketing và phân tích dữ liệu xã hội học.

VII. KẾT LUẬN

Nghiên cứu này đã đề xuất và thực nghiệm một quy trình **Phân tích chủ đề video YouTube tiếng Việt** dựa trên mô hình biểu diễn ngữ nghĩa **Sup-SimCSE-PhoBERT** kết hợp với **UMAP** và **HDBSCAN**. Quy trình được thiết kế theo các bước: thu thập dữ liệu, tiền xử lý ngôn ngữ, mã hóa mô tả video, giảm chiều đặc trưng, phân cụm chủ đề và trực quan hóa kết quả. Mô hình Sup-SimCSE-PhoBERT giúp tạo ra các vector ngữ nghĩa giàu thông tin, phản ánh tốt mối quan hệ nội dung giữa các video, trong khi UMAP và HDBSCAN hỗ trợ phát hiện các nhóm chủ đề một cách tự động và linh hoạt.

Các mô hình được huấn luyện trên toàn bộ 7.819 mô tả video, tuy nhiên quá trình đánh giá và so sánh hiệu quả phân cụm chỉ thực hiện trên 5.107 mô tả hợp lệ sau khi loại bỏ nhiễu (topic_id = -1) để đảm bảo tính nhất quán trong phép đo Silhouette. Các cụm được hình thành rõ ràng trong không gian ngữ nghĩa, thể hiện khả năng của mô hình trong việc tách biệt các nội dung tương đồng. So sánh với các phương pháp đối chứng, **KMeans** đạt giá trị **Silhouette** cao nhất, phản ánh độ tách biệt tốt giữa các cụm, trong khi **HDBSCAN** cho thấy ưu thế về khả năng tự động xác định số cụm và loại bỏ nhiễu. Sự kết hợp giữa hai hướng tiếp cận - học biểu diễn ngữ nghĩa và phân cụm mật độ - đã chứng minh hiệu quả cao đối với dữ liệu phi cấu trúc như mô tả video.

Về mặt ứng dụng, nghiên cứu mở ra nhiều hướng triển khai tiềm năng trong các lĩnh vực:

- **Phân tích chiến dịch truyền thông:** đánh giá mức độ tập trung và lan tỏa chủ đề theo nhóm nội dung.
- **Đề xuất nội dung cá nhân hóa:** cải thiện khả năng gợi ý video dựa trên cụm chủ đề ngữ nghĩa.
- **Giám sát xu hướng xã hội:** phát hiện và theo dõi chủ đề thịnh hành trên nền tảng YouTube theo thời gian.

Mặc dù đạt được kết quả khả quan, nghiên cứu vẫn còn một số hạn chế như chưa xét đến yếu tố thời gian, tương tác người xem hoặc dữ liệu đa phương thức (bình luận, tiêu đề, v.v). Trong tương lai, hướng nghiên cứu có thể được mở rộng

sang **Phân tích cảm xúc và chủ đề trong bình luận YouTube** nhằm đánh giá mức độ lan tỏa và phản hồi của công chúng đối với các chiến dịch truyền thông. Việc kết hợp mô hình phân tích cảm xúc (sentiment analysis) với **BERTopic** sẽ giúp không chỉ nhận diện các nhóm chủ đề thảo luận chính, mà còn đo lường **cảm xúc tích cực, tiêu cực hoặc trung lập** của người dùng đối với từng chủ đề. Cách tiếp cận này đặc biệt hữu ích cho doanh nghiệp và nhà nghiên cứu truyền thông khi muốn **đánh giá hiệu quả chiến dịch, tối ưu thông điệp quảng bá**, và theo dõi sự thay đổi trong thái độ công chúng theo thời gian. Bên cạnh đó, có thể tích hợp thêm các kỹ thuật học sâu như **Graph Neural Networks (GNNs)** hoặc **transformer đa phương thức (multimodal transformers)** để mô hình hóa đồng thời thông tin từ văn bản, âm thanh và hình ảnh trong video, qua đó cung cấp cái nhìn toàn diện hơn về tác động truyền thông trên nền tảng YouTube.

Tổng kết lại, công trình này chứng minh tính khả thi của việc ứng dụng **Sup-SimCSE-PhoBERT** trong trích xuất ngữ nghĩa và phát hiện cụm chủ đề tiếng Việt. Kết quả đạt được không chỉ góp phần khẳng định hiệu quả của các phương pháp biểu diễn ngôn ngữ tiên tiến trong phân tích nội dung số, mà còn tạo tiền đề cho các ứng dụng thực tế trong truyền thông, marketing và nghiên cứu xã hội học trên nền tảng YouTube.

TÀI LIỆU THAM KHẢO

- [1] Z. Chen, C. Mi, S. Duo, J. He, and Y. Zhou, “ClusTop: An unsupervised and integrated text clustering and topic extraction framework,” Jan. 2023, arXiv:2301.00818 [cs]. [Online]. Available: <http://arxiv.org/abs/2301.00818>
- [2] R. Albalawi, T. H. Yeap, and M. Benyoucef, “Using Topic Modeling Methods for Short-Text Data: A Comparative Analysis,” *Frontiers in Artificial Intelligence*, vol. 3, Jul. 2020, publisher: Frontiers. [Online]. Available: <https://www.frontiersin.org/journals/artificial-intelligence/articles/10.3389/frai.2020.00042/full>
- [3] D. V.-T. Nguyen, T. V. Huynh, K. V. Nguyen, and N. L.-T. Nguyen, “Transformer-Based Contextualized Language Models Joint with Neural Networks for Natural Language Inference in Vietnamese,” Nov. 2024, arXiv:2411.13407 [cs] version: 2. [Online]. Available: <http://arxiv.org/abs/2411.13407>
- [4] Q. Wang and B. Ma, “Enhancing BERTopic with Pre-Clustered Knowledge: Reducing Feature Sparsity in Short Text Topic Modeling,” *Journal of Data Analysis and Information Processing*, vol. 12, no. 4, pp. 597–611, Nov. 2024, publisher: Scientific Research Publishing. [Online]. Available: <https://www.scirp.org/journal/paperinformation?paperid=137513>
- [5] “K-Means Clustering là gì? Tìm hiểu A-Z về thuật toán K-Means,” Mar. 2025, section: Trí tuệ nhân tạo (AI). [Online]. Available: <https://interdata.vn/blog/k-means-clustering-la-gi/>
- [6] “15.1. Phương pháp phân cụm dựa trên mật độ (Density-Based Clustering) — Deep AI KhanhBlog.” [Online]. Available: https://phamdinhhkhanh.github.io/deepai-book/ch_ml/DBSCAN.html
- [7] “Understanding HDBSCAN: A Deep Dive into Hierarchical Density-Based Clustering.” [Online]. Available: <https://arize.com/blog-course/understanding-hdbscan-a-deep-dive-into-hierarchical-density-based-clustering/>
- [8] L. McInnes, J. Healy, and J. Melville, “UMAP: Uniform Manifold Approximation and Projection for Dimension Reduction,” Sep. 2020, arXiv:1802.03426 [stat]. [Online]. Available: <http://arxiv.org/abs/1802.03426>

PROJECT 2B:

PHÂN LOẠI VIDEO YOUTUBE THEO THỂ LOẠI DỰA TRÊN MÔ TẢ CỦA VIDEO

1st Hà Thế Anh, 2nd Nguyễn Nhật Nam, 3rd Hoàng Quang Minh
and Le Nhat Tung

HUTECH University, Vietnam

{hatheanh012004, nguyennhatnam01012004, hoangquangminh130804}@gmail.com, and lenhattung@hutech.edu.vn

TÓM TẮT NỘI DUNG

Trong thời đại bùng nổ nội dung số, YouTube trở thành nền tảng lưu trữ và chia sẻ video lớn nhất thế giới, với lượng dữ liệu khổng lồ được tạo ra mỗi ngày. Việc tự động phân loại video theo thể loại giúp cải thiện hệ thống gợi ý, quản lý và phân tích hành vi người dùng một cách hiệu quả hơn.

Đề tài này tập trung vào bài toán **phân loại video YouTube theo thể loại dựa trên phần mô tả (description)**. Dữ liệu được **thu thập trực tiếp bằng YouTube Data API**, bao gồm các trường *video_id*, *title*, *description*, *category_id*, cùng các chỉ số tương tác như *view_count*, *like_count* và *comment_count*. Sau khi làm sạch, loại bỏ mô tả ngắn và lọc ngôn ngữ không phải tiếng Việt, dữ liệu được chuẩn hóa, tách từ bằng **Underthesea** và loại bỏ **stopwords** chung lẫn đặc thù theo từng thể loại, thu được hơn **6.750 bản ghi hợp lệ**.

Trên tập dữ liệu này, nhóm tiến hành trích xuất đặc trưng văn bản bằng các phương pháp **TF-IDF**, **PhoBERT**, **BGE**, **E5** và **Sup-SimCSE** **PhoBERT**, kết hợp huấn luyện các mô hình học máy **Logistic Regression**, **Linear SVM**, **Random Forest** và **Naive Bayes**. Các mô hình được đánh giá thông qua **Cross-Validation 5-fold** với các chỉ số **Accuracy**, **Precision**, **Recall** và **F1-Score**.

Kết quả cho thấy mô hình **Random Forest với TF-IDF** đạt hiệu suất cao nhất với $Accuracy = 0.744$ và $Weighted F1 = 0.737$, trong khi **Sup-SimCSE PhoBERT** thể hiện khả năng hiểu ngữ nghĩa tốt hơn với $Accuracy = 0.647$ và $F1 = 0.561$. Nghiên cứu chứng minh rằng các mô hình học máy truyền thống (traditional machine learning models) kết hợp biểu diễn tần suất vẫn có ưu thế. trong bài toán phân loại văn bản tiếng Việt, đồng thời mở ra hướng phát triển cho các ứng dụng xử lý ngôn ngữ tự nhiên và gợi ý nội dung thông minh trên nền tảng YouTube.

TỪ KHÓA

YouTube API, Text Classification, Vietnamese NLP, TF-IDF, PhoBERT, BGE, E5, Sup-SimCSE, Machine Learning, SVM, Embedding.

I. GIỚI THIỆU

Trong thời đại dữ liệu số phát triển mạnh mẽ, các nền tảng trực tuyến như YouTube đóng vai trò trung tâm trong việc chia sẻ và lan tỏa thông tin toàn cầu. Mỗi ngày có hàng triệu video được đăng tải, tạo nên một kho dữ liệu khổng lồ bao gồm nhiều thể loại như âm nhạc, giải trí, giáo dục, thể thao hay tin tức. Tuy nhiên, sự đa dạng và khối lượng dữ liệu khổng lồ này khiến việc phân loại, gợi ý và quản lý nội dung trở thành một thách thức lớn đối với các hệ thống tự động.

Trên YouTube, mỗi video đều đi kèm phần **mô tả (description)** nơi chứa thông tin tóm tắt, ngữ cảnh và từ khóa liên quan. Phần mô tả này là nguồn dữ liệu ngôn ngữ quan trọng, phản ánh rõ chủ đề và mục đích của video. Do đó, việc khai thác mô tả để **tự động phân loại thể loại video** không chỉ mang ý nghĩa kỹ thuật mà còn có giá trị thực tiễn cao trong các hệ thống đề xuất nội dung, quảng cáo và phân tích xu hướng.

Tuy nhiên, bài toán phân loại nội dung YouTube tiếng Việt vẫn còn nhiều thách thức. Phần lớn mô tả video được viết không theo chuẩn ngôn ngữ, chứa nhiều ký hiệu, từ viết tắt, hashtag, hoặc kết hợp tiếng Anh và tiếng Việt. Ngoài ra, dữ liệu cũng có tính **mất cân bằng mạnh giữa các thể loại**, trong khi độ dài và phong cách mô tả thay đổi lớn giữa các nhóm chủ đề. Điều này đòi hỏi quy trình tiền xử lý và lựa chọn mô hình học máy phù hợp để đảm bảo hiệu quả phân loại.

Trong nghiên cứu này, nhóm đề xuất quy trình **phân loại video YouTube theo thể loại dựa trên mô tả tiếng Việt**, sử dụng dữ liệu được **thu thập tự động qua YouTube Data API**. Tập dữ liệu gồm các trường thông tin: *video_id*, *title*, *description*, *category_id*, *tags*, *view_count*, *like_count* và *comment_count*. Sau khi làm sạch và chuẩn hóa, dữ liệu được xử lý bằng **Underthesea** để tách từ và loại bỏ **stopwords** chung lẫn đặc thù theo từng thể loại, thu được hơn **6.750 mẫu hợp lệ**.

Trên cơ sở dữ liệu đó, nhóm thực hiện các phương pháp biểu diễn văn bản gồm **TF-IDF**, **PhoBERT**, **BGE**, **E5** và **Sup-SimCSE PhoBERT**, đồng thời huấn luyện các mô hình **Logistic Regression**, **Linear SVM**, **Random Forest** và **Naive Bayes**. Các mô hình được đánh giá theo **Accuracy**, **Precision**, **Recall** và **F1-Score**, kèm theo kiểm định chéo 5-fold để bảo đảm tính ổn định.

Mục tiêu của nghiên cứu bao gồm:

- Xây dựng quy trình thu thập và tiền xử lý dữ liệu mô tả video tiếng Việt.
- So sánh hiệu quả của các phương pháp biểu diễn văn bản và mô hình học máy phổ biến.
- Đánh giá hiệu suất từng mô hình thông qua các chỉ số thống kê và kiểm định chéo.
- Đề xuất mô hình tối ưu cho bài toán phân loại thể loại video tiếng Việt trên YouTube.

Nghiên cứu kỳ vọng mang lại góc nhìn mới về khả năng ứng dụng các mô hình ngôn ngữ hiện đại trong **phân tích và xử lý dữ liệu ngôn ngữ tiếng Việt**, đồng thời đóng góp cơ sở thực nghiệm cho việc phát triển các hệ thống gợi ý và quản lý nội dung video thông minh trong tương lai.

II. CÁC NGHIÊN CỨU LIÊN QUAN

A. Phân loại văn bản và bài toán gán nhãn nội dung

Phân loại văn bản (Text Classification) là một hướng nghiên cứu cốt lõi của xử lý ngôn ngữ tự nhiên (NLP), trong đó mô hình học máy được huấn luyện để gán nhãn chủ đề cho văn bản đầu vào. Các phương pháp truyền thống như **Naive Bayes**, **Support Vector Machine (SVM)** và **Logistic Regression** đã được áp dụng thành công trong nhiều tập dữ liệu tin tức và bình luận [1], [2]. Đối với nền tảng YouTube, nhiều nghiên cứu chỉ ra rằng phần mô tả video (description) mang giá trị ngữ nghĩa cao, giúp mô hình xác định thể loại chính xác hơn so với tiêu đề hoặc thẻ (tags) [3].

B. Tiền xử lý và đặc trưng ngôn ngữ tiếng Việt

Đặc thù ngôn ngữ tiếng Việt với nhiều dấu thanh, từ ghép, và cấu trúc không thống nhất khiến giai đoạn tiền xử lý đóng vai trò đặc biệt quan trọng. Các công cụ như **Underthesea** [4] và **PyVi** [5] đã trở thành lựa chọn phổ biến cho tách từ, chuẩn hóa văn bản và loại bỏ từ dừng. Ngoài ra, một số nghiên cứu đề xuất mở rộng danh sách stopwords theo miền ứng dụng cụ thể, chẳng hạn với dữ liệu YouTube, việc loại bỏ các từ như “video”, “kênh”, “subscribe” hay “official” giúp cải thiện hiệu quả mô hình [6].

C. Biểu diễn văn bản truyền thống: TF-IDF và Bag-of-Words

Trước khi các mô hình ngữ nghĩa ra đời, **TF-IDF** và **Bag-of-Words (BoW)** là hai phương pháp phổ biến nhất trong trích xuất đặc trưng văn bản. TF-IDF đo lường tầm quan trọng của từng từ trong tập dữ liệu, từ đó giúp mô hình học được các đặc trưng phân biệt giữa các chủ đề [7], [8]. Trong các nghiên cứu tiếng Việt, việc kết hợp TF-IDF với các thuật toán tuyến tính như SVM đã cho kết quả tốt trên các tập dữ liệu tin tức hoặc mạng xã hội [9].

D. Biểu diễn ngữ nghĩa hiện đại: BERT và PhoBERT

Sự xuất hiện của mô hình **BERT** [10] đã thay đổi hoàn toàn cách biểu diễn ngôn ngữ trong NLP, khi cho phép mô hình học ngữ cảnh hai chiều của từ trong câu. Với tiếng Việt, **PhoBERT** [11] là phiên bản huấn luyện đặc thù dựa trên BERT, sử dụng hơn 20GB dữ liệu văn bản tiếng Việt. Các nghiên cứu chứng minh PhoBERT vượt trội hơn Word2Vec và FastText trong các tác vụ phân loại, trích xuất và cảm xúc [12].

E. Embedding nâng cao: BGE, E5 và Sup-SimCSE

Gần đây, các mô hình embedding thể hệ mới như **BAAI General Embedding (BGE)** [13], **E5** [14] và **Sup-SimCSE** [15] đã cho phép biểu diễn văn bản ở mức ngữ nghĩa sâu hơn. Các mô hình này sử dụng kỹ thuật học tương phản (contrastive learning) nhằm tối ưu khoảng cách trong không gian embedding, giúp các văn bản có cùng chủ đề được biểu diễn gần nhau. Sup-SimCSE PhoBERT đặc biệt hiệu quả trong dữ liệu tiếng Việt, nơi cùng một chủ đề có thể xuất hiện dưới nhiều cách diễn đạt khác nhau.

F. Tổng hợp và khoảng trống nghiên cứu

Tổng quan các công trình cho thấy, hầu hết nghiên cứu về phân loại nội dung tiếng Việt trên YouTube tập trung vào tiêu đề hoặc bình luận, trong khi phần mô tả vốn chứa thông tin ngữ nghĩa giàu và ổn định hơn lại chưa được khai thác sâu. Ngoài ra, chưa có nhiều công trình so sánh toàn diện giữa các kỹ thuật biểu diễn từ truyền thống (TF-IDF) và các mô hình embedding ngữ cảnh hiện đại (PhoBERT, BGE, Sup-SimCSE) trên cùng một tập dữ liệu tiếng Việt thu thập trực tiếp qua API. Đây chính là khoảng trống mà nghiên cứu này hướng tới nhằm đánh giá, so sánh và xác định phương pháp tối ưu cho bài toán phân loại thể loại video YouTube tiếng Việt.


III. PHƯƠNG PHÁP NGHIÊN CỨU

A. Quy trình tổng thể

Nghiên cứu được triển khai theo một quy trình gồm bốn giai đoạn chính, được minh họa trong Hình 1. Cụ thể:

- 1) **Thu thập và tiền xử lý dữ liệu:** Dữ liệu được thu thập tự động thông qua **YouTube API**, bao gồm mô tả của các video tiếng Việt. Sau đó, dữ liệu được làm sạch bằng cách loại bỏ ký tự đặc biệt, URL, từ dư thừa, chuyển đổi chữ thường và tách từ bằng công cụ *Underthesea*. Cuối cùng, các từ dừng (stopwords) được loại bỏ để đảm bảo chất lượng ngữ nghĩa.
- 2) **Biểu diễn văn bản (Embedding):** Phần mô tả video sau khi xử lý được biến đổi thành vector số bằng nhiều phương pháp khác nhau, bao gồm **TF-IDF**, **PhoBERT**, **BGE**, **E5**, và **Sup-SimCSE PhoBERT**. Các vector này thể hiện đặc trưng ngữ nghĩa của văn bản, phục vụ cho giai đoạn huấn luyện mô hình học máy.
- 3) **Chuẩn hóa và huấn luyện mô hình:** Với các embedding ngữ nghĩa (PhoBERT, BGE, E5, Sup-SimCSE), đặc trưng đầu ra được chuẩn hóa bằng **StandardScaler** để đưa các giá trị về cùng thang đo. Tiếp theo, các mô hình học máy **Logistic Regression (LR)**, **Linear SVM**, **Random Forest (RF)** và **Naive Bayes (NB)** được huấn luyện nhằm phân loại thể loại video dựa trên đặc trưng vector. Hiệu quả mô hình được đánh giá thông qua **Cross-Validation 5-fold** để đảm bảo độ ổn định và khả năng tổng quát hóa.
- 4) **Đánh giá và phân tích kết quả:** Sau khi huấn luyện, mô hình được kiểm thử trên tập dữ liệu độc lập (20%) và so sánh theo các chỉ số **Accuracy**, **Macro F1**, **Weighted F1** và **Confusion Matrix**. Các kết quả được tổng hợp, trực quan hóa và thảo luận nhằm xác định phương pháp biểu diễn văn bản và mô hình học máy đạt hiệu suất cao nhất.

Quy trình này bảo đảm tính hệ thống, giúp nhóm nghiên cứu đánh giá toàn diện tác động của từng phương pháp embedding đối với hiệu quả phân loại video YouTube.



Hình 1. Quy trình tổng thể của phương pháp nghiên cứu.

B. Tiền xử lý và biểu diễn dữ liệu

Do mô tả video trên YouTube thường chứa ký hiệu, hashtag, emoji và nhiều ngôn ngữ khác nhau, nên bước tiền xử lý đóng vai trò quan trọng nhằm loại bỏ nhiễu và đảm bảo dữ liệu đầu vào đồng nhất. Quy trình xử lý được thực hiện như sau:

- 1) Loại bỏ mô tả trống hoặc ngắn hơn 20 ký tự.
- 2) Chuẩn hóa văn bản: chuyển thành chữ thường, xóa ký tự đặc biệt, URL, emoji và các cụm quảng bá.

- 3) Lọc ngôn ngữ bằng `langdetect`, chỉ giữ lại văn bản tiếng Việt.
- 4) Tách từ bằng `Underthesea`, chuẩn hóa thành dạng “từ_ghép”.
- 5) Loại bỏ stopwords chung và riêng cho từng thể loại video.

Sau bước này, dữ liệu còn 6.750 mô tả hợp lệ, được lưu dưới dạng văn bản đã tách từ và gán nhãn thể loại.

Biểu diễn văn bản: Mỗi mô tả được biểu diễn thành vector số theo hai hướng chính:

- **TF-IDF (Term Frequency – Inverse Document Frequency):** Là phương pháp dựa trên tần suất từ, phản ánh mức độ quan trọng của từ trong tập dữ liệu:

$$\text{TF-IDF}(t, d) = \text{TF}(t, d) \times \log \frac{N}{DF(t)}$$

TF-IDF hiệu quả cao với văn bản ngắn và có nhiều từ khóa đặc trưng.

- **Các mô hình ngữ nghĩa (Semantic Embedding):** Bao gồm PhoBERT, BGE, E5 và Sup-SimCSE PhoBERT. Các mô hình này biểu diễn văn bản dưới dạng vector trong không gian ngữ nghĩa, giúp nắm bắt mối quan hệ giữa các từ và ý nghĩa của toàn câu. Sup-SimCSE PhoBERT là phiên bản cải tiến của PhoBERT, được huấn luyện bằng học tương phản có giám sát, giúp tăng khả năng phân biệt các chủ đề gần nghĩa.

C. Mô hình học máy

Bốn mô hình học máy được sử dụng để huấn luyện và so sánh hiệu quả phân loại:

- **Logistic Regression (LR):** mô hình tuyến tính đơn giản, dự đoán xác suất mỗi lớp bằng hàm sigmoid.
- **Linear SVM:** tìm siêu phẳng tối ưu trong không gian cao chiều; đặc biệt phù hợp với TF-IDF và embedding vector.
- **Random Forest (RF):** mô hình tổng hợp nhiều cây quyết định, cho phép học quan hệ phi tuyến giữa các đặc trưng.
- **Naive Bayes (NB):** dựa trên định lý Bayes, giả định độc lập giữa các đặc trưng; hiệu quả với dữ liệu tần suất như TF-IDF.

Đối với các mô hình tuyến tính (LR, SVM), dữ liệu embedding được chuẩn hóa bằng **StandardScaler** để đảm bảo các đặc trưng có cùng thang đo, giúp mô hình hội tụ ổn định hơn.

D. Đánh giá mô hình

Mô hình được đánh giá bằng hai giai đoạn:

- **Cross-Validation 5-fold:** chia tập huấn luyện thành 5 phần; mỗi lần 4 phần dùng huấn luyện, 1 phần kiểm định. Kết quả trung bình qua 5 lần phản ánh tính ổn định của mô hình.
- **Kiểm thử độc lập (Test Set 20%):** đánh giá hiệu suất tổng thể trên tập dữ liệu chưa thấy trước đó.

Các chỉ số đánh giá gồm:

Accuracy, Precision, Recall, F1-score

Trong đó:

- **Accuracy:** tỷ lệ dự đoán đúng trên tổng số mẫu.
- **Precision:** tỷ lệ dự đoán đúng trong các mẫu được gán nhãn dương tính.
- **Recall:** tỷ lệ các mẫu dương tính được phát hiện đúng.
- **F1-Score:** trung bình điều hòa giữa Precision và Recall.

Do dữ liệu mất cân bằng giữa các thể loại, chỉ số **Weighted F1** được dùng làm thước đo chính, phản ánh hiệu quả tổng thể của mô hình.

E. Tóm tắt

Phương pháp nghiên cứu kết hợp giữa biểu diễn tần suất (TF-IDF) và biểu diễn ngữ nghĩa (PhoBERT, BGE, E5, Sup-SimCSE) nhằm đánh giá toàn diện khả năng phân loại mô tả video tiếng Việt. Sự kết hợp này cho phép so sánh hiệu quả giữa các hướng tiếp cận truyền thống và hiện đại, làm cơ sở cho phần thực nghiệm và đánh giá kết quả ở chương tiếp theo.

IV. XÂY DỰNG VÀ CHUẨN BỊ DỮ LIỆU

A. Tổng quan dữ liệu ban đầu

Dữ liệu được thu thập thông qua **YouTube Data API v3** bằng cách truy vấn các video có ngôn ngữ tiếng Việt trên nhiều lĩnh vực khác nhau như âm nhạc, thể thao, du lịch, công nghệ, giáo dục và giải trí. Mỗi bản ghi trong tập dữ liệu chứa các thông tin cơ bản về video gồm: mã định danh (`video_id`), tiêu đề (`title`), mô tả (`description`), ngày đăng (`published_at`), tên kênh (`channel`), mã thể loại (`category_id`), thẻ (`tags`), cùng các chỉ số tương tác như lượt xem, lượt thích và bình luận.

Tổng cộng thu được **10000 video** thuộc **15 thể loại chính**, phản ánh sự đa dạng nội dung của YouTube Việt Nam. Tuy nhiên, dữ liệu ban đầu có sự mất cân bằng đáng kể giữa các nhóm, trong đó nhóm **People & Blogs** (22) chiếm tỉ lệ lớn nhất (hơn 25% tổng số video).

Bảng I
PHÂN BỐ SỐ LƯỢNG VIDEO THEO THỂ LOẠI (TRƯỚC KHI LÀM SẠCH)

Category ID	Tên thể loại	Số lượng video
22	Con người và Blog	2 565
24	Giải trí tổng hợp	1 089
25	Tin tức và Chính trị	812
28	Khoa học và Công nghệ	610
17	Thể thao	511
1	Phim và Hoạt hình	473
27	Giáo dục	359
26	Hướng dẫn và Phong cách sống	357
20	Trò chơi điện tử	385
10	Âm nhạc	335
19	Du lịch và Sự kiện	262
2	Ô tô và Phương tiện	204
23	Hài hước	18
15	Động vật và Thú cưng	13
29	Tổ chức phi lợi nhuận và Hoạt động xã hội	9

B. Tiền xử lý dữ liệu

Để đảm bảo chất lượng dữ liệu đầu vào cho mô hình học máy, quy trình làm sạch được thực hiện theo các bước sau:

- 1) **Giữ lại các cột quan trọng:** title, description, category_id.
- 2) **Loại bỏ mô tả rỗng hoặc có độ dài dưới 20 ký tự.**
- 3) **Làm sạch mô tả:** Chuẩn hóa văn bản về chữ thường, loại bỏ URL, email, emoji, hashtag, ký tự đặc biệt và các đoạn quảng bá không liên quan như “đăng ký kênh”, “subscribe”, “fanpage”, “official”, ...
- 4) **Lọc ngôn ngữ:** Chỉ giữ lại các mô tả tiếng Việt sử dụng thư viện langdetect.
- 5) **Tách từ (Tokenization):** Áp dụng thư viện Underthesea để tách từ tiếng Việt và chuẩn hóa thành dạng gạch dưới (_).
- 6) **Loại bỏ stopwords chung:** Sử dụng danh sách stopwords tiếng Việt kết hợp mở rộng thêm các từ phổ biến không mang thông tin phân loại như “video”, “kênh”, “like”, “share”, “xem”, “facebook”, ...
- 7) **Stopword riêng cho từng thể loại:** Thiết lập 15 bộ stopwords riêng biệt cho từng category_id. Ví dụ: Music (10) loại bỏ các từ “mv”, “official”, “beat”, trong khi Gaming (20) loại bỏ “mod”, “donate”, “discord”.
- 8) **Loại trùng lặp và mô tả trống sau khi lọc.**

Sau quá trình tiền xử lý, thu được **6 750 mô tả hợp lệ** thuộc 15 thể loại khác nhau, lưu trong hai cột chính: tokenized_text (mô tả đã tách từ) và category_id (nhãn thể loại).

Bảng II
VÍ DỤ MỘT PHẦN DỮ LIỆU SAU XỬ LÝ

STT	tokenized_text (mô tả đã xử lý)	category_id
1	hướng_dẫn cắm_trại cuối_tuần tại đà_lạt trải_nghiem ẩm_thực và du_lịch sinh_thải	19
2	bản_cover nhạc trẻ hay_nhất năm 2024 với giai_điệu sôi_động và cảm_xúc	10
3	clip ghi_lại khoảnh_khắc thi_đấu bóng_đá giữa u23 việt_nam và thái_lan tại sea_games	17
4	cách chăm_sóc mèo con và lựa_chọn thức_ăn phù_hợp cho thú_cưng tại nhà	15
5	hướng_dẫn khiêu_vũ dân_vũ tập_luyện sức_khoẻ và giải_trí	22


C. Thống kê dữ liệu sau tiền xử lý

Để hiểu rõ hơn đặc trưng của tập dữ liệu sau khi làm sạch, nhóm tiến hành một số thống kê mô tả cơ bản:

- **Số lượng mẫu:** 6 750 video.
- **Số từ vựng duy nhất:** 37 196 từ.
- **Độ dài mô tả trung bình:** 59 từ/video.
- **15 từ phổ biến nhất:** “hướng_dẫn”, “nhạc”, “video”, “du_lịch”, “trải_nghiem”, “game”, “review”, “vlog”, ...

Hình 2 minh họa các từ khóa phổ biến nhất trong toàn bộ mô tả video sau khi làm sạch.

Các từ khóa xuất hiện phổ biến trong mô tả video YouTube (sau làm sạch)



Hình 2. Các từ khóa xuất hiện phổ biến trong mô tả video YouTube (sau làm sạch).

D. Chia tập huấn luyện và kiểm thử

Dữ liệu được chia thành hai phần: **80% cho huấn luyện** và **20% cho kiểm thử**, đảm bảo tỉ lệ phân bố các thể loại được giữ nguyên bằng tham số stratify. Tập huấn luyện (D_{train}) được sử dụng để huấn luyện mô hình, còn tập kiểm thử (D_{test}) phục vụ đánh giá khả năng tổng quát hóa.

$$|D_{train}| = 5\,400, \quad |D_{test}| = 1\,350$$

E. Tóm tắt quy trình chuẩn bị dữ liệu

Quy trình xử lý dữ liệu giúp loại bỏ nhiễu, chuẩn hóa ngữ liệu tiếng Việt và giữ lại đặc trưng ngữ nghĩa của mô tả video. Kết quả cuối cùng là một tập dữ liệu gồm 6750 mẫu hợp lệ, 15 thể loại, được tách từ, loại stopwords, và sẵn sàng cho các giai đoạn trích xuất đặc trưng bằng TF-IDF và các mô hình embedding hiện đại (PhoBERT, BGE, E5, Sup-SimCSE).

V. THỰC NGHIỆM VÀ ĐÁNH GIÁ MÔ HÌNH

A. Quy trình và cấu hình thực nghiệm

1. Mục tiêu thực nghiệm.

Phần này trình bày quy trình triển khai, huấn luyện và đánh giá các mô hình học máy trong bài toán phân loại thể loại video YouTube dựa trên phần mô tả tiếng Việt. Mục tiêu của thực nghiệm nhằm:

- So sánh hiệu suất giữa các phương pháp biểu diễn văn bản (TF-IDF, PhoBERT, BGE, E5 và Sup-SimCSE PhoBERT);
- Đánh giá khả năng khái quát hóa của từng mô hình thông qua kiểm định chéo (Cross-Validation);
- Xác định mô hình và phương pháp biểu diễn (embedding) tối ưu nhất cho bài toán phân loại mô tả video tiếng Việt.

2. Cấu hình phần cứng và phần mềm.

Các thí nghiệm được triển khai trên môi trường **Python 3.10**, với các thư viện hỗ trợ chính gồm: **pandas, scikit-learn, underthesea, transformers, matplotlib** và **seaborn**. Quá trình huấn luyện mô hình được thực hiện trên hệ thống có cấu hình phần cứng như sau:

- CPU:** Intel Core i7 (12 nhân, 20 luồng);
- RAM:** 32GB;
- GPU:** NVIDIA RTX 3060 (12GB VRAM);
- Hệ điều hành:** Windows 11 (64-bit).

3. Dữ liệu huấn luyện và kiểm thử.

Tập dữ liệu sau khi tiền xử lý bao gồm **6 750 mô tả video tiếng Việt** thuộc **15 thể loại chính**. Dữ liệu được chia thành hai phần theo tỷ lệ:

- **Tập huấn luyện (80%)** – dùng để huấn luyện và đánh giá mô hình bằng Cross-Validation;
- **Tập kiểm thử (20%)** – dùng để đánh giá độc lập mô hình cuối cùng.

Phương pháp chia dữ liệu sử dụng tham số `stratify`, nhằm đảm bảo tỷ lệ phân bố các lớp trong hai tập huấn luyện và kiểm thử tương đồng với toàn bộ dữ liệu gốc. Điều này giúp hạn chế sai lệch do mất cân bằng lớp khi đánh giá mô hình.

4. Chuẩn hóa dữ liệu (Feature Scaling). Đối với các mô hình tuyến tính như **Logistic Regression** và **Linear SVM**, việc chuẩn hóa dữ liệu là cần thiết để các đặc trưng có cùng thang đo và giúp mô hình hội tụ ổn định hơn. Trong thí nghiệm này, nhóm sử dụng **StandardScaler** thuộc thư viện `scikit-learn` để chuẩn hóa các đặc trưng embedding về dạng phân phối chuẩn có trung bình bằng 0 và độ lệch chuẩn bằng 1.

- Với **TF-IDF**, dữ liệu đã được chuẩn hóa sẵn theo chuẩn L2 nên không cần scale bổ sung.
- Với các biểu diễn embedding như **PhoBERT**, **BGE**, **E5** và **Sup-SimCSE PhoBERT**, nhóm áp dụng **StandardScaler** để đảm bảo giá trị của từng chiều có phân phối đồng đều quanh 0, tránh hiện tượng sai lệch khi tính khoảng cách hoặc khi huấn luyện mô hình tuyến tính.

Việc chuẩn hóa này giúp cải thiện độ ổn định của các mô hình tuyến tính, đặc biệt khi embedding có giá trị nằm trong khoảng rộng (từ -5 đến +5), đồng thời giúp mô hình đạt tốc độ hội tụ nhanh hơn và kết quả nhất quán hơn giữa các lần huấn luyện.

5. Quy trình đánh giá.

Để đảm bảo độ tin cậy và khả năng tổng quát của mô hình, nhóm áp dụng kỹ thuật **Cross-Validation 5-fold** trên tập huấn luyện. Cụ thể, dữ liệu được chia thành 5 phần bằng nhau; ở mỗi lần lặp, 4 phần được dùng để huấn luyện và 1 phần còn lại dùng để kiểm định. Kết quả trung bình của 5 lần huấn luyện cho phép đánh giá độ ổn định và hiệu suất tổng thể của mô hình.

Sau khi xác định được cấu hình tối ưu, mô hình được **huấn luyện lại trên toàn bộ tập huấn luyện (80%)** và **đánh giá trên tập kiểm thử độc lập (20%)** để thu được kết quả cuối cùng.

Các chỉ số đánh giá.

Hiệu suất mô hình được so sánh dựa trên bốn chỉ số cơ bản trong phân loại đa lớp:

- **Accuracy (Độ chính xác):** Tỷ lệ mẫu được dự đoán đúng trên tổng số mẫu;
- **Precision (Độ chính xác dương tính):** Tỷ lệ mẫu đúng trong tổng số mẫu được mô hình dự đoán là dương tính;
- **Recall (Độ bao phủ):** Tỷ lệ mẫu dương tính được mô hình phát hiện chính xác;
- **F1-Score:** Trung bình điều hòa giữa Precision và Recall, được tính theo hai biến thể:
 - **Macro F1:** Trung bình đều cho tất cả các lớp, phản ánh khả năng mô hình phân biệt các nhóm nhỏ
 - **Weighted F1:** Trung bình có trọng số theo quy mô của từng lớp, phản ánh hiệu suất tổng thể.

Do tập dữ liệu có sự mất cân bằng đáng kể giữa các thể loại (đặc biệt là 22 – Con người & Blog và 24 – Giải trí, chiếm hơn 40% tổng số mẫu), chỉ số **Weighted F1** được chọn làm tiêu chí chính để đánh giá độ chính xác tổng thể, trong khi **Macro F1** được dùng để đo lường khả năng mô hình nhận dạng các lớp hiếm.

Tổng quan quy trình thực nghiệm.

Trước hết, dữ liệu mô tả được tiền xử lý và biểu diễn bằng các phương pháp embedding khác nhau. Tiếp theo, các đặc trưng thu được được đưa vào huấn luyện với bốn mô hình học máy phổ biến: **Logistic Regression**, **Linear SVM**, **Random Forest** và **Naive Bayes**. Cuối cùng, các mô hình được đánh giá lần lượt thông qua Cross-Validation trên tập huấn luyện và kiểm thử độc lập để lựa chọn cấu hình có hiệu suất cao nhất.

B. Biểu diễn truyền thống: TF-IDF

Phương pháp **TF-IDF (Term Frequency – Inverse Document Frequency)** được sử dụng như một biểu diễn đặc trưng truyền thống cho dữ liệu mô tả video YouTube. Các vector TF-IDF thu được được đưa vào bốn mô hình học máy phổ biến gồm: **Logistic Regression (LR)**, **Linear SVM**, **Random Forest (RF)** và **Naive Bayes (NB)**. Phương pháp này đóng vai trò như *baseline* để so sánh với các kỹ thuật biểu diễn ngữ nghĩa hiện đại ở phần sau.

Kết quả đánh giá bằng Cross-Validation 5-fold.

Bảng III trình bày giá trị trung bình của chỉ số **Macro F1** trong 5 lần kiểm định chéo. Kết quả cho thấy **Linear SVM** đạt hiệu suất cao nhất với **F1 = 0.6638**, cho thấy khả năng tổng quát hóa ổn định trên tập huấn luyện.

Bảng III
KẾT QUẢ CROSS-VALIDATION 5-FOLD TRÊN BIỂU DIỄN TF-IDF

Mô hình	F1 Macro trung bình	Độ lệch chuẩn
Logistic Regression	0.6423	± 0.0258
Linear SVM	0.6638	± 0.0325
Naive Bayes	0.4870	± 0.0085
Random Forest	0.6127	± 0.0206


Kết quả kiểm thử độc lập.

Sau khi lựa chọn cấu hình tối ưu từ giai đoạn kiểm định chéo, các mô hình được huấn luyện lại trên toàn bộ tập huấn luyện (80%) và đánh giá trên tập kiểm thử (20%). Bảng IV thể hiện kết quả tổng hợp theo các chỉ số Accuracy, Macro F1 và Weighted F1.

Bảng IV
HIỆU SUẤT MÔ HÌNH TF-IDF TRÊN TẬP KIỂM THỬ ĐỘC LẬP

Mô hình	Accuracy	Macro F1	Weighted F1
Logistic Regression	0.690	0.630	0.680
Linear SVM	0.730	0.650	0.730
Random Forest	0.744	0.661	0.737
Naive Bayes	0.632	0.485	0.625

Kết quả được minh họa trực quan trong Hình 3. cho thấy các mô hình tuyến tính như Linear SVM và Logistic Regression có hiệu suất ổn định, trong khi Random Forest đạt độ chính xác cao nhất nhờ khả năng học các quan hệ phi tuyến giữa đặc trưng TF-IDF. Ngược lại, Naive Bayes thể hiện kết quả thấp do giả định độc lập giữa các đặc trưng không phù hợp với dữ liệu thực tế, nơi các từ khóa thường đồng xuất hiện theo cụm ngữ nghĩa. Điều này khẳng định rằng các mô hình phi tuyến vẫn tận dụng tốt đặc trưng tần suất, đặc biệt với dữ liệu ngắn như mô tả video.




Hình 3. So sánh Accuracy, Macro F1 và Weighted F1 giữa các mô hình huấn luyện trên biểu diễn TF-IDF.

Phân tích ma trận nhầm lẫn.

Hình 4 Thể hiện ma trận nhầm lẫn của các mô hình trên biểu diễn TF-IDF. Dễ thấy rằng Linear SVM có đường chéo chính rõ ràng nhất, chứng tỏ khả năng phân tách tốt giữa các lớp phổ biến như Con người Blog (22), Giải trí (24) và Tin tức (25). Random Forest vẫn đạt độ chính xác cao nhưng thể hiện khuynh hướng nghiêng về lớp lớn, trong khi Naive Bayes bị nhầm lẫn nhiều ở các lớp nhỏ. Nhìn chung, Linear SVM thể hiện khả năng ổn định và rõ ràng hơn, còn Random Forest đạt độ chính xác cao nhất tổng thể. Tuy nhiên, vẫn xuất hiện nhầm lẫn giữa các nhóm gần ngữ nghĩa như Du lịch (19) và Blog (22), cho thấy mô hình còn hạn chế trong việc tách biệt nội dung mang tính trải nghiệm cá nhân. Kết quả này phản ánh đặc điểm chồng lấn tự nhiên giữa các chủ đề YouTube tiếng Việt.

So sánh Confusion Matrix giữa các mô hình TF-IDF



Hình 4. Ma trận nhầm lẫn của mô hình Random Forest trên biểu diễn TF-IDF.

Nhận xét chung.

Các kết quả cho thấy TF-IDF, dù là phương pháp biểu diễn truyền thống, vẫn mang lại hiệu quả cao trong bài toán phân loại mô tả video ngắn. **Random Forest** đạt kết quả cao nhất về độ chính xác, trong khi **Linear SVM** thể hiện độ ổn định tốt hơn qua Cross-Validation. Phương pháp TF-IDF vì vậy được chọn làm *baseline* để so sánh với các phương pháp biểu diễn ngữ nghĩa hiện đại ở các phần tiếp theo.

C. Biểu diễn ngữ nghĩa: PhoBERT

PhoBERT là mô hình ngôn ngữ tiền huấn luyện dành riêng cho tiếng Việt, được xây dựng dựa trên kiến trúc **RoBERTa** và huấn luyện trên kho dữ liệu 20GB văn bản tiếng Việt. Khác với TF-IDF chỉ biểu diễn tần suất từ, PhoBERT có khả năng nắm bắt ngữ cảnh và mối quan hệ ngữ nghĩa giữa các từ, từ đó tạo ra các vector biểu diễn (embedding) giàu thông tin hơn cho từng câu mô tả video.

Trong thực nghiệm, các vector trung bình tầng ẩn của PhoBERT được trích xuất làm đầu vào cho ba mô hình học máy: **Logistic Regression (LR)**, **Linear SVM** và **Random Forest (RF)**. Kết quả này giúp đánh giá khả năng của PhoBERT khi được sử dụng như một bộ trích xuất đặc trưng (feature extractor) cho bài toán phân loại chủ đề video.

Kết quả đánh giá bằng Cross-Validation 5-fold.


Bảng V trình bày kết quả trung bình của chỉ số **Macro F1** qua 5 lần kiểm định chéo. Trong đó, **Linear SVM** đạt **F1 = 0.5470**, cao hơn một chút so với **Logistic Regression (0.5349)**.

Bảng V
KẾT QUẢ CROSS-VALIDATION 5-FOLD TRÊN BIỂU DIỄN PHOBERT

Mô hình	F1 Macro trung bình	Độ lệch chuẩn
Logistic Regression	0.5349	± 0.0231
Linear SVM	0.5470	± 0.0098

Kết quả kiểm thử độc lập.


Kết quả đánh giá trên tập kiểm thử 20% được thể hiện trong Hình 5. So với TF-IDF, hiệu suất của PhoBERT thấp hơn nhẹ, với **Accuracy dao động 0.61–0.62** và **Weighted F1 khoảng 0.61–0.62** cho Logistic Regression và Linear SVM. Điều này cho thấy PhoBERT chưa thể hiện được toàn bộ sức mạnh ngữ nghĩa khi chỉ dùng trung bình tầng ẩn, song vẫn giữ độ ổn định tốt giữa các mô hình tuyến tính.



Hình 5. So sánh Accuracy, Macro F1 và Weighted F1 giữa các mô hình huấn luyện trên biểu diễn PhoBERT.

Phân tích ma trận nhầm lẫn.

Hình 6 mô tả hiệu suất của ba mô hình trên embedding PhoBERT. Linear SVM đạt hiệu quả cao hơn ở các nhóm nội dung có ngữ nghĩa đặc trưng như Tin tức (25) và Giải trí (24). Tuy nhiên, các lớp có số mẫu nhỏ như Thú cưng (15) hoặc Phi lợi nhuận (29) vẫn bị dự đoán sai do dữ liệu thiếu. So với TF-IDF, PhoBERT giúp giảm lỗi nhầm lẫn giữa các lớp gần nghĩa, nhưng tổng thể hiệu suất vẫn thấp hơn do mô hình chưa được fine-tune.



Hình 6. Ma trận nhầm lẫn của các mô hình Logistic Regression, Linear SVM và Random Forest trên biểu diễn PhoBERT.

Nhận xét chung.

Kết quả thực nghiệm cho thấy các mô hình sử dụng đặc trưng từ PhoBERT đạt hiệu suất trung bình khá tốt, với Linear SVM vẫn là lựa chọn ổn định nhất. Tuy nhiên, so với TF-IDF, sự chênh lệch về Accuracy chưa đáng kể, nguyên nhân chủ yếu do kích thước tập dữ liệu huấn luyện còn hạn chế, khiến mô hình PhoBERT chưa tận dụng được đầy đủ thông tin ngữ cảnh. Điều này mở ra hướng cải tiến bằng cách **fine-tune trực tiếp PhoBERT** trên tập dữ liệu YouTube trong tương lai để khai thác tối đa khả năng biểu diễn ngữ nghĩa của mô hình.

D. Biểu diễn ngữ nghĩa: BGE

Mô hình **BGE (BAAI General Embedding)** là một trong những kỹ thuật biểu diễn ngữ nghĩa thế hệ mới, được phát triển nhằm tạo ra các vector biểu diễn ngắn gọn nhưng giàu thông tin ngữ nghĩa cho toàn bộ câu hoặc đoạn văn. Khác với PhoBERT, BGE không chỉ huấn luyện trên ngôn ngữ đơn lẻ mà còn được tối ưu hoá cho nhiệm vụ so sánh ngữ nghĩa (semantic similarity), do đó thích hợp với các bài toán phân loại văn bản đa chủ đề như mô tả video YouTube.

Trong thí nghiệm này, các vector embedding thu được từ mô hình **BGE-small** được sử dụng làm đầu vào cho ba bộ phân loại: **Logistic Regression (LR)**, **Linear SVM** và **Random Forest (RF)**. Các mô hình này giúp đánh giá mức độ hiệu quả của biểu diễn BGE khi áp dụng vào dữ liệu ngôn ngữ tiếng Việt.

Kết quả đánh giá bằng Cross-Validation 5-fold.


Bảng VI trình bày giá trị trung bình của chỉ số **Macro F1** thu được qua 5 lần kiểm định chéo. Trong đó, **Linear SVM** tiếp tục đạt kết quả cao nhất với **F1 = 0.5568**, cho thấy mô hình tuyến tính này vẫn hoạt động ổn định trên biểu diễn ngữ nghĩa.

Bảng VI
KẾT QUẢ CROSS-VALIDATION 5-FOLD TRÊN BIỂU DIỄN BGE

Mô hình	F1 Macro trung bình	Độ lệch chuẩn
Logistic Regression	0.5398	± 0.0318
Linear SVM	0.5568	± 0.0291

Kết quả kiểm thử độc lập.

Hiệu suất của các mô hình trên tập kiểm thử 20% được thể hiện trong Hình 7. Kết quả cho thấy **Linear SVM** và **Logistic Regression** đều đạt **Accuracy 0.62** và **Weighted F1 0.62**, cao hơn đáng kể so với **Random Forest (Weighted F1 = 0.49)**. Tuy nhiên, do đặc tính embedding của BGE hướng tới ngữ nghĩa tổng quát, các mô hình tuyến tính vẫn có lợi thế hơn so với mô hình cây quyết định trong việc tách biệt các chủ đề tương đồng.




Hình 7. So sánh Accuracy, Macro F1 và Weighted F1 giữa các mô hình huấn luyện trên biểu diễn BGE.

Phân tích ma trận nhầm lẫn.

Hình 8 Ma trận nhầm lẫn cho thấy Linear SVM tiếp tục thể hiện khả năng phân biệt tốt các lớp chính, trong khi Random Forest có xu hướng gộp nhiều dự đoán về nhóm Con người Blog (22). BGE giúp tăng tính khái quát ngữ nghĩa, nhưng chưa

đủ mạnh để phân tách các chủ đề gần nhau như Du lịch (19) và Giải trí (24). Tổng thể, biểu diễn BGE mang lại kết quả ổn định, nhưng độ chính xác chưa vượt được TF-IDF.



Hình 8. Ma trận nhầm lẫn của các mô hình Logistic Regression, Linear SVM và Random Forest trên biểu diễn BGE.

Nhận xét chung.

Biểu diễn BGE cho kết quả tương đương PhoBERT về mặt tổng thể, song có ưu thế về tốc độ trích xuất và dung lượng nhẹ hơn. Điều này giúp BGE trở thành lựa chọn hiệu quả cho các hệ thống phân loại lớn hoặc triển khai thực tế. Tuy nhiên, để cải thiện độ chính xác, việc kết hợp BGE với kỹ thuật tinh chỉnh (fine-tuning) theo miền dữ liệu tiếng Việt hoặc mô hình phân loại phi tuyến sâu hơn có thể mang lại kết quả tốt hơn trong tương lai.

E. Biểu diễn ngữ nghĩa: E5

Mô hình **E5 (Embedding from Explicitly Exploited Explanations)** được phát triển nhằm tối ưu cho các tác vụ ngữ nghĩa đa dạng như phân loại, tìm kiếm ngữ cảnh và truy xuất thông tin. Khác với các mô hình embedding truyền thống, E5 được huấn luyện theo cơ chế *instruction-based learning*, trong đó đầu vào được hướng dẫn bằng các câu lệnh ngữ nghĩa giúp mô hình hiểu rõ hơn mối quan hệ giữa văn bản và chủ đề. Nhờ vậy, E5 có khả năng nắm bắt ngữ cảnh sâu hơn, đặc biệt hiệu quả với văn bản ngắn như mô tả video.

Trong thực nghiệm, các vector embedding trung bình của mô hình **E5-base** được trích xuất và sử dụng làm đầu vào cho ba bộ phân loại: **Logistic Regression (LR)**, **Linear SVM** và **Random Forest (RF)**. Các mô hình này được huấn luyện và đánh giá theo quy trình giống các thí nghiệm trước đó.

Kết quả đánh giá bằng Cross-Validation 5-fold.


Bảng VII trình bày kết quả trung bình của chỉ số **Macro F1** qua 5 lần kiểm định chéo. **Linear SVM** tiếp tục đạt kết quả cao nhất với **F1 = 0.5768**, cao hơn Logistic Regression (0.5513). Điều này cho thấy E5 tạo ra biểu diễn ổn định và dễ phân tách cho các mô hình tuyến tính.

Bảng VII
KẾT QUẢ CROSS-VALIDATION 5-FOLD TRÊN BIỂU DIỄN E5

Mô hình	F1 Macro trung bình	Độ lệch chuẩn
Logistic Regression	0.5513	± 0.0274
Linear SVM	0.5768	± 0.0232

Kết quả kiểm thử độc lập.


Trên tập kiểm thử 20%, hiệu suất của các mô hình được thể hiện trong Hình 9. Cả **Logistic Regression** và **Linear SVM** đạt hiệu suất tương đương, với **Accuracy = 0.64** và **Weighted F1 = 0.64**. **Random Forest** cho kết quả thấp hơn đáng kể (Weighted F1 = 0.52), cho thấy các mô hình tuyến tính vẫn phù hợp hơn với embedding có cấu trúc ngữ nghĩa rõ ràng như E5.



Hình 9. So sánh Accuracy, Macro F1 và Weighted F1 giữa các mô hình huấn luyện trên biểu diễn E5.

Phân tích ma trận nhầm lẫn.

Hình 10 minh họa ma trận nhầm lẫn của ba mô hình sử dụng embedding E5. Kết quả cho thấy **Linear SVM** duy trì độ chính xác cao ở các lớp chính như 22 – Con người & Blog, 24 – Giải trí tổng hợp và 25 – Tin tức & Chính trị. Tuy nhiên, các lớp nhỏ (ví dụ 15 – Thú cưng, 29 – Phi lợi nhuận) vẫn gặp khó khăn trong việc phân biệt, một phần do số lượng mẫu huấn luyện hạn chế.



Hình 10. Ma trận nhầm lẫn của các mô hình Logistic Regression, Linear SVM và Random Forest trên biểu diễn E5.

Nhận xét chung.

Kết quả thực nghiệm cho thấy embedding E5 đạt hiệu suất tốt và ổn định, đặc biệt khi kết hợp với các mô hình tuyến tính. Hiệu quả của E5 nhìn chung cao hơn một chút so với PhoBERT và BGE, nhờ khả năng hiểu ngữ cảnh dựa trên câu lệnh (instruction). Tuy nhiên, để đạt hiệu quả tối đa, mô hình cần được fine-tune trên tập dữ liệu tiếng Việt thực tế, hoặc kết hợp thêm cơ chế attention để khai thác sâu hơn cấu trúc ngữ nghĩa của mô tả video.

F. Biểu diễn ngữ nghĩa nâng cao: Sup-SimCSE PhoBERT

Mô hình **Sup-SimCSE PhoBERT** (Supervised Simple Contrastive Sentence Embedding) là phiên bản cải tiến của PhoBERT được huấn luyện bổ sung theo phương pháp **học tương phản có giám sát (Supervised Contrastive Learning)**. Khác với PhoBERT gốc vốn chỉ dựa trên ngữ cảnh hai chiều, Sup-SimCSE tận dụng thông tin nhãn trong giai đoạn huấn luyện để tối ưu hóa khoảng cách giữa các câu có nghĩa tương đồng và tăng phân tách giữa các câu khác chủ đề. Nhờ vậy, biểu diễn

embedding của Sup-SimCSE thể hiện mối quan hệ ngữ nghĩa chính xác hơn, đặc biệt hiệu quả trong các bài toán phân loại chủ đề văn bản.

Trong thí nghiệm này, vector trung bình tầng ẩn cuối cùng của Sup-SimCSE PhoBERT được sử dụng làm đầu vào cho ba mô hình học máy: **Logistic Regression (LR)**, **Linear SVM** và **Random Forest (RF)**. Các thí nghiệm được thực hiện tương tự như các phần trước, trên cùng tập dữ liệu mô tả video tiếng Việt.

Kết quả đánh giá bằng Cross-Validation 5-fold.


Bảng VIII thể hiện kết quả trung bình của chỉ số **Macro F1** qua 5 lần kiểm định chéo. **Linear SVM** tiếp tục đạt hiệu suất cao nhất với **F1 = 0.5757**, nhỉnh hơn Logistic Regression (0.5655). Các giá trị lệch chuẩn nhỏ cho thấy độ ổn định của mô hình giữa các lần kiểm định.

Bảng VIII
KẾT QUẢ CROSS-VALIDATION 5-FOLD TRÊN BIỂU DIỄN SUP-SIMCSE PHOBERT

Mô hình	F1 Macro trung bình	Độ lệch chuẩn
Logistic Regression	0.5655	± 0.0156
Linear SVM	0.5757	± 0.0310

Kết quả kiểm thử độc lập.


Trên tập kiểm thử 20%, kết quả tổng hợp được trình bày trong Hình 11. **Linear SVM** đạt hiệu suất cao nhất với **Accuracy = 0.65** và **Weighted F1 = 0.65**, trong khi Logistic Regression đạt mức tương đương (0.62) và Random Forest thấp hơn đáng kể (Weighted F1 = 0.60). Điều này cho thấy việc bổ sung cơ chế học tương phản giúp mô hình Sup-SimCSE tạo ra embedding ổn định và phân tách tốt giữa các chủ đề gần nghĩa.



Hình 11. So sánh Accuracy, Macro F1 và Weighted F1 giữa các mô hình huấn luyện trên biểu diễn Sup-SimCSE PhoBERT.

Phân tích ma trận nhầm lẫn.

Hình 12 minh họa ma trận nhầm lẫn của ba mô hình khi sử dụng embedding Sup-SimCSE PhoBERT. Có thể thấy **Linear SVM** cho kết quả phân biệt rõ ràng giữa các nhóm nội dung phổ biến như 22 – Con người & Blog, 24 – Giải trí tổng hợp và 25 – Tin tức & Chính trị, đồng thời giảm đáng kể nhầm lẫn giữa các lớp có nội dung tương tự như 19 – Du lịch và 22 – Blog. **Random Forest** vẫn thể hiện độ chính xác thấp hơn, do không tận dụng hiệu quả cấu trúc ngữ nghĩa trong không gian embedding.



Hình 12. Ma trận nhầm lẫn của các mô hình Logistic Regression, Linear SVM và Random Forest trên biểu diễn Sup-SimCSE PhoBERT.

Nhận xét chung.

Kết quả cho thấy **Sup-SimCSE PhoBERT** đạt hiệu suất cao nhất trong nhóm các phương pháp embedding ngữ nghĩa, với độ chính xác và F1-score cao hơn các mô hình PhoBERT, BGE và E5. Cơ chế học tương phản có giám sát giúp cải thiện đáng kể khả năng nhận biết ngữ nghĩa giữa các mô tả video gần nhau về nội dung, từ đó tăng tính phân tách của không gian biểu diễn. Điều này chứng tỏ tiềm năng của Sup-SimCSE PhoBERT trong các ứng dụng phân loại ngữ nghĩa tiếng Việt phức tạp, đặc biệt khi được kết hợp cùng các mô hình tuyến tính mạnh như Linear SVM.

G. Tổng hợp và so sánh hiệu suất giữa các phương pháp embedding

Sau khi tiến hành huấn luyện và đánh giá trên năm phương pháp biểu diễn văn bản gồm **TF-IDF**, **PhoBERT**, **BGE**, **E5** và **Sup-SimCSE PhoBERT**, kết quả tổng hợp toàn bộ các mô hình được thể hiện trong Bảng IX. Phần này nhằm trình bày một cách tổng quát hiệu suất của từng phương pháp, từ đó xác định mô hình và biểu diễn ngữ nghĩa tối ưu nhất cho bài toán.


Bảng IX
BẢNG TỔNG HỢP KẾT QUẢ CÁC MÔ HÌNH TRÊN TỪNG EMBEDDING

Embedding	Mô hình	Accuracy	Macro F1	Weighted F1
TF-IDF	Random Forest	0.744	0.588	0.737
PhoBERT	Linear SVM	0.624	0.545	0.620
BGE	Linear SVM	0.623	0.557	0.620
E5	Linear SVM	0.640	0.585	0.638
Sup-SimCSE PhoBERT	Linear SVM	0.647	0.561	0.646

Biểu đồ thể hiện hiệu suất tổng thể giữa năm phương pháp embedding. TF-IDF vượt trội với Accuracy = 0.744 và Weighted F1 = 0.737, trong khi Sup-SimCSE PhoBERT xếp thứ hai với Accuracy 0.647. Các embedding E5 và BGE đạt mức trung bình, còn PhoBERT gốc thấp nhất. Điều này chứng minh rằng các phương pháp biểu diễn ngữ nghĩa hiện đại chỉ phát huy tối đa khi được huấn luyện lại theo miền dữ liệu tiếng Việt.

Hiệu suất tổng thể theo embedding.


Hình 13 minh họa sự khác biệt về **Accuracy**, **Macro F1** và **Weighted F1** giữa các embedding. Kết quả cho thấy **TF-IDF** đạt **Accuracy cao nhất (0.744)** và **Weighted F1 = 0.737**, vượt trội so với các phương pháp embedding ngữ nghĩa hiện đại. Điều này phản ánh đặc điểm riêng của tập dữ liệu mô tả video YouTube các đoạn mô tả thường ngắn, nhiều từ khóa đặc trưng, nên phương pháp thống kê tần suất như TF-IDF vẫn mang lại hiệu quả nổi bật.



Hình 13. So sánh hiệu suất (Accuracy / Macro F1 / Weighted F1) giữa các embedding.

Kết quả Cross-Validation.


Hình 14 minh họa kết quả Cross-Validation 5-fold cho từng embedding. TF-IDF đạt F1 Macro cao nhất (0.664), thể hiện khả năng khái quát hóa tốt và ổn định nhất trên toàn bộ dữ liệu. Các phương pháp embedding ngữ nghĩa như E5 và Sup-SimCSE đạt mức tiệm cận (0.575), trong khi PhoBERT và BGE vẫn thấp hơn do chưa được tinh chỉnh (fine-tune). Kết quả này khẳng định TF-IDF vẫn là lựa chọn tối ưu cho văn bản ngắn tiếng Việt.



Hình 14. So sánh kết quả Cross-Validation giữa các phương pháp embedding.

Mô hình tốt nhất trên từng embedding.

Hình 15 trình bày **Accuracy** của mô hình có hiệu suất cao nhất trên mỗi embedding. Dễ nhận thấy rằng **Linear SVM** chiếm ưu thế trong hầu hết các phương pháp biểu diễn ngữ nghĩa (PhoBERT, BGE, E5, Sup-SimCSE), cho thấy đặc trưng embedding tạo ra các không gian gần tuyến tính, trong khi **Random Forest** thể hiện vượt trội ở TF-IDF do khai thác tốt các đặc trưng phi tuyến của tần suất từ.



Hình 15. Hiệu suất (Accuracy) của mô hình tốt nhất trên từng embedding.

Tổng kết. Kết quả tổng hợp cho thấy:

- **TF-IDF + Random Forest** là kết hợp hiệu quả nhất cho dữ liệu mô tả video ngắn.
- Các embedding ngữ nghĩa hiện đại như **E5** và **Sup-SimCSE PhoBERT** đạt hiệu suất tiệm cận TF-IDF, chứng minh khả năng học biểu diễn ngữ nghĩa sâu và ổn định.
- **Linear SVM** là mô hình phù hợp nhất cho các vector embedding, trong khi các mô hình phi tuyến như Random Forest kém hiệu quả hơn ở không gian vector hóa cao chiều.

Những kết quả trên là cơ sở quan trọng để tiến hành phần **thảo luận chi tiết** ở mục sau, nơi nhóm tác giả sẽ phân tích sâu nguyên nhân của sự khác biệt này và định hướng cải thiện hiệu suất cho các mô hình embedding ngữ nghĩa.

VI. TỔNG KẾT VÀ THẢO LUẬN

A. Tổng kết

Kết quả thực nghiệm cho thấy:

- **TF-IDF + Random Forest** là **tổ hợp hiệu quả nhất** cho bài toán phân loại mô tả video ngắn tiếng Việt, đạt **Accuracy = 0.744** và **Weighted F1 = 0.737**. Cấu hình này thể hiện khả năng nắm bắt tốt tần suất và mức độ đặc trưng của các từ khóa trong từng thể loại video.
- Các **embedding ngữ nghĩa hiện đại** như **E5** và **Sup-SimCSE PhoBERT** đạt hiệu suất **tiệm cận TF-IDF**, chứng minh khả năng **biểu diễn ngữ nghĩa sâu và ổn định**, dù chưa được huấn luyện lại trên miền dữ liệu tiếng Việt đặc thù.
- **Linear SVM** là mô hình **tổng quát hóa tốt nhất** qua Cross-Validation, đặc biệt hiệu quả khi kết hợp với các vector embedding có chiều cao. Trong khi đó, **Random Forest** đạt hiệu quả cao hơn trên tập kiểm thử độc lập nhưng dễ thiên lệch về các lớp có kích thước lớn.

Tổng thể, các kết quả này cho thấy **TF-IDF vẫn là phương pháp biểu diễn mạnh mẽ** trong các bài toán phân loại văn bản ngắn, nơi yếu tố từ vựng đặc trưng đóng vai trò chính. Ngược lại, các **mô hình embedding ngữ nghĩa** như E5 và Sup-SimCSE PhoBERT cho thấy tiềm năng lớn trong việc **học biểu diễn ngữ nghĩa sâu**, hứa hẹn vượt TF-IDF khi được **fine-tune đúng miền dữ liệu**.

B. Thảo luận chi tiết

1) **Vì sao TF-IDF vẫn vượt trội:** Mặc dù các phương pháp embedding hiện đại được huấn luyện trên kho dữ liệu lớn, TF-IDF vẫn vượt trội trong bài toán này vì:

- Mô tả video YouTube thường **ngắn và giàu từ khóa đặc trưng**, giúp trọng số TF-IDF phản ánh rõ ràng chủ đề nội dung.

- Các embedding ngữ nghĩa (PhoBERT, E5, BGE, Sup-SimCSE) **thiếu bối cảnh huấn luyện đặc thù tiếng Việt trên miền video**, dẫn đến biểu diễn khái niệm chưa tối ưu.
- TF-IDF tạo đặc trưng **thừa nhưng có tính phân biệt cao**, giúp các mô hình như Random Forest hoặc SVM dễ tìm ranh giới quyết định.

2) *Nguyên nhân embedding ngữ nghĩa chưa vượt được TF-IDF*: Các phương pháp embedding cho kết quả tiệm cận nhưng vẫn thấp hơn TF-IDF do:

- Chưa được **fine-tune** trên dữ liệu cụ thể của bài toán, nên biểu diễn còn mang tính tổng quát.
- **Độ dài mô tả ngắn** (trung bình 25–40 từ) khiến embedding không khai thác được ngữ cảnh đầy đủ.
- Một số thể loại video có **nội dung ngữ nghĩa gần nhau** (ví dụ: *Du lịch, Con người & Blog, Giải trí*) khiến vector ngữ nghĩa bị chồng lấn.
- **Mất cân bằng dữ liệu** làm giảm khả năng học khái niệm của mô hình embedding.

3) *Về mô hình học máy*:

- **Linear SVM** cho thấy **khả năng ổn định nhất**, đặc biệt trong Cross-Validation, do phù hợp với không gian vector cao chiều và phân tách tuyến tính rõ ràng.
- **Random Forest** đạt **Accuracy cao nhất** trên tập kiểm thử, nhưng có xu hướng lệch về lớp phổ biến (*class imbalance bias*).
- **Naive Bayes** hoạt động kém với embedding vì giả định độc lập điều kiện không còn đúng khi đặc trưng mang tính ngữ nghĩa liên kết cao.

4) *Định hướng cải thiện*: Để nâng cao hiệu suất trong tương lai, nhóm đề xuất:

- **Fine-tune các embedding** (E5, Sup-SimCSE, PhoBERT) trên miền dữ liệu tiếng Việt của YouTube
- Áp dụng **kỹ thuật cân bằng dữ liệu** như SMOTE, focal loss hoặc re-weight class
- Thử nghiệm **mô hình kết hợp (ensemble)** giữa embedding và TF-IDF để tận dụng ưu thế của cả hai hướng
- Sử dụng **mô hình deep learning phân loại** như BiLSTM hoặc Transformer fine-tuned thay cho SVM/RF.

C. Kết luận

Như vậy, trong phạm vi nghiên cứu này, **TF-IDF + Random Forest** được xem là **mô hình tối ưu nhất**, đạt hiệu suất cao nhất trên tập kiểm thử độc lập. Tuy nhiên, sự tiệm cận của **E5** và **Sup-SimCSE PhoBERT** mở ra hướng phát triển mạnh mẽ cho các mô hình **embedding ngữ nghĩa tiếng Việt**, đặc biệt khi được tinh chỉnh theo miền dữ liệu video ngắn.

VII. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

A. Kết luận chung

Nghiên cứu này đã thực hiện bài toán **phân loại video YouTube theo thể loại dựa trên phần mô tả tiếng Việt**, sử dụng tập dữ liệu thu thập tự động từ **YouTube Data API v3**. Toàn bộ quy trình bao gồm các giai đoạn: **Tiền xử lý dữ liệu, biểu diễn văn bản bằng nhiều kỹ thuật khác nhau, huấn luyện mô hình học máy, và đánh giá hiệu suất thông qua Cross-Validation 5-fold**.

Kết quả thực nghiệm cho thấy:

- Phương pháp **TF-IDF kết hợp Random Forest** đạt hiệu suất cao nhất với **Accuracy = 0.744** và **Weighted F1 = 0.737**, chứng tỏ mô hình thống kê truyền thống vẫn mang lại hiệu quả mạnh mẽ đối với văn bản ngắn có tính đặc trưng cao.
- Các mô hình **embedding ngữ nghĩa hiện đại** như **E5** và **Sup-SimCSE PhoBERT** đạt kết quả tiệm cận TF-IDF, cho thấy khả năng học biểu diễn ngữ nghĩa sâu và ổn định, dù chưa được fine-tune trên miền dữ liệu tiếng Việt.
- **Linear SVM** thể hiện độ ổn định tốt nhất trong Cross-Validation, trong khi **Random Forest** đạt kết quả cao hơn trên tập kiểm thử độc lập nhưng dễ lệch về các lớp có kích thước lớn.

Từ những kết quả trên, có thể khẳng định rằng **TF-IDF vẫn là một phương pháp cơ bản nhưng hiệu quả** trong các bài toán phân loại mô tả video tiếng Việt. Tuy nhiên, xu hướng phát triển hiện nay cho thấy các mô hình embedding ngữ nghĩa như **E5** hay **Sup-SimCSE PhoBERT** hoàn toàn có tiềm năng vượt trội khi được tinh chỉnh phù hợp với miền dữ liệu cụ thể.

Ngoài ra, nghiên cứu cũng chỉ ra rằng **chất lượng dữ liệu và quy trình tiền xử lý** đóng vai trò quyết định trong hiệu quả của hệ thống phân loại. Việc chuẩn hóa văn bản, loại bỏ nhiễu, và cân bằng dữ liệu giữa các lớp có ảnh hưởng trực tiếp đến độ chính xác cuối cùng của mô hình.

B. Hướng phát triển trong tương lai

Từ những kết quả đạt được, nhóm đề xuất một số hướng mở rộng để cải thiện hiệu suất và mở rộng phạm vi ứng dụng:

- 1) **Fine-tune các mô hình embedding ngữ nghĩa**: Tinh chỉnh các mô hình như *PhoBERT, E5, Sup-SimCSE PhoBERT* trên tập dữ liệu YouTube tiếng Việt sẽ giúp khai thác sâu hơn ngữ cảnh đặc thù của mô tả video, tăng độ chính xác phân loại.
- 2) **Cân bằng dữ liệu và mở rộng tập huấn luyện**: Áp dụng các kỹ thuật như *SMOTE, data augmentation hoặc focal loss* để giảm thiên lệch lớp; đồng thời mở rộng dữ liệu sang nhiều thể loại và ngôn ngữ phụ để tăng tính tổng quát.

- 3) **Kết hợp nhiều phương pháp biểu diễn (Hybrid Embedding):** Kết hợp TF-IDF với các vector ngữ nghĩa từ PhoBERT hoặc E5 nhằm tận dụng đồng thời ưu điểm tần suất và ngữ cảnh, hướng tới một không gian biểu diễn lai giàu thông tin hơn.
- 4) **Triển khai mô hình học sâu (Deep Learning):** Thử nghiệm các kiến trúc **BiLSTM**, **CNN**, hoặc **Transformer fine-tuned** để thay thế mô hình truyền thống, cho phép học tự động đặc trưng ngữ nghĩa ở mức câu.
- 5) **Xây dựng hệ thống ứng dụng thực tế:** Phát triển một công cụ **tự động phân loại và gợi ý thể loại video YouTube tiếng Việt**, tích hợp vào hệ thống quản lý hoặc phân tích xu hướng nội dung.

TÀI LIỆU THAM KHẢO

- [1] T. Joachims, "Text categorization with support vector machines: Learning with many relevant features," in *Proceedings of the European Conference on Machine Learning (ECML)*, 1998. [Online]. Available: <https://link.springer.com/chapter/10.1007/BFb0026683>
- [2] F. Sebastiani, "Machine learning in automated text categorization," *ACM Computing Surveys*, vol. 34, no. 1, pp. 1–47, 2002. [Online]. Available: <https://dl.acm.org/doi/10.1145/505282.505283>
- [3] P. Saini, G. Kaur, and A. Sharma, "Video category classification using textual metadata and deep learning," *International Journal of Advanced Research in Computer and Communication Engineering*, 2020. [Online]. Available: <https://ijarccce.com/wp-content/uploads/2020/03/IJARCCCE.2020.9314.pdf>
- [4] T. H. Vu, "Underthesea: Vietnamese nlp toolkit," <https://github.com/undertheseanlp/underthesea>, 2018.
- [5] H. Nguyen, "Pyvi: Vietnamese text processing library," <https://pypi.org/project/pyvi/>, 2019.
- [6] K. Dang and T. Nguyen, "Stopword customization for vietnamese youtube data," *Vietnam Journal of Artificial Intelligence Research*, 2021.
- [7] J. Ramos, "Using tf-idf to determine word relevance in document queries," Department of Computer Science, Rutgers University, Tech. Rep., 2003. [Online]. Available: <https://www.semanticscholar.org/paper/Using-TF-IDF-to-determine-word-relevance-in-Ramos/0b2e9e2b56ef94e4e9ff6f5b25dd0b358a28f64a>
- [8] Y. Zhang, R. Jin, and Z. Zhou, "Understanding bag-of-words models: A statistical framework," *Pattern Recognition Letters*, vol. 31, no. 12, pp. 1337–1344, 2010. [Online]. Available: <https://doi.org/10.1016/j.patrec.2010.04.019>
- [9] Q.-T. Nguyen and M.-H. Tran, "Comparative study of vietnamese text classification using tf-idf and svm," *ICT Research Journal*, 2021.
- [10] J. Devlin, M.-W. Chang, K. Lee, and K. Toutanova, "Bert: Pre-training of deep bidirectional transformers for language understanding," in *Proceedings of NAACL-HLT*, 2019. [Online]. Available: <https://aclanthology.org/N19-1423/>
- [11] D. Q. Nguyen, A. T. Nguyen, D. Q. Nguyen, and S. B. Pham, "Phobert: Pre-trained language models for vietnamese," in *Findings of EMNLP*, 2020. [Online]. Available: <https://aclanthology.org/2020.findings-emnlp.92/>
- [12] H. M. Le, "A comparative evaluation of word embeddings for vietnamese text classification," *IEEE Access*, 2022. [Online]. Available: <https://ieeexplore.ieee.org/document/9744047>
- [13] BAAI Team, "Bge embeddings," <https://huggingface.co/BAAI/bge-base-en-v1.5>, 2023.
- [14] S. Wang, N. Reimers, and I. Gurevych, "Text embeddings by weakly-supervised contrastive pre-training," *arXiv preprint arXiv:2302.10866*, 2023. [Online]. Available: <https://arxiv.org/abs/2302.10866>
- [15] T. Gao, X. Yao, and D. Chen, "Simcse: Simple contrastive learning of sentence embeddings," in *Proceedings of EMNLP 2021*, 2021. [Online]. Available: <https://aclanthology.org/2021.emnlp-main.552/>

PROJECT 2C: PHÂN TÍCH CHỦ ĐỀ DỰA TRÊN MÔ TẢ VIDEO YOUTUBE

1st Hà Thế Anh, 2nd Nguyễn Nhật Nam, 3rd Hoàng Quang Minh
and Le Nhật Tung

HUTECH University, Vietnam

{hatheanh012004, nguyennhatnam01012004, hoangquangminh130804}@gmail.com, and lenhattung@hutech.edu.vn

TÓM TẮT NỘI DUNG

YouTube là nền tảng lưu trữ và chia sẻ video có quy mô dữ liệu khổng lồ, nơi các mô tả video phản ánh xu hướng, chủ đề và hành vi của người dùng trên không gian số. Nghiên cứu này tập trung vào việc phân tích chủ đề trong các mô tả video tiếng Việt bằng các mô hình học máy hiện đại, bao gồm **LDA (Latent Dirichlet Allocation)**, **BERTopic** và **Top2Vec**, đồng thời đề xuất mô hình kết hợp **CombinedTM (LDA + BERTopic)** nhằm cải thiện tính ổn định và khả năng diễn giải chủ đề. Dữ liệu được tiền xử lý thông qua các bước làm sạch ngôn ngữ, loại bỏ ký tự nhiễu, từ dừng, emoji và tách từ bằng Underthesea. Các mô hình được huấn luyện, đánh giá và trực quan hóa dựa trên nhiều chỉ số khác nhau để khám phá cấu trúc ngữ nghĩa tiềm ẩn trong dữ liệu YouTube tiếng Việt. Nghiên cứu góp phần chứng minh tính ứng dụng của các kỹ thuật *Topic Modeling* trong khai phá nội dung văn bản và hiểu biết xu hướng người dùng trên nền tảng video trực tuyến.

TỪ KHÓA

Topic Modeling, Video Description, YouTube, Machine Learning, Latent Dirichlet Allocation (LDA), BERTopic, Top2Vec, Contextualized Topic Model (CTM), Dimensionality Reduction, PCA, UMAP, Clustering, HDBSCAN, Vietnamese Language Data.

I. GIỚI THIỆU

Trong bối cảnh chuyển đổi số và sự bùng nổ của dữ liệu trực tuyến, YouTube đã trở thành một trong những nền tảng chia sẻ nội dung lớn nhất thế giới, nơi hàng triệu video được đăng tải mỗi ngày. Các mô tả video không chỉ cung cấp thông tin về nội dung mà còn phản ánh xu hướng, sở thích và hành vi của người dùng trong không gian mạng. Việc phân tích các mô tả này giúp khai thác tri thức tiềm ẩn, hỗ trợ hệ thống gợi ý, quảng cáo và nghiên cứu hành vi xã hội trên nền tảng số.

Tuy nhiên, dữ liệu mô tả video thường tồn tại dưới dạng văn bản phi cấu trúc, chứa nhiều nhiễu như ký tự đặc biệt, biểu tượng cảm xúc, từ dừng hoặc các yếu tố không mang giá trị ngữ nghĩa. Đặc biệt, với tiếng Việt, sự phức tạp trong cấu trúc ngữ pháp, dấu thanh và cách biểu đạt khiến cho việc xử lý và phân tích ngôn ngữ tự nhiên (NLP) trở nên thách thức hơn. Do đó, việc xây dựng một quy trình tiền xử lý chuyên sâu là bước không thể thiếu nhằm đảm bảo độ chính xác và nhất quán của dữ liệu đầu vào.

Nghiên cứu này tập trung vào bài toán **phân tích chủ đề (Topic Modeling)** trên tập dữ liệu mô tả video YouTube tiếng Việt, với mục tiêu phát hiện các cụm chủ đề tiềm ẩn phản ánh cấu trúc ngữ nghĩa trong nội dung. Ba mô hình chủ đề được áp dụng gồm **LDA (Latent Dirichlet Allocation)**, **BERTopic** và **Top2Vec**, đại diện cho ba hướng tiếp cận khác nhau: Thống kê xác suất, embedding ngữ nghĩa và học chủ đề không giám sát. Bên cạnh đó, nghiên cứu còn đề xuất mô hình lai **CombinedTM (LDA + BERTopic)** nhằm kết hợp ưu điểm của hai mô hình truyền thống và hiện đại, hướng đến tăng cường độ ổn định và khả năng diễn giải của kết quả.

Toàn bộ dữ liệu được thu thập và xử lý theo một quy trình chặt chẽ: Loại bỏ nhiễu, chuẩn hóa ký tự, xóa emoji, hashtag, từ dừng đặc thù của YouTube và tách từ bằng thư viện Underthesea. Sau đó, các mô hình được huấn luyện và đánh giá thông qua nhiều chỉ số khác nhau như **Coherence (C_V, U_{Mass}, NPMI)**, **Topic Diversity**, **NMI**, **ARI**, **Purity** và **Stability**. Kết hợp cùng các phương pháp trực quan hóa như *WordCloud* và *Bubble Chart*, nghiên cứu mang đến cái nhìn trực quan và toàn diện về cấu trúc chủ đề trong dữ liệu văn bản tiếng Việt trên YouTube.

Công trình này không chỉ góp phần minh chứng hiệu quả của các mô hình phân tích chủ đề hiện đại trong ngôn ngữ tiếng Việt mà còn mở ra hướng tiếp cận mới trong việc khai phá tri thức, phân loại nội dung và nhận diện xu hướng trên các nền tảng video trực tuyến.

II. CÁC NGHIÊN CỨU LIÊN QUAN

Trong lĩnh vực **phân tích chủ đề (Topic Modeling)**, nhiều công trình nghiên cứu đã được phát triển nhằm khám phá cấu trúc tiềm ẩn của văn bản. Từ các phương pháp thống kê truyền thống đến các mô hình ngữ nghĩa hiện đại, mục tiêu chung là trích xuất được các cụm từ đại diện phản ánh ngữ nghĩa tổng quát của dữ liệu. Phần này trình bày các công trình tiêu biểu có liên quan đến đề tài, bao gồm bốn hướng chính: LDA, BERTopic, Top2Vec và các mô hình kết hợp (CTM).

A. Latent Dirichlet Allocation (LDA)

Mô hình **LDA** do [1] đề xuất là một trong những nền tảng quan trọng nhất của Topic Modeling. LDA giả định rằng mỗi tài liệu là sự pha trộn của nhiều chủ đề, và mỗi chủ đề là một phân bố xác suất trên các từ vựng. Phương pháp này sử dụng các kỹ thuật xác suất Bayes để suy luận phân bố tiềm ẩn của các chủ đề trong tập dữ liệu văn bản. Các khảo sát như của [2] đã chỉ ra rằng LDA có độ ổn định cao và khả năng diễn giải tốt, nhưng lại phụ thuộc nhiều vào tiền xử lý dữ liệu, đặc biệt trong các ngôn ngữ có cấu trúc phức tạp như tiếng Việt.

B. BERTopic - Mô hình chủ đề dựa trên ngữ nghĩa

BERTopic, được phát triển bởi [3], là mô hình hiện đại kết hợp *sentence embedding*, gom cụm bằng HDBSCAN và trích xuất từ khóa bằng c-TF-IDF. Khác với LDA dựa trên tần suất từ, BERTopic khai thác thông tin ngữ nghĩa từ các mô hình ngôn ngữ Transformer (như BERT, RoBERTa), giúp nhóm các văn bản có ngữ cảnh tương tự lại với nhau. Theo [4], BERTopic đạt hiệu suất vượt trội trong việc phân tích dữ liệu mạng xã hội và nội dung đa ngôn ngữ nhờ khả năng học biểu diễn ngữ nghĩa sâu.

C. Top2Vec - Học chủ đề trên không gian vector

Top2Vec, do [5] giới thiệu, là một hướng tiếp cận mới trong học biểu diễn chủ đề. Phương pháp này học trực tiếp embedding của từ, tài liệu và chủ đề trong cùng một không gian vector, qua đó tự động phát hiện và gom nhóm các tài liệu mà không cần xác định trước số lượng chủ đề. Top2Vec khắc phục một số hạn chế của LDA khi làm việc với văn bản ngắn, tuy nhiên mô hình có thể gặp khó khăn với ngôn ngữ ít tài nguyên hoặc dữ liệu nhiễu như tiếng Việt.

D. Combined Topic Models (CTM)

Để kết hợp sức mạnh của các phương pháp thống kê và embedding ngữ nghĩa, nhiều công trình gần đây đã đề xuất **Combined Topic Models (CTM)**. Theo [6], việc tích hợp biểu diễn xác suất của LDA với embedding từ BERT giúp cải thiện đáng kể tính mạch lạc (coherence) và khả năng diễn giải của các chủ đề. Ngoài ra, nghiên cứu của [7] đã phát triển thư viện *contextualized-topic-models* cho phép huấn luyện các mô hình CTM trên dữ liệu đa ngôn ngữ, thể hiện hiệu quả cao trong các bài toán phân tích ngữ nghĩa phức tạp. Những ý tưởng này là nền tảng để xây dựng mô hình **CombinedTM (LDA + BERTopic)** trong nghiên cứu hiện tại, nhằm tận dụng đồng thời khả năng tổng quát hóa của LDA và sức mạnh biểu diễn ngữ cảnh của BERTopic.

E. Các khảo sát và ứng dụng gần đây

Theo tổng quan của [8], việc áp dụng các mô hình phân tích chủ đề trong dữ liệu mạng xã hội và mô tả ngắn (như video YouTube) đang trở thành xu hướng nghiên cứu quan trọng. Các khảo sát này nhấn mạnh vai trò của việc kết hợp mô hình truyền thống và hiện đại để đạt được sự cân bằng giữa độ ổn định và độ chính xác ngữ nghĩa. Bên cạnh đó, [4] cũng chỉ ra rằng các mô hình embedding như BERTopic và Top2Vec thường đạt hiệu quả cao hơn LDA khi làm việc với dữ liệu ngắn và đa chủ đề, nhưng lại cần nhiều tài nguyên tính toán hơn.

F. Tổng kết

Tổng hợp các nghiên cứu trên cho thấy sự tiến hóa của các mô hình phân tích chủ đề theo hướng kết hợp giữa *thống kê xác suất* và *ngữ nghĩa học sâu*. LDA vẫn là nền tảng vững chắc để mô hình hóa xác suất chủ đề, trong khi BERTopic và Top2Vec mở ra khả năng hiểu ngữ nghĩa sâu hơn của văn bản. Các mô hình lai như CombinedTM (LDA + BERTopic) chứng minh tiềm năng lớn trong việc nâng cao độ ổn định, tính mạch lạc và khả năng ứng dụng vào các bài toán khai phá nội dung tiếng Việt.

III. PHƯƠNG PHÁP NGHIÊN CỨU

Phần này mô tả quy trình và các kỹ thuật phân tích chủ đề được áp dụng trong đề tài “*Phân tích chủ đề trên dữ liệu mô tả video YouTube*”. Quy trình được thiết kế thành pipeline tự động, bao gồm bốn khối chính: (1) tiền xử lý văn bản, (2) mô hình hóa chủ đề, (3) đánh giá mô hình và (4) trực quan hóa kết quả.

A. Phương pháp tiền xử lý dữ liệu

Dữ liệu đầu vào được lấy từ tập `Project2C_youtube_data_cleaned.csv`, trong đó mỗi bản ghi chứa trường `clean_description` chuỗi mô tả video đã được làm sạch thông qua hàm `clean_text()` được xây dựng thủ công. Các bước xử lý gồm:

- Chuyển toàn bộ văn bản về dạng chữ thường
- Loại bỏ biểu tượng cảm xúc, URL, thẻ hashtag, ký tự đặc biệt và từ khóa quảng bá đặc trưng của YouTube (*like, subscribe, share, ...*)
- Chuẩn hóa dấu và ký tự tiếng Việt, chỉ giữ lại chữ cái và khoảng trắng;
- Tách từ bằng thư viện `Underthesea`
- Loại bỏ từ dừng tiếng Việt được mở rộng thủ công
- Lọc bỏ các mô tả ngắn dưới 5 token để đảm bảo đủ ngữ cảnh.

Kết quả thu được là danh sách token hóa (`texts`) và từ điển ánh xạ id-từ (`dictionary`) phục vụ cho quá trình huấn luyện LDA và các mô hình khác.

B. Phương pháp mô hình hóa chủ đề

Ba mô hình chủ đề được triển khai gồm **LDA**, **BERTopic** và **Top2Vec**, bên cạnh đó nhóm nghiên cứu đề xuất mô hình lai **CombinedTM (LDA + BERTopic)** nhằm tận dụng ưu thế của cả hai hướng tiếp cận: xác suất và ngữ nghĩa.

1) *Mô hình LDA (Latent Dirichlet Allocation)*: LDA giả định rằng mỗi tài liệu d là sự pha trộn của các chủ đề tiềm ẩn z , và mỗi chủ đề là một phân bố xác suất trên không gian từ vựng w . Quy trình sinh của mô hình được mô tả như sau:

$$P(w|d) = \sum_{z=1}^K P(w|z)P(z|d)$$

trong đó K là số chủ đề được xác định thông qua quá trình thử nghiệm trong khoảng 5 – 40. Việc huấn luyện được thực hiện bằng thư viện `gensim.models.LdaModel` với tham số `passes=20`, `iterations=100` và `random_state=42`. Hai chỉ số được dùng để chọn mô hình tối ưu là **Coherence (C_V)** và **Perplexity** [9].

2) *Mô hình BERTopic*: Mô hình **BERTopic** [3] sử dụng embedding ngữ nghĩa từ mô hình Transformer đa ngôn ngữ để biểu diễn các mô tả video trong không gian vector. Quy trình gồm ba giai đoạn: (1) mã hóa câu bằng mô hình Transformer, (2) giảm chiều bằng UMAP [10], (3) gom cụm bằng HDBSCAN [11]. Các cụm chủ đề được đặt tên bằng phương pháp **class-based TF-IDF (c-TF-IDF)** để trích xuất các từ khóa đại diện cho từng nhóm chủ đề. BERTopic được triển khai thông qua thư viện chính thức tại maartengr.github.io/BERTopic.

3) *Mô hình Top2Vec*: Mô hình **Top2Vec** [12] huấn luyện embedding của tài liệu, từ và chủ đề trong cùng một không gian vector. Khác với LDA, Top2Vec không yêu cầu xác định trước số lượng chủ đề mà tự động phát hiện các cụm dựa trên mật độ điểm embedding. Quy trình gồm ba bước: (1) sinh embedding bằng mô hình học sâu, (2) giảm chiều bằng UMAP, (3) phát hiện cụm chủ đề bằng HDBSCAN. Cấu trúc học này giúp phát hiện các cụm ngữ nghĩa tổng thể của dữ liệu và được triển khai bằng thư viện mã nguồn mở tại github.com/ddangelov/Top2Vec.

4) *Mô hình CombinedTM (LDA + BERTopic)*: Để kết hợp khả năng diễn giải cao của LDA [13] và khả năng học ngữ nghĩa sâu của BERTopic [3], một mô hình lai **CombinedTM** được đề xuất. Mỗi tài liệu được biểu diễn dưới dạng vector kết hợp giữa phân bố xác suất chủ đề từ LDA (θ_{LDA}) và embedding giảm chiều từ BERTopic sau khi PCA [14] ($PCA(E_{BERTopic})$), theo công thức:

$$\text{CombinedEmb} = [\theta_{LDA} || \text{PCA}(E_{BERTopic})]$$

Trong đó, ký hiệu $||$ thể hiện phép nối vector. Các vector được chuẩn hóa bằng `StandardScaler` [15], giảm chiều bằng UMAP [10], và gom cụm bằng HDBSCAN [11]. Mô hình này tận dụng sức mạnh thống kê của LDA trong việc diễn giải và khả năng học ngữ nghĩa sâu của BERTopic để tạo ra các cụm chủ đề ổn định và giàu ý nghĩa hơn.

IV. XÂY DỰNG VÀ CHUẨN BỊ DỮ LIỆU

A. Nguồn dữ liệu và cấu trúc ban đầu

Tập dữ liệu gốc được thu thập trực tiếp từ nền tảng YouTube thông qua API, bao gồm các thông tin cơ bản của video được công bố tại khu vực Việt Nam. Dữ liệu được lưu trữ dưới định dạng CSV với các trường chính như:

- `video_id`: mã định danh duy nhất của video trên YouTube
- `title`: tiêu đề của video;
- `description`: phần mô tả nội dung do người đăng tải cung cấp
- `published_at`: thời điểm xuất bản video (định dạng ISO 8601)
- `channel`: tên kênh đăng video;

- `category_id`: mã danh mục chủ đề của video
- `tags`: danh sách từ khóa gắn liền với video;
- `view_count`, `like_count`, `comment_count`: các chỉ số tương tác (lượt xem, thích, bình luận).

Các video được lấy mẫu từ nhiều danh mục khác nhau như *Âm nhạc*, *Giải trí*, *Thể thao*, *Khoa học & Công nghệ*, nhằm đảm bảo tính đa dạng nội dung. Danh mục chính thức (`category_name`) được ánh xạ từ mã `category_id` thông qua **YouTube Data API v3** [16], với endpoint:

`https://www.googleapis.com/youtube/v3/videoCategories?part=snippet®ionCode=VN`

Kết quả trả về bao gồm cặp giá trị `id` và `title`, giúp gán tên danh mục tiếng Anh và được dịch sang tiếng Việt trong nghiên cứu.

B. Tiền xử lý dữ liệu mô tả (Description)

Cột `description` được xem là trường dữ liệu quan trọng nhất, đóng vai trò đầu vào cho toàn bộ pipeline phân tích chủ đề. Để đảm bảo chất lượng và loại bỏ nhiễu trong ngôn ngữ tự nhiên, một hàm `clean_text()` được xây dựng nhằm thực hiện các bước xử lý sau:

- 1) **Chuyển chữ thường và loại bỏ khoảng trắng dư thừa.**
- 2) **Loại bỏ biểu tượng cảm xúc và ký tự đặc biệt:** Sử dụng thư viện `emoji` [17] để xóa toàn bộ biểu tượng ngoài ngôn ngữ.
- 3) **Xóa URL, email, hashtag, số điện thoại:** Áp dụng biểu thức chính quy (regex) để làm sạch chuỗi.
- 4) **Tách từ tiếng Việt:** Áp dụng công cụ `Underthesea` [18] để tách từ theo quy tắc ngữ pháp tiếng Việt.
- 5) **Loại bỏ từ dừng và token ngắn:** Danh sách stopwords mở rộng bao gồm các từ thông dụng và các cụm phổ biến trong video như “đăng ký”, “like”, “share”, “cảm ơn”, “video”, “kênh”.
- 6) **Xử lý lặp và lọc độ dài:** Loại bỏ token trùng liên tiếp (ví dụ “haha haha”) và chỉ giữ mô tả có ít nhất 5 token.

Kết quả của quá trình này là cột `clean_description`, được thêm vào `DataFrame` và lưu ra tệp. Tổng cộng có 7653 mô tả hợp lệ sau khi loại bỏ các hàng rỗng hoặc mô tả ngắn.

C. Chuẩn bị dữ liệu cho huấn luyện

Tập dữ liệu sau khi làm sạch được chuẩn bị theo hai cấu trúc chính:

- **Token list (texts):** Mỗi phần tử là một danh sách các từ (token) trong mô tả video, phục vụ cho các mô hình dựa trên tần suất như LDA.
- **Corpus và Dictionary:** Sử dụng `gensim.corpora.Dictionary` để ánh xạ từ-ID, và `doc2bow()` để tạo vector BoW (Bag-of-Words). Cấu trúc này là đầu vào của mô hình LDA, trong khi `BERTopic` và `Top2Vec` sử dụng dạng chuỗi văn bản gốc.

Tất cả văn bản được mã hóa UTF-8 để đảm bảo tương thích với các thư viện xử lý tiếng Việt. Dữ liệu cuối cùng gồm hai tệp chính:

- `Project2C_youtube_data_cleaned.csv`: chứa mô tả đã tiền xử lý.
- `lda_models/`: thư mục lưu mô hình LDA được huấn luyện cho các giá trị chủ đề khác nhau.


V. THỰC NGHIỆM VÀ ĐÁNH GIÁ

A. Thiết lập thực nghiệm

Các mô hình được triển khai và huấn luyện trực tiếp trên tập dữ liệu mô tả video YouTube sau khi tiền xử lý. Toàn bộ quá trình được thực hiện trong môi trường **Python 3.10** sử dụng các thư viện `gensim`, `bertopic`, `top2vec`, `hdbscan`, `umap-learn`, và `scikit-learn`. Tập dữ liệu gồm **7.653 mô tả video hợp lệ**, sau khi loại bỏ các trường thiếu, ký tự đặc biệt, emoji, đường dẫn URL, và các mô tả ngắn hơn 5 token.

Quy trình thực nghiệm được mô tả trong Hình 1, bao gồm bốn giai đoạn chính:

- 1) **Tiền xử lý dữ liệu:** làm sạch văn bản, chuẩn hóa, tách từ, loại bỏ stopwords tiếng Việt tự định nghĩa.
- 2) **Huấn luyện mô hình chủ đề:** lần lượt huấn luyện ba mô hình LDA, `BERTopic` và `Top2Vec` trên cùng tập dữ liệu đã làm sạch.
- 3) **Đánh giá định lượng:** tính toán các chỉ số *Coherence*, *Perplexity*, *NMI*, *ARI*, *Purity*, *Topic Diversity*.
- 4) **Trực quan hóa và phân tích:** biểu diễn kết quả bằng biểu đồ *Coherence*, *Bubble Chart*, *WordCloud* và *Bar Plot*.



Hình 1. Quy trình thực nghiệm phát hiện và đánh giá chủ đề trên dữ liệu YouTube.

Không áp dụng chia tập huấn luyện và kiểm thử, do mục tiêu của nghiên cứu là khám phá và so sánh chất lượng trích xuất chủ đề giữa các mô hình, thay vì huấn luyện mô hình dự đoán. Mỗi mô hình được huấn luyện một lần duy nhất với cấu hình cố định, đảm bảo tính nhất quán khi so sánh kết quả.

B. Cấu hình tham số mô hình

a) **LDA - Latent Dirichlet Allocation.**: LDA được huấn luyện trên tập token hoá sử dụng `gensim.LdaModel`. Để xác định số chủ đề tối ưu, mô hình được thử nghiệm với K trong khoảng $[5, 10, 15, 20, 25, 30, 35, 40]$. Mỗi lần huấn luyện chạy 20 vòng (`passes=20`) với 100 vòng lặp nội bộ (`iterations=100`). Chỉ số **Coherence** và **Perplexity** được sử dụng để lựa chọn cấu hình tốt nhất. Kết quả cho thấy số chủ đề tối ưu là **5**, tương ứng với $C_v = 0.549$ và $Perplexity = -7.74$.

b) **BERTopic.**: Mô hình BERTopic được cấu hình ở chế độ đa ngôn ngữ, cho phép xử lý các mô tả video tiếng Việt một cách hiệu quả. Mô hình sử dụng kiến trúc Transformer để mã hoá câu, sau đó giảm chiều bằng **UMAP** và gom cụm bằng **HDBSCAN**. Từ khóa đại diện cho từng chủ đề được trích xuất bằng phương pháp **class-based TF-IDF (c-TF-IDF)**, giúp tăng khả năng diễn giải và tách biệt ngữ nghĩa giữa các nhóm chủ đề.

c) **Top2Vec.**: Top2Vec được huấn luyện với tham số `speed='learn'` và `workers=8`. Mô hình kết hợp giữa embedding của tài liệu và cụm chủ đề trong cùng không gian vector, cho phép phát hiện chủ đề dựa trên sự tương đồng cosine của các đoạn mô tả. Các topic được tự động gán cho từng tài liệu thông qua phương thức `get_documents_topics()`.

d) **CombinedTM (LDA + BERTopic).**: Mô hình kết hợp được thiết kế nhằm tận dụng ưu điểm của LDA (khả năng mô hình hóa xác suất chủ đề) và BERTopic (khả năng học ngữ nghĩa sâu). Cụ thể, embedding của mỗi mô tả được xây dựng như sau:

$$\mathbf{h}_{\text{Combined}} = [\boldsymbol{\theta}_{LDA} \parallel \text{PCA}(E_{\text{BERTopic}})]$$

trong đó $\boldsymbol{\theta}_{LDA}$ là phân bố xác suất chủ đề của tài liệu trong không gian LDA, và E_{BERTopic} là vector ngữ nghĩa rút ra từ mô hình BERTopic (sau khi giảm chiều bằng PCA). Các vector hợp nhất này được chuẩn hóa bằng `StandardScaler`, sau

đó giảm chiều bằng UMAP và gom cụm bằng HDBSCAN. Mô hình này hướng tới việc tăng tính ổn định và độ chính xác phân cụm chủ đề.


Sau khi thiết lập, các mô hình được đánh giá dựa trên các tiêu chí: **Coherence** (C_v , U_{Mass} , $NPMI$), **NMI**, **ARI**, **Purity**, và **Topic Diversity**. Các kết quả chi tiết và biểu đồ so sánh được trình bày ở các phần tiếp theo.

C. Kết quả và phân tích

Phần này trình bày kết quả thực nghiệm và đánh giá hiệu năng của các mô hình phân tích chủ đề được áp dụng trong nghiên cứu, bao gồm: **LDA**, **BERTopic**, **Top2Vec**, và **CombinedTM**. Các mô hình được huấn luyện trên tập dữ liệu mô tả video YouTube đã được tiền xử lý, với mục tiêu xác định phương pháp nào mang lại hiệu quả cao nhất về mặt ngữ nghĩa và độ phân tách chủ đề.

1) *Kết quả mô hình LDA*: Mô hình **Latent Dirichlet Allocation (LDA)** được huấn luyện với số lượng chủ đề thay đổi từ 5 đến 40 để xác định cấu hình tối ưu. Hai chỉ số chính được sử dụng trong quá trình đánh giá là **Coherence** và **Perplexity**.

Kết quả cho thấy khi số chủ đề đạt khoảng 5–10, giá trị *Coherence* đạt mức cao nhất trong khi *Perplexity* giảm dần và ổn định (Hình 2). Điều này chứng tỏ mô hình LDA có khả năng phát hiện được cấu trúc chủ đề hợp lý, tránh tình trạng phân mảnh khi số chủ đề quá lớn.




Hình 2. Mối quan hệ giữa số lượng chủ đề và giá trị Coherence/Perplexity của mô hình LDA.

Phân tích nội dung các chủ đề sinh ra cho thấy LDA hình thành được các nhóm từ khóa có liên quan ngữ nghĩa như “âm nhạc, video, khán giả”, “thể thao, bóng đá, đội tuyển”, hoặc “du lịch, trải nghiệm, địa điểm”. Điều này thể hiện khả năng phân cụm theo ngữ cảnh khá tốt của LDA trong dữ liệu YouTube. Tuy nhiên, do đặc trưng dựa trên phân phối từ xác suất, một số chủ đề vẫn xuất hiện hiện tượng *chồng chéo nội dung*, đặc biệt ở các lĩnh vực có ngữ nghĩa gần nhau như “giải trí” và “vlog cá nhân”.



Hình 3. Biểu đồ WordCloud thể hiện các từ khóa nổi bật trong chủ đề sinh ra bởi LDA.

Nhìn chung, LDA mang lại độ ổn định và khả năng diễn giải trực quan tương đối tốt. Mô hình phù hợp cho các bài toán khám phá chủ đề tổng quát, nhưng hạn chế khi cần biểu diễn các mối quan hệ ngữ nghĩa sâu giữa các từ, điều mà các mô hình embedding hiện đại (như BERTopic) xử lý hiệu quả hơn.



Hình 4. Biểu đồ Bubble Chart thể hiện tầm quan trọng của các chủ đề trong mô hình LDA.

Hình 4 thể hiện kích thước và tầm quan trọng tương đối của từng chủ đề trong không gian hai chiều. Các chủ đề được biểu diễn dưới dạng các bong bóng có kích thước khác nhau, trong đó kích thước phản ánh độ phổ biến của chủ đề, và vị trí thể hiện mối quan hệ ngữ nghĩa tương đối giữa các cụm.

Quan sát cho thấy năm chủ đề chính có kích thước tương đối đồng đều, thể hiện khả năng phân bổ xác suất hợp lý của LDA. Không có cụm nào chiếm ưu thế vượt trội, cho thấy mô hình giữ được sự cân bằng giữa các nhóm nội dung. Tuy nhiên,

do giới hạn trong biểu diễn ngữ nghĩa, các cụm vẫn có mức độ chồng lấn nhất định, đặc biệt ở các chủ đề liên quan đến “văn hóa”, “giải trí” và “truyền thông”, vốn có xu hướng sử dụng từ ngữ tương đồng.

Về mặt định lượng, LDA đạt giá trị **Coherence** cao nhất ở mức $C_v = 0.549$ với $num_topics = 5$, và **Perplexity** đạt giá trị thấp nhất ở khoảng -7.7 . Các chỉ số này cho thấy mô hình đã tìm được số chủ đề tối ưu, đảm bảo cân bằng giữa tính khái quát và khả năng giải thích. Dù không đạt hiệu quả cao như BERTopic trong việc biểu diễn ngữ cảnh sâu, nhưng LDA vẫn chứng minh tính ổn định và dễ diễn giải – đặc biệt hữu ích cho các phân tích khám phá chủ đề trên tập dữ liệu lớn như YouTube.

2) *Kết quả mô hình BERTopic*: Mô hình **BERTopic** được huấn luyện với $language = 'multilingual'$ và $calculate_probabilities = True$, cho phép biểu diễn văn bản tiếng Việt trong không gian ngữ nghĩa đa ngôn ngữ. BERTopic kết hợp ba giai đoạn chính: mã hóa câu bằng Transformer, giảm chiều bằng **UMAP**, và gom cụm chủ đề bằng **HDBSCAN**. Cách tiếp cận này giúp phát hiện các chủ đề có ranh giới rõ ràng và ngữ nghĩa sâu hơn so với LDA truyền thống.

Kết quả thu được cho thấy mô hình BERTopic đã hình thành được các cụm chủ đề mang ý nghĩa thực tiễn, phản ánh đúng nội dung của các video YouTube được thu thập. Cụ thể, như minh họa trong Hình 5, có thể nhận thấy một số nhóm chủ đề tiêu biểu như:


- **Chủ đề 0 – Giải trí Việt Nam**: xuất hiện các từ khóa như “trộn”, “bộ”, “phim”, “truyền_hình”, “dâu”, “chồng”, đại diện cho nhóm nội dung phim truyện và chương trình truyền hình Việt.
- **Chủ đề 1 – Trò chơi điện tử**: các từ khóa “game”, “chơi”, “tài_xỉu”, “minecraft”, “nights”, “forest” phản ánh mảng nội dung gaming phổ biến.
- **Chủ đề 2 – Sức khỏe và đời sống**: gồm các từ khóa như “sức_khỏe”, “bác_sĩ”, “bệnh”, “sống”, “tốt”, “khám”, liên quan đến chủ đề chăm sóc sức khỏe, y tế và lối sống lành mạnh.
- **Chủ đề 3 – Xe cộ và công nghệ ô tô**: tập trung quanh các từ như “xehay”, “toyota”, “ô_tô”, “đánh_giá”, “hybrid”, phản ánh các video đánh giá, trải nghiệm xe.
- **Chủ đề 4 – Thiết bị công nghệ**: gồm các từ “surface”, “máy_tính”, “laptop”, “office”, “windows”, đại diện cho nhóm video hướng dẫn và đánh giá sản phẩm công nghệ.



Hình 5. WordCloud thể hiện 5 chủ đề tiêu biểu được phát hiện bởi mô hình BERTopic.

Từ Hình 5 có thể thấy, BERTopic cho ra các cụm từ khóa rõ ràng, không bị chồng chéo và có tính ngữ nghĩa cao. Các chủ đề được mô hình tự động tách biệt hợp lý, phản ánh đúng các lĩnh vực phổ biến trong nội dung YouTube như game, công nghệ, giải trí và sức khỏe.

Về mặt định lượng, BERTopic đạt giá trị **Coherence** và **NPMI** cao nhất trong các mô hình thử nghiệm, cùng với chỉ số **NMI** và **ARI** vượt trội, cho thấy mức độ phân cụm ổn định và chính xác hơn. Điều này chứng minh hiệu quả của việc kết hợp **ngữ nghĩa ngữ cảnh** (contextual embedding) và **gom cụm mật độ** (HDBSCAN) trong việc phát hiện các chủ đề thực tế và dễ diễn giải hơn so với các mô hình truyền thống.



Hình 6. Biểu đồ Bubble Chart thể hiện độ quan trọng và phân bố chủ đề trong mô hình BERTopic.

Hình 6 cho thấy phân bố kích thước của các chủ đề do mô hình BERTopic sinh ra. Có thể quan sát thấy rằng một số bong bóng có kích thước rất lớn, trong khi phần lớn còn lại nhỏ hơn đáng kể. Điều này phản ánh đặc trưng của dữ liệu YouTube, nơi chỉ một số chủ đề chính (như *giải trí*, *game*, *công nghệ*) chiếm ưu thế về số lượng video, còn nhiều chủ đề khác chỉ xuất hiện ở tần suất thấp hơn.

Các bong bóng lớn nằm ở khu vực đầu trục chủ đề (chủ đề 0–5) thể hiện những lĩnh vực có mức độ tập trung cao, tương ứng với các nhóm video nổi bật trong tập dữ liệu. Sự giảm dần kích thước theo hướng trục X cho thấy BERTopic có khả năng phát hiện đa dạng chủ đề, nhưng đồng thời vẫn duy trì được tính ổn định trong việc gom các nội dung tương tự vào cùng một cụm.

Về mặt định lượng, mô hình BERTopic đạt giá trị $C_v = 0.714$ và $NPMI = 0.252$, cao hơn đáng kể so với LDA ($C_v = 0.549$). Bên cạnh đó, các chỉ số $NMI = 0.63$ và $ARI = 0.54$ cũng khẳng định khả năng phân cụm có tính nhất quán và khớp với phân loại thực tế hơn. Điều này cho thấy mô hình không chỉ phát hiện được các nhóm chủ đề mang ý nghĩa rõ ràng, mà còn có độ tin cậy cao khi áp dụng trên dữ liệu có tính đa dạng cao như YouTube.

Tổng thể, BERTopic thể hiện hiệu năng vượt trội hơn LDA cả về *ngữ nghĩa* lẫn *độ tách biệt giữa các cụm*. Kết quả Bubble Chart cho thấy mô hình có xu hướng gom các nội dung phổ biến vào ít chủ đề lớn, phản ánh đúng đặc trưng của dữ liệu truyền thông hiện đại. Nhờ vào việc kết hợp giữa biểu diễn embedding ngữ cảnh và thuật toán HDBSCAN, BERTopic trở thành lựa chọn phù hợp cho các tác vụ **khám phá, phân loại và tóm tắt chủ đề** từ các nguồn dữ liệu văn bản mở.

3) *Kết quả mô hình Top2Vec*: Mô hình **Top2Vec** được huấn luyện nhằm tự động phát hiện các chủ đề tiềm ẩn trong dữ liệu mà không cần xác định trước số lượng cụm. Khác với LDA và BERTopic, Top2Vec không dựa trên phân phối xác suất mà biểu diễn toàn bộ tài liệu và từ vựng trong cùng một không gian vector. Các tài liệu có nội dung tương đồng sẽ được gom nhóm gần nhau trong không gian embedding, nhờ đó giúp mô hình tự động xác định được số lượng chủ đề tối ưu.

Khi áp dụng lên tập dữ liệu mô tả video YouTube, Top2Vec đã phát hiện được nhiều cụm chủ đề mang tính tương đồng cao. Hình 7 minh họa 5 chủ đề tiêu biểu được mô hình trích xuất, trong đó có thể nhận thấy sự xuất hiện của các nhóm từ khóa như:


- **Chủ đề 0 – Truyền thông và phát thanh:** “đài_phát_thanh”, “báo_điện_tử”, “đăng_ký”, “hải_đăng”, phản ánh nhóm nội dung tin tức và truyền thông.
- **Chủ đề 1 – Đánh giá và công nghệ:** “đánh_giá”, “đăng_kí”, “truyền_hình”, “đài_tưởng”, thể hiện nội dung đánh giá sản phẩm, thiết bị, hoặc chương trình.

- **Chủ đề 2 – Tin tức trong nước:** “đại_truyền_hình”, “đài_phát_thanh”, “đảo_nhà”, “đăng_kí”, đại diện cho các kênh báo chí và tin tức Việt Nam.
- **Chủ đề 3 – Truyền hình địa phương:** “đài_phát_thanh”, “đà_nẵng”, “nam_định”, “đăng_kí”, phản ánh các kênh truyền hình vùng miền.
- **Chủ đề 4 – Báo chí điện tử:** “báo_điện_tử”, “đăng_kí”, “đài_tượng”, “cầu_đò”, thể hiện hoạt động thông tin báo chí trực tuyến.



Hình 7. WordCloud thể hiện 5 chủ đề tiêu biểu được phát hiện bởi mô hình Top2Vec.

Quan sát Hình 7 cho thấy các cụm từ khóa có sự trùng lặp đáng kể giữa các chủ đề, và kích thước các cụm khá đồng đều. Điều này phản ánh hạn chế của mô hình khi không nắm bắt được rõ ngữ cảnh phân biệt giữa các chủ đề phụ một phần do đặc trưng ngôn ngữ tiếng Việt chứa nhiều từ đa nghĩa, câu mô tả ngắn, và thiếu cấu trúc ngữ pháp đầy đủ trong dữ liệu mô tả video.



Hình 8. Biểu đồ Bubble Chart thể hiện mức độ quan trọng của các chủ đề trong mô hình Top2Vec.

Hình 8 cho thấy các bong bóng có kích thước gần như đồng nhất, thể hiện việc các chủ đề được phân bố đều và không có sự chênh lệch đáng kể về mức độ quan trọng. Điều này cho thấy Top2Vec có xu hướng chia nhỏ không gian chủ đề một cách cân bằng, nhưng lại thiếu khả năng nhấn mạnh vào các cụm nội dung có trọng tâm rõ ràng như BERTopic.

Về mặt định lượng, Top2Vec đạt **Coherence = 0.421**, thấp nhất trong ba mô hình được so sánh (LDA, BERTopic, Top2Vec), và có các chỉ số **NMI = 0.41**, **ARI = 0.33**. Tuy nhiên, chỉ số **Diversity = 0.81** cao nhất trong ba mô hình, cho thấy khả năng phát hiện đa dạng từ khóa và chủ đề độc lập. Điều này phản ánh ưu điểm của Top2Vec trong việc bao quát không gian ngữ nghĩa, nhưng cũng nêu rõ nhược điểm là chưa thể hiện được ranh giới chủ đề cụ thể.

Tổng thể, Top2Vec cung cấp góc nhìn trực quan và tốc độ huấn luyện nhanh, phù hợp cho các bài toán khám phá sơ bộ hoặc dữ liệu ngắn. Tuy nhiên, hiệu quả phân tách chủ đề trên dữ liệu tiếng Việt còn hạn chế. Trong tương lai, mô hình có thể được cải thiện bằng cách **tinh chỉnh vector embedding** hoặc **kết hợp với mô hình ngữ cảnh như PhoBERT hoặc BGE**, nhằm tăng độ chính xác ngữ nghĩa và khả năng phân biệt chủ đề trong các tập dữ liệu phức tạp hơn.


4) **Đánh giá hiệu quả mô hình CombinedTM**: Sau khi huấn luyện mô hình **CombinedTM (LDA + BERTopic)**, quá trình đánh giá được tiến hành bằng cách so sánh kết quả chủ đề dự đoán với nhãn phân loại thực tế (*category_id*) trong tập dữ liệu YouTube. Các chỉ số được tính gồm **C_v**, **U_Mass**, **NPMI**, **Diversity**, **NMI**, **ARI**, **Purity** và **Mean_Stability**. Kết quả tổng hợp được trình bày trong Bảng I và biểu đồ Hình 9.

Bảng I
KẾT QUẢ ĐÁNH GIÁ MÔ HÌNH COMBINEDTM SO VỚI NHÃN PHÂN LOẠI THỰC TẾ.

Model	C_v	U_Mass	NPMI	Diversity	NMI	ARI	Purity	Mean Stability
CombinedTM (LDA + BERTopic)	0.6628	-4.5257	0.0757	0.7481	0.3385	0.0679	0.5626	0.5481

Kết quả cho thấy mô hình CombinedTM đạt giá trị **Coherence (C_v) = 0.6628**, cao hơn LDA và Top2Vec, chứng tỏ khả năng gắn kết ngữ nghĩa giữa các từ khóa trong từng chủ đề tốt hơn. Chỉ số **U_Mass = -4.5257** có giá trị âm tương đối nhỏ, cho thấy mức độ ổn định trong phân bố xác suất của các cụm chủ đề. Đáng chú ý, **Diversity = 0.7481** thể hiện sự đa dạng cao trong các chủ đề được tạo, trong khi **Mean_Stability = 0.5481** phản ánh mức độ ổn định trung bình giữa các lần huấn luyện.

NMI = 0.3385 và **ARI = 0.0679** ở mức trung bình, cho thấy mô hình vẫn gặp thách thức khi ánh xạ chính xác các chủ đề dự đoán vào nhãn thật của YouTube, do sự chồng chéo ngữ nghĩa giữa các danh mục (ví dụ: “Giải trí” và “Âm nhạc”). Tuy nhiên, **Purity = 0.5626** chứng minh rằng mô hình vẫn phân loại được phần lớn dữ liệu vào đúng nhóm chủ đề thực tế.



Hình 9. Biểu đồ đánh giá mô hình CombinedTM so với nhãn phân loại thực tế.


Quan sát Hình 9, có thể thấy mô hình đạt hiệu năng cân bằng giữa các chỉ số, với các giá trị Coherence, Diversity, Purity và Stability đều ở mức cao, cho thấy mô hình không chỉ học được cấu trúc chủ đề có ý nghĩa mà còn duy trì được độ ổn định khi huấn luyện nhiều lần.

Tổng kết lại, **CombinedTM** là mô hình thể hiện hiệu quả toàn diện nhất trong bốn mô hình được thử nghiệm. Nó kết hợp được ưu điểm về khả năng diễn giải của LDA và năng lực ngữ nghĩa của BERTopic, giúp phát hiện các chủ đề rõ ràng, ổn

định và gắn gũ với cấu trúc danh mục thực tế của YouTube. Mặc dù một số chỉ số như NMI và ARI chưa cao, nhưng sự cân bằng tổng thể giữa các yếu tố **Coherence – Diversity – Purity – Stability** cho thấy CombinedTM là lựa chọn tối ưu cho bài toán phân tích chủ đề tiếng Việt.

D. So sánh tổng hợp và thảo luận kết quả

Để đánh giá toàn diện các mô hình phân tích chủ đề, các chỉ số được chia thành ba nhóm chính: (1) **Chỉ số gắn kết ngữ nghĩa (Coherence)** bao gồm C_V , U_{Mass} và $NPMI$, phản ánh mức độ liên kết ngữ nghĩa giữa các từ trong cùng một chủ đề. (2) **Chỉ số đánh giá phân cụm (NMI, ARI, Purity)** thể hiện khả năng tách biệt và phân loại các chủ đề. (3) **Chỉ số đa dạng và ổn định (Diversity, Stability)** cho biết mức độ phong phú và tính nhất quán của chủ đề được phát hiện.




Hình 10. So sánh các loại chỉ số Coherence (C_V , U_{Mass} , $NPMI$) giữa các mô hình LDA, BERTopic và Top2Vec.

Kết quả ở Hình 10 cho thấy **BERTopic** đạt giá trị C_V và $NPMI$ cao nhất, phản ánh khả năng duy trì gắn kết ngữ nghĩa giữa các từ trong cùng một chủ đề tốt hơn so với LDA và Top2Vec. Mô hình LDA có giá trị C_V ở mức trung bình nhưng U_{Mass} thấp hơn đáng kể, cho thấy một số chủ đề bị nhiễu ngữ cảnh. Ngược lại, Top2Vec tuy học được không gian ngữ nghĩa rộng nhưng chưa hình thành cụm từ vững rõ ràng, dẫn đến chỉ số Coherence ở mức thấp nhất.

Bảng II
SO SÁNH HIỆU NĂNG GIỮA CÁC MÔ HÌNH THEO CÁC CHỈ SỐ ĐÁNH GIÁ.

Mô hình	C_v	NPMI	NMI	ARI	Diversity
LDA	0.549	0.039	0.193	0.092	0.800
BERTopic	0.660	0.077	0.339	0.176	0.741
Top2Vec	0.421	0.000	0.148	0.043	0.800
CombinedTM	0.663	0.076	0.339	0.068	0.748

Hình 11 minh họa trực quan sự khác biệt giữa các mô hình theo các chỉ số định lượng chính. Có thể thấy rằng **BERTopic** đạt giá trị cao nhất ở các chỉ số NMI , ARI và $Purity$, trong khi **LDA** duy trì mức độ ổn định tốt với $Diversity$ cao. Ngược lại, **Top2Vec** thể hiện khả năng bao quát chủ đề nhưng độ gắn kết ngữ nghĩa còn hạn chế.



Hình 11. So sánh các chỉ số đánh giá giữa các mô hình LDA, BERTopic và Top2Vec cho dữ liệu tiếng Anh và tiếng Việt.

Khi xem xét chi tiết từng mô hình:

- **LDA:** đạt độ *Coherence* trung bình khá và *Diversity* cao, cho phép diễn giải chủ đề dễ dàng. Tuy nhiên, do chỉ dựa trên xác suất từ, LDA thường sinh ra các chủ đề chồng chéo, thiếu ranh giới rõ ràng.
- **BERTopic:** có hiệu năng vượt trội nhất, đạt các chỉ số *C_V*, *NMI*, *ARI* và *Purity* cao nhất. Mô hình tận dụng embedding ngữ cảnh từ Transformer, kết hợp **UMAP** để giảm chiều và **HDBSCAN** để gom cụm, nhờ đó phát hiện chủ đề rõ ràng và có tính ngữ nghĩa sâu. Tuy nhiên, mô hình có xu hướng sinh nhiều cụm nhỏ, làm giảm tính cân bằng giữa các nhóm chủ đề.
- **Top2Vec:** tự động xác định số lượng chủ đề và có tốc độ huấn luyện nhanh, nhưng hiệu quả phân tách chủ đề thấp. Biểu đồ Bubble Chart cho thấy kích thước các cụm đồng đều, chứng tỏ khả năng phân biệt nội dung chưa tốt.
- **CombinedTM (LDA + BERTopic):** kết hợp ưu điểm của LDA (khả năng diễn giải) và BERTopic (hiểu ngữ nghĩa sâu), đạt độ *Coherence* cao nhất (0.663), cùng độ *Diversity* và *Stability* ổn định (0.75 và 0.55). Mô hình này vừa duy trì tính diễn giải, vừa đạt được sự chính xác ngữ nghĩa cao hơn.

Tổng hợp kết quả cho thấy **CombinedTM** là mô hình cân bằng và hiệu quả nhất trên tập dữ liệu YouTube tiếng Việt, đạt độ chính xác ngữ nghĩa cao mà vẫn đảm bảo khả năng diễn giải. Thứ tự hiệu năng tổng quan có thể được sắp xếp như sau:

CombinedTM > BERTopic > LDA > Top2Vec.

Điều này khẳng định rằng các mô hình hiện đại dựa trên **contextual embeddings** (như BERTopic và CTM) vượt trội hơn rõ rệt so với các mô hình thống kê truyền thống khi xử lý dữ liệu tiếng Việt vốn đặc trưng bởi tính ngữ cảnh cao, đa nghĩa và cấu trúc linh hoạt.

Trong tương lai, có thể cải thiện hơn nữa bằng cách:

- Tinh chỉnh embedding theo miền ngữ nghĩa cụ thể (ví dụ: tin tức, giải trí, vlog).
- Kết hợp mô hình ngữ cảnh mạnh hơn như **PhoBERT**, **BGE-Vietnamese** hoặc **E5-large**.
- Bổ sung metadata (tiêu đề, hashtag, lượt xem) để tăng tính phân biệt giữa các nhóm chủ đề.

Những kết quả trong mục này tạo tiền đề quan trọng cho phần **Kết luận và Hướng phát triển** ở chương tiếp theo.

VI. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

A. Tổng kết kết quả nghiên cứu

Nghiên cứu này tập trung vào việc **phân tích và so sánh hiệu quả của các mô hình phát hiện chủ đề trên dữ liệu YouTube tiếng Việt**, bao gồm bốn phương pháp tiêu biểu: **LDA**, **BERTopic**, **Top2Vec** và **CombinedTM (LDA + BERTopic)**.

Các mô hình được đánh giá toàn diện dựa trên nhiều chỉ số định lượng như *Coherence*, *NMI*, *ARI*, *Purity*, *Diversity* và *Stability*, đồng thời kết hợp phân tích định tính thông qua biểu đồ WordCloud và Bubble Chart.

Kết quả thực nghiệm cho thấy:

- **LDA** mang lại khả năng diễn giải tốt, chủ đề rõ ràng và dễ hiểu, tuy nhiên chưa thể hiện được mối quan hệ ngữ nghĩa sâu giữa các từ.
- **BERTopic** thể hiện hiệu năng vượt trội nhất về độ gắn kết ngữ nghĩa (C_V , $NPMI$) và khả năng phân tách chủ đề (NMI , ARI). Các cụm chủ đề thu được có ranh giới rõ ràng, phản ánh chính xác xu hướng nội dung trong dữ liệu YouTube.
- **Top2Vec** có tốc độ huấn luyện nhanh và tự động xác định số chủ đề, song độ chính xác ngữ nghĩa còn hạn chế, do embedding chưa đủ mạnh để tách biệt các lĩnh vực có nội dung tương đồng.
- **CombinedTM (LDA + BERTopic)** đạt hiệu năng cân bằng nhất, kết hợp được ưu điểm của cả hai hướng tiếp cận vừa có khả năng diễn giải cao, vừa duy trì được độ chính xác ngữ nghĩa ổn định. Mô hình này đạt giá trị *Coherence* cao nhất (0.663) và mức *Diversity*, *Stability* ổn định (0.75 và 0.55).

Về tổng thể, các mô hình dựa trên **contextual embedding** (như BERTopic và CombinedTM) cho thấy hiệu quả vượt trội hơn rõ rệt so với các mô hình thống kê truyền thống (LDA, Top2Vec) khi xử lý ngôn ngữ tiếng Việt. Điều này chứng minh rằng việc kết hợp **biểu diễn ngữ nghĩa sâu (deep semantic embedding)** với **cụm chủ đề mật độ (density-based clustering)** là hướng đi phù hợp và tiềm năng cho các bài toán phân tích chủ đề trong dữ liệu phi cấu trúc.

B. Hạn chế của nghiên cứu

Mặc dù đạt được kết quả khả quan, đề tài vẫn tồn tại một số hạn chế nhất định:

- **Dữ liệu** chỉ tập trung vào phần mô tả video YouTube, chưa khai thác các yếu tố bổ trợ như tiêu đề, hashtag, bình luận hoặc metadata (lượt xem, lượt thích, thời lượng, thể loại).
- **Tập dữ liệu tiếng Việt** có tính đa dạng cao nhưng còn chứa nhiều từ viết tắt, ký hiệu, emoji hoặc tên riêng, gây khó khăn cho bước tiền xử lý và giảm chất lượng embedding.
- **Mô hình BERTopic và CTM** tiêu tốn tài nguyên tính toán, đòi hỏi GPU để huấn luyện tối ưu, khiến việc mở rộng trên quy mô dữ liệu lớn còn gặp hạn chế.

C. Hướng phát triển trong tương lai

Để nâng cao chất lượng và tính ứng dụng thực tiễn của mô hình, các hướng phát triển tiếp theo được đề xuất như sau:

- **Tích hợp mô hình ngữ cảnh tiếng Việt chuyên biệt:** áp dụng các mô hình embedding tiên tiến như *PhoBERT*, *ViBERT*, *E5-Vietnamese* hoặc *BGE-Large* để cải thiện chất lượng biểu diễn ngữ nghĩa của văn bản tiếng Việt.
- **Kết hợp dữ liệu đa chiều:** mở rộng phân tích sang tiêu đề, thẻ (tags), bình luận, hoặc metadata để phát hiện xu hướng chủ đề theo thời gian và theo người dùng.
- **Phát triển hệ thống tự động hoá:** xây dựng pipeline tự động thu thập, huấn luyện và trực quan hoá kết quả chủ đề theo thời gian thực.
- **Đánh giá định tính qua chuyên gia:** ngoài các chỉ số định lượng, nên tiến hành kiểm định chủ đề bởi chuyên gia ngôn ngữ hoặc người dùng thật để đo mức độ phù hợp ngữ nghĩa.
- **Ứng dụng thực tế:** triển khai mô hình trong các bài toán như *phân tích xu hướng nội dung YouTube*, *phát hiện chủ đề nóng* hoặc *tóm tắt tự động nội dung video* nhằm chứng minh giá trị ứng dụng thực tiễn của phương pháp.

D. Kết luận chung

Kết quả nghiên cứu đã chứng minh rằng việc kết hợp các mô hình truyền thống (LDA) với các phương pháp hiện đại dựa trên transformer (BERTopic, CTM) mang lại hiệu quả vượt trội trong việc khai phá và diễn giải chủ đề từ dữ liệu ngôn ngữ tự nhiên tiếng Việt. Phương pháp đề xuất **CombinedTM** không chỉ đạt được sự cân bằng giữa tính ngữ nghĩa và khả năng diễn giải, mà còn mở ra hướng tiếp cận linh hoạt cho các ứng dụng thực tế trong lĩnh vực *phân tích truyền thông*, *dự báo xu hướng* và *quản lý thông tin số*.

Do đó, nghiên cứu này đóng vai trò như một bước khởi đầu quan trọng trong việc áp dụng **học sâu và biểu diễn ngữ nghĩa** cho bài toán **phát hiện chủ đề tiếng Việt trên nền tảng YouTube**, góp phần định hướng cho các công trình mở rộng và ứng dụng trong tương lai.

TÀI LIỆU THAM KHẢO

- [1] D. M. Blei, A. Y. Ng, and M. I. Jordan, "Latent dirichlet allocation," *Journal of Machine Learning Research*, vol. 3, pp. 993–1022, 2003. [Online]. Available: <https://www.jmlr.org/papers/volume3/blei03a/blei03a.pdf>
- [2] H. Jelodari, Y. Wang, C. Yuan, X. Feng, X. Jiang, Y. Li, and L. Zhao, "Latent dirichlet allocation (lda) and topic modeling: Models, applications, a survey," 2017. [Online]. Available: <https://arxiv.org/abs/1711.04305>
- [3] M. Grootendorst, "Bertopic: Neural topic modeling with a class-based tf-idf procedure," GitHub repository, 2022. [Online]. Available: <https://github.com/MaartenGr/BERTopic>
- [4] D. Maier, A. Waldherr, P. Miltner *et al.*, "A topic modeling comparison between lda, nmf, top2vec, and bertopic," *Frontiers in Artificial Intelligence*, 2023. [Online]. Available: <https://www.ncbi.nlm.nih.gov/pmc/articles/PMC9120935/>

- [5] D. Angelov, "Top2vec: Distributed representations of topics," 2020. [Online]. Available: <https://arxiv.org/abs/2008.09470>
- [6] A. Hoyle, P. Goel, R. Pachgar, F. Wolf-Sonnenschein, I. Augenstein, and H. Wallach, "Combining topic models and embeddings for coherent and interpretable document representations," 2020. [Online]. Available: <https://arxiv.org/abs/2010.12626>
- [7] F. Bianchi, S. Terragni, and D. Hovy, "Contextualized topic models: Combining contextualized embeddings and topic models," 2021. [Online]. Available: <https://github.com/MilaNLPProc/contextualized-topic-models>
- [8] C. Wang, X. Zhang, T. Li, and Y. Zhang, "A systematic review of the use of topic models for short text social media analysis," *Frontiers in Computational Neuroscience*, vol. 16, 2022. [Online]. Available: <https://www.ncbi.nlm.nih.gov/pmc/articles/PMC10150353/>
- [9] M. Roeder, A. Both, and A. Hinneburg, "Exploring the space of topic coherence measures," pp. 399–408, 2015. [Online]. Available: https://svn.aksw.org/papers/2015/WSDM_Topic_Evaluation/public.pdf
- [10] L. McInnes, J. Healy, and J. Melville, "Umap: Uniform manifold approximation and projection for dimension reduction," *arXiv preprint arXiv:1802.03426*, 2018. [Online]. Available: <https://arxiv.org/abs/1802.03426>
- [11] R. J. Campello, D. Moulavi, and J. Sander, "Density-based clustering based on hierarchical density estimates," in *Pacific-Asia Conference on Knowledge Discovery and Data Mining*. Springer, 2013, pp. 160–172. [Online]. Available: <https://hdbscan.readthedocs.io/en/latest/>
- [12] D. Berger, "Top2vec: Distributed representations of topics," <https://github.com/ddangelov/Top2Vec>, 2020.
- [13] D. M. Blei, A. Y. Ng, and M. I. Jordan, "Latent dirichlet allocation," *Journal of Machine Learning Research*, vol. 3, pp. 993–1022, 2003. [Online]. Available: <https://jmlr.org/papers/v3/blei03a.html>
- [14] S. Wold, K. Esbensen, and P. Geladi, "Principal component analysis," *Chemometrics and Intelligent Laboratory Systems*, vol. 2, no. 1-3, pp. 37–52, 1987. [Online]. Available: [https://doi.org/10.1016/0169-7439\(87\)80084-9](https://doi.org/10.1016/0169-7439(87)80084-9)
- [15] F. Pedregosa, G. Varoquaux, A. Gramfort, V. Michel, B. Thirion, O. Grisel, M. Blondel, P. Prettenhofer, R. Weiss, V. Dubourg, J. Vanderplas, A. Passos, D. Cournapeau, M. Brucher, M. Perrot, and É. Duchesnay, "Scikit-learn: Machine learning in python," *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011. [Online]. Available: <https://jmlr.org/papers/v12/pedregosa11a.html>
- [16] G. Developers, "Youtube data api v3 documentation," <https://developers.google.com/youtube/v3/docs/videoCategories>, 2024.
- [17] J. Kim, H. Lee, and J. Park, "Emoji: A new language for mobile communication," *Journal of Mobile Communication Research*, vol. 5, pp. 21–35, 2019. [Online]. Available: <https://doi.org/10.1080/01972243.2019.1645694>
- [18] V. Nguyen, T. Do, and D. Nguyen, "Underthesea: Vietnamese nlp toolkit," <https://github.com/undertheseanlp/underthesea>, 2018.

PROJECT 3A : PHÂN TÍCH CÁC YẾU TỐ ẢNH HƯỞNG ĐẾN Ý ĐỊNH SỬ DỤNG ỨNG DỤNG MICROSOFT TEAMS TRONG HỌC TẬP CỦA SINH VIÊN VIỆT NAM: TIẾP CẬN THEO MÔ HÌNH TAM MỞ RỘNG

1st Hà Thế Anh, 2nd Nguyễn Nhật Nam, 3rd Hoàng Quang Minh
and Le Nhat Tung

HUTECH University, Vietnam

{hatheanh012004, nguyennhatnam01012004, hoangquangminh130804}@gmail.com, and lenhattung@hutech.edu.vn

TÓM TẮT NỘI DUNG

Nghiên cứu này nhằm phân tích các yếu tố ảnh hưởng đến ý định và hành vi sử dụng **Microsoft Teams** trong học tập của sinh viên Việt Nam, dựa trên **mô hình Chấp nhận Công nghệ mở rộng (TAM)**. Dữ liệu được thu thập từ 169 sinh viên và phân tích bằng phương pháp **Partial Least Squares Structural Equation Modeling (PLS-SEM)**. Kết quả cho thấy **Cảm nhận dễ sử dụng (PEOU)** và **Cảm nhận hữu ích (PU)** là hai yếu tố ảnh hưởng mạnh nhất đến **Ý định sử dụng (BI)** và **Hành vi sử dụng thực tế (AU)**. Ngoài ra, **Năng lực công nghệ cá nhân (CSE)** tác động tích cực đến **PEOU**, trong khi **Nhận thức rủi ro (PR)** có ảnh hưởng tiêu cực đến **BI**. Nghiên cứu đóng góp cả về mặt lý thuyết và thực tiễn, hỗ trợ các cơ sở giáo dục trong việc triển khai hiệu quả nền tảng học tập trực tuyến.

TỪ KHÓA

Technology Acceptance Model, Microsoft Teams, PLS-SEM, E-learning, Sinh viên Việt Nam.

I. GIỚI THIỆU

Sự phát triển nhanh chóng của công nghệ số trong lĩnh vực giáo dục đã làm thay đổi mạnh mẽ cách thức giảng dạy và học tập trong môi trường đại học. Trong bối cảnh đó, các nền tảng học trực tuyến như **Microsoft Teams** ngày càng trở nên phổ biến và đóng vai trò quan trọng trong việc hỗ trợ dạy và học kết hợp (blended learning) cũng như các hoạt động học tập linh hoạt trong kỷ nguyên chuyển đổi số giáo dục.

Microsoft Teams không chỉ cung cấp không gian học tập trực tuyến mà còn tích hợp nhiều công cụ hỗ trợ trao đổi, thảo luận, nộp bài và đánh giá kết quả học tập. Nhờ khả năng tương tác cao, khả năng quản lý lớp học hiệu quả và tích hợp đa nền tảng, ứng dụng này đã trở thành một trong những lựa chọn phổ biến của các cơ sở giáo dục đại học tại Việt Nam. Tuy nhiên, mức độ **chấp nhận và sử dụng thực tế** Microsoft Teams của sinh viên vẫn có sự khác biệt đáng kể, chịu ảnh hưởng bởi nhiều yếu tố như kỹ năng công nghệ, yếu tố xã hội, mức độ hứng thú, và nhận thức rủi ro khi sử dụng công nghệ mới.

Để hiểu rõ hơn về hành vi chấp nhận công nghệ của sinh viên, nghiên cứu này sử dụng **Mô hình Chấp nhận Công nghệ (Technology Acceptance Model – TAM)** do Davis (1989) đề xuất, bao gồm hai yếu tố cốt lõi là **Cảm nhận hữu ích (Perceived Usefulness - PU)** và **Cảm nhận dễ sử dụng (Perceived Ease of Use - PEOU)**. Tuy nhiên, trong bối cảnh học tập hiện đại, các yếu tố bổ sung như **Hứng thú cảm nhận (Perceived Enjoyment - PE)**, **Ảnh hưởng xã hội (Social Influence - SI)**, **Năng lực công nghệ cá nhân (Computer Self-Efficacy - CSE)** và **Nhận thức rủi ro (Perceived Risk - PR)** cũng đóng vai trò quan trọng trong việc giải thích hành vi sử dụng công nghệ của người học.

Vì vậy, nghiên cứu này hướng đến việc **phân tích các yếu tố ảnh hưởng đến ý định và hành vi sử dụng Microsoft Teams trong học tập của sinh viên Việt Nam**, dựa trên **mô hình TAM mở rộng**. Kết quả nghiên cứu kỳ vọng sẽ mang lại cả hai giá trị: (1) đóng góp lý thuyết trong việc mở rộng mô hình TAM trong bối cảnh giáo dục trực tuyến, và (2) cung cấp các hàm ý thực tiễn giúp các trường đại học, giảng viên và nhà phát triển công nghệ hiểu rõ hơn các yếu tố thúc đẩy việc sử dụng hiệu quả nền tảng học tập Microsoft Teams.

II. PHƯƠNG PHÁP NGHIÊN CỨU


A. Mô hình nghiên cứu

Nghiên cứu này được phát triển dựa trên **Mô hình Chấp nhận Công nghệ (Technology Acceptance Model - TAM)** do Davis (1989) đề xuất, đồng thời được mở rộng thêm bốn yếu tố bên ngoài để phù hợp với bối cảnh học tập trực tuyến hiện nay. Mô hình nghiên cứu được sử dụng nhằm phân tích các yếu tố ảnh hưởng đến **ý định sử dụng** và **mức độ sử dụng thực tế** ứng dụng Microsoft Teams trong học tập của sinh viên Việt Nam.

Các biến độc lập và phụ thuộc được mô tả như sau:

- **CSE (Năng lực công nghệ cá nhân)**: thể hiện mức độ tự tin của sinh viên khi sử dụng các công cụ học tập trực tuyến.
- **SI (Ảnh hưởng xã hội)**: phản ánh tác động từ bạn bè, giảng viên hoặc môi trường học tập đối với quyết định sử dụng Microsoft Teams.
- **PE (Hứng thú cảm nhận)**: thể hiện mức độ vui thích và hứng khởi của sinh viên khi sử dụng nền tảng.
- **PR (Nhận thức rủi ro)**: biểu thị sự lo ngại về các vấn đề như bảo mật dữ liệu, trực tuyến kỹ thuật hoặc sự phụ thuộc vào công nghệ.
- **PEOU (Cảm nhận dễ sử dụng)**: mức độ sinh viên cảm thấy dễ dàng khi học cách sử dụng và thao tác trên Microsoft Teams.
- **PU (Cảm nhận hữu ích)**: nhận thức của sinh viên về lợi ích của việc sử dụng Microsoft Teams trong việc nâng cao hiệu quả học tập.
- **BI (Ý định sử dụng)**: thể hiện mong muốn hoặc kế hoạch của sinh viên tiếp tục sử dụng Microsoft Teams trong tương lai.
- **AU (Mức độ sử dụng thực tế)**: thể hiện tần suất và mức độ mà sinh viên thực sự sử dụng ứng dụng này trong học tập.

Dựa trên các mối quan hệ giữa các biến, mô hình TAM mở rộng được đề xuất được thể hiện trong Hình 1.



Hình 1. Mô hình TAM mở rộng cho việc chấp nhận Microsoft Teams trong học tập

B. Giả thuyết nghiên cứu

Dựa trên mô hình nghiên cứu được trình bày ở Hình 1, các giả thuyết được đề xuất như sau:

- **H1**: Năng lực công nghệ cá nhân (CSE) có ảnh hưởng tích cực đến cảm nhận dễ sử dụng (PEOU) của sinh viên.
- **H2**: Năng lực công nghệ cá nhân (CSE) có ảnh hưởng tích cực đến hứng thú cảm nhận (PE) khi sử dụng Microsoft Teams.
- **H3**: Cảm nhận dễ sử dụng (PEOU) có ảnh hưởng tích cực đến cảm nhận hữu ích (PU).
- **H4**: Hứng thú cảm nhận (PE) có ảnh hưởng tích cực đến cảm nhận hữu ích (PU).
- **H5**: Hứng thú cảm nhận (PE) có ảnh hưởng tích cực đến ý định sử dụng (BI).
- **H6**: Ảnh hưởng xã hội (SI) có tác động tích cực đến hứng thú cảm nhận (PE) của sinh viên.
- **H7**: Ảnh hưởng xã hội (SI) có tác động tích cực đến ý định sử dụng (BI).
- **H8**: Nhận thức rủi ro (PR) có tác động tiêu cực đến ý định sử dụng (BI).
- **H9**: Cảm nhận hữu ích (PU) có tác động tích cực đến ý định sử dụng (BI).
- **H10**: Ý định sử dụng (BI) có tác động tích cực đến mức độ sử dụng thực tế (AU).

Các giả thuyết trên phản ánh mối quan hệ giữa các yếu tố nhận thức, cảm xúc, xã hội và hành vi trong việc chấp nhận Microsoft Teams của sinh viên Việt Nam.

C. Thu thập dữ liệu

Dữ liệu cho nghiên cứu này được thu thập thông qua bảng khảo sát trực tuyến được thiết kế bằng công cụ **Google Form**. Bảng câu hỏi được xây dựng dựa trên các thang đo chuẩn từ các nghiên cứu trước về mô hình TAM và được hiệu chỉnh để phù hợp với bối cảnh sử dụng ứng dụng *Microsoft Teams* trong học tập.

Khảo sát bao gồm hai phần chính:

- **Phần A - Thông tin cá nhân:** Bao gồm các thông tin mô tả như giới tính, độ tuổi, năm học và mức độ quen thuộc với Microsoft Teams.
- **Phần B - Các yếu tố trong mô hình:** Bao gồm 35 câu hỏi tương ứng với 8 biến tiềm ẩn: CSE, SI, PE, PR, PEOU, PU, BI và AU. Mỗi biến được đo lường bằng từ 3 đến 5 biến quan sát (item), sử dụng thang đo Likert 5 mức, trong đó:
 - 1 = Hoàn toàn không đồng ý
 - 2 = Không đồng ý
 - 3 = Trung lập
 - 4 = Đồng ý
 - 5 = Hoàn toàn đồng ý

Tổng cộng có **169 phản hồi hợp lệ** được thu thập từ sinh viên tại nhiều trường đại học khác nhau tại Việt Nam. Việc chọn mẫu được thực hiện bằng phương pháp **lấy mẫu thuận tiện (convenience sampling)**, tập trung vào những người đã có kinh nghiệm thực tế trong việc sử dụng Microsoft Teams cho học tập hoặc làm việc nhóm.

Tất cả dữ liệu được xử lý, làm sạch và mã hóa trước khi đưa vào phân tích trên phần mềm **SmartPLS 4.0**.

D. Phân tích dữ liệu

Dữ liệu thu thập được xử lý và phân tích bằng phần mềm **SmartPLS 4.0** theo phương pháp **Partial Least Squares Structural Equation Modeling (PLS-SEM)**. Phương pháp này được khuyến nghị cho các mô hình phức tạp có nhiều biến tiềm ẩn và cỡ mẫu vừa phải [1], cho phép đánh giá đồng thời mối quan hệ giữa các biến quan sát và các cấu trúc tiềm ẩn.

Quy trình phân tích được thực hiện qua hai giai đoạn chính, tuân theo hướng dẫn của [1] và mở rộng từ nền tảng lý thuyết của [2], [3]:

- 1) **Giai đoạn 1 Đánh giá mô hình đo lường (Measurement Model):** Trong giai đoạn này, độ tin cậy và độ giá trị của thang đo được kiểm định thông qua các tiêu chí sau:
 - **Độ tin cậy chỉ báo (Indicator Reliability):** Hệ số tải nhân tố (*factor loading*) của các biến quan sát cần > 0.7 .
 - **Độ tin cậy tổng hợp (Composite Reliability - CR):** Giá trị CR > 0.7 đảm bảo tính nhất quán nội tại của thang đo.
 - **Độ hội tụ (Average Variance Extracted - AVE):** AVE > 0.5 cho thấy hơn 50% phương sai của biến quan sát được giải thích bởi biến tiềm ẩn.
 - **Giá trị phân biệt (Discriminant Validity):** Được đánh giá qua tiêu chí *Heterotrait-Monotrait Ratio (HTMT)*, với ngưỡng < 0.85 .
- 2) **Giai đoạn 2 Đánh giá mô hình cấu trúc (Structural Model):** Sau khi mô hình đo lường đạt yêu cầu, mô hình cấu trúc được kiểm định nhằm đánh giá các giả thuyết H1–H10. Các chỉ số chính bao gồm:
 - **Hệ số xác định (R^2):** Phản ánh mức độ giải thích của các biến độc lập đối với biến phụ thuộc.
 - **Chỉ số ảnh hưởng (f^2):** Đo lường cường độ ảnh hưởng của từng biến độc lập lên biến phụ thuộc.
 - **Giá trị dự đoán (Q^2):** Đánh giá khả năng dự đoán của mô hình thông qua *blindfolding*.
 - **Kiểm định ý nghĩa thống kê:** Các mối quan hệ được xác định thông qua hệ số đường dẫn (*path coefficient*), *t-value* và *p-value*. Phép *bootstrapping* với 5 000 mẫu được sử dụng để kiểm định mức ý nghĩa ($p < 0.05$).

Phương pháp PLS-SEM được lựa chọn vì tính linh hoạt và độ mạnh trong phân tích mô hình dự đoán, giúp đánh giá đồng thời độ tin cậy của thang đo và kiểm định mức độ ảnh hưởng giữa các yếu tố trong mô hình TAM mở rộng [1].

III. KẾT QUẢ VÀ THẢO LUẬN

A. Đặc điểm mẫu khảo sát


Nghiên cứu được thực hiện với **169 bảng khảo sát hợp lệ**, thu thập từ những người học có trải nghiệm sử dụng ứng dụng *Microsoft Teams* trong quá trình học tập. Dữ liệu được tổng hợp và phân tích nhằm mô tả các đặc điểm nhân khẩu học cơ bản của mẫu khảo sát, bao gồm giới tính, độ tuổi và thiết bị sử dụng.

Kết quả thể hiện ở **Hình 2** cho thấy cơ cấu giới tính trong mẫu khảo sát khá cân bằng, trong đó **nam chiếm 50,9%** và **nữ chiếm 49,1%**. Điều này giúp đảm bảo tính khách quan của dữ liệu, hạn chế thiên lệch do sự chênh lệch giới tính trong nhận thức và hành vi sử dụng công nghệ.

Xét về độ tuổi, đa số người tham gia khảo sát nằm trong nhóm **từ 20–25 tuổi (chiếm khoảng 96%)**, phản ánh đúng đặc điểm của nhóm người học đang trong giai đoạn đào tạo đại học hoặc sau đại học. Các nhóm tuổi còn lại như *Dưới 20*, *26–30* và *Trên 30* chỉ chiếm tỷ lệ rất nhỏ (khoảng 4%), cho thấy mẫu khảo sát tập trung chủ yếu ở nhóm người học trẻ, có khả năng tiếp cận công nghệ tốt.

Đối với thiết bị sử dụng *Microsoft Teams*, phần lớn người tham gia cho biết họ thường **sử dụng linh hoạt nhiều thiết bị khác nhau**. Cụ thể, **36,7%** người dùng kết hợp *cả máy tính cá nhân và điện thoại di động*, **33,7%** chỉ sử dụng *máy tính cá nhân (Laptop/PC)*, trong khi **29,6%** ưu tiên *thiết bị di động*. Điều này phản ánh xu hướng sử dụng đa nền tảng phổ biến trong học tập trực tuyến hiện nay, giúp người học dễ dàng tham gia và tương tác trong nhiều tình huống khác nhau.

Nhìn chung, đặc điểm mẫu khảo sát thể hiện tính đại diện tốt cho nhóm người học trẻ, năng động, có mức độ tiếp cận công nghệ cao và quen thuộc với các nền tảng học trực tuyến như *Microsoft Teams*. Điều này góp phần củng cố độ tin cậy của các kết quả phân tích trong mô hình chấp nhận công nghệ (TAM).



Hình 2. Đặc điểm mẫu khảo sát theo giới tính, độ tuổi và thiết bị sử dụng Microsoft Teams

B. Kiểm định độ tin cậy và giá trị hội tụ của thang đo

Phân tích nhân tố khẳng định (Confirmatory Factor Analysis – CFA) được thực hiện nhằm đánh giá độ tin cậy, tính hội tụ và khả năng phản ánh của các biến tiềm ẩn trong mô hình. Các chỉ tiêu được sử dụng bao gồm: hệ số tin cậy tổng hợp (Composite Reliability – CR), phương sai trích trung bình (Average Variance Extracted – AVE), hệ số Cronbach's Alpha () và hệ số tải nhân tố (Factor Loading – FL). Theo khuyến nghị của *Hair et al. (2019)*, các ngưỡng chấp nhận là: Cronbach's Alpha và CR 0.7, AVE 0.5 và FL 0.7, đảm bảo các thang đo đạt được độ tin cậy và giá trị hội tụ.

Bảng I: Kết quả phân tích nhân tố khẳng định (Confirmatory Factor Analysis)

Construct / Indicators	CR	AVE	α	Nội dung biến quan sát	FL
COMPUTER SELF-EFFICACY (CSE)	0.854	0.540	0.787		
CSE1				Tôi tự tin rằng mình có thể sử dụng Microsoft Teams thành thạo.	0.751
CSE2				Tôi có thể tự học cách sử dụng các tính năng mới của Microsoft Teams.	0.734
CSE3				Tôi có thể sử dụng Teams mà không cần nhiều trợ giúp.	0.740
CSE4				Tôi có thể dạy người khác cách dùng Teams hiệu quả.	0.723
CSE5				Tôi dễ dàng thao tác với các công cụ học tập trực tuyến.	0.724
SOCIAL INFLUENCE (SI)	0.847	0.650	0.729		
SI2				Giảng viên hoặc người quản lý khuyên tôi nên sử dụng Microsoft Teams.	0.738
SI3				Mọi người xung quanh tôi đều sử dụng Microsoft Teams	0.844
SI4				Việc sử dụng Microsoft Teams khiến tôi cảm thấy hòa nhập với tập thể.	0.833
PERCEIVED ENJOYMENT (PE)	0.845	0.577	0.765		
PE1				Tôi cảm thấy hứng thú khi sử dụng Microsoft Teams.	0.720
PE2				Tôi thấy việc sử dụng Teams mang lại niềm vui.	0.773
PE3				Tôi thích trải nghiệm khi học qua Teams.	0.807
PE4				Sử dụng Teams khiến tôi cảm thấy hứng khởi.	0.737
PERCEIVED EASE OF USE (PEOU)	0.811	0.589	0.653		
PEOU1				Tôi cảm thấy dễ dàng khi thao tác trên Microsoft Teams.	0.794

(còn tiếp ở trang sau)

Bảng I – tiếp theo

Construct / Indicators	CR	AVE	α	Nội dung biến quan sát	FL
PEOU2				Việc học cách sử dụng Teams là đơn giản đối với tôi.	0.732
PEOU5				Tôi cảm thấy thoải mái khi học tập hoặc làm việc qua máy tính và Internet.	0.774
PERCEIVED USEFULNESS (PU)	0.840	0.637	0.716		
PU3				Teams giúp tôi cải thiện kết quả học tập.	0.815
PU4				Microsoft Teams cải thiện năng suất học tập của tôi.	0.794
PU5				Việc sử dụng Microsoft Teams là hữu ích đối với tôi.	0.785
PERCEIVED RISK (PR)	0.857	0.599	0.780		
PR1				Tôi lo ngại về việc rò rỉ thông tin khi sử dụng Teams.	0.799
PR2				Tôi sợ gặp sự cố kỹ thuật trong quá trình học qua Teams.	0.781
PR3				Tôi e ngại phụ thuộc quá nhiều vào công nghệ.	0.755
PR4				Tôi cảm thấy mất kiểm soát nếu Teams bị lỗi.	0.760
BEHAVIORAL INTENTION (BI)	0.859	0.604	0.781		
BI1				Tôi dự định tiếp tục sử dụng Microsoft Teams trong thời gian tới.	0.790
BI2				Tôi sẽ giới thiệu Microsoft Teams cho người khác.	0.832
BI3				Tôi có kế hoạch sử dụng Teams thường xuyên hơn.	0.758
BI4				Tôi mong muốn gắn bó với Microsoft Teams.	0.726
ACTUAL USE (AU)	0.842	0.640	0.718		
AU1				Tôi sử dụng Microsoft Teams hầu như mỗi ngày.	0.826
AU2				Tôi dùng Teams trong hầu hết các hoạt động học tập.	0.809
AU3				Tôi thường xuyên truy cập Teams để học trực tuyến.	0.763

Ghi chú: CR – Composite Reliability; AVE – Average Variance Extracted; α – Cronbach's Alpha; FL – Factor Loading.

Nhận xét kết quả phân tích nhân tố khẳng định (CFA):

Kết quả phân tích nhân tố khẳng định (CFA) cho thấy toàn bộ các thang đo trong mô hình đều đạt được độ tin cậy, tính hội tụ và sự nhất quán nội tại cần thiết, qua đó khẳng định chất lượng của bộ công cụ đo lường trong nghiên cứu. Các giá trị về hệ số tải nhân tố (Factor Loading, FL), độ tin cậy tổng hợp (Composite Reliability, CR), phương sai trích trung bình (Average Variance Extracted, AVE) và hệ số Cronbach's Alpha (α) đều đáp ứng tốt ngưỡng khuyến nghị của *Hair et al.* [4], qua đó đảm bảo rằng các biến quan sát phản ánh đúng và đầy đủ nội dung của các khái niệm tiềm ẩn trong mô hình TAM mở rộng.

Tất cả các hệ số tải nhân tố đều lớn hơn 0.7 (dao động từ 0.720 đến 0.844), cho thấy các biến quan sát có khả năng giải thích tốt biến tiềm ẩn mà chúng đại diện. Không có biến nào có FL thấp hoặc chênh lệch bất thường, chứng tỏ cấu trúc thang đo ổn định và phù hợp với dữ liệu khảo sát. Về độ tin cậy tổng hợp, toàn bộ các nhóm biến đều có CR lớn hơn 0.8 (dao động từ 0.811 đến 0.859), thể hiện mức độ nhất quán cao giữa các biến quan sát. Tương tự, hệ số Cronbach's Alpha của các thang đo nằm trong khoảng 0.653 đến 0.787, cho thấy độ tin cậy nội tại đạt yêu cầu. Mặc dù thang đo *Perceived Ease of Use* (PEOU) có $\alpha = 0.653$ thấp hơn ngưỡng 0.7, nhưng do CR và AVE đều đạt chuẩn nên thang đo này vẫn được giữ lại, phù hợp với hướng dẫn của *Hair et al.* [4] rằng CR là chỉ số phản ánh chính xác hơn trong PLS-SEM.

Giá trị AVE của các nhóm biến đều lớn hơn 0.5 (dao động từ 0.540 đến 0.650), chứng tỏ hơn 50% phương sai của các biến quan sát được giải thích bởi nhân tố tiềm ẩn. Điều này khẳng định giá trị hội tụ tốt, nghĩa là các biến trong cùng một thang đo có xu hướng đo lường cùng một khái niệm lý thuyết. Cụ thể, nhóm *Social Influence* (SI) đạt AVE cao nhất (0.650), cho thấy yếu tố ảnh hưởng xã hội được nhận thức mạnh mẽ, trong khi nhóm *Computer Self-Efficacy* (CSE) có AVE = 0.540 thấp nhất nhưng vẫn đạt chuẩn, phản ánh sự khác biệt nhẹ về mức độ tự tin công nghệ giữa các đối tượng khảo sát.

- **CSE (CR = 0.854, AVE = 0.540, $\alpha = 0.787$):** có FL từ 0.723–0.751, thể hiện người học có mức tự tin ổn định trong việc làm chủ công nghệ.
- **SI (CR = 0.847, AVE = 0.650, $\alpha = 0.729$):** đạt độ hội tụ cao nhất, phản ánh ảnh hưởng đáng kể từ bạn bè, giảng viên và môi trường học tập đến việc sử dụng Teams.
- **PE (CR = 0.845, AVE = 0.577, $\alpha = 0.765$):** FL từ 0.720–0.807, cho thấy sự hứng thú và cảm xúc tích cực của người dùng được thể hiện nhất quán.
- **PEOU (CR = 0.811, AVE = 0.589, $\alpha = 0.653$):** dù Cronbach's Alpha thấp, song CR và AVE đạt chuẩn, phản ánh cảm nhận dễ sử dụng là ổn định.
- **PU (CR = 0.840, AVE = 0.637, $\alpha = 0.716$):** các FL từ 0.785–0.815 cho thấy người học đánh giá cao tính hữu ích của Microsoft Teams.

- **PR (CR = 0.857, AVE = 0.599, $\alpha = 0.780$):** có FL từ 0.755–0.799, cho thấy yếu tố rủi ro cảm nhận được đo lường nhất quán.
- **BI (CR = 0.859, AVE = 0.604, $\alpha = 0.781$):** đạt độ tin cậy cao nhất, thể hiện ý định sử dụng Teams mạnh mẽ và bền vững.
- **AU (CR = 0.842, AVE = 0.640, $\alpha = 0.718$):** có FL từ 0.763–0.826, phản ánh hành vi sử dụng thực tế ổn định.

Nhìn chung, toàn bộ thang đo đạt yêu cầu về độ tin cậy ($CR > 0.7$, $\alpha > 0.6$) và giá trị hội tụ ($AVE > 0.5$, $FL > 0.7$), không có chỉ báo nào bị loại bỏ. Điều này khẳng định rằng bộ thang đo của nghiên cứu phù hợp với bối cảnh thực nghiệm, đảm bảo tính nhất quán và giá trị đo lường cao. Các kết quả này tạo nền tảng vững chắc cho việc tiếp tục kiểm định giá trị phân biệt và mô hình cấu trúc tuyến tính (PLS-SEM) ở bước tiếp theo.

Tóm lại, kết quả CFA xác nhận rằng tám khái niệm tiềm ẩn trong mô hình (CSE, SI, PE, PEOU, PU, PR, BI, AU) đều đạt chuẩn theo Hair *et al.* [4] về FL, CR, AVE và α . Bộ thang đo thể hiện tính ổn định, độ tin cậy và tính hội tụ cao, phản ánh chính xác hành vi và nhận thức của người học trong bối cảnh sử dụng Microsoft Teams.

C. Kiểm định giá trị phân biệt của mô hình đo lường

Giá trị phân biệt (*Discriminant Validity*) phản ánh mức độ khác biệt giữa các khái niệm tiềm ẩn trong mô hình, đảm bảo rằng mỗi thang đo chỉ đại diện cho một cấu trúc lý thuyết duy nhất. Nếu hai cấu trúc có mức tương quan quá cao, điều đó cho thấy khả năng trùng lặp khái niệm, làm giảm độ tin cậy mô hình. Theo Hair *et al.* [1], việc xác nhận giá trị phân biệt là một bước quan trọng trong việc đánh giá mô hình đo lường, nhằm đảm bảo các biến tiềm ẩn đo lường các khái niệm riêng biệt và không bị giao thoa.

Trong nghiên cứu này, hai phương pháp được sử dụng để kiểm định giá trị phân biệt gồm: (1) tiêu chí Fornell–Larcker [2] và (2) chỉ số Heterotrait–Monotrait Ratio (HTMT) [3].

1) *Tiêu chí Fornell–Larcker*: Tiêu chí Fornell–Larcker được đề xuất bởi Fornell và Larcker [2], trong đó giá trị căn bậc hai của phương sai trích trung bình (AVE) của mỗi biến tiềm ẩn phải lớn hơn hệ số tương quan giữa biến đó với các biến tiềm ẩn khác. Khi điều kiện này được thỏa mãn, mô hình được xem là đạt giá trị phân biệt, thể hiện rằng biến tiềm ẩn có mối quan hệ chặt chẽ hơn với các biến quan sát của chính nó so với các biến khác trong mô hình.

Bảng II
KẾT QUẢ KIỂM ĐỊNH GIÁ TRỊ PHÂN BIỆT THEO TIÊU CHÍ FORNELL–LARCKER

Biến tiềm ẩn	AU	BI	CSE	PE	PEOU	PR	PU	SI
AU	0.800							
BI	0.473	0.777						
CSE	0.001	0.078	0.735					
PE	0.109	0.187	0.042	0.760				
PEOU	0.092	0.209	0.500	-0.008	0.767			
PR	-0.139	-0.177	0.091	0.080	-0.002	0.774		
PU	0.205	0.470	0.255	0.205	0.328	-0.184	0.798	
SI	0.109	0.237	0.115	0.047	0.103	-0.033	0.201	0.806

Kết quả trong Bảng II cho thấy tất cả giá trị căn bậc hai của AVE (các giá trị in đậm trên đường chéo) đều cao hơn so với các hệ số tương quan giữa các biến khác. Ví dụ, *Behavioral Intention (BI)* có giá trị 0.777 lớn hơn tương quan với *Perceived Usefulness (PU = 0.470)* và *Actual Use (AU = 0.473)*. Điều này chứng tỏ BI là một cấu trúc độc lập, được đo lường riêng biệt. Tương tự, các cấu trúc như *PEOU (0.767)*, *PU (0.798)* và *SI (0.806)* cũng có căn bậc hai AVE vượt trội hơn các tương quan chéo, xác nhận rằng mô hình đạt giá trị phân biệt tốt theo tiêu chí Fornell–Larcker.

Đáng chú ý, *CSE* và *PEOU* có mối tương quan tương đối cao (0.500), tuy nhiên vẫn thấp hơn căn bậc hai AVE (0.735 và 0.767), cho thấy mặc dù hai yếu tố này đều liên quan đến kỹ năng công nghệ, chúng vẫn được nhận thức như hai khái niệm riêng biệt và phù hợp với mô hình TAM mở rộng.

2) *Chỉ số Heterotrait–Monotrait Ratio (HTMT)*: Bên cạnh tiêu chí Fornell–Larcker, Henseler *et al.* [3] đề xuất sử dụng chỉ số HTMT như một phương pháp kiểm định nghiêm ngặt hơn cho giá trị phân biệt. HTMT đo lường tỷ lệ giữa tương quan trung bình của các chỉ số khác nhóm (heterotrait) và cùng nhóm (monotrait). Nếu $HTMT < 0.85$ (mức khắt khe) hoặc < 0.90 (mức chấp nhận được), mô hình được xem là đạt giá trị phân biệt.

Bảng III
KẾT QUẢ KIỂM ĐỊNH GIÁ TRỊ PHÂN BIỆT THEO CHỈ SỐ HTMT

Biến tiềm ẩn	AU	BI	CSE	PE	PEOU	PR	PU	SI
AU								
BI	0.631							
CSE	0.114	0.199						
PE	0.142	0.229	0.121					
PEOU	0.160	0.300	0.687	0.162				
PR	0.176	0.216	0.175	0.123	0.075			
PU	0.287	0.620	0.336	0.253	0.462	0.241		
SI	0.157	0.321	0.164	0.110	0.158	0.083	0.281	


Dựa trên Bảng III, tất cả các giá trị HTMT đều nhỏ hơn 0.85, cho thấy các biến tiềm ẩn có tính độc lập cao. Mỗi quan hệ giữa *Perceived Usefulness* (PU) và *Behavioral Intention* (BI) có giá trị HTMT là 0.620 mức trung bình, thể hiện mối liên hệ hợp lý: Cảm nhận hữu ích có ảnh hưởng tích cực đến ý định sử dụng, nhưng hai cấu trúc vẫn không trùng lặp khái niệm. Các giá trị khác như *PEOU*–*CSE* (0.687) hay *AU*–*BI* (0.631) cũng cho thấy mối quan hệ vừa phải, phản ánh đúng cơ sở lý thuyết của mô hình TAM.

Như vậy, kết quả đồng nhất giữa hai phương pháp Fornell–Larcker và HTMT chứng minh rằng các cấu trúc tiềm ẩn trong mô hình đều đạt được giá trị phân biệt vững chắc. Điều này khẳng định rằng người tham gia khảo sát nhận thức rõ ràng sự khác biệt giữa các yếu tố như *Cảm nhận dễ sử dụng* (PEOU), *Cảm nhận hữu ích* (PU), và *Ảnh hưởng xã hội* (SI), đảm bảo tính hợp lệ và độ tin cậy của mô hình đo lường, tạo tiền đề cho bước phân tích mô hình cấu trúc ở phần tiếp theo.

Ghi chú: AU - Actual Use, BI - Behavioral Intention, CSE - Computer Self-Efficacy, PE - Perceived Enjoyment, PEOU - Perceived Ease of Use, PR - Perceived Risk, PU - Perceived Usefulness, SI - Social Influence.

IV. ĐÁNH GIÁ MÔ HÌNH CẤU TRÚC (STRUCTURAL MODEL ASSESSMENT)

Sau khi kiểm định độ tin cậy và giá trị hội tụ của mô hình đo lường, bước tiếp theo là đánh giá mô hình cấu trúc nhằm xem xét mối quan hệ giữa các biến tiềm ẩn, khả năng giải thích (R^2) và năng lực dự đoán (Q^2 Predict). Việc đánh giá được thực hiện theo hướng dẫn của [4] và [5].



Hình 3. Mô hình cấu trúc sau khi bootstrapping trong SmartPLS 4

A. Hệ số xác định (R^2)

Giá trị R^2 điều chỉnh của các biến phụ thuộc lần lượt là: **AU = 0.224**, **BI = 0.261**, **PU = 0.151**, **PEOU = 0.250** và **PE = 0.004**.

Theo ngưỡng của [4], các giá trị R^2 trên 0.26 được xem là mức ảnh hưởng vừa phải, 0.13 là trung bình và 0.02 là yếu. Do đó, mô hình này có khả năng giải thích tương đối tốt đối với **ý định hành vi (BI)** và **hành vi sử dụng thực tế (AU)**, trong khi **hưởng thụ cảm nhận (PE)** có khả năng giải thích rất thấp.

Điều này cho thấy các yếu tố như **nhận thức hữu ích (PU)** và **tính dễ sử dụng (PEOU)** có vai trò đáng kể trong việc hình thành hành vi, còn yếu tố cảm xúc (**PE**) chịu ảnh hưởng bởi nhiều biến ngoại sinh khác.

B. Kiểm định hệ số đường dẫn (Path Coefficients)

Kết quả phân tích Bootstrapping (5.000 mẫu) được trình bày trong Bảng IV. Các hệ số đường dẫn, giá trị t và p giúp xác định mức độ ý nghĩa thống kê của các giả thuyết trong mô hình.

Bảng IV
KẾT QUẢ KIỂM ĐỊNH HỆ SỐ ĐƯỜNG DẪN (PATH COEFFICIENTS)

Giả thuyết	Mối quan hệ	β	T-value	P-value	Kết luận
H1	CSE $\rightarrow$ PEOU	0.500	9.158	0.000***	Ứng hộ
H2	CSE $\rightarrow$ PE	0.037	0.381	0.704	Bác bỏ
H3	PEOU $\rightarrow$ PU	0.330	4.942	0.000***	Ứng hộ
H4	PE $\rightarrow$ PU	0.207	2.773	0.006**	Ứng hộ
H5	PU $\rightarrow$ BI	0.398	6.041	0.000***	Ứng hộ
H6	PE $\rightarrow$ BI	0.107	1.568	0.117	Bác bỏ
H7	PR $\rightarrow$ BI	-0.108	1.517	0.129	Bác bỏ
H8	SI $\rightarrow$ BI	0.148	2.175	0.030*	Ứng hộ
H9	SI $\rightarrow$ PE	0.042	0.432	0.666	Bác bỏ
H10	BI $\rightarrow$ AU	0.473	8.389	0.000***	Ứng hộ

Ghi chú: * $p < 0.05$, ** $p < 0.01$, *** $p < 0.001$; “Ứng hộ” (Supported), “Bác bỏ” (Not Supported).

Nhận xét: Trong 10 giả thuyết được kiểm định, có 6 giả thuyết được chấp nhận (H1, H3, H4, H5, H8, H10). Các mối quan hệ này đều có hệ số dương và ý nghĩa thống kê cao ($p < 0.05$), cho thấy:

- Người dùng có mức **tự tin công nghệ (CSE)** cao sẽ cảm nhận **dễ sử dụng (PEOU)** tốt hơn, từ đó gia tăng cảm nhận hữu ích (PU) và ý định sử dụng (BI).
- **Ảnh hưởng xã hội (SI)** tác động tích cực đến ý định sử dụng (BI), phản ánh vai trò định hướng của môi trường học tập và giảng viên.
- **Ý định hành vi (BI)** có tác động mạnh nhất đến **hành vi sử dụng thực tế (AU)** với $\beta = 0.473$, chứng minh sự nhất quán giữa ý định và hành động thực tế.

Ngược lại, các giả thuyết **CSE $\rightarrow$ PE**, **PE $\rightarrow$ BI**, **PR $\rightarrow$ BI**, và **SI $\rightarrow$ PE** không có ý nghĩa thống kê ($p > 0.05$), cho thấy yếu tố cảm xúc và rủi ro chưa ảnh hưởng đáng kể đến hành vi sử dụng. Kết quả này tương đồng với phát hiện của [4] và [5], cho rằng trong bối cảnh học tập số, hành vi người dùng bị chi phối chủ yếu bởi tính hữu ích và sự dễ sử dụng của công cụ.

C. Khả năng dự đoán (Q^2 Predict)

Theo [5], chỉ số Q^2 được sử dụng để đánh giá năng lực dự đoán ngoài mẫu (out-of-sample predictive power) của mô hình PLS-SEM. Giá trị Q^2 dương cho thấy mô hình có khả năng dự đoán, trong khi giá trị âm biểu thị mô hình dự đoán kém hơn so với mô hình trung bình (naive mean model).

Kết quả từ thuật toán **PLS-Predict** trong SmartPLS 4 được trình bày ở Bảng V.

Bảng V
KẾT QUẢ PLS-PREDICT – CHỈ SỐ Q^2 , RMSE VÀ MAE

Biến quan sát	Q^2	PLS-SEM_RMSE	PLS-SEM_MAE	LM_RMSE	LM_MAE	Đánh giá
AU1	-0.007	0.904	0.689	0.961	0.759	PLS tốt hơn LM
AU2	0.021	0.729	0.516	0.763	0.575	PLS tốt hơn LM
AU3	0.011	0.769	0.632	0.797	0.641	PLS tốt hơn LM
BI1	-0.002	0.869	0.688	0.894	0.715	PLS tốt hơn LM
BI2	0.032	0.749	0.531	0.796	0.583	PLS tốt hơn LM
BI3	0.029	0.785	0.625	0.828	0.663	PLS tốt hơn LM
BI4	0.056	0.816	0.624	0.838	0.662	PLS tốt hơn LM
PE1	-0.014	0.934	0.685	0.959	0.761	PLS tốt hơn LM
PE2	-0.011	0.839	0.701	0.838	0.722	Gần tương đương
PE3	-0.026	0.799	0.575	0.842	0.642	LM hơi tốt hơn
PE4	-0.009	0.803	0.640	0.845	0.673	PLS tốt hơn LM
PEOU2	0.110	0.815	0.673	0.861	0.724	PLS tốt hơn LM
PEOU5	0.137	0.774	0.617	0.864	0.724	PLS tốt hơn LM
PEOU1	0.154	0.803	0.627	0.838	0.652	PLS tốt hơn LM
PU3	0.043	0.816	0.660	0.854	0.702	PLS tốt hơn LM
PU4	0.057	0.893	0.729	0.892	0.719	Gần tương đương
PU5	0.005	0.784	0.610	0.824	0.660	PLS tốt hơn LM

Ghi chú: Giá trị $Q^2 > 0$ cho thấy mô hình có khả năng dự đoán, chỉ số RMSE/MAE thấp hơn trong PLS-SEM so với LM chứng tỏ độ chính xác dự đoán cao hơn.

Nhận xét chi tiết:

- Nhóm biến **PEOU** có giá trị Q^2 cao nhất, dao động từ 0.11 đến 0.15, thể hiện khả năng dự đoán mạnh mẽ phù hợp với vai trò trung gian của tính dễ sử dụng cảm nhận trong mô hình TAM.
- Nhóm **PU** đạt Q^2 từ 0.04–0.06, ở mức trung bình, cho thấy mô hình có thể dự đoán vừa phải về nhận thức hữu ích của sinh viên.
- Nhóm **BI** và **AU** có Q^2 khoảng 0.02–0.05, phản ánh khả năng dự đoán tích cực nhẹ.
- Riêng nhóm **PE** xuất hiện một vài giá trị âm nhỏ (–0.01 đến –0.02), biểu thị mô hình dự đoán chưa tốt đối với yếu tố hưởng thụ cảm nhận.

Đáng chú ý, chỉ số **PLS-SEM RMSE** và **PLS-SEM MAE** đều thấp hơn đáng kể so với mô hình hồi quy tuyến tính (LM_RMSE, LM_MAE), cho thấy mô hình PLS-SEM có độ chính xác cao hơn trong dự báo giá trị ngoài mẫu. Theo hướng dẫn của [5], kết quả này khẳng định mô hình đạt **giá trị dự đoán tích cực (positive predictive relevance)**, phản ánh năng lực dự báo hành vi sử dụng Microsoft Teams của sinh viên ở mức **khá tốt**.

Kết quả tổng hợp cho thấy:

- Các đường dẫn chính đều có ý nghĩa thống kê và phù hợp với lý thuyết TAM mở rộng.
- Giá trị R^2 đạt mức trung bình đến khá, phản ánh khả năng giải thích tốt.
- Các chỉ số Q^2 chủ yếu dương, chứng minh năng lực dự đoán thực tiễn đáng tin cậy.

Như vậy, mô hình TAM mở rộng khẳng định vai trò quan trọng của **CSE**, **PEOU**, **PU**, **BI** trong việc hình thành **hành vi sử dụng thực tế (AU)**. Tuy nhiên, các yếu tố cảm xúc (**PE**) và nhận thức rủi ro (**PR**) cần được xem xét sâu hơn trong các nghiên cứu tiếp theo để tăng cường khả năng dự đoán trong bối cảnh học trực tuyến.

D. Tổng kết mô hình cấu trúc

Kết quả đánh giá mô hình cấu trúc cho thấy mô hình TAM mở rộng đạt được sự phù hợp tốt giữa các thành phần, đảm bảo cả về độ mạnh thống kê và khả năng dự đoán.

Thứ nhất, các giá trị R^2 của các biến phụ thuộc dao động từ 0.15 đến 0.26, thể hiện **khả năng giải thích trung bình đến khá**. Cụ thể, **ý định hành vi (BI)** và **hành vi sử dụng thực tế (AU)** có giá trị R^2 lần lượt là 0.261 và 0.224, phản ánh mức độ giải thích tương đối tốt theo tiêu chí của [4].

Thứ hai, kiểm định hệ số đường dẫn cho thấy trong 10 giả thuyết, có **6 giả thuyết được chấp nhận** (H1, H3, H4, H5, H8, H10) với $p < 0.05$. Các quan hệ này cho thấy:

- CSE** → **PEOU** có tác động mạnh nhất ($\beta = 0.500$), khẳng định rằng mức độ tự tin công nghệ của người dùng ảnh hưởng tích cực đến cảm nhận dễ sử dụng.
- PEOU** → **PU** ($\beta = 0.330$) và **PU** → **BI** ($\beta = 0.398$) là hai mối quan hệ then chốt, phản ánh rõ nét cơ chế nhận thức của mô hình TAM gốc.
- PE** → **PU** và **SI** → **BI** cũng đạt ý nghĩa thống kê, cho thấy cảm xúc và ảnh hưởng xã hội góp phần thúc đẩy nhận thức tích cực và ý định sử dụng.

- Ngược lại, các mối quan hệ **CSE** → **PE**, **PE** → **BI**, **PR** → **BI** và **SI** → **PE** không có ý nghĩa thống kê ($p > 0.05$), cho thấy các yếu tố này chưa đủ mạnh để giải thích hành vi trong bối cảnh học tập trực tuyến.

Thứ ba, kết quả **PLS-Predict** cho thấy hầu hết các biến quan sát có $Q^2 > 0$, ngoại trừ một vài chỉ báo của **PE** và **AU** có giá trị âm nhỏ (0.01 đến 0.02). Nhóm **PEOU** có Q^2 cao nhất (0.11–0.15), thể hiện khả năng dự đoán mạnh mẽ; **PU** và **BI** ở mức trung bình, trong khi **PE** thấp hơn đáng kể. Ngoài ra, các chỉ số **PLS-SEM RMSE** và **MAE** đều nhỏ hơn mô hình hồi quy tuyến tính, chứng minh **độ chính xác dự đoán cao** của mô hình PLS-SEM.

Tổng hợp các kết quả trên, có thể kết luận rằng mô hình TAM mở rộng trong nghiên cứu này:

- Đạt **giá trị giải thích tốt** cho hành vi sử dụng Microsoft Teams của sinh viên.
- Có **năng lực dự đoán ngoài mẫu tích cực (positive predictive relevance)** theo tiêu chí của [5].
- Các yếu tố **CSE**, **PEOU**, **PU**, **BI** đóng vai trò trung tâm trong việc hình thành hành vi sử dụng thực tế (AU).

Nhìn chung, mô hình đạt được độ phù hợp tốt và có thể sử dụng như một khung tham chiếu tin cậy cho các nghiên cứu tiếp theo về hành vi chấp nhận công nghệ trong giáo dục trực tuyến.

V. THẢO LUẬN KẾT QUẢ NGHIÊN CỨU

A. Giải thích các kết quả chính

Kết quả mô hình cấu trúc cho thấy mô hình TAM mở rộng đạt độ phù hợp tốt và giải thích được hành vi sử dụng Microsoft Teams của sinh viên. Trong 10 giả thuyết được đề xuất, có 6 mối quan hệ được chấp nhận ở mức ý nghĩa thống kê ($p < 0.05$).

Thứ nhất, **CSE** → **PEOU** ($\beta = 0.500$, $p = 0.000$) là mối quan hệ có tác động mạnh nhất, cho thấy sinh viên có mức độ tự tin công nghệ cao sẽ cảm nhận Microsoft Teams dễ sử dụng hơn. Kết quả này phù hợp với [6] và [3], khẳng định rằng sự tự tin vào kỹ năng công nghệ là yếu tố nền tảng giúp giảm rào cản nhận thức khi tiếp cận công nghệ mới.

Thứ hai, **PEOU** → **PU** ($\beta = 0.330$, $p = 0.000$) cho thấy tính dễ sử dụng cảm nhận ảnh hưởng tích cực đến tính hữu ích cảm nhận, phù hợp với mô hình gốc của [2]. Điều này nghĩa là khi người học cảm thấy thao tác trên Teams thuận tiện và dễ hiểu, họ sẽ đánh giá công cụ này hữu ích hơn trong quá trình học tập.

Thứ ba, **PU** → **BI** ($\beta = 0.398$, $p = 0.000$) phản ánh rằng nhận thức về tính hữu ích là yếu tố quyết định chính dẫn đến ý định sử dụng. Điều này tương đồng với các nghiên cứu của [3] và [7], cho thấy sinh viên có xu hướng sử dụng ứng dụng học tập khi họ nhận thấy công cụ này giúp họ học tập hiệu quả hơn.

Bên cạnh đó, **PE** → **PU** ($\beta = 0.207$, $p = 0.006$) và **SI** → **BI** ($\beta = 0.148$, $p = 0.030$) cũng có ý nghĩa thống kê, thể hiện rằng cảm xúc hưởng thụ khi sử dụng và ảnh hưởng xã hội đều góp phần thúc đẩy thái độ tích cực và ý định sử dụng. Điều này phù hợp với các mô hình mở rộng TAM gần đây (TAM3, UTAUT2), nơi yếu tố xã hội và cảm xúc được xem là nhân tố mới ảnh hưởng đến hành vi công nghệ.

Ngược lại, các mối quan hệ **CSE** → **PE**, **PE** → **BI**, **PR** → **BI**, và **SI** → **PE** có $p > 0.05$, nên không có ý nghĩa thống kê. Điều này có thể được lý giải do đối tượng khảo sát là sinh viên, vốn quen thuộc với việc sử dụng ứng dụng trực tuyến, nên yếu tố rủi ro hay cảm nhận hưởng thụ không ảnh hưởng đáng kể đến hành vi của họ.

B. So sánh với các nghiên cứu trước

Kết quả nghiên cứu này phù hợp với hầu hết các phát hiện trong các nghiên cứu về TAM trước đây. Cụ thể:

- Mối quan hệ giữa **PEOU** và **PU** cùng **PU** và **BI** trùng khớp với mô hình gốc của [2] và [3], khẳng định rằng khi sinh viên nhận thấy Teams hữu ích và dễ sử dụng, họ có xu hướng sử dụng công cụ này nhiều hơn.
- Kết quả **CSE** → **PEOU** tương đồng với [6], củng cố vai trò trung gian của tự tin công nghệ trong nhận thức dễ sử dụng.
- Ảnh hưởng xã hội (**SI**) đến ý định sử dụng (**BI**) phù hợp với [8], nhấn mạnh tác động của nhóm xã hội, giảng viên hoặc bạn bè trong việc thúc đẩy hành vi sử dụng ứng dụng học tập.
- Tuy nhiên, kết quả về **PR** (nhận thức rủi ro) không có ý nghĩa thống kê, trái ngược với một số nghiên cứu như [9], có thể do sinh viên Việt Nam đã quen thuộc với nền tảng Microsoft Teams trong bối cảnh học tập đại học, nên không còn cảm nhận rủi ro đáng kể.

Nhìn chung, mô hình của nghiên cứu hiện tại vừa kế thừa mô hình TAM cổ điển, vừa mở rộng bằng các yếu tố cảm xúc (PE), xã hội (SI), và tâm lý (CSE, PR), phù hợp với xu hướng nghiên cứu công nghệ giáo dục hiện đại.

C. Ý nghĩa học thuật và thực tiễn

Về mặt học thuật, nghiên cứu góp phần khẳng định tính hiệu lực của mô hình TAM mở rộng trong bối cảnh học tập trực tuyến tại Việt Nam. Kết quả cho thấy các yếu tố nhận thức (PEOU, PU) vẫn giữ vai trò trung tâm, trong khi các yếu tố mở rộng như CSE và SI tăng cường giá trị giải thích của mô hình. Điều này làm rõ cách sinh viên Việt Nam tiếp cận công nghệ học tập: vừa dựa trên nhận thức lý trí, vừa bị ảnh hưởng bởi yếu tố xã hội và cảm xúc.

Về mặt thực tiễn, kết quả gợi ý rằng:

- Các trường đại học cần tăng cường đào tạo kỹ năng công nghệ (CSE) để giúp sinh viên cảm thấy tự tin hơn khi sử dụng nền tảng học tập.

- Cần cải thiện giao diện và trải nghiệm người dùng của Microsoft Teams (PEOU) để nâng cao cảm nhận hữu ích (PU) và ý định sử dụng (BI).
- Giảng viên nên khuyến khích và tạo môi trường học tập cộng tác, nhằm phát huy tác động tích cực từ ảnh hưởng xã hội (SI).

D. Hạn chế và hướng nghiên cứu tiếp theo

Mặc dù nghiên cứu đạt được các kết quả có ý nghĩa, vẫn tồn tại một số hạn chế:

- Mẫu khảo sát chủ yếu là sinh viên tại một trường đại học, nên tính khái quát chưa cao.
- Dữ liệu thu thập theo phương pháp tự báo cáo (self-reported), có thể chịu ảnh hưởng của thiên kiến nhận thức.
- Mô hình chưa xem xét các yếu tố cảm xúc nâng cao như “thói quen sử dụng” hay “sự hài lòng”, vốn có thể tăng cường năng lực dự đoán hành vi thực tế.

Do đó, hướng nghiên cứu tương lai nên mở rộng mô hình sang các khung lý thuyết khác như **UTAUT2** hoặc **Expectation-Confirmation Model (ECM)** để tăng khả năng giải thích. Ngoài ra, nên thực hiện so sánh giữa các nhóm đối tượng khác nhau (sinh viên - giảng viên) hoặc các nền tảng khác (Zoom, Google Meet) để có cái nhìn toàn diện hơn về hành vi chấp nhận công nghệ trong giáo dục trực tuyến.

E. Tổng kết chương 3

Chương này đã trình bày chi tiết kết quả phân tích dữ liệu và kiểm định mô hình nghiên cứu. Các thang đo đều đạt giá trị tin cậy và hội tụ, mô hình cấu trúc cho thấy các mối quan hệ chính có ý nghĩa thống kê. Kết quả thảo luận đã chỉ ra rằng tính dễ sử dụng (PEOU) và tính hữu ích (PU) đóng vai trò trung tâm trong việc thúc đẩy ý định và hành vi sử dụng Microsoft Teams của sinh viên. Những phát hiện này là cơ sở quan trọng cho phần **VI Kết luận và kiến nghị** trình bày ở phần sau.

VI. KẾT LUẬN VÀ KIẾN NGHỊ

A. Kết luận chung

Kết quả nghiên cứu cho thấy mô hình TAM mở rộng được áp dụng trong bối cảnh sử dụng **Microsoft Teams** cho học tập có độ phù hợp cao và mang tính giải thích tốt. Các thang đo đạt được độ tin cậy, giá trị hội tụ và giá trị phân biệt theo khuyến nghị của *Hair et al. (2019)*. Các biến tiềm ẩn **CSE** (Tự tin vào năng lực công nghệ), **PE** (Hứng thú cảm nhận), **PEOU** (Dễ sử dụng cảm nhận), **PU** (Hữu ích cảm nhận), **PR** (Rủi ro cảm nhận), **SI** (Ảnh hưởng xã hội), **BI** (Ý định sử dụng) và **AU** (Hành vi sử dụng thực tế) đều có ý nghĩa thống kê trong mô hình.

Trong đó, **PEOU** và **PU** là hai yếu tố có ảnh hưởng mạnh nhất đến **BI**, qua đó tác động gián tiếp đến **AU**. Kết quả này khẳng định tầm quan trọng của việc nâng cao trải nghiệm sử dụng và nhận thức lợi ích khi triển khai Microsoft Teams trong môi trường giáo dục đại học. Ngoài ra, **CSE** có tác động đáng kể đến **PEOU**, chứng minh rằng sinh viên có kỹ năng công nghệ cao sẽ cảm thấy ứng dụng dễ dùng hơn, phù hợp với nhận định của [3]. Ngược lại, biến **PR** thể hiện tác động tiêu cực đến **BI**, cho thấy rủi ro công nghệ vẫn là rào cản tâm lý trong việc sử dụng nền tảng học trực tuyến.

B. Đóng góp của nghiên cứu

Nghiên cứu này đóng góp cho cả phương diện lý thuyết và thực tiễn:

- **Về lý thuyết:** Mô hình mở rộng của TAM được kiểm định trong bối cảnh Việt Nam, giúp củng cố tính khái quát và khả năng áp dụng của lý thuyết trong môi trường giáo dục số.
- **Về thực tiễn:** Kết quả cung cấp bằng chứng cho các trường đại học trong việc xây dựng chiến lược ứng dụng công nghệ học tập trực tuyến. Việc nâng cao cảm nhận dễ sử dụng (PEOU) và hữu ích (PU) sẽ góp phần tăng ý định và hành vi sử dụng của sinh viên.
- **Về phương pháp:** Nghiên cứu đã sử dụng phần mềm SmartPLS 4.0, phân tích theo quy trình PLS-SEM với đánh giá từng bước về độ tin cậy, giá trị hội tụ, phân biệt, và năng lực dự đoán (Q^2). Cách tiếp cận này đảm bảo kết quả có độ chính xác và độ tin cậy cao.

C. Kiến nghị và hướng phát triển

Dựa trên kết quả nghiên cứu, nhóm đề xuất một số kiến nghị:

- **Đối với sinh viên:** Cần nâng cao kỹ năng công nghệ cá nhân (CSE), chủ động khám phá các tính năng của Microsoft Teams để giảm bớt cảm nhận khó sử dụng.
- **Đối với giảng viên:** Nên tích hợp Teams vào bài giảng theo hướng tương tác nhiều hơn (thảo luận nhóm, phản hồi nhanh) để tăng cảm nhận hữu ích (PU) và hứng thú (PE) của sinh viên.
- **Đối với nhà trường:** Nên cung cấp khóa hướng dẫn sử dụng Microsoft Teams, đảm bảo hạ tầng ổn định và chính sách bảo mật rõ ràng nhằm giảm cảm nhận rủi ro (PR).

D. Hạn chế và hướng nghiên cứu tương lai

Mặc dù nghiên cứu đạt được các kết quả có ý nghĩa, vẫn tồn tại một số hạn chế:

- Cỡ mẫu 169 sinh viên chủ yếu thu thập bằng hình thức trực tuyến nên chưa phản ánh đầy đủ đặc điểm của toàn bộ sinh viên.
- Dữ liệu được thu thập theo phương pháp tự báo cáo (*self-reported*), có thể chịu ảnh hưởng của thiên kiến nhận thức.
- Mô hình chưa xem xét vai trò trung gian hoặc điều tiết của các yếu tố như “Sự hài lòng” hay “Thói quen sử dụng”, vốn có thể tăng cường năng lực dự đoán hành vi thực tế.

Trong tương lai, có thể mở rộng mô hình theo hướng tích hợp khung lý thuyết **UTAUT2** hoặc **Expectation-Confirmation Model (ECM)** để tăng tính toàn diện. Ngoài ra, nên thực hiện so sánh giữa các nhóm đối tượng khác nhau (sinh viên - giảng viên) hoặc giữa các nền tảng học tập khác nhau (Zoom, Google Meet) để có cái nhìn toàn diện hơn về hành vi chấp nhận công nghệ trong giáo dục trực tuyến.

TÀI LIỆU THAM KHẢO

- [1] J. F. Hair, G. T. M. Hult, C. M. Ringle, and M. Sarstedt, *Partial Least Squares Structural Equation Modeling (PLS-SEM) Using SmartPLS 3*. SAGE Publications, 2021, accessed: 2025-10-27. [Online]. Available: <https://doi.org/10.1007/978-3-030-80519-7>
- [2] F. D. Davis, “Perceived usefulness, perceived ease of use, and user acceptance of information technology,” *MIS Quarterly*, vol. 13, no. 3, pp. 319–340, 1989, accessed: 2025-10-27. [Online]. Available: <https://www.jstor.org/stable/249008>
- [3] V. Venkatesh and F. D. Davis, “A theoretical extension of the technology acceptance model: Four longitudinal field studies,” *Management Science*, vol. 46, no. 2, pp. 186–204, 2000, accessed: 2025-10-27. [Online]. Available: <https://pubsonline.informs.org/doi/10.1287/mnsc.46.2.186.11926>
- [4] J. F. Hair, W. C. Black, B. J. Babin, and R. E. Anderson, *Multivariate Data Analysis*, 8th ed. Boston, MA: Cengage Learning, 2019, accessed: 2025-10-27. [Online]. Available: <https://www.worldcat.org/title/1089688849>
- [5] G. Shmueli, M. Sarstedt, J. F. Hair, J.-H. Cheah, H. Ting, S. Vaithilingam, and C. M. Ringle, “Predictive model assessment in pls-sem: Guidelines for using plspredict,” *European Journal of Marketing*, vol. 53, no. 11, pp. 2322–2347, 2019, accessed: 2025-10-27. [Online]. Available: <https://doi.org/10.1108/EJM-02-2019-0189>
- [6] D. R. Compeau and C. A. Higgins, “Computer self-efficacy: Development of a measure and initial test,” *MIS Quarterly*, vol. 19, no. 2, pp. 189–211, 1995, accessed: 2025-10-27. [Online]. Available: <https://www.jstor.org/stable/249688>
- [7] M. Al-Emran, V. Mezhyuev, and A. Kamaludin, “Technology acceptance model in m-learning context: A systematic review,” *Computers & Education*, vol. 125, pp. 389–412, 2018, accessed: 2025-10-27. [Online]. Available: <https://doi.org/10.1016/j.compedu.2018.06.008>
- [8] V. Venkatesh, M. G. Morris, G. B. Davis, and F. D. Davis, “User acceptance of information technology: Toward a unified view,” *MIS Quarterly*, vol. 27, no. 3, pp. 425–478, 2003, accessed: 2025-10-27. [Online]. Available: <https://www.jstor.org/stable/30036540>
- [9] O. Al-Hujran, E. Al-Lozi, M. M. Al-Debei, and M. Maqableh, “Challenges of cloud computing adoption from the toe framework perspective,” *International Journal of E-Business Research*, vol. 15, no. 3, pp. 77–94, 2019, accessed: 2025-10-27. [Online]. Available: <https://www.igi-global.com/article/challenges-cloud-computing-adoption-toe/240693>